

《动手学深度学习》

PyTorch 版学习笔记

内容提炼

2026 年 9 月 14 日

说明

本笔记按 d2l-zh 2.0.0 PyTorch 版原书目录提炼全书。正文保留全部章、节、子节标题；印刷目录与书签只显示到章和主要节。正文以公式陈述定义、成立条件、关键推导与结论。每一公式后必须写明：数学上如何由输入算出输出，以及得到的数在问题中的实际含义。有信息量的原书图随文插入，图号与题注沿用原书，并在图下注释符号。衔接句只连接相邻公式，代码仅作最小验证。

目录

说明	i
前言	viii
安装	ix
符号	x
第一章 引言	1
1.1 日常生活中的机器学习	1
1.2 机器学习中的关键组件	1
1.3 各种机器学习问题	2
1.4 起源	3
1.5 深度学习的发展	4
1.6 深度学习的成功案例	4
1.7 特点	4
1.8 小结	4
1.9 练习	4
第二章 预备知识	5
2.1 数据操作	5
2.2 数据预处理	7
2.3 线性代数	9
2.4 微积分	12
2.5 自动微分	14
2.6 概率	15

2.7 查阅文档	18
第三章 线性神经网络	19
3.1 线性回归	19
3.2 线性回归的从零开始实现	25
3.3 线性回归的简洁实现	27
3.4 softmax 回归	29
3.5 图像分类数据集	33
3.6 softmax 回归的从零开始实现	34
3.7 softmax 回归的简洁实现	36
第四章 多层感知机	38
4.1 多层感知机	38
4.2 多层感知机的从零开始实现	41
4.3 多层感知机的简洁实现	42
4.4 模型选择、欠拟合和过拟合	43
4.5 权重衰减	46
4.6 暂退法 (Dropout)	49
4.7 前向传播、反向传播和计算图	51
4.8 数值稳定性和模型初始化	53
4.9 环境和分布偏移	56
4.10 实战 Kaggle 比赛：预测房价	61
第五章 深度学习计算	64
5.1 层和块	64
5.2 参数管理	66
5.3 延后初始化	69
5.4 自定义层	69
5.5 读写文件	70
5.6 GPU	71
第六章 卷积神经网络	74
6.1 从全连接层到卷积	74

6.2	图像卷积	77
6.3	填充和步幅	80
6.4	多输入多输出通道	82
6.5	汇聚层	84
6.6	卷积神经网络 (LeNet)	86
第七章	现代卷积神经网络	88
7.1	深度卷积神经网络 (AlexNet)	88
7.2	使用块的网络 (VGG)	93
7.3	网络中的网络 (NiN)	95
7.4	含并行连结的网络 (GoogLeNet)	97
7.5	批量规范化	99
7.6	残差网络 (ResNet)	101
7.7	稠密连接网络 (DenseNet)	105
第八章	循环神经网络	108
8.1	序列模型	108
8.2	文本预处理	111
8.3	语言模型和数据集	113
8.4	循环神经网络	115
8.5	循环神经网络的从零开始实现	118
8.6	循环神经网络的简洁实现	120
8.7	通过时间反向传播	121
第九章	现代循环神经网络	126
9.1	门控循环单元 (GRU)	126
9.2	长短期记忆网络 (LSTM)	130
9.3	深度循环神经网络	134
9.4	双向循环神经网络	135
9.5	机器翻译与数据集	138
9.6	编码器-解码器架构	139
9.7	序列到序列学习 (seq2seq)	140

9.8 束搜索	143
第十章 注意力机制	147
10.1 注意力提示	147
10.2 注意力汇聚: Nadaraya-Watson 核回归	150
10.3 注意力评分函数	152
10.4 Bahdanau 注意力	154
10.5 多头注意力	155
10.6 自注意力和位置编码	157
10.7 Transformer	159
第十一章 优化算法	163
11.1 优化和深度学习	163
11.2 凸性	164
11.3 梯度下降	169
11.4 随机梯度下降	171
11.5 小批量随机梯度下降	173
11.6 动量法	174
11.7 AdaGrad 算法	177
11.8 RMSProp 算法	178
11.9 Adadelta	179
11.10 Adam 算法	180
11.11 学习率调度器	181
第十二章 计算性能	184
12.1 编译器和解释器	184
12.2 异步计算	186
12.3 自动并行	189
12.4 硬件	190
12.5 多 GPU 训练	197
12.6 多 GPU 的简洁实现	200
12.7 参数服务器	201

第十三章 计算机视觉	207
13.1 图像增广	207
13.2 微调	208
13.3 目标检测和边界框	210
13.4 锚框	211
13.5 多尺度目标检测	213
13.6 目标检测数据集	214
13.7 单发多框检测 (SSD)	215
13.8 区域卷积神经网络 (R-CNN) 系列	218
13.9 语义分割和数据集	221
13.10 转置卷积	223
13.11 全卷积网络	225
13.12 风格迁移	227
13.13 实战 Kaggle 比赛: 图像分类 (CIFAR-10)	229
13.14 实战 Kaggle 比赛: 狗的品种识别 (ImageNet Dogs)	231
第十四章 自然语言处理: 预训练	233
14.1 词嵌入 (word2vec)	233
14.2 近似训练	237
14.3 用于预训练词嵌入的数据集	238
14.4 预训练 word2vec	239
14.5 全局向量的词嵌入 (GloVe)	241
14.6 子词嵌入	242
14.7 词的相似性和类比任务	243
14.8 来自 Transformers 的双向编码器表示 (BERT)	244
14.9 用于预训练 BERT 的数据集	246
14.10 预训练 BERT	247
第十五章 自然语言处理: 应用	249
15.1 情感分析及数据集	249
15.2 情感分析: 使用循环神经网络	250
15.3 情感分析: 使用卷积神经网络	251

15.4 自然语言推断与数据集	254
15.5 自然语言推断：使用注意力	256
15.6 针对序列级和词元级应用微调 BERT	259
15.7 自然语言推断：微调 BERT	262
附录 A 深度学习工具	264
A.1 使用 Jupyter Notebook	264
A.2 使用 Amazon SageMaker	265
A.3 使用 Amazon EC2 实例	266
A.4 选择服务器和 GPU	268
A.5 为本书做贡献	269
A.6 d2l API 文档	270

前言

本书把深度学习写成可运行的对象与映射：用数据构造经验分布，用可微模型给出预测，用标量目标衡量误差，用优化算法更新参数。笔记只保留定义、成立条件、关键推导和结论。

同一对象用三种等价表示同时出现：概念、公式、可执行计算。后文以公式为主陈述模型，代码只在需要核验映射时出现。若把一次观测写成输入 $\mathbf{x}$ 与目标 y ，带参数 $\boldsymbol{\theta}$ 的模型给出

$$\hat{y} = f_{\boldsymbol{\theta}}(\mathbf{x}).$$

$\hat{y}$ 由 $\mathbf{x}$ 与 $\boldsymbol{\theta}$ 算出：回归时它是与 y 同量纲的点预测，不是概率；分类时它往往先是未归一化分数，再经后续映射才变成 $[0, 1]$ 上的类概率。标量损失

$$L(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}), y^{(i)})$$

把每条样本的预测与真值收成一个非负实数再取平均，表示这批预测整体离真值有多远，不是某类发生的概率。参数更新

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta})$$

沿梯度的反方向走一步： $\nabla_{\boldsymbol{\theta}} L$ 的第 j 个分量是 θ_j 增加 1 个单位时 L 大约增加多少， $\eta > 0$ 是步长。

安装

运行原书代码需要 Python 3、PyTorch 与辅助包 d2l。记依赖集合为 $\mathcal{P}$ 。把解释器版本与 $\mathcal{P}$ 配成同一隔离环境后，笔记本里的张量运算才能按后文章节的公式求值；配错版本则同一符号可能对应不同实现。

原书推荐用 conda 创建名为 d2l 的环境，再安装 CPU 或 GPU 版 PyTorch。有 NVIDIA GPU 且已配置 CUDA 时，同一前向

$$\hat{y} = f_{\theta}(\boldsymbol{x})$$

与同一反向 $\nabla_{\theta} L$ 可在加速器上求值：算出的 $\hat{y}$ 、 L 与各梯度分量在数学含义上与 CPU 相同，只是求值更快。前几章用 CPU 即可完成。

每次运行前激活该环境。激活成功表示后续 `import torch` 读到的是这一套包，而不是系统里另一份；它本身不是一个数值，而是“公式将在哪一套实现上被计算”的选择。

符号

沿用原书记号。后文向量一律写成 $\boldsymbol{x}$ 。下面每个符号都给出：它由什么算出、这个数表示什么。

数字

$x \in \mathbb{R}$	标量,
$\boldsymbol{x} \in \mathbb{R}^n$	向量,
$\boldsymbol{X} \in \mathbb{R}^{a \times b}$	矩阵,
$\mathbf{X}$	高阶张量,
$\boldsymbol{I}$	单位矩阵,
$x_i = [\boldsymbol{x}]_i$	向量第 i 个元素,
$x_{ij} = [\boldsymbol{X}]_{ij}$	矩阵第 i 行第 j 列.

x 是一个实数，例如一个房价、一个损失值，没有方向。 $\boldsymbol{x}$ 是 n 个这样的实数排成一列， x_i 是第 i 个特征（或第 i 个坐标）上的取值。 $\boldsymbol{X}$ 的条目 x_{ij} 在数据矩阵里常是第 i 个样本的第 j 个特征，在权重矩阵里常是“输出单元 i 对输入特征 j 的权重”。 $\mathbf{X}$ 是更高阶的同类对象，例如批量图像。 $\boldsymbol{I}$ 的对角为 1、其余为 0，表示“该坐标保持原值、不与其他坐标混合”。

集合

$\mathcal{X}$	集合, $\mathbb{Z}$ 整数, $\mathbb{R}$ 实数,
$\mathbb{R}^n, \mathbb{R}^{a \times b}$	向量与矩阵空间,
$\mathcal{A} \cup \mathcal{B}, \mathcal{A} \cap \mathcal{B}, \mathcal{A} \setminus \mathcal{B}$	并、交、相对补.

$\mathcal{X}$ 标明哪些对象被允许出现，本身不是测量值。 $\mathbb{R}^n$ 表示“有序的 n 个实数”，维数 n 是特征个数，不是欧氏长度。并、交、差得到的仍是集合：并是“至少属于其中一个”，交是“同时属于两个”，差是“在 $\mathcal{A}$ 但不在 $\mathcal{B}$ ”。

函数与算子

$$\begin{array}{ll}
 f(\cdot), \log(\cdot), \exp(\cdot), \mathbf{1}_{\mathcal{X}} & \text{指示函数,} \\
 (\cdot)^{\top}, \mathbf{X}^{-1}, \odot & \text{转置、逆、Hadamard 积,} \\
 [\cdot, \cdot], |\mathcal{X}|, \|\cdot\|_p, \|\cdot\| & \text{连结、基数、} L_p \text{ 与 } L_2, \\
 \langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^{\top} \mathbf{y}, \quad \sum, \prod, \stackrel{\text{def}}{=} & .
 \end{array}$$

$f(\mathbf{x})$ 由输入算出输出。 $\log$ 与 $\exp$ 互为反函数；后文 $\log$ 默认自然对数，因而交叉熵的单位是 nats（自然单位），不是 bit。指示 $\mathbf{1}_{\mathcal{X}}$ 取值 $\{0, 1\}$ ：1 表示“属于该集合”，0 表示不属于。转置只交换行列角色，不改变那些数。Hadamard 积 $(\mathbf{A} \odot \mathbf{B})_{ij} = a_{ij}b_{ij}$ 是对应位置相乘，不是加权求和。 $|\mathcal{X}|$ 是元素个数，一个非负整数。 $\|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}$ 是欧氏长度，非负，为零当且仅当 $\mathbf{x} = \mathbf{0}$ 。点积 $\mathbf{x}^{\top} \mathbf{y} = \sum_i x_i y_i$ 是一个标量：若 $\mathbf{x}$ 是权重、 $\mathbf{y}$ 是特征，它就是一次线性打分。

微积分

$$\frac{dy}{dx}, \quad \frac{\partial y}{\partial x}, \quad \nabla_{\mathbf{x}} y, \quad \int_a^b f(x) dx.$$

dy/dx 是切线斜率：输入增加极小 h 时，输出大约增加该斜率乘 h 。 $\partial y / \partial x_i$ 只动第 i 个自变量。 $\nabla_{\mathbf{x}} y$ 把这些偏导收成向量，第 j 个分量是 x_j 增加 1 个单位时 y 大约增加多少。积分 $\int_a^b f(x) dx$ 是密度在区间上的累积；若 f 是概率密度，该积分才是 $[0, 1]$ 上的概率。

概率与信息论

$$\begin{array}{ll}
 P(\cdot), \quad z \sim P, \quad \mathbb{E}_{x \sim P}[f(x)], \quad \text{Var}(f(x)), & \\
 H(X), \quad D_{\text{KL}}(P \| Q). &
 \end{array}$$

$P(\mathcal{A}) \in [0, 1]$ 是事件发生的可能性； $z \sim P$ 表示按这个分布抽样。 $\mathbb{E}[X]$ 是按概率加权的平均水平，与 X 同量纲。 $\text{Var}(X)$ 是相对均值的平方偏离的平均，量纲是 X 的平方。熵

$$H(X) = \sum_j -P(j) \log P(j)$$

是按 P 编码时的平均自信息，单位为 nats，表示“平均有多不确定”。

$$D_{\text{KL}}(P \| Q) = \sum_j P(j) \log \frac{P(j)}{Q(j)}$$

是用 Q 编码 P 时多付出的平均码长，非负，为零当且仅当 $P = Q$ 。

第一章 引言

程序不再只执行固定业务规则，而从数据中估计映射 f 。深度学习把 f 参数化为一串可微变换，用优化更新参数。

1.1 日常生活中的机器学习

日常系统把观测 x 映到决策 a 。语音识别、推荐、视觉检测都是在估计

$$a = \hat{f}(x), \quad \hat{f} \in \mathcal{F},$$

其中 $\mathcal{F}$ 由数据而非手写规则确定。 $\hat{f}(x)$ 由当前输入算出：它是系统将要执行的决策或预测值（类别、分数、推荐列表中的排序分），不是训练损失。经验增加时，同一测试分布上 $\hat{f}$ 的风险下降；固定规则程序不自动改进。

1.2 机器学习中的关键组件

学习问题写成四元组 $(\mathcal{D}, \mathcal{F}, L, \mathcal{A})$ ：数据、模型类、目标、优化算法。四者分别提供样本、允许的映射、误差标量、以及如何改参数。

1.2.1 数据

训练集

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$$

提供经验。 $\mathbf{x}^{(i)} \in \mathbb{R}^d$ 是第 i 个样本的特征， $y^{(i)}$ 是该样本要拟合的目标（回归时与预测同量纲的实数，分类时是类别编号）。样本应尽可能独立同分布地来自未知 $P(\mathbf{x}, y)$ 。特征维度 d 、标签类型和样本量 n 决定 $\mathcal{F}$ 能多复杂： n 是样本个数，不是误差大小。

1.2.2 模型

模型是带参数 θ 的映射

$$\hat{y} = f_{\theta}(\mathbf{x}).$$

线性模型对应 $\mathcal{F} = \{\mathbf{x} \mapsto \mathbf{w}^\top \mathbf{x} + b\}$: $\mathbf{w}^\top \mathbf{x} + b$ 由特征加权求和再加偏置得到, 回归时是与 y 同量纲的点预测, 不是概率。深度模型把若干简单映射复合为 $f_L \circ \cdots \circ f_1$, 最终输出仍是预测, 须再经损失才变成误差。

1.2.3 目标函数

目标（损失）把预测与真值变成可比较的标量：

$$L(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}), y^{(i)}).$$

$L(\boldsymbol{\theta})$ 是 n 条样本损失的算术平均, 表示这批预测整体有多差; 它不是 $[0, 1]$ 上的概率。回归常用平方损失（均方误差, 与 y 的量纲平方同量纲）, 分类常用交叉熵（模型对真类有多惊讶, 单位 nats）。经验风险 $L(\boldsymbol{\theta})$ 是对真实风险

$$R(\boldsymbol{\theta}) = \mathbb{E}[\ell(f_{\boldsymbol{\theta}}(\mathbf{x}), y)]$$

的样本近似; R 是在未知分布 P 上的平均损失, 无法直接计算, 只能用独立测试集估计。

1.2.4 优化算法

训练求解

$$\boldsymbol{\theta}^* \in \operatorname{argmin}_{\boldsymbol{\theta}} L(\boldsymbol{\theta}).$$

$\boldsymbol{\theta}^*$ 是使训练损失最小的参数, 不是预测值本身。深度学习中 L 通常非凸且无闭式解, 故用梯度迭代

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \widehat{\nabla L}(\boldsymbol{\theta}),$$

其中 $\widehat{\nabla L}$ 常由小批量估计。第 j 个分量是：该参数增加 1 个单位时, 损失大约增加多少; 减去它乘步长 η , 是为了减小 L 。

1.3 各种机器学习问题

按是否提供标签、是否与环境交互, 学习问题分成不同的条件设置。每种设置里, 模型输出与损失所代表的数并不相同。

1.3.1 监督学习

每个 $\mathbf{x}$ 配有 y , 目标是估计 $P(y | \mathbf{x})$ 或 $f(\mathbf{x}) \approx y$ 。回归取 $y \in \mathbb{R}$, 此时 $\hat{y}$ 是与 y 同单位的点预测。分类取 $y \in \{1, \dots, K\}$, 此时模型通常输出 K 维概率, 第 k 个分量是“属于类 k ”的概率, 在 $[0, 1]$ 且和为 1。

1.3.2 无监督学习

只有 $\{\mathbf{x}^{(i)}\}$ 。任务是估计结构，例如密度 $p(\mathbf{x})$ （可以大于 1，本身不是概率）、聚类划分（样本到簇编号的映射）、或低维表示

$$\mathbf{z} = g(\mathbf{x}).$$

$\mathbf{z}$ 由 $\mathbf{x}$ 算出，是压缩后的坐标，用来保留变化方向，不是类别概率。

1.3.3 与环境互动

数据不再一次性给定，而由策略与环境交互产生轨迹

$$(\mathbf{s}_t, a_t, r_t, \mathbf{s}_{t+1})_{t \geq 0}.$$

$\mathbf{s}_t$ 是 t 时刻状态， a_t 是当时采取的动作， r_t 是即时标量奖励（可正可负，不是正确率）， $\mathbf{s}_{t+1}$ 是下一状态。分布依赖于当前策略，因此 i.i.d. 假设不自动成立。

1.3.4 强化学习

目标是最大化期望回报

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t r_t \right], \quad 0 \leq \gamma \leq 1.$$

$J(\pi)$ 由策略 π 下的轨迹对折扣奖励求和再取期望得到：它是“长期能拿到多少奖励”的平均水平，与单步 r_t 同量纲； γ 接近 1 时更看重远期。监督信号是延迟的标量奖励，而不是每步的正确标签。

1.4 起源

可学习机器的思想来自神经科学中的神经元加权求和、统计学中的回归与决策理论、以及控制论中的反馈。感知机给出

$$\hat{y} = \mathbf{1}\{\mathbf{w}^T \mathbf{x} + b > 0\}.$$

先算线性打分 $\mathbf{w}^T \mathbf{x} + b$ （与特征同型加权后的实数），再看是否为正：指示函数取值 $\{0, 1\}$ ，1 表示判为正类，0 表示负类，不是 $[0, 1]$ 上的平滑概率。多层网络则取消线性可分限制。

1.5 深度学习的发展

关键条件是：可微复合模型、反向传播计算 $\nabla_{\theta}L$ 、大规模数据与并行硬件。 $\nabla_{\theta}L$ 的每个分量仍是“该参数增加 1 时损失大约增加多少”。深度指复合层数 L 增大， L 是层的个数（正整数），不是损失值；层数增大使 $\mathcal{F}$ 更丰富。

1.6 深度学习的成功案例

当 x 具有局部相关结构（图像、语音、文本）且 n 足够大时，端到端训练的 f_{θ} 在分类、检测、翻译等风险上低于手工特征加浅层模型。这里比较的是测试风险或错误率（错误个数占总样本的比例，取值 $[0, 1]$ ），不是训练损失本身。

1.7 特点

深度学习用端到端可微管道代替分阶段特征工程：

$$x \xrightarrow{f_1} h_1 \xrightarrow{f_2} \cdots \xrightarrow{f_L} \hat{y},$$

$h_{\ell} = f_{\ell}(h_{\ell-1})$ 是第 ℓ 层算出的表示（一组激活值）， $\hat{y}$ 是最终预测。各 f_{ℓ} 的参数由同一 $L(\theta)$ 的梯度同时更新：每个梯度分量仍表示损失对该参数的敏感度。

1.8 小结

机器学习估计 f_{θ} ， $\hat{y} = f_{\theta}(x)$ 是预测；深度学习把 f_{θ} 写成深层复合，并用 $L(\theta)$ 的梯度迭代求解。 L 是平均误差大小，不是概率；梯度分量是参数每增加一单位时损失的变化量。

1.9 练习

核验四元组 $(\mathcal{D}, \mathcal{F}, L, \mathcal{A})$ 在回归与分类中如何特化：回归的 $\hat{y}$ 与 y 同量纲， L 常为均方误差；分类的 softmax 第 k 分量是类概率， L 常为交叉熵（nats）。再核验经验风险 L 是有限样本平均，真实风险 R 是对未知 P 的期望。

第二章 预备知识

本章把后续计算写成同一套对象与映射：数据是张量，前向是线性映射，训练目标是可微标量，自动微分在计算图上实现链式法则，概率把预测写成分布。每一公式先写如何由输入算出输出，再写这个数在问题里表示什么。

2.1 数据操作

记 n 阶张量为 $\mathbf{X} \in \mathbb{R}^{d_1 \times \cdots \times d_n}$ 。 $n = 0, 1, 2$ 分别对应标量、向量、矩阵；更高阶用于批量、通道或时间轴。

2.1.1 入门

形状与元素总数为

$$\text{shape}(\mathbf{X}) = (d_1, \dots, d_n), \quad \text{numel}(\mathbf{X}) = \prod_{i=1}^n d_i.$$

`shape` 得到的是各轴长度，表示“有几条样本、几个特征、几条通道”等几何尺寸，本身不是数据值。`numel` 得到的是一个正整数，表示这块内存里存了多少个数字。`reshape` 只改变轴的划分，不改变元素值与存储次序。若

$$\prod_{i=1}^n d_i = \prod_{j=1}^m d'_j,$$

则存在把 $\mathbb{R}^{d_1 \times \cdots \times d_n}$ 重新解释为 $\mathbb{R}^{d'_1 \times \cdots \times d'_m}$ 的双射：输出张量里每一个数仍是原来的测量值，只是被看成另一组轴上的条目。某个 $d'_k = -1$ 时，由上式唯一确定该轴长度。

```
x = torch.arange(12).reshape(3, 4)
x.shape, x.numel()
```

这里 12 个数被排成 3×4 ：每一项仍是 $0, 1, \dots, 11$ 中的那个整数，不是新算出来的量。

2.1.2 运算符

形状相同后，二元运算默认逐元素进行。若 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$,

$$(f(\mathbf{u}, \mathbf{v}))_i = f(u_i, v_i), \quad i = 1, \dots, d.$$

第 i 个输出只由第 i 个输入对算出。 $u_i + v_i$ 是两个对应位置测量值之和； $u_i v_i$ 是对应位置的乘积，仍是一个特征上的数，不是点积那种“整体相似度”。沿轴 k 连接要求除第 k 轴外形状一致：

$$\text{cat}(\mathbf{A}, \mathbf{B}; k) \in \mathbb{R}^{d_1 \times \dots \times (d_k^{(A)} + d_k^{(B)}) \times \dots \times d_n}.$$

连接不产生新数值，只把两段已有数据沿指定轴拼在一起。比较返回 $\{0, 1\}$ ：得到的 1 表示“该位置关系成立”，0 表示不成立。求和

$$\sum(\mathbf{X}) = \sum_{i_1=1}^{d_1} \cdots \sum_{i_n=1}^{d_n} X_{i_1 \dots i_n}$$

把全部条目收成一个标量，表示这些数的总量（例如像素强度总和），不再保留位置。

2.1.3 广播机制

形状不同时，从末轴向前对齐。第 i 轴可运算当且仅当

$$d_i^{(X)} = d_i^{(Y)} \quad \text{或} \quad d_i^{(X)} = 1 \quad \text{或} \quad d_i^{(Y)} = 1.$$

长度为 1 的轴在逻辑上复制到目标长度。于是

$$\mathbb{R}^{3 \times 1} + \mathbb{R}^{1 \times 2} \longrightarrow \mathbb{R}^{3 \times 2}, \quad (A + B)_{ij} = A_{i1} + B_{1j}.$$

$(A + B)_{ij}$ 是“第 i 个行标量”与“第 j 个列标量”配对相加后的数；几何上相当于把短轴上的值复制后逐元素相加，并不增加新的独立观测。

2.1.4 索引和切片

对 $\mathbf{X} \in \mathbb{R}^{m \times n}$ ，下标从 0 起算。切片 $[a : b]$ 取 $\{a, a + 1, \dots, b - 1\}$ ，即半开区间 $[a, b)$ ，且 -1 表示最后一个合法下标。多轴独立作用：

$$\mathbf{X}[i, j] = X_{ij}, \quad \mathbf{X}[a : b, :] \in \mathbb{R}^{(b-a) \times n}.$$

X_{ij} 就是第 i 行第 j 列那个原始测量值；切片得到的仍是原表中的一块，不是统计量。

2.1.5 节省内存

记 $\text{id}(\cdot)$ 为对象标识。赋值

$$\mathbf{Y} \leftarrow \mathbf{Y} + \mathbf{X}$$

通常分配新存储后再改引用；切片写回

$$\mathbf{Y}[:,] \leftarrow \mathbf{Y} + \mathbf{X}$$

保持 $\text{id}(\mathbf{Y})$ 不变。这里比较的不是数值大小，而是“是否仍是同一块内存”。 id 相同表示后续原地修改会改到同一批数。

2.1.6 转换为其他 Python 对象

PyTorch 张量与 NumPy 数组可共享同一块内存，因此对一侧的原地更新会改变另一侧。标量提取是映射

$$\mathbb{R}^1 \longrightarrow \mathbb{R}, \quad \mathbf{x} \mapsto x = \text{item}(\mathbf{x}).$$

得到的 x 就是那一个张量条目的数值，供 Python 标量运算使用，不再带有梯度或形状信息。

2.1.7 小结

数据操作把结构写成 `shape`、个数写成 `numel`，把组合写成逐元素映射与广播，把取值写成索引。算出来的每一个条目，除非经过求和等归约，否则仍表示原来位置上的数据值。

2.1.8 练习

核验三件事：`numel` 这个正整数是否等于各轴长度之积、广播后每个位置的数是哪两个输入配对相加、共享内存是否意味着改一侧会改另一侧的数。

2.2 数据预处理

原始表通常含缺失与非数值字段，不能直接作为上一节中的 $\mathbf{X}$ 。预处理的目标是构造数值张量 $(\mathbf{X}, \mathbf{y})$ 。

2.2.1 读取数据集

设表有 n 行、 p 列。一行是一个样本，一列是一个属性。划分后

$$\mathbf{x}^{(i)} \in \mathbb{R}^{p-1}, \quad y^{(i)} \in \mathbb{R}, \quad i = 1, \dots, n.$$

$\mathbf{x}^{(i)}$ 中的数是第 i 个样本的输入特征； $y^{(i)}$ 是该样本要预测的目标值。缺失在 pandas 中记为 NaN，表示“这个位置没有观测”，不是数值 0。

2.2.2 处理缺失值

对数值列 j ，令观测指标集 $\mathcal{I}_j = \{i : x_{ij} \text{ 非缺失}\}$ 。样本均值

$$\bar{x}_j = \frac{1}{|\mathcal{I}_j|} \sum_{i \in \mathcal{I}_j} x_{ij}$$

是该列已观测值的算术平均，表示“这一属性的典型水平”，不是某一次真实测量。填充 $x_{ij} \leftarrow \bar{x}_j$ 只是用这个典型水平代替缺口。类别列取值于有限集 $\mathcal{C}$ 时，独热映射为

$$c \mapsto \mathbf{e}_c \in \{0, 1\}^{|\mathcal{C}|}, \quad (\mathbf{e}_c)_{c'} = [c = c'].$$

向量里的 1 表示“属于该类”，0 表示“不属于”；各分量互斥，和为 1。缺失可并入一个额外类别，使编码落在 $\mathbb{R}^{|\mathcal{C}|+1}$ 。

2.2.3 转换为张量格式

全部字段数值化且类型一致后，

$$(\mathbf{x}^{(i)}, y^{(i)})_{i=1}^n \longrightarrow \mathbf{X} \in \mathbb{R}^{n \times d}, \quad \mathbf{y} \in \mathbb{R}^n.$$

X_{ij} 是第 i 个样本第 j 个特征的数值； y_i 是第 i 个样本的标签。二者已经是模型可做加減乘的实数，不再含字符串或 NaN。

2.2.4 小结

预处理不改变学习目标 y 的含义，只把不完整字段映成可计算的 $(\mathbf{X}, \mathbf{y})$ ： $\mathbf{X}$ 的条目是特征， $\mathbf{y}$ 的条目是要拟合的量。

2.2.5 练习

删除缺失最多的列是丢掉一维特征；均值填充则仍保留该维，但缺口处的数是列均值，不是观测。

2.3 线性代数

张量给出对象；线性代数给出映射。从标量升到矩阵，再由点积与乘法得到层间变换，最后用范数把误差压成标量。

2.3.1 标量

标量 $x \in \mathbb{R}$ 满足

$$x + y, \quad xy, \quad x/y \ (y \neq 0), \quad x^p.$$

结果仍是一个实数：和、积、商、幂都表示在同一条数轴上的量，没有方向。

2.3.2 向量

n 个标量排成列向量

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n.$$

x_i 是第 i 个坐标上的分量，例如第 i 个特征的取值；整个 $\mathbf{x}$ 表示一个有序的特征组合。

2.3.2.1 长度、维度和形状

$\mathbf{x} \in \mathbb{R}^n$ 表示分量数（向量维度）为 n ，对应一维张量形状 $(n,)$ 。这里的 n 是“有几个特征”，不是向量的欧氏长度 $\|\mathbf{x}\|_2$ 。张量的“维数”还可指轴数 k 。

2.3.3 矩阵

$$\mathbf{A} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

a_{ij} 是第 i 行第 j 列的数：在数据矩阵里常表示第 i 个样本的第 j 个特征；在权重矩阵里常表示“输出单元 i 对输入特征 j 的权重”。转置 $(\mathbf{A}^\top)_{ij} = a_{ji}$ 只交换行与列的角色，不改变那些数本身。若 $\mathbf{A} = \mathbf{A}^\top$ ，则 $\mathbf{A}$ 对称，此时 $m = n$ 。

2.3.4 张量

向量、矩阵分别是 1 阶、2 阶张量。图像 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ 中，每个 X_{hwc} 是位置 (h, w) 、通道 c 上的像素强度（或特征响应）。加入批量后 $\mathbb{R}^{B \times H \times W \times C}$ 的第一轴下标表示第几张图。

2.3.5 张量算法的基本性质

同形状逐元素运算保持形状。Hadamard 积

$$(\mathbf{A} \odot \mathbf{B})_{ij} = a_{ij}b_{ij}$$

得到的仍是位置 (i, j) 上的一个数，表示两个对应条目的乘积，不是加权求和。标量广播 $(\alpha + \mathbf{A})_{ij} = \alpha + a_{ij}$ 表示把同一个偏移加到每一个位置。

2.3.6 降维

对 $\mathbf{A} \in \mathbb{R}^{m \times n}$,

$$\sum_{i=1}^m \sum_{j=1}^n a_{ij}$$

是一个标量，表示全部条目的总和。沿轴归约

$$\left(\sum_{i=1}^m \mathbf{A}\right)_j = \sum_{i=1}^m a_{ij} \in \mathbb{R}^n, \quad \left(\sum_{j=1}^n \mathbf{A}\right)_i = \sum_{j=1}^n a_{ij} \in \mathbb{R}^m$$

分别表示“每一列的合计”和“每一行的合计”。均值

$$\bar{A} = \frac{1}{mn} \sum_{i=1}^m \sum_{j=1}^n a_{ij}$$

是这些数的平均水平，与单个条目同量纲。

2.3.6.1 非降维求和

行归一化

$$\tilde{a}_{ij} = \frac{a_{ij}}{\sum_{k=1}^n a_{ik}} \quad \left(\sum_k a_{ik} \neq 0\right)$$

得到 $\tilde{a}_{ij} \in [0, 1]$ （若原行为非负），且 $\sum_j \tilde{a}_{ij} = 1$ 。它表示第 i 行内部的相对比重，不再是原始量纲。累积和

$$s_{ij} = \sum_{k=1}^j a_{ik}$$

是该行从左到第 j 列的部分和，表示“前 j 项累计了多少”。

2.3.7 点积 (Dot Product)

$$\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^d x_i y_i.$$

结果是一个标量：把 $\mathbf{y}$ 的各分量用 $\mathbf{x}$ 作权重求和。若 $\mathbf{x}$ 是权重、 $\mathbf{y}$ 是特征，它就是线性层的一次打分；若二者都是单位向量，该标量等于夹角余弦，取值 $[-1, 1]$ ，表示方向有多一致。

2.3.8 矩阵-向量积

对 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 、 $\mathbf{x} \in \mathbb{R}^n$,

$$(\mathbf{Ax})_i = \mathbf{a}_i^\top \mathbf{x}.$$

第 i 个输出是第 i 个输出单元对输入 $\mathbf{x}$ 的线性响应（一个打分）。整个 $\mathbf{Ax} \in \mathbb{R}^m$ 是 m 个这样的打分。线性性 $f(\alpha\mathbf{x} + \beta\mathbf{z}) = \alpha f(\mathbf{x}) + \beta f(\mathbf{z})$ 表示叠加输入则打分叠加。

2.3.9 矩阵-矩阵乘法

若 $\mathbf{A} \in \mathbb{R}^{n \times k}$ 、 $\mathbf{B} \in \mathbb{R}^{k \times m}$ ，则

$$c_{ij} = \mathbf{a}_i^\top \mathbf{b}_j = \sum_{\ell=1}^k a_{i\ell} b_{\ell j}.$$

c_{ij} 是 $\mathbf{A}$ 的第 i 行与 $\mathbf{B}$ 的第 j 列的点积：一批输入同时通过同一线性层时，第 i 个样本在第 j 个输出通道上的响应。

2.3.10 范数

范数 $f: \mathbb{R}^n \rightarrow \mathbb{R}_{\geq 0}$ 满足绝对齐次、三角不等式与正定。

$$\|\mathbf{x}\|_1 = \sum_i |x_i|, \quad \|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}, \quad \|\mathbf{X}\|_F = \sqrt{\sum_{i,j} x_{ij}^2}.$$

这些数都是“有多大”： $\|\mathbf{x}\|_2$ 是欧氏长度， $\|\mathbf{x}\|_1$ 是各分量绝对值和（对异常值不那么敏感）， $\|\mathbf{X}\|_F$ 把矩阵当成向量后的欧氏长度。它们都 ≥ 0 ，为零当且仅当对象是零。

2.3.10.1 范数和目标

$$\min_{\theta} \|\mathbf{y} - f_{\theta}(\mathbf{X})\|_2^2$$

中的 $\|\mathbf{y} - \hat{\mathbf{y}}\|_2^2$ 是预测误差向量的平方欧氏长度，数值越大表示整体预测离真值越远；它与单个 y 同量纲的平方。

2.3.11 关于线性代数的更多信息

后续章节主要用到 $\mathbf{Ax}$ 的打分、 $\mathbf{AB}$ 的批量打分，以及 $\|\cdot\|$ 作为误差大小。

2.3.12 小结

线性代数把数据写成张量，把层写成点积/矩阵乘（输出是打分），把误差大小写成范数（非负标量）。

2.3.13 练习

核验恒等式两边每个条目是否同一数，以及结果形状是否等于“行点列”所要求的 (n, m) 。

2.4 微积分

前向已写成映射 f ；训练要知道参数扰动如何改变标量目标。

2.4.1 导数和微分

若极限存在，

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}.$$

$f'(x)$ 是一个实数：输入增加极小 h 时，输出大约增加 $f'(x)h$ 。正值表示局部上升，负值表示局部下降，绝对值是变化有多陡。对 $f(x) = 3x^2 - 4x$,

$$f'(1) = 2$$

表示在 $x = 1$ 处，输入增加 Δx 则输出大约增加 $2\Delta x$ 。一阶展开

$$f(x + \Delta x) = f(x) + f'(x)\Delta x + o(\Delta x)$$

右边第二项就是用这个变化率作的线性近似。

2.4.2 偏导数

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_i + h, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}.$$

这是一个实数：只动第 i 个自变量、其余固定时， y 对 x_i 的敏感度。它不描述沿其他方向的变化。

2.4.3 梯度

$$\nabla_x f(\mathbf{x}) = \begin{bmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{bmatrix}.$$

第 i 个分量是 f 对 x_i 的偏导。整个向量指向 f 上升最快的方向；其长度表示沿该方向的变化有多快。一阶展开中

$$\nabla_x f(\mathbf{x})^\top \Delta \mathbf{x}$$

就是“沿 $\Delta \mathbf{x}$ 走一步， f 大约增加多少”。 $\nabla_x \|\mathbf{x}\|_2^2 = 2\mathbf{x}$ 表示：平方欧氏长度对 $\mathbf{x}$ 的敏感度就是 $2\mathbf{x}$ 本身。

2.4.4 链式法则

$$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}.$$

左边是复合后 y 对最外层输入 x 的总敏感度，等于“ y 对中间量 u 的敏感度”乘“ u 对 x 的敏感度”。多路径时

$$\frac{\partial y}{\partial x_i} = \sum_{j=1}^m \frac{\partial y}{\partial u_j} \frac{\partial u_j}{\partial x_i}$$

把每条路径的敏感度相加。反向传播算出的就是这个总敏感度，用来决定参数该往哪边改。

2.4.5 小结

$f'(x)$ 是切线斜率（输出随输入变多快）；偏导是沿单一坐标的斜率；梯度把这些斜率收成一个向量；链式法则把各层斜率连成对参数的总斜率。

2.4.6 练习

画出 f 与切线时，切线斜率必须等于所求的 $f'(x)$ 那个数。

2.5 自动微分

前向记录计算图 $\mathcal{G}$ ，反向对每个节点应用

$$\frac{\partial L}{\partial u} = \sum_{v: u \rightarrow v} \frac{\partial L}{\partial v} \frac{\partial v}{\partial u}.$$

左边是损失 L 对中间量 u 的敏感度，由下游敏感度与局部导数相乘再相加得到。

2.5.1 一个简单的例子

$$y = 2\mathbf{x}^\top \mathbf{x} = 2 \sum_i x_i^2, \quad \nabla_{\mathbf{x}} y = 4\mathbf{x}.$$

y 是一个非负标量，表示 $2\|\mathbf{x}\|_2^2$ 。 $\nabla_{\mathbf{x}} y$ 的第 i 个分量 $4x_i$ 表示： x_i 增加 1， y 大约增加 $4x_i$ 。`x.grad` 读到的就是这些数。默认累积：第二次反向若不清零，`x.grad` 变成 $8\mathbf{x}$ ，那是两次敏感度相加，不再是单次导数。

2.5.2 非标量变量的反向传播

Jacobian $J_{ij} = \partial y_i / \partial x_j$ 表示“第 i 个输出对第 j 个输入的敏感度”。训练通常算 $\mathbf{v}^\top J$ ：得到的向量是“把各输出用 $\mathbf{v}$ 加权后的总损失”对 $\mathbf{x}$ 的梯度。取 $\mathbf{v} = \mathbf{1}$ 时，

$$\nabla_{\mathbf{x}} \sum_i x_i^2 = 2\mathbf{x}$$

的含义是：把所有输出分量同等看待后加总，再问 $\mathbf{x}$ 往哪边能减小这个总和。

2.5.3 分离计算

$\mathbf{u} = \text{detach}(\mathbf{y})$ 后 $\nabla_{\mathbf{x}} z = \mathbf{u}$ 。这里每个分量 u_i 被当作常数权重，梯度不再包含“ $\mathbf{u}$ 本身还依赖 $\mathbf{x}$ ”那一条路。因此得到的数是部分导数，不是完整复合 $z = \sum_i x_i^3$ 的 $3x_i^2$ 。

2.5.4 Python 控制流的梯度计算

若本次路径上 $f(a) = ka$ ，则

$$\frac{df}{da} = k = \frac{f(a)}{a}, \quad a \neq 0.$$

k 这个数就是本次实际执行的那段仿射关系的斜率；换一条分支， k 会变。

2.5.5 小结

`x.grad` 里的每一个数都是 $\partial L / \partial x_i$ ：对应参数增大时，标量损失大约增加多少。要减小损失，应沿其负方向更新。

2.5.6 练习

核验二阶时每个海森条目 $\partial^2 L / \partial x_i \partial x_j$ 表示一阶敏感度再对 x_j 的变化；重复反向时 `grad` 中的数会叠加。

2.5.7 练习解答

2.5.7.1 1. 为什么二阶导数的开销更大？

海森 H_{ij} 有最多 n^2 个数，每个都是“梯度的第 i 个分量再对 x_j 求导”。要保存并再遍历一阶图，时间和内存都按这一矩阵规模增加。

2.5.7.2 2. 连续运行两次反向传播

第二次得到的 `grad` 是两次 ∇L 之和，数值上约为单次的两倍，不是新的一次导数。

2.5.7.3 3. 将控制流例子中的输入改成向量或矩阵

$\mathbf{1}^\top \mathbf{f}(\mathbf{a})$ 把各输出加总成一个标量；其梯度每个分量仍是该路径上的斜率 k ，含义不变：对应输入增大时，输出总和大约增加 k 。

2.5.7.4 4. 重新设计控制流梯度例子

$x > 0$ 时 $g'(x) = 2x$ 表示抛物线的切线斜率； $x < 0$ 时 $-3x^2$ 是另一支的斜率。分支选择本身没有导数。

2.6 概率

点估计给出 $\hat{y}$ ；概率把不确定性写成 $[0, 1]$ 上的数。

2.6.1 基本概率论

$$\hat{P}_N(\mathcal{A}) = \frac{1}{N} \sum_{i=1}^N \mathbf{1}\{X_i \in \mathcal{A}\}$$

是 N 次独立试验中事件发生的频率，取值 $[0, 1]$ 。大数定律下它逼近真实概率 $P(\mathcal{A})$ ，即“该事件长期发生的比例”。

2.6.1.1 概率论公理

$P(\mathcal{A}) \in [0, 1]$ ， $P(\mathcal{S}) = 1$ 表示“必然发生”。互斥并的概率相加，表示把不重叠情形的可能性拼起来。 $P(\emptyset) = 0$ 表示不可能事件。

2.6.1.2 随机变量

$P(X = x)$ 是离散取值恰好为 x 的概率。连续时

$$P(a \leq X \leq b) = \int_a^b p(x) dx$$

是落在区间内的概率； $p(x)$ 本身是密度，可以大于 1，不是概率。

2.6.2 处理多个随机变量

联合、条件、边际都是 $[0, 1]$ 上的数，但条件不同。

2.6.2.1 联合概率

$P(A = a, B = b)$ 是两件事同时发生的概率，不会超过任一边际。

2.6.2.2 条件概率

$$P(B = b \mid A = a) = \frac{P(A = a, B = b)}{P(A = a)}.$$

这是在已经知道 $A = a$ 的子总体里， $B = b$ 所占的比例，不是无条件下的发生频率。

2.6.2.3 贝叶斯定理

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}.$$

$P(A)$ 是见到 B 之前认为 A 为真的程度； $P(B | A)$ 是 A 为真时看到 B 的可能性； $P(A | B)$ 是见到 B 之后更新过的相信程度，仍在 $[0, 1]$ 。

2.6.2.4 边际化

$P(B) = \sum_A P(A, B)$ 把 A 的各种可能加总，得到“不管 A 如何， B 发生的总概率”。

2.6.2.5 独立性

$P(A, B) = P(A)P(B)$ 表示联合恰好是边际的乘积：知道 B 不会改变对 A 的概率，即 $P(A | B) = P(A)$ 这个数保持不变。

2.6.2.6 应用

$P(H = 1) = 0.0015$ 表示感染的先验比例约 0.15%。 $P(D_1 = 1) = 0.011485$ 表示一次检测呈阳性的总比例。后验

$$P(H = 1 | D_1 = 1) \approx 0.1306$$

表示：在已经阳性的人里，真正感染的比例约 13%，不是 100%。灵敏度高只说明“有病时几乎一定阳性”，不能把阳性直接读成“一定有病”。

2.6.3 期望和方差

$$\mathbb{E}[X] = \sum_x xP(X = x)$$

是按概率加权的平均水平，与 X 同量纲。

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

是相对均值的平方偏离的平均，量纲是 X 的平方；标准差开方后与 X 同量纲，表示典型起伏有多大。

2.6.4 小结

概率值是 $[0, 1]$ 上的可能性；条件概率是限制子总体后的比例；后验是用数据更新后的相信程度；期望是平均水平，方差是分散程度。

2.6.5 练习

核验频率 $\hat{P}_N$ 是否逼近概率，以及后验是否真的被先验和似然共同决定。

2.7 查阅文档

接口随版本变化，核验对象本身。这里没有新的数值，只核验函数签名是否对应前面的数学映射。

2.7.1 查找模块中的所有函数和类

`dir(module)` 返回名称列表，不是数值结果。

2.7.2 查找特定函数和类的用法

`help` 给出参数与返回值说明，用来核对实现是否就是本节公式所定义的那个映射。

2.7.3 小结

先列出候选对象，再读签名，确认输入输出的数学含义与文档一致。

2.7.4 练习

对选定张量函数：文档中的返回值对应公式里的哪一个数（形状、归约轴、是否就地修改）。

第三章 线性神经网络

线性模型把输入 $\boldsymbol{x}$ 映成标量或类别分数，再用平方损失或交叉熵得到可微目标。训练在小批量上用梯度更新参数；分类时在线性输出后再接 softmax。下面按原书顺序写出对象、损失、最优条件和实现所对应的映射。每一公式先写如何由输入算出输出，再写这个数在问题里表示什么。

3.1 线性回归




图 3.1.1 用线性模型拟合数据。

符号： x ：特征； y ：观测； 直线： $\hat{y} = wx + b$




图 3.1.2 线性回归是一个单层神经网络。

符号: x_i : 特征; w_i : 权重; b : 偏置; $\hat{y}$: 点预测




图 3.1.3 真实的神经元。

符号: 树突: 输入; 胞体: 加权求和; 轴突: 输出激活

回归估计 $y \in \mathbb{R}$ 。给定特征 $\mathbf{x} \in \mathbb{R}^d$, 模型输出一个实数预测 $\hat{y}$ 。 $\hat{y}$ 与 y 同量纲, 是点预测, 不是概率。

3.1.1 线性回归的基本元素

线性回归假设 $\hat{y}$ 对 $\mathbf{x}$ 仿射, 噪声为加性高斯。训练集

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$$

用来确定权重 $\mathbf{w}$ 与偏置 b 。 $\mathbf{x}^{(i)}$ 是第 i 个样本的 d 个特征, $y^{(i)}$ 是该样本的真实目标值 (例如房价, 单位与预测相同)。

3.1.1.1 线性模型

房价例子把面积与房龄写成加权和

$$\text{price} = w_{\text{area}} \cdot \text{area} + w_{\text{age}} \cdot \text{age} + b.$$

右边由两个特征各乘一个权重再加偏置得到，算出的 price 是与真实房价同单位的点预测，不是 $[0, 1]$ 上的概率。一般地， d 个特征给出

$$\hat{y} = w_1 x_1 + \cdots + w_d x_d + b = \mathbf{w}^\top \mathbf{x} + b.$$

w_j 是特征 x_j 的权重：该特征增加 1 个单位时，点预测大约增加 w_j ； b 是无特征时的基线预测。把 n 个样本排成 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 后，向量形式为

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w} + b.$$

$\hat{\mathbf{y}} \in \mathbb{R}^n$ 的第 i 个分量是第 i 个样本的点预测，仍与对应的 $y^{(i)}$ 同量纲。

3.1.1.2 损失函数

第 i 个样本的平方损失为

$$l^{(i)}(\mathbf{w}, b) = \frac{1}{2} (\hat{y}^{(i)} - y^{(i)})^2.$$

先算残差 $\hat{y}^{(i)} - y^{(i)}$ （预测减真值，与 y 同量纲），再平方并乘 $1/2$ 。得到的是非负标量，表示该样本点预测偏离真值有多远；它不是概率，也不是正确率。经验风险是样本平均

$$\begin{aligned} L(\mathbf{w}, b) &= \frac{1}{n} \sum_{i=1}^n l^{(i)}(\mathbf{w}, b) \\ &= \frac{1}{n} \sum_{i=1}^n \frac{1}{2} (\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)})^2. \end{aligned}$$

L 是均方误差（差一个常数因子 $1/2$ ）：把 n 个平方损失取算术平均，表示整批预测的典型平方偏离，仍不是 $[0, 1]$ 上的概率。参数估计定义为

$$\mathbf{w}^*, b^* = \underset{\mathbf{w}, b}{\operatorname{argmin}} L(\mathbf{w}, b).$$

$(\mathbf{w}^*, b^*)$ 是使训练均方误差最小的权重与偏置，本身是参数，不是新样本上的 $\hat{y}$ 。

3.1.1.3 解析解

把偏置并入 $\mathbf{X}$ 的全 1 列后，正规方程给出

$$\mathbf{w}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

成立条件是 $\mathbf{X}^\top \mathbf{X}$ 可逆，即特征线性无关且 n 足够大。左边每个分量仍是一个权重：对应特征增加 1 时点预测增加多少。右端由特征矩阵与标签算出，不经过迭代。

3.1.1.4 随机梯度下降

小批量 $\mathcal{B}$ 上的更新为

$$(\mathbf{w}, b) \leftarrow (\mathbf{w}, b) - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \partial_{(\mathbf{w}, b)} l^{(i)}(\mathbf{w}, b).$$

$\partial l^{(i)} / \partial w_j$ 是 w_j 增加 1 个单位时该样本平方损失大约增加多少；对批量求平均再乘步长 η ，沿其反方向改参数以减小 L 。平方损失的显式梯度是

$$\begin{aligned} \mathbf{w} &\leftarrow \mathbf{w} - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \mathbf{x}^{(i)} (\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)}), \\ b &\leftarrow b - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} (\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)}). \end{aligned}$$

括号里的残差 $\hat{y}^{(i)} - y^{(i)}$ 是点预测相对真值的有符号误差；乘上 $\mathbf{x}^{(i)}$ 后得到权重梯度，表示“残差大且特征大时，对应权重应改得更多”。

3.1.1.5 用模型进行预测

学得 $(\hat{\mathbf{w}}, \hat{b})$ 后，新样本的预测是仿射映射

$$\hat{y} = \hat{\mathbf{w}}^\top \mathbf{x} + \hat{b}.$$

输入是新特征向量，输出仍是与 y 同量纲的点预测，不是类概率。

3.1.2 矢量化加速

对 $\mathbf{a}, \mathbf{b} \in \mathbb{R}^m$ ，逐元素求和应写成一次向量加法

$$\mathbf{c} = \mathbf{a} + \mathbf{b}, \quad c_i = a_i + b_i,$$

而不是 m 次标量循环。 c_i 就是第 i 个位置两个输入之和，与 a_i 同量纲。小批量上的 $\mathbf{X}\mathbf{w}$ 同样一次完成：第 i 个输出仍是第 i 个样本的点预测。

3.1.3 正态分布与平方损失

高斯密度为

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right).$$

输入是标量 x 与参数 (μ, σ^2) ，输出是该点上的密度值：可以大于 1，不是事件概率；真正的概率是密度在区间上的积分。 μ 是分布中心， σ 是起伏尺度，与 x 同量纲。

观测模型把标签写成点预测加噪声

$$y = \mathbf{w}^\top \mathbf{x} + b + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2).$$

输入是特征 $\mathbf{x}$ 、参数 $(\mathbf{w}, b)$ 与噪声 ϵ ；输出 y 与点预测同量纲。 ϵ 是观测扰动：均值为 0 表示无系统偏差， σ^2 是扰动的平方起伏。由 $\epsilon = y - \mathbf{w}^\top \mathbf{x} - b$ 得条件密度

$$P(y | \mathbf{x}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(y - \mathbf{w}^\top \mathbf{x} - b)^2\right).$$

输入是已观测的 $(\mathbf{x}, y)$ 与待估参数 $(\mathbf{w}, b)$ ；输出是 y 处的密度，不是 $[0, 1]$ 概率。均值 $\mathbf{w}^\top \mathbf{x} + b$ 是点预测；残差越大，该密度越小，表示这组参数越难解释该观测。固定数据而把上式看成 $(\mathbf{w}, b)$ 的函数，就是单样本似然：它度量“参数有多合理”，不是 $P(\mathbf{w}, b | \text{数据})$ 。

独立同分布样本下，整批观测的联合密度是各样本密度之积

$$P(\mathbf{y} | \mathbf{X}) = \prod_{i=1}^n p(y^{(i)} | \mathbf{x}^{(i)}).$$

输入是全部 $(\mathbf{X}, \mathbf{y})$ 与 $(\mathbf{w}, b)$ ；输出仍是联合密度。乘积成立的条件是各样本相互独立：独立事件同时发生的密度等于各自密度相乘。该量越大，表示当前 $(\mathbf{w}, b)$ 越能同时解释整批标签。极大似然估计定义为

$$\mathbf{w}^*, b^* = \operatorname{argmax}_{\mathbf{w}, b} P(\mathbf{y} | \mathbf{X}).$$

$(\mathbf{w}^*, b^*)$ 是使已观测数据最容易出现的权重与偏置，本身是参数，不是新样本上的 $\hat{y}$ 。

乘积不便求导，且大量小于 1 的密度相乘易下溢。对数严格递增，故

$$\operatorname{argmax} P(\mathbf{y} | \mathbf{X}) = \operatorname{argmax} \log P(\mathbf{y} | \mathbf{X}) = \operatorname{argmin} (-\log P(\mathbf{y} | \mathbf{X})).$$

把乘积化为求和并改成最小化，不改变最优参数。代入高斯密度得负对数似然

$$\begin{aligned} -\log P(\mathbf{y} | \mathbf{X}) &= \sum_{i=1}^n \frac{1}{2} \log(2\pi\sigma^2) \\ &\quad + \frac{1}{2\sigma^2} (y^{(i)} - \mathbf{w}^\top \mathbf{x}^{(i)} - b)^2. \end{aligned}$$

输入是全部残差与固定 σ ；输出是非负标量。第一项与 $(\mathbf{w}, b)$ 无关；第二项是残差平方和，再被 $2\sigma^2$ 缩放。 σ 固定时，后一项与经验风险 $L(\mathbf{w}, b)$ 只差正常数，故

$$\operatorname{argmax}_{\mathbf{w}, b} P(\mathbf{y} | \mathbf{X}) = \operatorname{argmin}_{\mathbf{w}, b} L(\mathbf{w}, b).$$

结论：高斯噪声下，极大似然与最小化均方误差给出同一组 $(\mathbf{w}, b)$ ；最小化的仍是平方预测误差，不是在估计一个概率值。

3.1.4 从线性回归到深度学习

同一仿射映射可看成只有一层计算单元的网络：输入给定，输出由 $\mathbf{w}, b$ 计算，得到点预测。

3.1.4.1 神经网络图

输入层提供 $x_1, \dots, x_d$, 输出层一个单元

$$o_1 = \mathbf{w}^\top \mathbf{x} + b.$$

o_1 就是 $\hat{y}$: 与 y 同量纲的点预测。每个输入都连到该单元, 参数个数为 $d+1$, 每个 w_j 仍是“该特征增加 1 时预测增加多少”。

3.1.4.2 生物学

树突接收 x_i , 突触权重为 w_i , 胞体做加权和后再经激活

$$o = \phi(\mathbf{w}^\top \mathbf{x} + b).$$

$\mathbf{w}^\top \mathbf{x} + b$ 先算出一个实数打分, ϕ 再把它变成输出激活。线性回归对应 ϕ 为恒等映射, 故 o 仍是点预测。

3.1.5 小结

对象是仿射点预测 $\hat{y} = \mathbf{w}^\top \mathbf{x} + b$ (与 y 同量纲, 不是概率), 目标 $L(\mathbf{w}, b)$ 是均方误差 (平均平方偏离, 不是概率); 高斯噪声下它等于负对数似然; 可逆时用正规方程, 否则用小批量梯度 (每个分量是参数增加 1 时损失大约增加多少)。

3.1.6 练习

核验 $\sum_i (x_i - b)^2$ 对 b 的驻点。对 b 求导并令其为零得

$$b^* = \frac{1}{n} \sum_{i=1}^n x_i.$$

输入是标量样本 $\{x_i\}$, 输出是样本均值: 表示使平方偏离最小的常数水平, 不是某一个观测。若 $x_i = b + \epsilon_i$ 且 $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$, 则 b 的极大似然估计就是该均值。

把 b 并入 $\mathbf{X}$ 的全 1 列后, 平方损失写成

$$L(\mathbf{w}) = \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2.$$

输入是 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 、 $\mathbf{w} \in \mathbb{R}^d$ 、 $\mathbf{y} \in \mathbb{R}^n$; 输出是非负标量, 仍是均方误差型偏离。梯度为 $\nabla_{\mathbf{w}} L = \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y})$, 其第 j 个分量是 w_j 增加 1 时损失大约增加多少。令梯度为零得正规方程 $\mathbf{X}^\top \mathbf{X}\mathbf{w} = \mathbf{X}^\top \mathbf{y}$; $\mathbf{X}^\top \mathbf{X}$ 可逆时 $\mathbf{w}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ 。 $\mathbf{X}^\top \mathbf{X}$ 奇异时解析解不存在, 梯度法仍可沿减小均方误差的方向走。

若附加噪声改为拉普拉斯（原书称指数）分布

$$p(\epsilon) = \frac{1}{2} \exp(-|\epsilon|),$$

输入是标量残差 ϵ ，输出是该点密度：在 0 处最高，向两侧按绝对值指数衰减，积分仍为 1。由 $\epsilon^{(i)} = y^{(i)} - \mathbf{w}^\top \mathbf{x}^{(i)} - b$ 得单样本条件密度

$$p(y^{(i)} | \mathbf{x}^{(i)}) = \frac{1}{2} \exp(-|y^{(i)} - \mathbf{w}^\top \mathbf{x}^{(i)} - b|).$$

输入是已观测的 $(\mathbf{x}^{(i)}, y^{(i)})$ 与 $(\mathbf{w}, b)$ ；输出是 $y^{(i)}$ 处的密度。绝对值残差越小，密度越大，表示这组参数越能解释该观测。独立样本下联合似然为乘积

$$P(\mathbf{y} | \mathbf{X}) = \left(\frac{1}{2}\right)^n \exp\left(-\sum_{i=1}^n |y^{(i)} - \mathbf{w}^\top \mathbf{x}^{(i)} - b|\right).$$

输入是全部残差；输出是联合密度。乘积同样要求样本独立。取负对数得

$$-\log P(\mathbf{y} | \mathbf{X}) = n \log 2 + \sum_{i=1}^n |y^{(i)} - \mathbf{w}^\top \mathbf{x}^{(i)} - b|.$$

输入是全部绝对残差；输出是非负标量。 $n \log 2$ 与参数无关，故极大似然等价于

$$\min_{\mathbf{w}, b} \sum_{i=1}^n |y^{(i)} - \mathbf{w}^\top \mathbf{x}^{(i)} - b|.$$

被最小化的是绝对误差之和，与 y 同量纲，不是平方偏离，也不是概率。一般多元情形下符号函数 $\text{sign}(\hat{y} - y)$ 依赖未知参数，没有与正规方程同类的闭式解；仅估计常数 b 时，最优值是 $\{y^{(i)}\}$ 的中位数。小批量上可用次梯度

$$\nabla_{\mathbf{w}} L = \sum_{i \in \mathcal{B}} \text{sign}(\hat{y}^{(i)} - y^{(i)}) \mathbf{x}^{(i)}, \quad \frac{\partial L}{\partial b} = \sum_{i \in \mathcal{B}} \text{sign}(\hat{y}^{(i)} - y^{(i)}).$$

$\text{sign}(\hat{y} - y) \in \{-1, 0, 1\}$ 只保留误差方向；残差接近 0 时梯度不自动缩小，固定步长下参数可能在驻点附近振荡。

3.2 线性回归的从零开始实现

实现对应四个映射：采样数据、按批读取、仿射预测、平方损失上的小批量更新。

3.2.1 生成数据集

真值为

$$\mathbf{y} = \mathbf{X}\mathbf{w} + b + \boldsymbol{\epsilon},$$

其中 $\boldsymbol{\epsilon}$ 的分量独立同分布。 $\mathbf{X}\mathbf{w} + b$ 是无噪声的点预测， ϵ_i 是第 i 个样本的加性扰动，与 y 同量纲；合成数据时 $\mathbf{w}, b$ 已知，用来对照估计出的权重是否接近真值。

3.2.2 读取数据集

一次迭代取出小批量

$$(\mathbf{X}_B, \mathbf{y}_B), \quad |\mathcal{B}| = B.$$

$\mathbf{X}_B \in \mathbb{R}^{B \times d}$ 的每一行仍是一个样本的特征， $\mathbf{y}_B \in \mathbb{R}^B$ 是对应点目标。遍历前打乱下标，使各批对梯度的估计近似无偏。 B 是本批样本个数，不是损失。

3.2.3 初始化模型参数

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, 0.01^2 \mathbf{I}), \quad b = 0,$$

并对其后每次损失关于 $(\mathbf{w}, b)$ 求梯度。 w_j 的初值是接近 0 的随机权重，表示起步时“几乎不看任何特征”； $b = 0$ 表示基线预测从 0 开始。

3.2.4 定义模型

前向是矩阵-向量积加偏置广播

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w} + b.$$

输入 $\mathbf{X} \in \mathbb{R}^{B \times d}$ ，输出 $\hat{\mathbf{y}} \in \mathbb{R}^B$ ：每个分量是该样本的点预测，与 $\mathbf{y}$ 同量纲。

3.2.5 定义损失函数

批量平方损失与上一节一致，实现时把 $\mathbf{y}$ 的形状对齐到 $\hat{\mathbf{y}}$ ：

$$l = \frac{1}{2} \|\hat{\mathbf{y}} - \mathbf{y}\|_2^2 \quad (\text{再按约定取平均或求和}).$$

$\|\hat{\mathbf{y}} - \mathbf{y}\|_2^2$ 是残差向量的平方欧氏长度，再乘 1/2。得到的是均方误差型标量（求和或平均只差因子 B ），表示这批点预测离真值有多远，不是概率。

3.2.6 定义优化算法

一步小批量梯度下降

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \frac{\eta}{|\mathcal{B}|} \nabla_{\boldsymbol{\theta}} \sum_{i \in \mathcal{B}} l^{(i)}, \quad \boldsymbol{\theta} = (\mathbf{w}, b).$$

$\nabla_{\boldsymbol{\theta}}$ 的每个分量是对应参数增加 1 时批量损失大约增加多少。用 $|\mathcal{B}|$ 规范化后，步长不随批量大小线性膨胀。

3.2.7 训练

每个周期对全部小批量执行

$$\begin{aligned}\hat{\mathbf{y}} &\leftarrow \mathbf{X}_{\mathcal{B}}\mathbf{w} + b, \\ g &\leftarrow \partial_{(\mathbf{w}, b)} \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} l^{(i)}, \\ (\mathbf{w}, b) &\leftarrow (\mathbf{w}, b) - \eta g.\end{aligned}$$

第一行算出点预测，第二行算出“参数每增 1 损失变多少”，第三行沿负梯度改权重以减小均方误差。

3.2.8 小结

从零实现把训练写成张量上的 $\hat{\mathbf{y}} = \mathbf{X}\mathbf{w} + b$ （点预测）与 $(\mathbf{w}, b) \leftarrow (\mathbf{w}, b) - \eta g$ （ g 为损失对参数的敏感度），不引入层对象。

3.2.9 练习

核验 $\mathbf{w} = \mathbf{0}$ 时梯度是否仍指向残差方向：此时 $\hat{y} = b$ ，梯度由 $b - y$ 驱动。二阶导数 $\partial^2 L / \partial w_j \partial w_k$ 表示一阶敏感度再随 w_k 变多快。 n 不能整除 $|\mathcal{B}|$ 时最后一批的基数小于 B ，平均损失仍是该批样本的均方误差。

3.3 线性回归的简洁实现

同一映射改由层、损失类与优化器组合，前向与更新规则不变。

3.3.1 生成数据集

仍用 $\mathbf{y} = \mathbf{X}\mathbf{w} + b + \epsilon$ 生成 $(\mathbf{X}, \mathbf{y})$ 。 $\mathbf{y}$ 的每个分量是带噪声的真实目标，与随后的 $\hat{\mathbf{y}}$ 同量纲。

3.3.2 读取数据集

数据迭代器实现

$$(\mathbf{X}, \mathbf{y}) \mapsto \{(\mathbf{X}_{\mathcal{B}}, \mathbf{y}_{\mathcal{B}})\}.$$

每次取出的 $\mathbf{X}_{\mathcal{B}}$ 是特征块， $\mathbf{y}_{\mathcal{B}}$ 是对应目标。训练模式下每个周期打乱样本次序，不改变这些数的含义。

3.3.3 定义模型

全连接层

$$f(\mathbf{X}) = \mathbf{X}\mathbf{W} + \mathbf{b}, \quad \mathbf{W} \in \mathbb{R}^{d \times 1}$$

作为唯一计算层；顺序容器只含这一层。输出每个分量仍是点预测： W_{j1} 是第 j 个特征的权重。

3.3.4 初始化模型参数

$$W_{ij} \sim \mathcal{N}(0, 0.01^2), \quad b = 0.$$

初值接近 0 的权重表示起步时预测接近常数 b ；它们将被梯度改成拟合数据的权重。

3.3.5 定义损失函数

均方误差是平方 L_2 的样本平均

$$L = \frac{1}{n} \sum_{i=1}^n \frac{1}{2} (\hat{y}^{(i)} - y^{(i)})^2.$$

L 是均方误差，表示平均平方偏离，不是类概率，也不是准确率。

3.3.6 定义优化算法

优化器在参数集合上执行

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} L_{\mathcal{B}}.$$

$\nabla_{\boldsymbol{\theta}} L_{\mathcal{B}}$ 的分量是该参数增加 1 时本批均方误差大约增加多少。

3.3.7 训练

每个小批量依次：前向 $L_{\mathcal{B}}$ 、反向 $\nabla_{\boldsymbol{\theta}} L_{\mathcal{B}}$ 、参数更新。 $L_{\mathcal{B}}$ 监控的是本批均方误差大小；周期结束时用全训练 L 看整体拟合，二者都不是概率。

3.3.8 小结

简洁实现把 $\mathbf{X} \mapsto \mathbf{X}\mathbf{W} + \mathbf{b}$ 、平方损失与小批量梯度封装成可组合对象，数学映射与从零实现相同： $\hat{y}$ 是点预测， L 是均方误差。

3.3.9 练习

核验分段损失

$$l(y, y') = \begin{cases} |y - y'| - \frac{\sigma}{2}, & |y - y'| > \sigma, \\ \frac{1}{2\sigma}(y - y')^2, & \text{其它情况} \end{cases}$$

在 $|y - y'| = \sigma$ 处的连续性与可导性。 $|y - y'|$ 是绝对误差，与 y 同量纲；中间段的平方项仍是误差大小，不是概率。 σ 是分段阈值，与残差同量纲。

3.4 softmax 回归




图 3.4.1 softmax 回归是一种单层神经网络

符号： $\mathbf{x}$: 输入； $\mathbf{o}$: 线性分数； $\hat{\mathbf{y}}$: 类别概率

分类不估计“多少”，而估计“哪一类”。线性层输出 q 个分数，再用 softmax 变成单纯形上的概率。

3.4.1 分类问题

$q = 3$ 时标签用独热向量

$$\mathbf{y} \in \{(1, 0, 0), (0, 1, 0), (0, 0, 1)\}.$$

向量里的 1 表示“属于该类”，0 表示“不属于”；各分量互斥，和为 1。一般 $y \in \{1, \dots, q\}$ 对应 $\mathbf{y} = \mathbf{e}_y \in \{0, 1\}^q$ ，其中下标 y 是真实类别编号。

3.4.2 网络架构

四个特征、三个类别时，线性分数为

$$o_1 = x_1 w_{11} + x_2 w_{12} + x_3 w_{13} + x_4 w_{14} + b_1,$$

$$o_2 = x_1 w_{21} + x_2 w_{22} + x_3 w_{23} + x_4 w_{24} + b_2,$$

$$o_3 = x_1 w_{31} + x_2 w_{32} + x_3 w_{33} + x_4 w_{34} + b_3.$$

o_k 由特征加权求和得到，是类 k 的未归一化打分 (logit)，可正可负，不是概率。矩阵形式 $\mathbf{o} = \mathbf{W}\mathbf{x} + \mathbf{b}$ ， $\mathbf{W} \in \mathbb{R}^{q \times d}$ 。 W_{kj} 是：特征 j 增加 1 时，类 k 的打分增加多少。

3.4.3 全连接层的参数开销

d 入 q 出的全连接层参数个数为

$$\#(\mathbf{W}, \mathbf{b}) = dq + q = \mathcal{O}(dq).$$

这是一个正整数，表示要存储并更新多少个权重与偏置，不是损失值。

3.4.4 softmax 运算

把分数映到概率单纯形

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{o}), \quad \hat{y}_j = \frac{\exp(o_j)}{\sum_k \exp(o_k)}.$$

先对每个打分取指数（保证为正），再除以所有类指数之和。 $\hat{y}_j$ 是类 j 的概率：取值 $[0, 1]$ ，且 $\sum_j \hat{y}_j = 1$ 。指数严格递增，故

$$\operatorname{argmax}_j \hat{y}_j = \operatorname{argmax}_j o_j.$$

左边是概率最大的类编号，右边是打分最高的类编号，二者给出同一个离散预测。

3.4.5 小批量样本的矢量化

$\mathbf{X} \in \mathbb{R}^{n \times d}$ 时

$$\mathbf{O} = \mathbf{X}\mathbf{W} + \mathbf{b},$$

$$\hat{\mathbf{Y}} = \text{softmax}(\mathbf{O}),$$

其中 softmax 沿类别轴作用。 O_{ij} 是第 i 个样本对类 j 的打分； $\hat{Y}_{ij}$ 是第 i 个样本属于类 j 的概率，在 $[0, 1]$ 。

3.4.6 损失函数

仍由最大似然导出：独立样本下最小化 $-\log P(\mathbf{Y} | \mathbf{X})$ 。该标量越大，表示模型对真实标签越惊讶。

3.4.6.1 对数似然

$$P(\mathbf{Y} | \mathbf{X}) = \prod_{i=1}^n P(\mathbf{y}^{(i)} | \mathbf{x}^{(i)}).$$

每一项 $P(\mathbf{y}^{(i)} | \mathbf{x}^{(i)})$ 是模型分给真实类的概率，在 $(0, 1]$ 。负对数似然分解为交叉熵之和

$$-\log P(\mathbf{Y} | \mathbf{X}) = \sum_{i=1}^n -\log P(\mathbf{y}^{(i)} | \mathbf{x}^{(i)}) = \sum_{i=1}^n l(\mathbf{y}^{(i)}, \hat{\mathbf{y}}^{(i)}),$$

其中

$$l(\mathbf{y}, \hat{\mathbf{y}}) = -\sum_{j=1}^q y_j \log \hat{y}_j.$$

独热标签时 $l = -\log \hat{y}_{y^*}$ ：只取出真实类概率再取负对数。 $\log$ 为自然对数，故 l 的单位是 nats，表示模型对真类有多惊讶：真类概率接近 1 时 l 接近 0，真类概率接近 0 时 l 趋向 $+\infty$ 。它不是均方误差，也不是准确率。

3.4.6.2 softmax 及其导数

把 $\hat{y}_j$ 代入交叉熵：

$$\begin{aligned} l(\mathbf{y}, \hat{\mathbf{y}}) &= -\sum_{j=1}^q y_j \log \frac{\exp(o_j)}{\sum_{k=1}^q \exp(o_k)} \\ &= \sum_{j=1}^q y_j \log \sum_{k=1}^q \exp(o_k) - \sum_{j=1}^q y_j o_j \\ &= \log \sum_{k=1}^q \exp(o_k) - \sum_{j=1}^q y_j o_j. \end{aligned}$$

第一项是各打分的 logsumexp ，第二项是真实类的打分。对分数求导得到

$$\begin{aligned} \partial_{o_j} l(\mathbf{y}, \hat{\mathbf{y}}) &= \frac{\exp(o_j)}{\sum_{k=1}^q \exp(o_k)} - y_j \\ &= \text{softmax}(\mathbf{o})_j - y_j. \end{aligned}$$

$\partial l / \partial o_j$ 是打分 o_j 增加 1 时交叉熵大约增加多少，数值上等于“预测的类 j 概率减去真实独热标签”。因此反向传播中， $\nabla_{\mathbf{o}} l = \hat{\mathbf{y}} - \mathbf{y}$ 。再经 $\mathbf{o} = \mathbf{W}\mathbf{x} + \mathbf{b}$ 链式法则，

$$\nabla_{\mathbf{W}} l = (\hat{\mathbf{y}} - \mathbf{y}) \mathbf{x}^\top, \quad \nabla_{\mathbf{b}} l = \hat{\mathbf{y}} - \mathbf{y}.$$

左边每个条目是对应权重或偏置增大时交叉熵大约增加多少。批量 $\mathbf{X} \in \mathbb{R}^{B \times d}$ 、 $\hat{\mathbf{Y}}, \mathbf{Y} \in \mathbb{R}^{B \times q}$ 时

$$\nabla_{\mathbf{W}} L = \frac{1}{B} \mathbf{X}^\top (\hat{\mathbf{Y}} - \mathbf{Y}).$$

与线性回归对照：回归用标量残差 $(\hat{y} - y)$ 乘 $\mathbf{x}$ ；这里用向量残差 $(\hat{\mathbf{y}} - \mathbf{y})$ 乘 $\mathbf{x}$ 。指数出现在 softmax 的 e^{o_j} 上，不是把权重 $\mathbf{W}$ 指数化。

3.4.6.3 交叉熵损失

若 $\mathbf{y}$ 本身已是分布而非独热，同一式

$$l(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_{j=1}^q y_j \log \hat{y}_j$$

仍是交叉熵，等于在标签分布下对 $-\log \hat{y}_j$ 的期望，单位仍是 nats：表示用模型概率编码真实分布时平均有多惊讶。

3.4.7 信息论基础

交叉熵同时度量编码长度与似然。

3.4.7.1 熵

分布 P 的熵

$$H[P] = \sum_j -P(j) \log P(j)$$

是按 P 编码时的最小期望码长，单位 nats。 $H[P] \geq 0$ ；越接近均匀分布越大，确定事件则为 0。

3.4.7.2 信息量

事件 j 的自信息为

$$I(j) = -\log P(j) = \log \frac{1}{P(j)}.$$

$P(j)$ 越小， $I(j)$ 越大：越罕见的事件一旦发生，惊讶越大。熵是自信息的期望。

3.4.7.3 重新审视交叉熵

从 P 到 Q 的交叉熵

$$H(P, Q) = \sum_j -P(j) \log Q(j) = H(P) + D_{\text{KL}}(P \| Q)$$

在 $Q = P$ 时取最小 $H(P)$ 。 $H(P, Q)$ 是用 Q 编码 P 的平均码长 (nats)； D_{KL} 是多付的那部分，非负。分类目标等价于极大似然，也等价于降低用 $\hat{\mathbf{y}}$ 编码真实标签所需的惊异。

3.4.8 模型预测和评估

预测类别

$$\hat{y} = \operatorname{argmax}_j \hat{y}_j.$$

$\hat{y}_j$ 是类概率，取最大者得到离散类编号，不是概率本身。精度是正确个数与总数之比

$$\text{acc} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{\hat{y}^{(i)} = y^{(i)}\}.$$

指示为 1 表示该样本预测类等于真类，0 表示错误； $\text{acc} \in [0, 1]$ 是判对的比例。精度不可导，训练仍最小化交叉熵。

3.4.9 小结

softmax 把打分 $\mathbf{o}$ 映到类概率（第 k 个分量在 $[0, 1]$ 且和为 1），交叉熵 $l = -\log \hat{y}_{y^*}$ 是模型对真类的惊讶（nats）， $\nabla_{\mathbf{o}} l = \hat{\mathbf{y}} - \mathbf{y}$ 的分量是打分增加 1 时惊讶大约增加多少；精度是判对样本所占比例。

3.4.10 练习

核验交叉熵对 $\mathbf{o}$ 的 Hessian 与 $\text{softmax}(\mathbf{o})$ 的协方差是否一致：二阶导表示一阶敏感度再随打分变化有多快。均匀分布 $(\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ 下每个类概率都是 1/3，熵为 $\log 3$ nats。

3.5 图像分类数据集

Fashion-MNIST 提供 $q = 10$ 的服装灰度图，后续 softmax 实验都在该 $\mathcal{D}$ 上评估。

3.5.1 读取数据集

训练集 $n_{\text{train}} = 60000$ ，测试集 $n_{\text{test}} = 10000$ ，每类分别 6000 与 1000 张。这些正整数是样本个数，不是精度。单张图

$$\mathbf{X} \in \mathbb{R}^{28 \times 28}, \quad C = 1,$$

形状记为 $h \times w = 28 \times 28$ 。每个像素 X_{hw} 是该位置的灰度强度。测试集不参与参数更新，用来估计判对比例。

3.5.2 读取小批量

迭代器输出

$$\mathbf{X} \in \mathbb{R}^{|\mathcal{B}| \times 1 \times 28 \times 28}, \quad \mathbf{y} \in \{1, \dots, 10\}^{|\mathcal{B}|}.$$

$\mathbf{X}$ 的第一轴是样本编号，后面是通道与空间； $\mathbf{y}$ 的每个分量是真实类编号。训练时打乱，测试时按序。

3.5.3 整合所有组件

读取映射把批量大小与可选边长映到训练与测试迭代器。可选边长把 28×28 双线性映到指定 (h', w') ：输出每个像素仍是灰度，只是网格变了。

3.5.4 小结

图像对象是 $h \times w$ 灰度阵（像素是强度），批量读取把它们变成可并行的 $(\mathbf{X}, \mathbf{y})$ ； $\mathbf{y}$ 是类编号，随后将变成独热或用于选取 $\hat{y}_y$ 。

3.5.5 练习

核验 $|\mathcal{B}| \rightarrow 1$ 时 I/O 相对计算的占比，以及迭代器是否成为训练的时间瓶颈。这里比较的是运行时间，不是交叉熵或精度这两个数的含义。

3.6 softmax 回归的从零开始实现

把 28×28 展平为 $\mathbb{R}^{784}$ ，线性层输出 10 维，再接 softmax 与交叉熵。

3.6.1 初始化模型参数

$$\mathbf{W} \in \mathbb{R}^{784 \times 10}, \quad \mathbf{b} \in \mathbb{R}^{1 \times 10},$$

$W_{ij} \sim \mathcal{N}(0, \sigma^2)$, $b_j = 0$ 。 W_{ij} 是像素 i 对类 j 打分的权重。展平是

$$\mathbb{R}^{28 \times 28} \longrightarrow \mathbb{R}^{784}.$$

每个像素强度原样排成向量，不改变那些灰度值。

3.6.2 定义 softmax 操作

对矩阵按行归一化

$$\text{softmax}(\mathbf{X})_{ij} = \frac{\exp(X_{ij})}{\sum_k \exp(X_{ik})}.$$

第 i 行第 j 列是样本 i 属于类 j 的概率，在 $[0, 1]$ ，且同行求和为 1。

3.6.3 定义模型

$$\hat{\mathbf{Y}} = \text{softmax}(\mathbf{X}\mathbf{W} + \mathbf{b}),$$

其中 $\mathbf{X}$ 已展平为 $|\mathcal{B}| \times 784$ 。先得打分 $\mathbf{X}\mathbf{W} + \mathbf{b}$ ，再变成类概率； $\hat{Y}_{ij}$ 不是点预测房价那种实数目标。

3.6.4 定义损失函数

独热选取使

$$l(\mathbf{y}, \hat{\mathbf{Y}}) = - \sum_{i=1}^{|\mathcal{B}|} \log \hat{Y}_{i, y^{(i)}}.$$

对每个样本取出真实类概率再取 $-\log$ ，单位 nats，再对批量求和（或平均）：表示这批样本上模型对真类有多惊讶。

3.6.5 分类精度

$$\text{acc}(\hat{\mathbf{Y}}, \mathbf{y}) = \frac{1}{|\mathcal{B}|} \sum_i \mathbf{1}\{\arg\max_j \hat{Y}_{ij} = y^{(i)}\}.$$

先对每行概率取最大类，再数判对的比例。acc $\in [0, 1]$ 是正确样本所占分数，不可导。

3.6.6 训练

与线性回归同一循环：前向 $\hat{\mathbf{Y}}$ 、交叉熵、反向、小批量更新。每个周期在测试集上报告 acc，即测试判对比例；更新所用的梯度仍来自交叉熵，不是来自 acc。

3.6.7 预测

对新图取

$$\hat{y} = \arg\max_j \text{softmax}(\mathbf{x}^\top \mathbf{W} + \mathbf{b})_j.$$

先把打分变成十类概率，再取概率最大的类编号，作为离散预测。

3.6.8 小结

从零实现的核心是 $\hat{\mathbf{Y}} = \text{softmax}(\mathbf{XW} + \mathbf{b})$ （类概率）与 $l = -\sum \log \hat{y}_y$ （nats 惊讶），训练循环与线性回归同构，但 L 不再是均方误差。

3.6.9 练习

核验 $\exp(o_j)$ 在 o_j 很大时的溢出、 $\log \hat{y}_j$ 在 $\hat{y}_j \rightarrow 0$ 时的定义域：后者趋向 $+\infty$ ，对应“对真类几乎零概率”的无限惊讶。 argmax 给出的是类编号，在 0-1 损失下是贝叶斯最优决策，对其他代价未必最优。

3.7 softmax 回归的简洁实现

同一分类映射改由全连接层加交叉熵实现；数值上把 softmax 与 log 合并。

3.7.1 初始化模型参数

顺序模型中一层 $\mathbb{R}^{784} \rightarrow \mathbb{R}^{10}$,

$$W_{ij} \sim \mathcal{N}(0, 0.01^2), \quad b_j = 0.$$

W_{ij} 仍是像素到类打分的权重，初值接近 0 表示起步时各类打分接近相等。

3.7.2 重新审视 Softmax 的实现

平移不变性给出数值稳定形式

$$\begin{aligned} \hat{y}_j &= \frac{\exp(o_j - \max_k o_k) \exp(\max_k o_k)}{\sum_k \exp(o_k - \max_k o_k) \exp(\max_k o_k)} \\ &= \frac{\exp(o_j - \max_k o_k)}{\sum_k \exp(o_k - \max_k o_k)}. \end{aligned}$$

减去最大值只改指数的尺度，不改变概率 $\hat{y}_j \in [0, 1]$ 。对数概率为

$$\begin{aligned} \log \hat{y}_j &= \log \frac{\exp(o_j - \max_k o_k)}{\sum_k \exp(o_k - \max_k o_k)} \\ &= o_j - \max_k o_k - \log \sum_k \exp(o_k - \max_k o_k). \end{aligned}$$

$\log \hat{y}_j \leq 0$ ，是类 j 概率的对数；交叉熵直接用 $-\log \hat{y}_{y^*}$ （nats），避免先指数再取对数造成的下溢。

3.7.3 优化算法

小批量随机梯度

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} L_{\mathcal{B}}, \quad \eta = 0.1.$$

$L_{\mathcal{B}}$ 是本批平均交叉熵 (nats)；梯度分量是对应参数增加 1 时该惊讶大约增加多少。 $\eta = 0.1$ 是步长，无量纲地缩放这一敏感度。

3.7.4 训练

调用与从零实现相同的周期循环；框架在交叉熵内部完成稳定的 $\log \text{softmax}$ 。监控的 L 仍是平均惊讶，acc 仍是判对比例。

3.7.5 小结

简洁路径仍是 $\boldsymbol{O} = \boldsymbol{XW} + \boldsymbol{b}$ 与交叉熵，差别在于用 $\log \hat{y}_j = o_j - \max o - \text{LSE}(\boldsymbol{o} - \max o)$ 保证数值稳定； $\hat{y}_j$ 的含义不变：类 j 的概率。

3.7.6 练习

核验增大周期后测试精度下降是否对应过拟合：训练交叉熵仍降、测试判对比例却降。 $|\mathcal{B}|, \eta$ 影响 $\nabla L_{\mathcal{B}}$ 的方差：批量越小，每次“损失对参数的敏感度”估计越吵。

第四章 多层感知机

线性层只能表示仿射关系。在层间插入非线性 σ 后，复合映射可以逼近更一般的 f 。训练仍最小化可微损失，但深度带来梯度消失或爆炸，并用权重衰减、暂退法控制容量。分布一旦偏离训练 P ，经验风险不再自动逼近真实风险。

4.1 多层感知机




图 4.1.1 一个单隐藏层的多层感知机，具有 5 个隐藏单元

符号： $\mathbf{x}$ ：输入；隐层： h ； $\mathbf{o}$ ：输出 logits

softmax 回归是一次仿射再归一化。多层感知机在仿射之间加入隐藏层与逐元素非线性。

4.1.1 隐藏层

仿射 $\mathbf{x} \mapsto \mathbf{W}\mathbf{x} + \mathbf{b}$ 对每个特征是单调的。隐藏层用来表示特征之间的交互。

4.1.1.1 线性模型可能会出错

权重为正时, x_j 增大则线性分数增大。许多关系非单调, 例如体温与风险在正常值两侧反向变化, 单次仿射无法同时拟合两支: 线性打分只能沿一个方向走, 不能在同一特征上先降后升。

4.1.1.2 在网络中加入隐藏层

$L - 1$ 个隐藏层给出表示, 最后一层做线性预测。一层隐藏、宽度 h 的 MLP 为

$$\begin{aligned} \mathbf{h} &= \sigma(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)}), \\ \mathbf{o} &= \mathbf{W}^{(2)}\mathbf{h} + \mathbf{b}^{(2)}. \end{aligned}$$

$\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)}$ 先得到 h 个预激活 (实数打分); σ 逐元素作用后, h_j 是第 j 个隐藏单元被保留下来的激活值。 $\mathbf{o}$ 再由这些激活线性组合: 回归时是点预测, 分类时是各类打分。两层都全连接。输入层不计计算, 故该网络层数为 2。层数是正整数, 不是损失。

4.1.1.3 从线性到非线性

若隐层不用 σ , 则

$$\begin{aligned} \mathbf{H} &= \mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)}, \\ \mathbf{O} &= \mathbf{H}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}, \end{aligned}$$

复合后仍是仿射

$$\begin{aligned} \mathbf{O} &= (\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)})\mathbf{W}^{(2)} + \mathbf{b}^{(2)} \\ &= \mathbf{X}\mathbf{W}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(2)} \\ &= \mathbf{X}\mathbf{W} + \mathbf{b}. \end{aligned}$$

$\mathbf{O}$ 的每个分量仍只是输入的一次加权和, 与单层线性模型同类。插入逐元素 σ 后

$$\begin{aligned} \mathbf{H} &= \sigma(\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)}), \\ \mathbf{O} &= \mathbf{H}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}. \end{aligned}$$

H_{ij} 是样本 i 第 j 个隐藏单元的激活 (ReLU 时为被保留的非负响应); 此时一般不能再合并为单次仿射。非线性来自 σ , 不是来自把权重写成 e^w 。对 $\sigma = \text{ReLU}$, 若某隐单元 $z_j < 0$ 则 $h_j = 0$, 该路被关掉; 输入从 $\mathbf{x}$ 换成 $2\mathbf{x}$ 时, 被截断的路不必按比例恢复, 故一般 $f(2\mathbf{x}) \neq 2f(\mathbf{x})$ 。

4.1.1.4 通用近似定理

单隐层、宽度足够且 σ 非多项式时，MLP 可在紧集上一致逼近连续函数。可表示不等于可学习：定理只说存在某组权重使 $\hat{y}$ 任意接近目标 $f(\mathbf{x})$ ，不保证梯度下降能找到它们。更深的复合往往用更少的单元逼近同一类 f 。

4.1.2 激活函数

激活 $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ 是可微（或几乎处处可微）的逐元素非线性，作用在仿射输出上。输入是一个预激活实数，输出是该单元的激活值。

4.1.2.1 ReLU 函数

$$\text{ReLU}(x) = \max(x, 0).$$

$x > 0$ 时输出就是 x 本身（该激活被保留）； $x \leq 0$ 时输出 0（该激活被截断）。输出取值 $[0, +\infty)$ ，与预激活同量纲。其亚梯度在 $x \neq 0$ 为 $\mathbf{1}\{x > 0\}$ ：1 表示正半轴上“激活原样通过”，0 表示负半轴上梯度被挡住。带泄露参数 α 的变体

$$\text{pReLU}(x) = \max(0, x) + \alpha \min(0, x).$$

正半轴仍保留 x ；负半轴保留 αx （ α 通常较小），避免完全死掉。

4.1.2.2 sigmoid 函数

$$\text{sigmoid}(x) = \frac{1}{1 + \exp(-x)}.$$

把任意实数打分压到 $(0, 1)$ ：接近 1 表示该单元几乎饱和和开通，接近 0 表示几乎关闭。它是平滑门控，不是 ReLU 那种“保留或截断”。导数为

$$\begin{aligned} \frac{d}{dx} \text{sigmoid}(x) &= \frac{\exp(-x)}{(1 + \exp(-x))^2} \\ &= \text{sigmoid}(x)(1 - \text{sigmoid}(x)). \end{aligned}$$

该导数是 x 增加 1 时 sigmoid 输出大约增加多少，最大为 1/4； $|x|$ 大时趋于 0，表示饱和区里再改预激活几乎不改变门控值。

4.1.2.3 tanh 函数

$$\tanh(x) = \frac{1 - \exp(-2x)}{1 + \exp(-2x)}.$$

把实数打分压到 $(-1, 1)$ ：正值表示正向激活，负值表示反向激活，不是类概率。导数

$$\frac{d}{dx} \tanh(x) = 1 - \tanh^2(x)$$

是预激活增加 1 时 $\tanh$ 输出大约增加多少，在 0 处最大为 1。奇函数且值域 $(-1, 1)$ 。恒等式 $\tanh(x) + 1 = 2 \operatorname{sigmoid}(2x)$ 表示二者只差仿射变换，饱和时梯度同样变小。

4.1.3 小结

MLP 的定义是 $\mathbf{H} = \sigma(\mathbf{XW}^{(1)} + \mathbf{b}^{(1)})$ 再接线性输出；ReLU 的输出是被保留的非负激活；无 σ 则退回 $\mathbf{O} = \mathbf{XW} + \mathbf{b}$ 。

4.1.4 练习

核验 pReLU 的导数：正半轴为 1（保留），负半轴为 α （按比例保留）。仅用 ReLU 的网络输出是连续分段线性函数。再核验 $\tanh(x) + 1 = 2 \operatorname{sigmoid}(2x)$ 两边每个 x 是否同一实数。

4.2 多层感知机的从零开始实现

在 Fashion-MNIST 上实现单隐层 MLP：展平后 $784 \rightarrow 256 \rightarrow 10$ 。

4.2.1 初始化模型参数

$$\mathbf{W}^{(1)} \in \mathbb{R}^{784 \times 256}, \quad \mathbf{b}^{(1)} \in \mathbb{R}^{256}, \quad \mathbf{W}^{(2)} \in \mathbb{R}^{256 \times 10}, \quad \mathbf{b}^{(2)} \in \mathbb{R}^{10}.$$

$W_{jk}^{(1)}$ 是像素 j 对隐单元 k 预激活的权重； $W_{k\ell}^{(2)}$ 是隐激活 k 对类 ℓ 打分的权重。每层单独存储，以便 $\partial J / \partial \mathbf{W}^{(\ell)}$ 写回：该偏导的每个分量是对应权重增加 1 时损失大约增加多少。

4.2.2 激活函数

逐元素

$$\sigma(\mathbf{Z}) = \operatorname{ReLU}(\mathbf{Z}) = \max(\mathbf{Z}, \mathbf{0}).$$

$Z_{ij} > 0$ 的位置输出原值（保留的激活），其余为 0（被截断）。形状与 $\mathbf{Z}$ 相同。

4.2.3 模型

展平后

$$\begin{aligned} \mathbf{H} &= \text{ReLU}(\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)}), \\ \mathbf{O} &= \mathbf{H}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}. \end{aligned}$$

$\mathbf{H}$ 的条目是保留下来的隐藏激活； $\mathbf{O}$ 的第 i 行是样本 i 的十类打分，随后再变概率。

4.2.4 损失函数

对 $\mathbf{O}$ 用交叉熵（内含稳定 softmax）

$$L = \frac{1}{|\mathcal{B}|} \sum_i l(\mathbf{y}^{(i)}, \text{softmax}(\mathbf{o}^{(i)})).$$

$\text{softmax}(\mathbf{o}^{(i)})_k$ 是样本 i 属于类 k 的概率； l 是 $-\log$ 真类概率，单位 nats。 L 是本批平均惊讶，不是均方误差，也不是精度。

4.2.5 训练

与 softmax 回归同一循环，只是 f_{θ} 换成上面的两层映射；典型设置周期 10、 $\eta = 0.1$ 。周期数是遍历训练集的次数， η 缩放“损失对参数的敏感度”。

4.2.6 小结

从零实现把 MLP 写成两组 $(\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)})$ 与一次 ReLU（保留非负激活）；层数增多时参数命名与梯度缓冲会线性增加，每个梯度分量含义不变。

4.2.7 练习

核验隐藏宽度、层数与 η 对训练损失（平均 nats）和测试精度（判对比例）的联合影响，以及超参数积空间为何使网格搜索代价上升：要试的组合数是各超参数取值个数之积。

4.3 多层感知机的简洁实现

用顺序容器堆叠线性层与 ReLU，训练循环不变。

4.3.1 模型

$$\mathbf{X} \xrightarrow{\text{Linear}(784,256)} \text{ReLU} \xrightarrow{\text{Linear}(256,10)} \mathbf{O}.$$

第一线性层输出预激活，ReLU 留下非负激活，第二线性层给出十类打分。损失与优化器与 softmax 简洁实现相同：交叉熵仍是惊讶，梯度仍是损失变化率。

4.3.2 小结

简洁实现与 softmax 回归的差别只是中间多了 $\mathbf{H} = \text{ReLU}(\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)})$ ，即多了一层被保留的隐藏激活。

4.3.3 练习

核验隐层数、 σ 的选取以及 $\mathbf{W}$ 的初值分布对同一分类损失的影响：比较的是交叉熵（nats）与测试判对比例，不是点预测均方误差。

4.4 模型选择、欠拟合和过拟合




图 4.4.1 模型复杂度对欠拟合和过拟合的影响

符号：横轴：模型容量；纵轴：误差；训练/泛化两条曲线

目标是降低来自同一 P 的新样本上的风险，而不是只把训练集误差打到零。

4.4.1 训练误差和泛化误差

训练误差 R_{emp} 在 $\mathcal{D}_{\text{train}}$ 上计算，是有限样本的平均损失。泛化误差是

$$R(f) = \mathbb{E}_{(\mathbf{x}, y) \sim P} [\ell(f(\mathbf{x}), y)],$$

对未知 P 取期望，表示“新样本上典型损失有多大”，只能用独立测试集估计。回归时该损失是均方误差，分类时是交叉熵或 0-1 错误率。

4.4.1.1 统计学习理论

监督学习默认独立同分布： $\mathcal{D}_{\text{train}}$ 与测试样本均来自同一 P ，且样本间无记忆。在该条件下，经验风险以可控制的速率逼近 $R(f)$ ；函数类越丰富，逼近越慢。这里的“速率”描述 $R_{\text{emp}} - R$ 这个差距（仍是损失单位）随 n 缩小得有多快。

4.4.1.2 模型复杂性

参数多、取值范围大或需要更多更新步的模型更复杂。简单模型加大数据时 $R_{\text{emp}} \approx R$ ，两个误差都表示同一损失的大小；复杂模型加小样本时 R_{emp} 下降而 R 上升，表示只记住了训练集。

4.4.2 模型选择

在候选 $\mathcal{F}_1, \dots, \mathcal{F}_m$ （含超参数）中选一个，依据不能是测试集。

4.4.2.1 验证集

数据划分为训练、验证、测试。超参数只在验证集上比较；测试集保留给最终估计 R 。验证误差是验证样本上的平均损失或错误率，含义与测试误差相同，只是不能当作最终报告。反复使用验证集等于间接拟合验证分布。

4.4.2.2 K 折交叉验证

把训练集分成 K 个不交子集 $\mathcal{I}_1, \dots, \mathcal{I}_K$ 。第 k 折在 $\bigcup_{j \neq k} \mathcal{I}_j$ 上训练，在 $\mathcal{I}_k$ 上验证，再平均 K 次误差。每一次折误差是该折验证样本上的平均损失； K 次平均是对 R 的更稳估计。 K 是折数，正整数。

4.4.3 欠拟合还是过拟合？

训练与验证误差都高且接近，是欠拟合： $\mathcal{F}$ 不足以表示目标，两个数都表示“误差仍然大”。训练误差明显低于验证误差，是过拟合：容量相对 n 过大，训练误差不再代表新样本上的误差。

4.4.3.1 模型复杂性

多项式

$$\hat{y} = \sum_{i=0}^d x^i w_i$$

由各次幂加权求和得到， $\hat{y}$ 是与 y 同量纲的点预测。阶数 d 直接控制容量： d 过小欠拟合， d 过大过拟合。 d 是最高次数，不是损失。

4.4.3.2 数据集大小

n 越小越容易过拟合。固定 P 时，增大 n 通常降低 R ； n 是样本个数。数据足够才支撑更复杂的 $\mathcal{F}$ 。

4.4.4 多项式回归

用已知阶数的多项式生成数据，再比较不同 d 的拟合。

4.4.4.1 生成数据集

$$y = 5 + 1.2x - 3.4\frac{x^2}{2!} + 5.6\frac{x^3}{3!} + \epsilon, \quad \epsilon \sim \mathcal{N}(0, 0.1^2).$$

前四项给出无噪声的点真值， ϵ 是与 y 同量纲的加性噪声。特征常取 $x^i/i!$ 以平衡各阶尺度，除阶乘不改变“这是 x 的 i 次幂特征”的含义。

4.4.4.2 对模型进行训练和测试

在训练集上最小化平方损失，在测试集上估计 R 。训练 L 是均方误差（点预测的平均平方偏离）；测试 L 是同一误差在新样本上的估计。

4.4.4.3 三阶多项式函数拟合（正常）

取 $d = 3$ 与数据生成同阶。训练损失与测试损失同时下降，估计接近

$$\mathbf{w} \approx (5, 1.2, -3.4, 5.6).$$

每个 w_i 是对应幂次特征的权重：该特征增加 1 时点预测增加 w_i 。

4.4.4.4 线性函数拟合 (欠拟合)

$d = 1$ 只能表示仿射。非线性真值下训练损失停在高位，验证损失同样高：两个均方误差都大，表示点预测整体离真值远。

4.4.4.5 高阶多项式函数拟合 (过拟合)

d 过大时高阶系数缺乏约束，拟合噪声。训练均方误差可很低，测试均方误差仍高：说明 $\hat{y}$ 在训练点上很准，在新 x 上不是可靠的点预测。

4.4.5 小结

比较的是 R_{emp} 与验证估计的 R ：二者都是误差大小（回归为均方误差，分类可为交叉熵或错误率）。二者都高为欠拟合，差距大为过拟合。用验证集或 K 折选择 d 一类复杂度，而不是把训练损失当作泛化。

4.4.6 练习

核验多项式正规方程是否有闭式解、训练损失随 d 降到 0 所需阶数（能把 n 个点的均方误差打到接近 0 的最低 d ），以及去掉 $1/i!$ 缩放后各列条件数的变化：条件数大表示权重估计对数据扰动更敏感。

4.5 权重衰减

在不能增加 n 时，用参数范数惩罚降低有效容量。

4.5.1 范数与权重衰减

无惩罚的平方损失为

$$L(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n \frac{1}{2} (\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)})^2.$$

L 仍是均方误差，表示点预测的平均平方偏离。 L_2 正则目标

$$L(\mathbf{w}, b) + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

在原损失上加上一项： $\frac{\lambda}{2}\|\mathbf{w}\|^2 = \frac{\lambda}{2}\sum_j w_j^2$ 是为权重过大而额外付出的损失，不是数据拟合误差本身。 $\lambda \geq 0$ 越大，越惩罚大权重。对应高斯先验。梯度步把惩罚写成衰减

$$\mathbf{w} \leftarrow (1 - \eta\lambda)\mathbf{w} - \frac{\eta}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \mathbf{x}^{(i)} (\mathbf{w}^\top \mathbf{x}^{(i)} + b - y^{(i)}).$$

因子 $(1 - \eta\lambda)$ 先把每个权重按比例缩小，再减去数据梯度（数据梯度分量仍是：该权重增加 1 时均方误差大约增加多少）。 $\lambda = 0$ 退回普通 SGD； b 通常不惩罚，因为偏置不是“特征权重过大”。

4.5.2 高维线性回归

合成

$$y = 0.05 + \sum_{i=1}^d 0.01 x_i + \epsilon, \quad \epsilon \sim \mathcal{N}(0, 0.01^2),$$

0.05 是基线，0.01 是每个特征的真权重， ϵ 是噪声，三者与 y 同量纲。取 d 大于 n 时，无正则的最小二乘会过拟合：训练均方误差可很小，测试均方误差大。

4.5.3 从零开始实现

把 $\frac{\lambda}{2}\|\mathbf{w}\|_2^2$ 加进批量损失，再用原有线性模型与平方损失。前者是大权重的额外损失，后者是点预测误差。

4.5.3.1 初始化模型参数

与线性回归相同： $\mathbf{w}$ 小高斯， $b = 0$ 。初值接近 0 表示起步时权重尚未变大。

4.5.3.2 定义 L_2 范数惩罚

$$\frac{\lambda}{2}\|\mathbf{w}\|_2^2 = \frac{\lambda}{2}\sum_j w_j^2.$$

每个 w_j^2 是该权重大小的平方，求和再乘 $\lambda/2$ 得到额外损失：权重越远离 0，这项越大。

4.5.3.3 定义训练代码实现

批量目标

$$\frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \frac{1}{2} (\hat{y}^{(i)} - y^{(i)})^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2,$$

第一项是本批均方误差，第二项是大权重的额外损失。梯度同时含数据项与 $\lambda\mathbf{w}$ ： λw_j 就是惩罚项对 w_j 的敏感度。

4.5.3.4 忽略正则化直接训练

$\lambda = 0$ 时训练误差下降、测试误差不降，对应过拟合：没有为过大权重付出额外损失。

4.5.3.5 使用权重衰减

$\lambda > 0$ 时训练误差上升、测试误差下降，有效范数 $\|\mathbf{w}\|$ 被压小。 $\|\mathbf{w}\|$ 是权重向量的欧氏长度，表示参数整体有多大；被压小意味着模型更平滑。

4.5.4 简洁实现

优化器在每步对选定参数做

$$\mathbf{w} \leftarrow (1 - \eta\lambda)\mathbf{w} - \eta\nabla_{\mathbf{w}}L_{\mathcal{B}},$$

可只衰减 $\mathbf{w}$ 而不衰减 b 。与把惩罚写入损失在一阶上等价：都是在拟合误差之外，为权重过大再加一项损失并沿其梯度缩小权重。

4.5.5 小结

权重衰减把目标写成 $L + \frac{\lambda}{2}\|\mathbf{w}\|^2$ ：前一项是数据上的误差，后一项是大权重的额外损失；更新中出现因子 $(1 - \eta\lambda)$ 。

4.5.6 练习

核验测试误差随 λ 的曲线： λ 过小过拟合，过大则欠拟合（额外损失压过了拟合项）。把惩罚改成 $\sum_j |w_j|$ 后是 L_1 ，近端更新会把小权重推到恰好 0。 $\|\mathbf{w}\|_2^2 = \mathbf{w}^\top \mathbf{w}$ 在矩阵参数上对应 Frobenius 式 $\|\mathbf{W}\|_F^2$ ，仍是“所有权重大小的平方和”，作为额外损失。

4.6 暂退法 (Dropout)




图 4.6.1 dropout 前后的多层感知机

符号：实心：保留单元；虚线/空心：按概率丢弃的单元

暂退法在训练时随机将隐藏活性置零并重标定，降低对单一隐藏单元的依赖。

4.6.1 重新审视过拟合

线性模型偏差高、方差低；深度网可表示特征交互，方差高。特征多而 n 小时过拟合更严重。暂退法在不删特征的前提下注入噪声。

4.6.2 扰动的稳健性

对活性 h ，以丢弃概率 p 定义

$$h' = \begin{cases} 0, & \text{概率为 } p, \\ \frac{h}{1-p}, & \text{其他情况.} \end{cases}$$

掩码为 0 表示该激活被丢弃（输出 0）；掩码为 1 表示被保留，并除以 $1-p$ 以保持期望。于是 $\mathbb{E}[h'] = h$ ：平均看来激活大小不变。测试时不用暂退，直接用 h 。

4.6.3 实践中的暂退法

暂退作用在激活之后。被置零的单元前向为 0（丢弃），反向梯度亦为 0（这条路不传敏感度）。靠近输入的层常用较小的 p 。推断默认 $p = 0$ ，即全部激活都被保留。

4.6.4 从零开始实现

掩码 $M_j \sim \text{Bernoulli}(1 - p)$,

$$h'_j = \frac{M_j}{1 - p} h_j.$$

$M_j \in \{0, 1\}$: 0 表示丢弃该隐藏激活, 1 表示保留。 $p = 0$ 为恒等 (全部保留), $p = 1$ 输出全零 (全部丢弃)。

4.6.4.1 定义模型参数

两隐层 MLP, $784 \rightarrow 256 \rightarrow 256 \rightarrow 10$, 各层 $(\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)})$ 。权重含义与普通 MLP 相同: 连接两端激活的线性系数。

4.6.4.2 定义模型

训练时

$$\begin{aligned}\mathbf{H}_1 &= \text{dropout}_{p_1}(\text{ReLU}(\mathbf{X}\mathbf{W}^{(1)} + \mathbf{b}^{(1)})), \\ \mathbf{H}_2 &= \text{dropout}_{p_2}(\text{ReLU}(\mathbf{H}_1\mathbf{W}^{(2)} + \mathbf{b}^{(2)})), \\ \mathbf{O} &= \mathbf{H}_2\mathbf{W}^{(3)} + \mathbf{b}^{(3)},\end{aligned}$$

ReLU 先给出保留的非负激活, dropout 再按掩码把一部分置 0 (丢弃)、其余放大 (保留)。常见 $p_1 = 0.2$ 、 $p_2 = 0.5$; 评估时两处暂退关闭, 掩码全为 1。

4.6.4.3 训练和测试

训练循环与普通 MLP 相同; 测试前向是无掩码的确定性映射, 每个激活都被保留。损失仍是交叉熵 (nats), 精度仍是判对比例。

4.6.5 简洁实现

在每个全连接与激活之后插入暂退层, 训练随机丢弃 (掩码 0) 或保留 (掩码 1), 测试恒等通过。

4.6.6 小结

暂退把 h 换成期望仍为 h 的 h' : 掩码 0/1 表示丢弃/保留; 只在训练使用。它与范数惩罚从不同方向限制共适应: 一个随机丢掉激活, 一个为过大权重加额外损失。

4.6.7 练习

核验交换两层 p 对 $\text{Var}(\mathbf{H}_\ell)$ 的影响：方差描述该层激活起伏有多大。测试期保持暂退会改变 $\mathbb{E}[\hat{y}]$ ，因为随机丢弃使类概率的平均不再等于无掩码前向。同时使用 $\lambda\|\mathbf{w}\|^2$ 与暂退时，验证误差（平均损失或错误率）是否可加。

4.7 前向传播、反向传播和计算图




图 4.7.1 前向传播的计算图

符号： x ：输入； y ：输出； L ：损失；箭头：前向计算图

以带 L_2 的单隐层 MLP 为例，把梯度写成计算图上的反向复合。

4.7.1 前向传播

省略偏置后

$$\begin{aligned}
 \mathbf{z} &= \mathbf{W}^{(1)}\mathbf{x}, \\
 \mathbf{h} &= \phi(\mathbf{z}), \\
 \mathbf{o} &= \mathbf{W}^{(2)}\mathbf{h}, \\
 L &= l(\mathbf{o}, y), \\
 s &= \frac{\lambda}{2} (\|\mathbf{W}^{(1)}\|_F^2 + \|\mathbf{W}^{(2)}\|_F^2), \\
 J &= L + s.
 \end{aligned}$$

$\mathbf{z}$ 是隐层预激活， $\mathbf{h} = \phi(\mathbf{z})$ 是激活（ReLU 时为被保留的非负响应）， $\mathbf{o}$ 是输出打分， L 是数据损失（回归为均方误差，分类为交叉熵 nats）， s 是大权重的额外损失， J 是二者之和，训练真正最小化的标量。前向按依赖顺序计算并缓存 $\mathbf{z}, \mathbf{h}, \mathbf{o}, L, s, J$ 。

4.7.2 前向传播计算图

结点是变量与算子。数据从 $\mathbf{x}$ 流向 J : $\mathbf{x}, \mathbf{W}^{(1)} \rightarrow \mathbf{z} \rightarrow \mathbf{h}$, 再与 $\mathbf{W}^{(2)}$ 得 $\mathbf{o}$, $(\mathbf{o}, y)$ 得 L , $(\mathbf{W}^{(1)}, \mathbf{W}^{(2)})$ 得 s , 最后 $J = L + s$ 。图上每个结点的值就是上一小节对应的那个数。

4.7.3 反向传播

张量复合用

$$\frac{\partial Z}{\partial X} = \text{prod}\left(\frac{\partial Z}{\partial Y}, \frac{\partial Y}{\partial X}\right).$$

prod 按维把下游敏感度与局部导数乘起来：得到的是 X 增加时 Z 大约增加多少。目标对两分支

$$\frac{\partial J}{\partial L} = 1, \quad \frac{\partial J}{\partial s} = 1.$$

二者都是 1，表示 J 对数据损失与权重惩罚同等相加，各增加 1 则 J 增加 1。对输出

$$\frac{\partial J}{\partial \mathbf{o}} = \text{prod}\left(\frac{\partial J}{\partial L}, \frac{\partial L}{\partial \mathbf{o}}\right) = \frac{\partial L}{\partial \mathbf{o}} \in \mathbb{R}^q.$$

第 k 个分量是打分 o_k 增加 1 时 J 大约增加多少。正则项

$$\frac{\partial s}{\partial \mathbf{W}^{(1)}} = \lambda \mathbf{W}^{(1)}, \quad \frac{\partial s}{\partial \mathbf{W}^{(2)}} = \lambda \mathbf{W}^{(2)}.$$

每个条目是：该权重增加 1 时，大权重额外损失大约增加 λ 倍的当前权重。第二层权重

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{W}^{(2)}} &= \text{prod}\left(\frac{\partial J}{\partial \mathbf{o}}, \frac{\partial \mathbf{o}}{\partial \mathbf{W}^{(2)}}\right) + \text{prod}\left(\frac{\partial J}{\partial s}, \frac{\partial s}{\partial \mathbf{W}^{(2)}}\right) \\ &= \frac{\partial J}{\partial \mathbf{o}} \mathbf{h}^\top + \lambda \mathbf{W}^{(2)}. \end{aligned}$$

第一项是数据路径上的梯度，第二项来自额外损失；和的每个分量仍是“该权重增加 1 时 J 大约增加多少”。隐层

$$\frac{\partial J}{\partial \mathbf{h}} = \text{prod}\left(\frac{\partial J}{\partial \mathbf{o}}, \frac{\partial \mathbf{o}}{\partial \mathbf{h}}\right) = \mathbf{W}^{(2)\top} \frac{\partial J}{\partial \mathbf{o}}.$$

第 j 个分量是隐藏激活 h_j 增加 1 时 J 大约增加多少。预激活

$$\frac{\partial J}{\partial \mathbf{z}} = \text{prod}\left(\frac{\partial J}{\partial \mathbf{h}}, \frac{\partial \mathbf{h}}{\partial \mathbf{z}}\right) = \frac{\partial J}{\partial \mathbf{h}} \odot \phi'(\mathbf{z}).$$

Hadamard 积把激活导数乘上去：ReLU 在被截断处 $\phi' = 0$ ，故那些位置的敏感度为 0。第一层权重

$$\begin{aligned} \frac{\partial J}{\partial \mathbf{W}^{(1)}} &= \text{prod}\left(\frac{\partial J}{\partial \mathbf{z}}, \frac{\partial \mathbf{z}}{\partial \mathbf{W}^{(1)}}\right) + \text{prod}\left(\frac{\partial J}{\partial s}, \frac{\partial s}{\partial \mathbf{W}^{(1)}}\right) \\ &= \frac{\partial J}{\partial \mathbf{z}} \mathbf{x}^\top + \lambda \mathbf{W}^{(1)}. \end{aligned}$$

同样是数据项加额外损失项，每个条目是损失对该权重的变化率。

4.7.4 训练神经网络

每步先前向缓存中间量，再反向用这些值组梯度，最后

$$\mathbf{W}^{(\ell)} \leftarrow \mathbf{W}^{(\ell)} - \eta \frac{\partial J}{\partial \mathbf{W}^{(\ell)}}.$$

减去的是“权重增加 1 时 J 的变化率”乘步长，目的是减小 $J = L + s$ 。反向依赖前向的 $\mathbf{h}, \mathbf{z}$ ；下一次前向又依赖更新后的 $\mathbf{W}$ 。训练需保存中间激活，内存大于纯预测。

4.7.5 小结

前向按图计算 $J = L + s$ （数据误差加大权重额外损失），反向按 $\partial J / \partial \mathbf{W}^{(2)} = \frac{\partial J}{\partial \mathbf{o}} \mathbf{h}^\top + \lambda \mathbf{W}^{(2)}$ 与 $\partial J / \partial \mathbf{W}^{(1)} = \frac{\partial J}{\partial \mathbf{z}} \mathbf{x}^\top + \lambda \mathbf{W}^{(1)}$ 写回参数梯度：每个分量都是对应参数增加 1 时总损失大约增加多少。

4.7.6 练习

核验 $f(\mathbf{X})$ 对 $\mathbf{X} \in \mathbb{R}^{n \times m}$ 的梯度形状必须与 $\mathbf{X}$ 相同，每个条目是该输入增加 1 时标量目标大约增加多少。给隐层加 $\mathbf{b}$ 后多一条 $\partial J / \partial \mathbf{b}$ ，含义同权重梯度。二阶导数如何加厚计算图：每个海森条目是一阶敏感度再对另一参数求导。

4.8 数值稳定性和模型初始化

深度复合中每层的尺度进入梯度乘积。初始化决定起步时梯度是否可用，并打破隐藏单元对称。

4.8.1 梯度消失和梯度爆炸

L 层网络

$$\mathbf{h}^{(l)} = f_l(\mathbf{h}^{(l-1)}), \quad \mathbf{o} = f_L \circ \dots \circ f_1(\mathbf{x}).$$

$\mathbf{h}^{(l)}$ 是第 l 层算出的激活， $\mathbf{o}$ 是最终输出（打分或点预测）。对第 l 层权重

$$\partial_{\mathbf{W}^{(l)}} \mathbf{o} = \underbrace{\partial_{\mathbf{h}^{(L-1)}} \mathbf{h}^{(L)}}_{\mathbf{M}^{(L)}} \dots \underbrace{\partial_{\mathbf{h}^{(l)}} \mathbf{h}^{(l+1)}}_{\mathbf{M}^{(l+1)}} \underbrace{\partial_{\mathbf{W}^{(l)}} \mathbf{h}^{(l)}}_{\mathbf{v}^{(l)}}.$$

每个 $\mathbf{M}$ 是一层对上一层激活的局部敏感度。各 $\mathbf{M}$ 的奇异值大于 1 则爆炸，小于 1 则消失：连乘后得到的数不再是可用的“损失变化率”，而是数值上的 0 或溢出。

4.8.1.1 梯度消失

sigmoid 的导数最大为 $1/4$ ，且 $|x|$ 大时接近 0。多层连乘后 $\partial J / \partial \mathbf{W}^{(1)}$ 可数值为零：看起来像“改第一层权重几乎不改变损失”，其实是饱和造成的。ReLU 在正半轴导数为 1（保留的激活原样传梯度），减轻该问题。

4.8.1.2 梯度爆炸

若每层 Jacobian 的尺度约 1 但略大，或初始化方差过大，则 $\prod_{\ell} \mathbf{M}^{(\ell)}$ 指数增长，一步更新即可使参数溢出。此时梯度分量不再是可信的损失变化率，而是被放大到无意义的大数。

4.8.1.3 打破对称性

隐单元置换不改变可表示函数。若 $\mathbf{W}^{(1)}$ 各行相同，则各隐单元激活相同、梯度相同，对称无法被梯度打破。随机独立初始化使各单元轨迹分离：起步时各权重是不同的随机数，不是同一个值。

4.8.2 参数初始化

用适当方差的随机初始化控制前向与反向的尺度。

4.8.2.1 默认初始化

不指定时框架用小方差随机分布；中等深度往往可用，但不能保证任意深度。这些初值仍是权重，只是幅度被限制，以免一开始激活或梯度过大。

4.8.2.2 Xavier 初始化

一层

$$o_i = \sum_{j=1}^{n_{\text{in}}} w_{ij} x_j.$$

o_i 是第 i 个输出打分（或预激活），由输入加权求和得到。设 $E[w_{ij}] = E[x_j] = 0$ 且独立， $E[x_j^2] = \gamma^2$ ， $E[w_{ij}^2] = \sigma^2$ ，则

$$\begin{aligned} E[o_i] &= \sum_{j=1}^{n_{\text{in}}} E[w_{ij}] E[x_j] = 0, \\ \text{Var}[o_i] &= E[o_i^2] - (E[o_i])^2 \end{aligned}$$

$$\begin{aligned}
&= \sum_{j=1}^{n_{\text{in}}} E[w_{ij}^2] E[x_j^2] \\
&= n_{\text{in}} \sigma^2 \gamma^2.
\end{aligned}$$

$E[o_i]$ 是输出的平均水平; $\text{Var}[o_i]$ 是输出起伏有多大, 与 o_i 量纲的平方相同。希望 $\text{Var}[o_i]$ 不随 n_{in} 爆炸, 同时反向不随 n_{out} 爆炸, 折中

$$\begin{aligned}
\frac{1}{2}(n_{\text{in}} + n_{\text{out}})\sigma^2 &= 1, \\
\sigma &= \sqrt{\frac{2}{n_{\text{in}} + n_{\text{out}}}}.
\end{aligned}$$

σ 是每个权重的标准差: 权重作为随机数时典型绝对值有多大。对应均匀分布

$$U\left(-\sqrt{\frac{6}{n_{\text{in}} + n_{\text{out}}}}, \sqrt{\frac{6}{n_{\text{in}} + n_{\text{out}}}}\right).$$

采样得到的每个 w_{ij} 仍是权重, 只是范围按输入输出维数缩放, 以便激活方差接近常数。

4.8.2.3 额外阅读

Xavier 只覆盖独立、零均值、方差匹配的情形。共享参数、残差或序列模型需要各自的尺度启发式。那些启发式同样是在规定“权重作为随机数时应有多大”, 以便梯度仍表示可信的损失变化率。

4.8.3 小结

梯度是一层层局部敏感度 $\mathbf{M}^{(\ell)}$ 的乘积。Xavier 取 $\sigma = \sqrt{2/(n_{\text{in}} + n_{\text{out}})}$, 使输出方差与梯度方差同时可控; 随机初始化用来打破对称。

4.8.4 练习

核验线性或 softmax 回归把全部 w_{ij} 设成同一常数是否仍能学: 对称时各隐单元 (若有) 梯度相同, 无法分化。矩阵乘积特征值界对 $\prod \mathbf{M}^{(\ell)}$ 尺度的含义: 特征值大于 1 则敏感度连乘爆炸。

4.9 环境和分布偏移



图 4.9.1 区分猫和狗的训练数据

符号：见图中标注；各块含义见题注。




图 4.9.2 区分猫和狗的测试数据

符号：见图中标注；各块含义见题注。




图 4.9.3 美国软饮名称的概念偏移

符号：见图中标注；各块含义见题注。

部署时样本来自 p_T ，训练来自 p_S 。二者不同则经验风险最小解不必在测试上最优。

4.9.1 分布偏移的类型

无结构假设时， $p_S(\mathbf{x}) = p_T(\mathbf{x})$ 仍可有 $p_S(y | \mathbf{x}) = 1 - p_T(y | \mathbf{x})$ ，不可学。 $p(y | \mathbf{x})$ 是条件概率，在 $[0, 1]$ 。因此要对 $p(y | \mathbf{x})$ 或 $p(\mathbf{x} | y)$ 施加不变性。

4.9.1.1 协变量偏移

假设条件标签不变、特征边缘变：

$$p(y | \mathbf{x}) = q(y | \mathbf{x}), \quad p(\mathbf{x}) \neq q(\mathbf{x}).$$

左边两个条件概率相等，表示同一 $\mathbf{x}$ 下标签的可能性不变；右边两个密度不同，表示特征出现的频率变了。在认为 $\mathbf{x}$ 导致 y 时自然成立。

4.9.1.2 标签偏移

假设类条件特征不变、标签边缘变：

$$p(\mathbf{x} | y) = q(\mathbf{x} | y), \quad p(y) \neq q(y).$$

$p(y)$ 是类的先验比例，在 $[0, 1]$ 且各类和为 1；源与目标的先验可以不同。在认为 y 导致 $\mathbf{x}$ （如疾病导致症状）时自然成立。

4.9.1.3 概念偏移

$p(y | \mathbf{x})$ 本身随时间或地点改变，即同一 $\mathbf{x}$ 对应的标签定义漂移：同一个特征向量现在对应的“正确 y ”已经不是训练时的那个含义。

4.9.2 分布偏移示例

下列情形中 p_S 与 p_T 的差异往往被精度数字掩盖。精度仍是判对比例，但不能代表目标分布上的同一比例。

4.9.2.1 医学诊断

用医院患者与校园献血者构造对照，则 $p(\mathbf{x})$ 混入年龄等与疾病无关的差异，即使 $p(y | \mathbf{x})$ 在目标人群中不同，训练集精度也不能迁移：那个 $\text{acc} \in [0, 1]$ 只描述源分布上的判对比例。

4.9.2.2 自动驾驶汽车

合成渲染的路沿纹理恒定，检测器学到该伪特征。真实图像的 $p(\mathbf{x})$ 不含这一捷径，部署失败。检测分数或框的 IoU 在源域上的数值，不再表示目标域上的同一质量。

4.9.2.3 非平稳分布

P 缓变而模型不更新：广告中的新设备、垃圾邮件的新模板、节后过时的推荐，都属于 $p_T \neq p_S$ 。原有 $\hat{y}$ 仍按旧分布给出点预测或类概率，但这些数对当前总体不再校准。

4.9.2.4 更多轶事

训练缺特写人脸、英美查询词分布不同、类别在网上均匀而现实长尾，都使经验风险偏离真实风险。经验风险是源样本平均损失，真实风险是目标 P 上的期望损失，二者不是同一个数。

4.9.3 分布偏移纠正

在可检验的不变性下，用重要性权重改写风险积分。

4.9.3.1 经验风险与实际风险

经验风险最小化

$$\underset{f}{\text{minimize}} \quad \frac{1}{n} \sum_{i=1}^n l(f(\mathbf{x}_i), y_i)$$

把 n 条样本损失取平均，得到源分布上的平均误差。它逼近真实风险

$$\mathbb{E}_{p(\mathbf{x}, y)}[l(f(\mathbf{x}), y)] = \iint l(f(\mathbf{x}), y) p(\mathbf{x}, y) d\mathbf{x} dy$$

仅当样本来自同一个 p ；右边是对密度加权后的平均损失，与单条 l 同量纲。

4.9.3.2 协变量偏移纠正

$p(y | \mathbf{x}) = q(y | \mathbf{x})$ 时

$$\begin{aligned} & \iint l(f(\mathbf{x}), y) p(y | \mathbf{x}) p(\mathbf{x}) d\mathbf{x} dy \\ &= \iint l(f(\mathbf{x}), y) q(y | \mathbf{x}) q(\mathbf{x}) \frac{p(\mathbf{x})}{q(\mathbf{x})} d\mathbf{x} dy. \end{aligned}$$

样本权重

$$\beta_i \stackrel{\text{def}}{=} \frac{p(\mathbf{x}_i)}{q(\mathbf{x}_i)}$$

是两个密度之比，非负：大于 1 表示该 $\mathbf{x}$ 在目标域相对更常见，应在平均损失里占更大份。给出加权经验风险

$$\underset{f}{\text{minimize}} \quad \frac{1}{n} \sum_{i=1}^n \beta_i l(f(\mathbf{x}_i), y_i).$$

每条损失仍是原来的误差或惊讶，只是按 β_i 重新加权。用分类器区分源/目标域，

$$P(z = 1 | \mathbf{x}) = \frac{p(\mathbf{x})}{p(\mathbf{x}) + q(\mathbf{x})}, \quad \frac{P(z = 1 | \mathbf{x})}{P(z = -1 | \mathbf{x})} = \frac{p(\mathbf{x})}{q(\mathbf{x})}.$$

$P(z = 1 | \mathbf{x}) \in [0, 1]$ 是“该样本来自目标域”的概率。若 $h(\mathbf{x})$ 为对数几率，则

$$\begin{aligned} \beta_i &= \frac{1/(1 + \exp(-h(\mathbf{x}_i)))}{\exp(-h(\mathbf{x}_i))/(1 + \exp(-h(\mathbf{x}_i)))} \\ &= \exp(h(\mathbf{x}_i)). \end{aligned}$$

$h(\mathbf{x})$ 是未归一化对数几率， $\exp(h)$ 还原成密度比 β_i 。

4.9.3.3 标签偏移纠正

$p(\mathbf{x} | y) = q(\mathbf{x} | y)$ 时

$$\iint l(f(\mathbf{x}), y) p(\mathbf{x} | y) p(y) d\mathbf{x} dy$$

$$= \iint l(f(\mathbf{x}), y) q(\mathbf{x} | y) q(y) \frac{p(y)}{q(y)} d\mathbf{x} dy,$$

权重

$$\beta_i \stackrel{\text{def}}{=} \frac{p(y_i)}{q(y_i)}$$

是两类先验之比：目标域更常见的类，其样本在平均损失中权重更大。混淆关系

$$\mathbf{C} p(\mathbf{y}) = \mu(\hat{\mathbf{y}})$$

用源域混淆矩阵 $\mathbf{C}$ 与目标域预测边缘 $\mu(\hat{\mathbf{y}})$ 反解 $p(\mathbf{y})$ 。 C_{kj} 是真类为 j 时预测为 k 的比例，在 $[0, 1]$ ； μ 是目标域上各类被预测到的频率。

4.9.3.4 概念偏移纠正

$p(y | \mathbf{x})$ 改变时重要性加权不再成立，需新标签。缓慢漂移可用新数据继续更新已有 θ ：更新所用的梯度仍是新损失对参数的变化率。

4.9.4 学习问题的分类法

按数据何时到达、环境是否记得行动，把学习写成不同的信息约束。

4.9.4.1 批量学习

一次给定 $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ，学得 f 后在同一 P 上部署，不再更新。 n 条样本上的平均损失在部署后不再重新计算。

4.9.4.2 在线学习

$$f_t \longrightarrow \mathbf{x}_t \longrightarrow f_t(\mathbf{x}_t) \longrightarrow y_t \longrightarrow l(y_t, f_t(\mathbf{x}_t)) \longrightarrow f_{t+1}.$$

每步先给出预测 $f_t(\mathbf{x}_t)$ ，再看到 y_t ，算出这一步的损失（误差或惊讶），然后更新。 l 是标量，含义与批量中的单样本损失相同。

4.9.4.3 老虎机

行动集有限，每步选一只臂并观测损失。该损失是拉臂后看到的标量代价（或负奖励），比连续参数化的 f 有更强的后悔界。后悔是相对最优臂多付的累计损失。

4.9.4.4 控制

环境状态依赖历史行动，例如锅炉温度依赖是否加热。策略必须考虑动力学，而不只是 i.i.d. 样本。状态变量（如温度）与奖励/损失仍是有量纲的测量值。

4.9.4.5 强化学习

在可记忆、甚至对抗的环境中选行动以最大化期望回报。回报是折扣奖励之和，与单步奖励同量纲；监督批学习是其无交互特例。

4.9.4.6 考虑到环境

若行动改变未来的 P ，静止环境上的最优 f 部署后可能失效。变化慢可限制参数步长 η （每步少改一点）；变化稀但剧烈则需检测后再适应。

4.9.5 机器学习中的公平、责任和透明度

部署把 $\hat{y}$ 变成影响人的决策。精度不是唯一风险：不同子群上 $p(y | \mathbf{x})$ 不同、各类错误代价不对称时，应用代价敏感的损失而不是单纯 acc。acc 只是全体样本上的判对比例，不区分哪一类错误更贵。

4.9.6 小结

真实风险是 $\mathbb{E}_p[l]$ ，经验风险是其样本平均，二者都是损失大小。协变量偏移用 $\beta_i = p(\mathbf{x}_i)/q(\mathbf{x}_i)$ （密度比）纠偏，标签偏移用 $\beta_i = p(y_i)/q(y_i)$ （先验比）；概念偏移则要求更新标签定义。

4.9.7 练习

核验用域分类器估计 β_i 是否恢复 $p(\mathbf{x})/q(\mathbf{x})$ ： β_i 应是非负密度比。以及除分布偏移外还有哪些因素使 R_{emp} 偏离 R （有限样本、过拟合、标签噪声）。

4.10 实战 Kaggle 比赛：预测房价

把前面的预处理、线性或 MLP、权重衰减与 K 折选择用到带缺失的表格回归。

4.10.1 下载和缓存数据集

名称映到 (url, sha1)。本地缓存命中且校验一致则不再下载。校验和是文件指纹，用来确认磁盘上的字节就是预期的那一份，不是房价数值。

4.10.2 Kaggle

比赛提供训练表（含房价）与测试表（无房价）。提交的是测试集上的 $\hat{y}$ 向量：每个分量是一座房屋的点预测房价，与美元（或对数价格）同量纲，不是概率。

4.10.3 访问和读取数据集

每行一座房屋，特征含数值与类别，缺失记为 NA。NA 表示该位置没有观测，不是数值 0。价格 y 只在训练集出现，是要拟合的目标。划分训练集得到验证折；官方测试误差只在提交后可见。

4.10.4 数据预处理

数值列标准化

$$x \leftarrow \frac{x - \mu}{\sigma},$$

μ 是列均值（该属性的典型水平）， σ 是列标准差（起伏有多大）；标准化后的 x 无量纲，表示“偏离均值多少个标准差”。缺失用列均值填充：缺口处的数是典型水平，不是观测。类别列独热：1 表示属于该类，0 表示不属于。训练集与测试集的编码与 μ, σ 必须同源统计量。

4.10.5 训练

比赛指标是对数均方根误差

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (\log y_i - \log \hat{y}_i)^2},$$

先对价格取对数（相对尺度），再算均方误差的平方根。得到的是典型相对误差大小，不是绝对美元误差，也不是概率。模型可以是线性层（点预测）或带权重衰减的 MLP（隐藏激活再映射到价格）。

4.10.6 K 折交叉验证

第 i 折取切片 $\mathcal{I}_i$ 为验证、其余为训练。 K 次后报告平均训练误差与平均验证误差。这两个数都是对数 RMSE，表示相对预测误差的典型大小。

4.10.7 模型选择

在折平均验证误差上选层宽、 λ 、暂退 p 与 η 。训练误差远低于折验证误差表示过拟合：训练对数 RMSE 不再代表新房屋上的相对误差。 λ 控制大权重的额外损失， p 是丢弃激活的概率。

4.10.8 提交 Kaggle 预测

用选定超参数在全部训练样本上重拟合，再映射测试特征到 $\hat{y}$ ，写成提交表。表中每一项仍是点预测房价。

4.10.9 小结

表格映射是：标准化与独热得到 $\mathbf{X}$ （特征），用 $\log$ RMSE 训练（相对误差），用 K 折选超参数后再全量拟合。 $\hat{y}$ 始终是与价格相关的点预测，不是类概率。

4.10.10 练习

核验直接优化 $\log y$ 与优化 y 再取对数的差别：前者把损失定义在对数价格上。均值填充在非随机缺失下的偏差：填进去的是列均值，不是真实未观测房价。不标准化连续列时梯度尺度：取值大的列会使对应权重的“损失变化率”被放大。

第五章 深度学习计算

层把输入映成输出并携带参数；块把层或块再复合。训练需要访问、初始化与共享这些参数，必要时延后到首次前向才确定形状。自定义层给出新的映射，读写把参数与张量固化到存储，计算设备决定张量所在的空间。

5.1 层和块




图 5.1.1 多个层被组合成块，形成更大的模型

符号：层：基本运算；块：层的组合；模型：块的堆叠

单输出线性模型是映射 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ ，带参数 θ 。一层接受向量、产生向量、并由可训练参数描述；整个多层感知机仍是同一类对象。块（block）是可嵌套的计算单元：输入进前向映射，输出可改形状，梯度由反向传播给出。

5.1.1 自定义块

块必须实现前向 $f(x)$ ，并持有参数以便求导与初始化。以单隐层感知机为例，设 $x \in \mathbb{R}^{20}$,

$$\begin{aligned} h &= \text{ReLU}(\mathbf{W}_1 x + \mathbf{b}_1), & \mathbf{W}_1 &\in \mathbb{R}^{256 \times 20}, \\ o &= \mathbf{W}_2 h + \mathbf{b}_2, & \mathbf{W}_2 &\in \mathbb{R}^{10 \times 256}. \end{aligned}$$

输入 $\mathbf{x}$ 先被映成 256 维隐向量 $\mathbf{h}$ ，再映成 10 维输出 $\mathbf{o}$ 。 $\mathbf{h}$ 的每个分量是该隐单元对输入的非线性响应（负半轴被截成 0）； $\mathbf{o}$ 的每个分量是一类的未归一化打分，与标签同索引，不是概率。复合 $f = \ell_2 \circ \text{ReLU} \circ \ell_1$ 允许 $f(\mathbf{x}) \in \mathbb{R}^{10}$ 与 $\mathbf{x} \in \mathbb{R}^{20}$ 形状不同。反向传播给出的 $\nabla_{\mathbf{w}_1} L$ 、 $\nabla_{\mathbf{w}_2} L$ 、 $\nabla_{\mathbf{x}} L$ 中，每个条目是对应参数或输入增大时标量损失大约增加多少。并非所有块都是纯顺序复合：残差块在前向里做 $\mathbf{Y} \leftarrow F(\mathbf{X}) + \mathbf{X}$ ，稠密块做通道维连结 $\mathbf{X} \leftarrow [\mathbf{X}, F(\mathbf{X})]$ 。二者都必须写在自定义前向中；Seq 不会自动相加或拼接。相加要求形状相同，连结只增加通道个数。

5.1.2 顺序块

顺序复合定义为

$$(\text{Seq}(f_1, \dots, f_n))(\mathbf{x}) = f_n \circ f_{n-1} \circ \dots \circ f_1(\mathbf{x}).$$

左边是把 n 个子映射串成一条管道后的总映射：输入先进 f_1 ，其输出再进 f_2 ，直到 f_n 。得到的仍是最后一个子块的输出张量，形状由 f_n 决定，含义由最后一层给出（打分、特征图等）。追加操作把 f_{n+1} 接到链条末端。参数集是各子块参数的不交并

$$\text{params}(\text{Seq}(f_1, \dots, f_n)) = \bigsqcup_{i=1}^n \text{params}(f_i),$$

右边收集到的是全部可训练张量的集合，不是把参数数值相加。每个 f_i 必须登记为子模块，而不能只放入普通列表，否则这些张量不会出现在优化器看到的 θ 里。

5.1.3 在前向传播函数中执行代码

并非所有架构都是 $f_n \circ \dots \circ f_1$ 。前向中可插入控制流或与参数无关的常数。设 c 为常数参数（constant parameter），层

$$f(\mathbf{x}, \mathbf{w}) = c \cdot \mathbf{w}^\top \mathbf{x}$$

算出的是一个标量：先把 $\mathbf{x}$ 用 $\mathbf{w}$ 做线性打分，再乘固定系数 c 。该标量与 $\mathbf{w}^\top \mathbf{x}$ 同量纲，只是被 c 缩放； c 不进入 $\text{params}(f)$ ，因此梯度不更新 c 。亦允许按范数分支，例如

$$\mathbf{h} \leftarrow \begin{cases} \mathbf{h}/\|\mathbf{h}\|_2, & \|\mathbf{h}\|_2 > 1, \\ \mathbf{h}, & \text{otherwise,} \end{cases}$$

再进入后续线性层。 $\|\mathbf{h}\|_2$ 是隐向量的欧氏长度（非负标量）；大于 1 时把 $\mathbf{h}$ 缩到单位球面，每个分量变成方向余弦，不再保留原来的幅度。只要这些运算可微或次可微，反向传播仍给出 $\nabla_{\theta} L$ ，其含义仍是损失对参数的敏感度。

5.1.4 效率

前向若含大量宿主解释与字典查找，加速器上的核必须等待。总时间可写成

$$T = T_{\text{host}} + T_{\text{device}} + T_{\text{copy}}.$$

三个加数都是以秒（或毫秒）计的墙钟时间： T_{host} 是 CPU 解释与调度， T_{device} 是核上算术， T_{copy} 是主机与器件之间搬数据。当 T_{host} 因全局解释器锁而串行时， T_{device} 被阻塞。把可向量化的映射尽量放进一次设备核，可减小比值 T_{host}/T ，该比值是无量纲的时间占比，越接近 0 表示越少时间浪费在解释上。

5.1.5 小结

块是可嵌套映射 f ，顺序块实现 $f_n \circ \cdots \circ f_1$ ，并负责参数登记与反向传播。前向算出的是表示或打分；`params` 收集的是可训练张量； T 的各分量是时间，不是模型输出。

5.1.6 练习

核验列表存储是否仍使 `params` 递归可收集，以及并联 $[f_1(\mathbf{x}), f_2(\mathbf{x})]$ 与重复实例 $f \circ \cdots \circ f$ 的形状。并联输出是把两路特征在通道或特征维上拼在一起，每个条目仍是对应子映射的响应，不是两路打分之和。

5.2 参数管理

架构与超参数固定后，训练求解

$$\boldsymbol{\theta}^* \in \operatorname{argmin}_{\boldsymbol{\theta}} L(\boldsymbol{\theta}).$$

$L(\boldsymbol{\theta})$ 是标量训练损失； $\boldsymbol{\theta}^*$ 是使该损失尽可能小的那一组参数值，与 $\boldsymbol{\theta}$ 同形状。随后需要读出 $\boldsymbol{\theta}$ 以便复用、保存或检查。下面把访问、初始化与共享写成对 $\boldsymbol{\theta}$ 的运算。

5.2.1 参数访问

顺序模型中第 ℓ 层参数是命名张量，通常含权重 $\mathbf{W}^{(\ell)}$ 与偏置 $\mathbf{b}^{(\ell)}$ 。 $W_{ij}^{(\ell)}$ 是第 ℓ 层输出单元 i 对输入特征 j 的权重； $b_i^{(\ell)}$ 是该单元的加性偏移，与该层打分同量纲。名称在整网中唯一，即使层数达数百。

5.2.1.1 目标参数

参数对象同时携带值、梯度与状态。未反向传播时 $\nabla_{\theta} L$ 处于初始（通常为零）状态，零表示“尚未计入任何损失敏感度”，不是“损失对该参数不敏感”。一次 `L.backward` 之后

$$\frac{\partial L}{\partial \mathbf{W}^{(\ell)}}, \quad \frac{\partial L}{\partial \mathbf{b}^{(\ell)}}$$

才有定义：每个条目是对应权重或偏置增加 1 个单位时，标量损失大约增加多少。对参数的数值运算必须先取出底层张量。

5.2.1.2 一次性访问所有参数

嵌套块的参数树为

$$\text{params}(B) = \text{local}(B) \cup \bigcup_{B' \in \text{children}(B)} \text{params}(B').$$

左边是块 B 下全部参数张量的集合：本层的 `local(B)` 并上每个子块递归收集的结果。一次性遍历给出全部 `(name,  $\theta_{\text{name}}$ )`，名称是字符串键，张量才是数值；不必按层手工索引。

5.2.1.3 从嵌套块收集参数

若 $B = \text{Seq}(B_1, B_2, \dots)$ 且每个 B_i 自身又是顺序块，则名称按层级拼接。访问“第一主块、第二子块、第一层”的偏置，对应路径索引下的 $\mathbf{b}$ ，读到的每个 b_i 仍是该层第 i 个单元的偏移，不是路径编号本身。分层嵌套与嵌套列表索引同构。

5.2.2 参数初始化

默认把 $\mathbf{W}$ 、 $\mathbf{b}$ 抽自由输入输出维决定的均匀区间。自定义规则是从另一分布 P 抽样

$$\mathbf{W} \sim P.$$

抽到的每个 w_{ij} 是该连接的初始权重，本身没有“正确/错误”含义，只决定训练起点附近的打分尺度。

5.2.2.1 内置初始化

高斯初始化取

$$w_{ij} \sim \mathcal{N}(0, 0.01^2), \quad b_i = 0.$$

w_{ij} 是均值为 0、标准差为 0.01 的随机权重，使初始线性打分接近 0； $b_i = 0$ 表示一开始不加偏移。亦可令全部元素为常数，例如 $\mathbf{W} = \mathbf{1}$ ，此时每个 $w_{ij} = 1$ 表示“所有输

入特征等权相加”。不同块可使用不同规则：第一层 Xavier，第三层常数 42。Xavier 对 $\mathbf{W} \in \mathbb{R}^{n_{\text{out}} \times n_{\text{in}}}$ 满足

$$\text{Var}(w) = \frac{2}{n_{\text{in}} + n_{\text{out}}}.$$

左边是每个权重作为随机变量的方差（无量纲，若把激活视为无量纲），右边用输入输出宽度标定，使前向激活与反向梯度的方差大致不随层宽爆炸或消失。均匀区间可按该方差再标定上下界。

5.2.2.2 自定义初始化

按元素独立抽样

$$w \sim \begin{cases} U(5, 10), & \text{probability } 1/4, \\ 0, & \text{probability } 1/2, \\ U(-10, -5), & \text{probability } 1/4. \end{cases}$$

每个 w 以 1/2 概率恰好为 0（该连接一开始不贡献），否则落在远离零的两侧区间，绝对值约 5 到 10。该规则仍是合法的 P ，只是把质量放在远离零的两侧与原点。

5.2.3 参数绑定

共享指定 $\mathbf{W}^{(3)} = \mathbf{W}^{(5)} = \mathbf{W}$ 为同一张量，而非值相等的两份副本。于是 $d\mathbf{W}^{(3)} = d\mathbf{W}^{(5)}$ ：两处看到的是同一组权重数值。反向传播时梯度相加：

$$\frac{\partial L}{\partial \mathbf{W}} = \frac{\partial L}{\partial \mathbf{W}^{(3)}} + \frac{\partial L}{\partial \mathbf{W}^{(5)}}.$$

左边每个条目是该共享权重增大时总损失的敏感度，等于两条使用路径上敏感度之和，而不是取平均或取较大者。前向两次使用同一 $\mathbf{W}$ ，更新一步同时改变两处表现层。

5.2.4 小结

参数是带梯度的命名张量；初始化给定 P ，抽到的数是训练起点上的权重；绑定使若干层共享同一 $\mathbf{W}$ 并把两条路径的 $\partial L / \partial \mathbf{W}$ 相加。

5.2.5 练习

在含共享层的感知机上核验 $\mathbf{W}^{(i)} = \mathbf{W}^{(j)}$ 是否为同一存储，以及 $\nabla_{\mathbf{W}} L$ 是否等于两条路径梯度之和。若相等，读到的每个梯度分量就是“该共享权重增大时损失增加多少”，已计入两处使用。

5.3 延后初始化

定义网络时可以暂不给出输入维 d 。此时第一层权重 $\mathbf{W}^{(1)} \in \mathbb{R}^{h \times d}$ 中的 d 未知，无法分配。延后初始化（deferred initialization）把形状推断推迟到数据第一次通过模型。

5.3.1 实例化网络

实例化后、首次前向之前，`params` 为空，表示还没有可训练数值，不是权重全为零。设首个批量 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 到达， n 是批量大小， d 是每条样本的特征数，由 d 确定

$$\mathbf{W}^{(1)} \in \mathbb{R}^{h \times d}, \quad \mathbf{W}^{(2)} \in \mathbb{R}^{q \times h},$$

再依层顺序分配并抽样。这里的 h, d, q 都是轴长度（有几个隐单元、几个输入特征、几个输出），不是权重的数值。仅第一层真正依赖未知输入维，但框架仍按拓扑顺序完成全部形状。

5.3.2 小结

首次前向把未知维代入，使

$$\text{shape}(\mathbf{W}^{(\ell)})$$

全部成为已知的整数元组后再初始化。该元组表示权重矩阵有几行几列，不是矩阵里那些权重的大小。

5.3.3 练习

核验：只给出第一层输入维时哪些层立即分配；维不匹配是否使乘法 $\mathbf{W}\mathbf{x}$ 无定义；输入维改变时共享参数如何约束形状。形状约束的是轴长度必须一致，与权重取值无关。

5.4 自定义层

层是块的特例。当预置层不包含所需映射时，按同一接口定义新层：前向 f 加上可选的 `params(f)`。

5.4.1 不带参数的层

中心化层是无参数映射

$$f(\mathbf{x}) = \mathbf{x} - \bar{x}\mathbf{1}, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

输入 $\mathbf{x} \in \mathbb{R}^n$ 时, $\bar{x}$ 是各分量的算术平均, 与 x_i 同量纲, 表示这组数的中心水平; $f(\mathbf{x})$ 的第 i 个分量是相对该中心的偏差, 和应接近 0 (浮点下只是接近)。对批量矩阵按约定的轴取均值后广播相减。该层可嵌入任意 Seq。

5.4.2 带参数的层

自定义全连接层需要 $\mathbf{W} \in \mathbb{R}^{q \times d}$ 、 $\mathbf{b} \in \mathbb{R}^q$,

$$f(\mathbf{x}) = \text{ReLU}(\mathbf{W}\mathbf{x} + \mathbf{b}).$$

输入 $\mathbf{x} \in \mathbb{R}^d$, 输出 $\mathbf{f}(\mathbf{x}) \in \mathbb{R}^q$: 每个分量是该输出单元的 ReLU 响应, 负打分被置 0, 正打分原样保留。用框架的参数构造器登记 $\mathbf{W}, \mathbf{b}$, 则访问、初始化、共享、序列化都沿用统一接口, 而不必为该层单独写读写程序。

5.4.3 小结

自定义层是映射 f , 可无参数或带 $\mathbf{W}, \mathbf{b}$; 登记后即可出现在任意架构中。无参数层输出的是变换后的数据值; 有参数层输出的是可学习的打分或激活。

5.4.4 练习

核验二次型层

$$y_k = \sum_{i,j} W_{ijk} x_i x_j$$

的形状 $k \mapsto y_k$, 以及把输入映到傅里叶系数前半部分的线性映射。 y_k 是一个标量: 用第 k 张权重切片对特征做二次型, 表示特征两两交互对该输出通道的贡献, 不是线性打分。

5.5 读写文件

训练得到 θ 后, 需要把张量或整份参数字典写入存储, 以便部署或断点续训。

5.5.1 加载和保存张量

单个张量的读写是一对互逆映射

$$\text{save}(\mathbf{X}, p), \quad \mathbf{X}' = \text{load}(p),$$

在格式一致时 $\mathbf{X}' = \mathbf{X}$: 读回来的每个条目仍是原来的数值, 形状也相同。列表 $(\mathbf{X}_1, \dots, \mathbf{X}_m)$ 与字典 $k \mapsto \mathbf{X}_k$ 同样可往返, 后者直接对应“全部权重名到张量”, 键是名称, 值才是参数数值。

5.5.2 加载和保存模型参数

整网保存的是参数字典而非可执行架构，因为架构含任意代码，难以序列化。恢复过程为

$$f \leftarrow \text{arch}(), \quad \theta(f) \leftarrow \text{load}(p).$$

先用代码重建与保存时相同的映射 f ，再把文件里的权重填回去。填入后每个参数张量的条目等于保存时的值，随机初始化被覆盖；架构本身（有哪些层、如何连接）仍由代码给出，不是从文件里读出来的数。

5.5.3 小结

`save/load` 作用于张量，读写的是数值本身；整网只固化 θ ，架构仍由代码给出。

5.5.4 练习

核验只加载前两层 $\theta_{1:2}$ 并入新架构是否形状相容，以及同时保存架构时必须对 f 施加何种可序列化限制。形状相容指轴长度一致，使矩阵乘有定义。

5.6 GPU




图 5.6.1 复制数据以在同一设备上执行操作

符号：CPU/GPU：设备；箭头：张量拷贝到同一设备再运算

张量带有设备（device）。默认在主机内存由 CPU 计算；GPU 把同一线性代数核放到高吞吐器件上。记设备集合 $\{\text{cpu}, \text{cuda:0}, \dots, \text{cuda:k} - 1\}$ 。

5.6.1 计算设备

cpu 表示全部主机核与内存；cuda: i 表示第 i 块卡及其显存 (i 从 0 起)。cuda:0 与 cuda 等价。可用卡数 k 是一个非负整数，表示有几块可用 GPU，不是某张量里的数据值。查询后第 i 块记为 cuda: i 。

5.6.2 张量与 GPU

每个张量 $\mathbf{X}$ 有位置 $\text{loc}(\mathbf{X})$ 。二元运算 $\mathbf{X} + \mathbf{Y}$ 有定义当且仅当

$$\text{loc}(\mathbf{X}) = \text{loc}(\mathbf{Y}),$$

否则结果的存储位置与计算位置均不确定。该等式比较的是设备标识是否相同，不是比较 $\mathbf{X}$ 与 $\mathbf{Y}$ 的数值。和 $\mathbf{X} + \mathbf{Y}$ 的每个条目才是对应位置数据值之和。

5.6.2.1 存储在 GPU 上

创建时可指定 $\text{loc}(\mathbf{X}) = \text{cuda:0}$ 。该张量只占用该卡显存，容量受显存上界约束；上界是字节数，不是张量条目的取值范围。第二块卡上的张量满足 $\text{loc}(\mathbf{Y}) = \text{cuda:1}$ 。

5.6.2.2 复制

若 $\text{loc}(\mathbf{X}) \neq \text{loc}(\mathbf{Y})$ ，应先做设备间复制

$$\mathbf{Z} = \text{copy}_{\text{loc}(\mathbf{Y})}(\mathbf{X}),$$

再计算 $\mathbf{Z} + \mathbf{Y}$ 。 $\mathbf{Z}$ 与 $\mathbf{X}$ 数值相同、形状相同，只是住在另一块内存；加法得到的仍是对应条目之和。若 $\mathbf{Z}$ 已在目标设备，再次请求同一设备不分配新存储，即 id 不变。id 相同表示仍是同一块存储，不是数值相等。

5.6.2.3 旁注

器件间传输带宽远低于器件内计算。多次小复制的开销通常大于一次大复制。打印或转为主机数组会把数据拉回内存，并可能触发全局解释器锁，从而阻塞全部 GPU 核。这里增加的是 T_{copy} ，不改变张量里那些数的含义。

5.6.3 神经网络与 GPU

模型参数同样带位置。把 θ 放到设备 d 后，输入必须满足

$$\text{loc}(\mathbf{X}) = d,$$

前向才在 d 上计算 $f_{\theta}(\mathbf{X})$ 。 $f_{\theta}(\mathbf{X})$ 的数值含义与在 CPU 上相同（打分、概率等），只是计算发生在另一器件。数据和参数同设备是有效训练的成立条件。

5.6.4 小结

运算要求全部输入同设备；默认 `loc = cpu`。不必要的 `copy` 会支配 T ，但复制本身不改写条目的数学含义。

5.6.5 练习

比较大矩阵乘法上 CPU 与 GPU 的 T ，并核验逐次把 Frobenius 范数拉回主机是否显著增加 T_{copy} ；两卡并行与单卡顺序的时间比应接近线性。 $\|\mathbf{X}\|_F$ 仍是矩阵条目平方和的平方根（非负，表示整体幅度），与在哪块设备上算出无关。

第六章 卷积神经网络

全连接层把图像展平后不再区分空间邻近。卷积用平移不变与局部性约束核，使同一组权重在所有位置复用。下面从全连接出发得到互相关，再加入填充、步幅、通道与汇聚，最后组成 LeNet。

6.1 从全连接层到卷积



图 6.1.1 沃尔多游戏示例图。

符号：见图中标注；各块含义见题注。



图 6.1.2 发现沃尔多。

符号：见图中标注；各块含义见题注。

表格数据中特征无预定空间结构，多层感知机合适。对高维图像，若像素数为 10^6 、隐单元为 10^3 ，单层参数已达

$$10^6 \times 10^3 = 10^9.$$

左边两个因子都是计数：像素个数与隐单元个数；乘积 10^9 是该层权重的个数，不是像素强度，也不是某次前向的输出。需要把平移不变性与局部性写进映射，以减少自由参数。

6.1.1 不变性

检测物体的响应不应随物体平移而改变。同一滤波器在所有空间位置上扫描，等价于要求隐藏表示随输入平移而平移：某处的输出条目仍是“该局部模式的匹配分数”，只是分数出现的位置跟着物体走。

6.1.2 多层感知机的限制

把图像 $\mathbf{X} \in \mathbb{R}^{n_h \times n_w}$ 与四维核 $\mathbf{W}$ 的全连接写成

$$\begin{aligned} [\mathbf{H}]_{i,j} &= [\mathbf{U}]_{i,j} + \sum_k \sum_l [\mathbf{W}]_{i,j,k,l} [\mathbf{X}]_{k,l} \\ &= [\mathbf{U}]_{i,j} + \sum_a \sum_b [\mathbf{V}]_{i,j,a,b} [\mathbf{X}]_{i+a,j+b}. \end{aligned}$$

输入 X_{kl} 是位置 (k, l) 的像素强度（或上一层响应）。 H_{ij} 是输出特征图在位置 (i, j) 的一个数：对整幅图（第一式）或相对窗口（第二式）加权求和后的局部模式分数，不是把像素强度简单搬到该格，也不是输出图的高或宽。第二式只是把求和指标改成相对位移 (a, b) ，尚未减少参数。

6.1.2.1 平移不变性

令核与偏置都不依赖输出位置 (i, j) ，即 $[V]_{i,j,a,b} = [V]_{a,b}$ 、 $[U]_{i,j} = u$ ，则

$$[H]_{i,j} = u + \sum_a \sum_b [V]_{a,b} [X]_{i+a,j+b}.$$

同一 V 在所有位置复用。 H_{ij} 仍是位置 (i, j) 处窗口与核的匹配分数： V_{ab} 大且对应像素也大时分数升高，表示该局部模式在此处更强。

6.1.2.2 局部性

再限制位移只在窗口 $|a|, |b| \leq \Delta$ 内，

$$[H]_{i,j} = u + \sum_{a=-\Delta}^{\Delta} \sum_{b=-\Delta}^{\Delta} [V]_{a,b} [X]_{i+a,j+b}.$$

远处像素不进入该处隐藏表示。 Δ 是窗口半径（像素个数，正整数），不是强度。 $\Delta = 0$ 时退化为逐像素通道混合，此时 H_{ij} 只由同一格的输入算出。

6.1.3 卷积

连续卷积为

$$(f * g)(\mathbf{x}) = \int f(\mathbf{z}) g(\mathbf{x} - \mathbf{z}) d\mathbf{z}.$$

$(f * g)(\mathbf{x})$ 是位置 $\mathbf{x}$ 处的叠加响应：把核 f 翻转到所有位移后与 g 相乘再积分，得到的是该处的匹配程度，不是坐标本身。一维、二维离散形式为

$$\begin{aligned} (f * g)(i) &= \sum_a f(a) g(i - a), \\ (f * g)(i, j) &= \sum_a \sum_b f(a, b) g(i - a, j - b). \end{aligned}$$

$(f * g)(i, j)$ 是整数格点 (i, j) 上的一个数，含义同连续情形的局部匹配分数。与上一小节的互相关相比，卷积在核上多了翻转 $(a, b) \mapsto (-a, -b)$ 。

6.1.4 “沃尔多在哪里” 回顾

用滤波器 $\mathbf{V}$ 在图上滑动窗口并加权，得到目标出现的响应图。学习 $\mathbf{V}$ 使响应在目标位置取大值：特征图上某个大的 H_{ij} 表示“沃尔多这类模式在位置 (i, j) 的分数高”，不是该像素被涂成了目标。

6.1.4.1 通道

输入 $\mathbf{X}$ 与输出 $\mathbf{H}$ 可有通道。四维核 $\mathbf{V}$ 把输入通道 c 混到输出通道 d ：

$$[\mathbf{H}]_{i,j,d} = \sum_{a=-\Delta}^{\Delta} \sum_{b=-\Delta}^{\Delta} \sum_c [\mathbf{V}]_{a,b,c,d} [\mathbf{X}]_{i+a,j+b,c}.$$

H_{ijd} 是输出通道 d 在空间位置 (i, j) 的局部模式分数：把窗口内所有输入通道的强度用该通道的核加权求和。不同 d 检测不同局部模式（边缘、颜色组合等）。

6.1.5 小结

平移不变给出与位置无关的 $\mathbf{V}$ ，局部性把求和限制在 Δ 窗口；多通道时用 $\mathbf{V}$ 混合通道。特征图上每一个条目都是该位置、该通道的局部模式分数，不是空间尺寸。

6.1.6 练习

当 $\Delta = 0$ 时核验上式是否在每个空间位置上退化为通道上的全连接；并说明二维离散卷积 $f * g = g * f$ 由核翻转后的交换性得出。 $\Delta = 0$ 时 H_{ijd} 仍是通道混合后的分数，只是窗口缩成单像素。

6.2 图像卷积




图 6.2.1 二维互相关运算。阴影部分是第一个输出元素，以及用于计算输出的输入张量元素和核张量元素： $0 \times 0 + 1 \times 1 + 3 \times 2 + 4 \times 3 = 19$ 。

符号： X ：输入； K ：卷积核； Y ：互相关输出；阴影格：当前窗口

上节给出原理；本节把二维互相关写成可学习层，并用于边缘检测。

6.2.1 互相关运算

输入 $\mathbf{X} \in \mathbb{R}^{n_h \times n_w}$ 、核 $\mathbf{K} \in \mathbb{R}^{k_h \times k_w}$ 的互相关（cross-correlation）为

$$[\mathbf{Y}]_{ij} = \sum_{a=0}^{k_h-1} \sum_{b=0}^{k_w-1} [\mathbf{X}]_{i+a, j+b} [\mathbf{K}]_{ab}.$$

窗口从输入的 (i, j) 起覆盖 $k_h \times k_w$ 块，与核逐元素相乘再相加。 Y_{ij} 是该窗口与核的匹配分数：核形状在此处越吻合，该数越大（可正可负，取决于核的符号）。它是特征响应，不是像素强度的拷贝，更不是输出图有几行几列。对 3×3 输入与 2×2 核，四个输出为

$$0 \cdot 0 + 1 \cdot 1 + 3 \cdot 2 + 4 \cdot 3 = 19,$$

$$1 \cdot 0 + 2 \cdot 1 + 4 \cdot 2 + 5 \cdot 3 = 25,$$

$$3 \cdot 0 + 4 \cdot 1 + 6 \cdot 2 + 7 \cdot 3 = 37,$$

$$4 \cdot 0 + 5 \cdot 1 + 7 \cdot 2 + 8 \cdot 3 = 43.$$

19, 25, 37, 43 分别是四个窗口位置上的局部模式分数，不是那四个像素本身。无填充、步幅为 1 时输出形状

$$(n_h - k_h + 1) \times (n_w - k_w + 1).$$

这两个整数是输出特征图的空间高度与宽度（有几个空间位置），不是像素强度，也不是那些匹配分数的取值。

6.2.2 卷积层

卷积层在互相关之后加标量偏置：

$$\mathbf{Y} = \mathbf{X} \star \mathbf{K} + b.$$

可训练参数是 $\mathbf{K}$ 与 b 。 Y_{ij} 仍是位置 (i, j) 的局部模式分数，只是整体平移了 b ； b 与该分数同量纲。高宽为 h, w 的核称为 $h \times w$ 卷积核，对应层称为 $h \times w$ 卷积层；这里的 h, w 是核的空间尺寸（格点数）。

6.2.3 图像中目标的边缘检测

核 $\mathbf{K} = [1, -1]$ 在水平相邻像素上计算差分。相邻相等时输出 0，否则非零：由白到黑得 1，由黑到白得 -1。该输出是边缘响应：绝对值大为垂直边缘强，0 表示该处水平方向无跳变。该 $\mathbf{K}$ 检测垂直边缘；转置输入后垂直边缘响应消失，因其不匹配水平结构。

6.2.4 学习卷积核

给定配对 $(\mathbf{X}, \mathbf{Y})$ ，学习

$$\min_{\mathbf{K}} \|\mathbf{X} \star \mathbf{K} - \mathbf{Y}\|_F^2.$$

$\mathbf{X} \star \mathbf{K} - \mathbf{Y}$ 是每个位置上“预测的局部模式分数减目标分数”；Frobenius 范数的平方是这些误差的平方和，非负标量，越大表示整张特征图拟合越差。梯度更新 $\mathbf{K}$ 若干步后，所得核接近手工差分核 $[1, -1]$ 。

6.2.5 互相关和卷积

严格卷积要求核翻转后再做互相关。若层执行互相关并学到 $\mathbf{K}$ ，则执行严格卷积时学到翻转后的 $\mathbf{K}'$ 。二者前向差一个核翻转；核从数据学习时，可表示的函数类相同，输出的局部模式分数不受本质影响。

6.2.6 特征映射和感受野

卷积输出称为特征映射（feature map）。图上每个条目是对应位置的局部模式分数。某元素 x 的感受野（receptive field）是前向中能影响 x 的所有先前元素。 2×2 核下，输出中对应 19 的元素感受野为输入的四覆盖像素：19 这个分数只由那四个输入强度与核共同决定。叠层后感受野增长，可超过原始输入尺寸（若计入填充）。

6.2.7 小结

二维卷积层的核心是 $\mathbf{Y} = \mathbf{X} \star \mathbf{K} + b$ ；每个 Y_{ij} 是该处的局部模式分数。核可手工设计或由 $\|\mathbf{X} \star \mathbf{K} - \mathbf{Y}\|_F^2$ 学习，后者是分数误差的平方和。

6.2.8 练习

核验把 $\mathbf{X}$ 、 $\mathbf{K}$ 适当展开后 $\star$ 可写成一次矩阵乘法，以及对角边缘图像上 $\mathbf{K}$ 与 $\mathbf{K}^\top$ 的响应如何改变。矩阵乘算出的每个数仍是对应位置的局部模式分数。

6.3 填充和步幅




图 6.3.1 带填充的二维互相关。

符号: p : 填充格数; X : 输入; Y : 输出




图 6.3.2 垂直步幅为 3，水平步幅为 2 的二维互相关运算。

符号: s_h, s_w : 垂直/水平步幅; X : 输入; K : 核

无填充时输出为 $(n_h - k_h + 1) \times (n_w - k_w + 1)$ ，这两个整数是特征图的空间高与宽。连续卷积会快速缩小空间尺寸。填充 (padding) 与步幅 (stride) 是另外两个控制输出形状的量。

6.3.1 填充

在输入四周补 p_h 行、 p_w 列（通常上下分摊 p_h 、左右分摊 p_w ）后，输出形状为

$$(n_h - k_h + p_h + 1) \times (n_w - k_w + p_w + 1).$$

n_h, n_w 是输入特征图的空间高宽， k_h, k_w 是核的空间高宽， p_h, p_w 是沿高、宽方向补上的总格点数。公式算出的两个整数仍是输出特征图有几行几列，不是像素强度，也不是卷积分数。当 k_h 为奇数且 $p_h = k_h - 1$ （步幅 1）时，

$$n_h - k_h + (k_h - 1) + 1 = n_h,$$

右边的 n_h 表示输出高度与输入高度相同（格点数不变）。 3×3 核常用每边填充 1。

6.3.2 步幅

窗口每次在高、宽上分别滑动 s_h 、 s_w 。输出形状为

$$\left\lfloor \frac{n_h - k_h + p_h + s_h}{s_h} \right\rfloor \times \left\lfloor \frac{n_w - k_w + p_w + s_w}{s_w} \right\rfloor.$$

s_h, s_w 是每次窗口跳过的格点数（正整数）。取整后的两个因子是输出特征图的空间高度与宽度：有多少个窗口落点，不是那些窗口上算出的匹配分数，更不是像素亮度。 $s_h = s_w = 2$ 时空间尺寸大约减半，意思是高、宽上的位置个数大约变成原来的一半。步幅大于 1 减少后续层的位置数，从而减少计算。

6.3.3 小结

填充增大输出高宽，常用于保持与输入相同；步幅按上式减小高宽。二者共同决定的是特征图的空间格点数，不是格点上的响应强度。

6.3.4 练习

把给定的 (n_h, n_w, k, p, s) 代入上式，核验是否与层输出形状一致；并解释音频上 $s = 2$ 对应时间轴下采样。音频里该整数是时间维上的帧数（有几个时间位置），不是采样点的振幅。

6.4 多输入多输出通道




图 6.4.1 两个输入通道的互相关计算。

符号: c_i : 输入通道; X : 多通道输入; K : 各通道核




图 6.4.2 互相关计算使用了具有 3 个输入通道和 2 个输出通道的 1×1 卷积核。其中，输入和输出具有相同的高度和宽度。

符号: 1×1 核: 跨通道线性组合, 不改变空间高宽

彩色输入形状为 $c_i \times h \times w$, 通道维长度为 c_i (例如 RGB 中 $c_i = 3$)。 c_i, h, w 都是轴长度: c_i 是有几条通道, h, w 是空间高宽。输入、核与输出都升为至少三维张量。

6.4.1 多输入通道

输入通道数为 c_i 时, 核也必须有 c_i 个二维切片, 形状 $c_i \times k_h \times k_w$ 。对各通道做二维互相关再求和:

$$Y = \sum_{c=1}^{c_i} X^{(c)} \star K^{(c)}.$$

每个 $\mathbf{X}^{(c)} \star \mathbf{K}^{(c)}$ 是该通道上的局部模式分数图；求和后 $\mathbf{Y}$ 仍是单通道二维图， Y_{ij} 是把各输入通道的局部匹配加总后的总分数。这就是“多通道汇成一张图”：不是把 c_i 张图叠着显示，而是各通道先与自己的核做互相关，再在通道维相加。某通道的核全为 0 时，该路对 Y_{ij} 无贡献。 $c_i = 1$ 时退化为上一节。若需要 c_o 张图，则平行准备 c_o 套这样的核，每套各自汇成一张；中间层通常保持多通道，不在每一层都压回单通道。

6.4.2 多输出通道

设输出通道数为 c_o 。每个输出通道配备一套形状为 $c_i \times k_h \times k_w$ 的核，总核形状为

$$c_o \times c_i \times k_h \times k_w.$$

这四个整数是核张量的轴长度（几条输出通道、几条输入通道、核高、核宽），不是核条目的取值。第 d 个输出通道为

$$\mathbf{Y}^{(d)} = \sum_{c=1}^{c_i} \mathbf{X}^{(c)} \star \mathbf{K}^{(d,c)}, \quad d = 1, \dots, c_o.$$

$Y_{ij}^{(d)}$ 是第 d 种局部模式在位置 (i, j) 的分数；不同 d 对应不同滤波器。加深网络时通常减小空间分辨率（高宽这两个整数变小）、增大 c_o ，使每处位置携带更多特征。

6.4.3 1×1 卷积层

$k_h = k_w = 1$ 时窗口内无空间邻域交互，计算只发生在通道上。在每个空间位置 (i, j) ,

$$[\mathbf{Y}]_{i,j,:} = \mathbf{W} [\mathbf{X}]_{i,j,:}, \quad \mathbf{W} \in \mathbb{R}^{c_o \times c_i},$$

即逐像素的全连接。核张量形状为 $c_o \times c_i \times 1 \times 1$ ：每个“核”在空间上只有一个数，不看邻域像素。同一 $\mathbf{W}$ 在所有 (i, j) 复用。 Y_{ijd} 是该像素处第 d 个输出通道的混合分数，由该格 c_i 个输入通道线性组合得到，高宽这两个空间尺寸不变。 1×1 可以改通道数（ $c_i \rightarrow c_o$ ），也可以保持 $c_o = c_i$ 只做通道非线性前的线性混合；感受野不因 1×1 扩大。若还要把 c_o 张图压成一张且保留空间，可令 $c_o = 1$ ，仍用上式在每个位置把通道加权求和。

6.4.4 小结

多通道把互相关推广为对 c_i 求和、对 c_o 并列； 1×1 卷积是每像素上的 $\mathbf{W}\mathbf{x}$ 。每个空间-通道格点上的数仍是局部（或逐像素）模式分数；形状公式里的整数仍是通道数与高宽。

6.4.5 练习

核验无非线性时两个核串联可否写成一次卷积，以及前向乘法次数 $c_o c_i k_h k_w n'_h n'_w$ 随 c_i, c_o 加倍如何变化。该乘积是乘加次数（计数），其中 n'_h, n'_w 是输出特征图的空间高宽。

6.5 汇聚层




图 6.5.1 汇聚窗口形状为 2×2 的最大汇聚层。着色部分是第一个输出元素，以及用于计算这个输出的输入元素： $\max(0, 1, 3, 4) = 4$ 。

符号：窗口 2×2 ；输出：窗口内最大（或平均）值

需要逐渐降低空间分辨率、增大感受野，使顶层对整图敏感。汇聚（pooling）在窗口上聚合，并减轻卷积响应对精确位置的敏感。

6.5.1 最大汇聚层和平均汇聚层

窗口 $\mathcal{W}_{ij}$ 上，

$$[\mathbf{H}]_{ij}^{\max} = \max_{(a,b) \in \mathcal{W}_{ij}} [\mathbf{X}]_{ab},$$

$$[\mathbf{H}]_{ij}^{\text{avg}} = \frac{1}{|\mathcal{W}_{ij}|} \sum_{(a,b) \in \mathcal{W}_{ij}} [\mathbf{X}]_{ab}.$$

输入 X_{ab} 是窗口内各位置的卷积响应（局部模式分数）。最大汇聚的 $H_{ij}^{\max}$ 是该窗口内的最强响应：只要窗口里某处模式很强，输出就大，对精确位置不敏感。平均汇聚的 H_{ij}^{avg} 是窗口内响应的算术平均，表示该邻域的典型响应强度，与单个响应同量纲。二者都是

局部摘要，不是又一次与可学习核的匹配。对与卷积示例相同的 2×2 窗口，最大汇聚给出

$$\max(0, 1, 3, 4) = 4,$$

$$\max(1, 2, 4, 5) = 5,$$

$$\max(3, 4, 6, 7) = 7,$$

$$\max(4, 5, 7, 8) = 8.$$

4, 5, 7, 8 分别是四个窗口里的最强输入响应，不是窗口的边长。

6.5.2 填充和步幅

汇聚的输出形状与卷积相同，窗口 $k_h \times k_w$ 扮演核的角色：

$$\left\lfloor \frac{n_h - k_h + p_h + s_h}{s_h} \right\rfloor \times \left\lfloor \frac{n_w - k_w + p_w + s_w}{s_w} \right\rfloor.$$

这两个整数同样是输出摘要图的空间高度与宽度（有几个窗口位置），不是摘要值本身，也不是像素强度。默认步幅常取与窗口相等，例如 3×3 窗口默认 $s_h = s_w = 3$ ，表示相邻窗口在高宽上各跳 3 格。窗口、填充、步幅均可取矩形且高宽不同。

6.5.3 多个通道

汇聚在每个输入通道上独立进行，不做通道间求和，因此

$$c_o = c_i.$$

该等式说的是通道个数不变，不是把通道上的响应数值设为相等。通道维连结后的输入，汇聚后通道数保持不变；每个通道上的数仍是该通道的局部最强或平均响应。

6.5.4 小结

最大汇聚取窗口 $\max$ （最强响应），平均汇聚取均值（平均响应）；填充与步幅改变的是摘要图的空间高宽，通道个数不变。

6.5.5 练习

把平均汇聚写成元素全为 $1/(p_h p_w)$ 的卷积核；并比较最大、平均与 softmax 加权聚合在窗口上的不同。softmax 权在 $[0, 1]$ 且和为 1，得到的是窗口内响应的加权平均，介于最大与均匀平均之间。

6.6 卷积神经网络 (LeNet)




图 6.6.1 LeNet 中的数据流。输入是手写数字，输出为 10 种可能结果的概率。

符号：输入：手写数字；C1/C3：卷积；S2/S4：汇聚；F5/F6：全连接；10：类别分数




图 6.6.2 LeNet 的简化版。

符号：自上而下：卷积—汇聚—卷积—汇聚—全连接—输出

不再把 28×28 图像展成 $\mathbb{R}^{784}$ ，而在空间上保留二维结构。卷积替代全连接可大幅减少参数。LeNet 是早期完整卷积网络。

6.6.1 LeNet

LeNet-5 分为卷积编码器与全连接块。每个卷积单元是 5×5 卷积、sigmoid 与 2×2 平均汇聚（步幅 2）：

$$\begin{aligned} C_1 &= \sigma(X \star K_1 + b_1) \in \mathbb{R}^{6 \times 24 \times 24}, \\ S_2 &= \text{AvgPool}_{2 \times 2}(C_1) \in \mathbb{R}^{6 \times 12 \times 12}, \\ C_3 &= \sigma(S_2 \star K_3 + b_3) \in \mathbb{R}^{16 \times 8 \times 8}, \\ S_4 &= \text{AvgPool}_{2 \times 2}(C_3) \in \mathbb{R}^{16 \times 4 \times 4}. \end{aligned}$$

C_1 每个条目是第一层某种局部模式经 sigmoid 后的响应，落在 $(0, 1)$ ；形状中的 6, 24, 24 是通道数与空间高宽。 S_2 每个条目是 2×2 窗口内这些响应的平均； 12×12 是摘要图的空间尺寸，约为上一层高宽之半。 C_3 、 S_4 含义相同，只是通道增至 16、空间继续按形状公式缩小。展平后 $z \in \mathbb{R}^{256}$ ，再

$$h_5 = \sigma(W_5 z + b_5) \in \mathbb{R}^{120}, \quad h_6 = \sigma(W_6 h_5 + b_6) \in \mathbb{R}^{84}, \quad o = W_o h_6 + b_o \in \mathbb{R}^{10}.$$

h_5, h_6 的分量是全连接隐单元的激活； o 的 10 个分量是 10 类的未归一化打分，不是概率，也不是空间尺寸。池化使空间维数每次约减为 $1/4$ （高、宽各约减半，格点数相乘），同时通道由 6 增至 16。

6.6.2 模型训练

训练映射与多层感知机相同：小批量上计算损失、反向、更新 θ 。交叉熵里用到的是 $\text{softmax}(o)$ 的各类概率，在 $[0, 1]$ 且和为 1。每个参数参与的乘法次数多于同等参数量的全连接网，故常用 GPU。批量 X 与 θ 须满足 $\text{loc}(X) = \text{loc}(\theta)$ 。

6.6.3 小结

LeNet 把 $\sigma \circ (\cdot \star K)$ 与平均汇聚叠成编码器，再接全连接得到 $o \in \mathbb{R}^{10}$ 。卷积特征图上的数是局部模式分数，汇聚上的数是局部摘要，最后 10 维是类别打分。

6.6.4 练习

核验把平均汇聚换成最大汇聚、把 σ 换成 ReLU、或改变 k 与 c_o 时，各层形状是否仍由填充-步幅公式给出。公式给出的始终是特征图的空间高宽与通道个数，与激活函数把响应截成何值无关。

第七章 现代卷积神经网络

LeNet 之后，更深的卷积网依靠更多数据与 GPU 才超过手工特征。AlexNet 证明学习特征可行；VGG 用重复块，NiN 用 1×1 卷积，GoogLeNet 用并行 Inception，BatchNorm 稳定深层分布，ResNet 用 $\boldsymbol{x} + F(\boldsymbol{x})$ ，DenseNet 用通道连结。

7.1 深度卷积神经网络（AlexNet）




图 7.1.1 AlexNet 第一层学习到的特征抽取器。

符号：见图中标注；各块含义见题注。




图 7.1.2 从 LeNet（左）到 AlexNet（右）

符号：卷积组：特征提取；全连接：分类；1000：ImageNet 类别

小数据上卷积早已有效，但在更大真实图像上，神经网络曾长期不敌支持向量机（support vector machine）。记一张图为 X 、标签为 y 。传统视觉把图映成固定特征向量再接线性分类器：

$$\phi(X) \in \mathbb{R}^d, \quad o = W^T \phi(X) + b \in \mathbb{R}^q.$$

$\phi(X)$ 的各分量是 SIFT、HOG 等描述子； d 是描述子维数。 $W \in \mathbb{R}^{d \times q}$ 的第 k 列是第 k 类对这 d 个特征的权重， o 的分量是各类线性打分。 n 张图可堆成特征矩阵再一次矩阵乘：

$$\Phi = \begin{bmatrix} \phi(X_1)^T \\ \vdots \\ \phi(X_n)^T \end{bmatrix} \in \mathbb{R}^{n \times d}, \quad O = \Phi W + 1b^T \in \mathbb{R}^{n \times q}.$$

Φ 的第 i 行是第 i 张图的手工特征； O 的第 i 行是该图的 q 类打分。卷积神经网络不再冻结 ϕ ，而把 X 经可学习核与权重一直映到同类打分

$$o = f_{\theta}(X),$$

θ 含全部 K_{ℓ}, W_{ℓ} 。

7.1.1 学习表征

2012 年前主导的是 SIFT、SURF、HOG 与视觉词袋等固定 ϕ 。另一路线主张特征矩阵本身由多层共同学习。记 $H^{(0)} = X$,

$$H^{(\ell)} = f_{\ell}(H^{(\ell-1)}; K_{\ell}, b_{\ell}),$$

f_{ℓ} 是互相关加非线性（及可能的汇聚）。 $H^{(\ell)}$ 每个空间-通道格点是该层局部模式分数；其形状中的整数是通道数与高宽。

7.1.1.1 缺少的成分：数据

把 n 张有标签图写成张量 $X \in \mathbb{R}^{n \times c \times n_h \times n_w}$ 与标签向量 $y \in \{1, \dots, q\}^n$ 。经验风险

$$\hat{R}_n(f_{\theta}) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\theta}(X_{i,:,:,}), y_i)$$

是标量平均损失； n 须足够大才约束过参数化的 θ 。ImageNet 约 $n = 10^6$ 、 $q = 10^3$ ： 10^6 是样本个数， 10^3 是类别个数。

7.1.1.2 缺少的成分：硬件

二维互相关在每个输出格点是窗口与核的 Frobenius 内积

$$[Y]_{ij} = \langle \text{vec}(X_{i:i+k_h, j:j+k_w}), \text{vec}(K) \rangle = \text{vec}(K)^{\top} \text{vec}(X_{i:i+k_h, j:j+k_w}).$$

左边是该位置的局部匹配分数。把所有窗口排成矩阵后，整层就是一次矩阵-矩阵积。GPU 原本优化 4×4 的 Av ，与这类乘加同类，从而降低器件时间 T_{device} （秒）。

7.1.2 AlexNet

AlexNet 为八层可学习映射：五层卷积、两层全连接隐层、一层全连接输出。与 LeNet 同构但更深更宽，且用逐元素 ReLU 替代 σ 。

7.1.2.1 模型设计

输入按 $n_h = n_w = 224$ 计。填充-步幅公式（第 6 章）给出输出高宽

$$n'_h = \left\lfloor \frac{n_h - k_h + p_h + s_h}{s_h} \right\rfloor;$$

n'_h 是特征图行数。第一层 $K_1 \in \mathbb{R}^{96 \times 11 \times 11 \times 11}$ 、步幅 4、 $p_h = p_w = 2$ ，故

$$\left\lfloor \frac{224 - 11 + 2 + 4}{4} \right\rfloor = 54.$$

54 是第一层特征图的空间边长。多通道互相关（第 6.4 节）为

$$[C]_{d,:,:} = \sum_c X^{(c)} \star K^{(d,c)} + b_d;$$

C 的第 d 张图是第 d 个滤波器的局部模式分数。书中精简实现（单通道输入、输出 $q = 10$ ）写成

$$\begin{aligned} C_1 &= \text{ReLU}(X \star K_1 + \mathbf{b}_1) \in \mathbb{R}^{96 \times 54 \times 54}, \\ S_1 &= \text{MaxPool}_{3 \times 3, 2}(C_1) \in \mathbb{R}^{96 \times 26 \times 26}, \\ C_2 &= \text{ReLU}(S_1 \star K_2 + \mathbf{b}_2) \in \mathbb{R}^{256 \times 26 \times 26}, \\ S_2 &= \text{MaxPool}_{3 \times 3, 2}(C_2) \in \mathbb{R}^{256 \times 12 \times 12}, \end{aligned}$$

其中 $K_2 \in \mathbb{R}^{256 \times 96 \times 5 \times 5}$ 。随后三层保持空间尺寸（ 3×3 、填充 1）：

$$\begin{aligned} C_3 &= \text{ReLU}(S_2 \star K_3 + \mathbf{b}_3) \in \mathbb{R}^{384 \times 12 \times 12}, \\ C_4 &= \text{ReLU}(C_3 \star K_4 + \mathbf{b}_4) \in \mathbb{R}^{384 \times 12 \times 12}, \\ C_5 &= \text{ReLU}(C_4 \star K_5 + \mathbf{b}_5) \in \mathbb{R}^{256 \times 12 \times 12}, \\ S_5 &= \text{MaxPool}_{3 \times 3, 2}(C_5) \in \mathbb{R}^{256 \times 5 \times 5}. \end{aligned}$$

$K_3 \in \mathbb{R}^{384 \times 256 \times 3 \times 3}$, $K_4 \in \mathbb{R}^{384 \times 384 \times 3 \times 3}$, $K_5 \in \mathbb{R}^{256 \times 384 \times 3 \times 3}$ 。最大汇聚每个条目是窗口内最强响应。展平后接全连接

$$\begin{aligned} \mathbf{z} &= \text{vec}(S_5) \in \mathbb{R}^{6400}, \quad 6400 = 256 \cdot 5 \cdot 5, \\ \mathbf{h}_6 &= \text{dropout}_p(\text{ReLU}(\mathbf{W}_6 \mathbf{z} + \mathbf{b}_6)) \in \mathbb{R}^{4096}, \\ \mathbf{h}_7 &= \text{dropout}_p(\text{ReLU}(\mathbf{W}_7 \mathbf{h}_6 + \mathbf{b}_7)) \in \mathbb{R}^{4096}, \\ \mathbf{o} &= \mathbf{W}_o \mathbf{h}_7 + \mathbf{b}_o \in \mathbb{R}^q. \end{aligned}$$

$\mathbf{W}_6 \in \mathbb{R}^{4096 \times 6400}$ 、 $\mathbf{W}_7 \in \mathbb{R}^{4096 \times 4096}$ 、 $\mathbf{W}_o \in \mathbb{R}^{q \times 4096}$ ：行对应输出单元，列对应输入特征，条目是该连接的权重。 $\mathbf{h}_6, \mathbf{h}_7$ 的分量是隐单元激活； $\mathbf{o}$ 的分量是类别 logit。演示取 $q = 10$ ，原论文取 $q = 1000$ 。原实现曾把这些矩阵拆到两块 GPU；显存充足时可放在单设备上。

7.1.2.2 激活函数

对预激活张量或向量 $\mathbf{U}$,

$$\text{ReLU}(\mathbf{U}) = \max(\mathbf{0}, \mathbf{U}), \quad [\sigma(\mathbf{U})]_{ij} = \frac{1}{1 + e^{-U_{ij}}}$$

均逐元素作用，输出与 $\mathbf{U}$ 同形状。ReLU($\mathbf{U}$) 保留正的打分、把负分置 0； $\sigma(\mathbf{U})$ 的每条目落在 $(0, 1)$ 。Jacobian 为对角阵

$$\text{diag}(\sigma'(\mathbf{u})), \quad \sigma'(u) = \sigma(u)(1 - \sigma(u)),$$

饱和时对角接近 0，回传到 $\mathbf{W}$ 的梯度几乎为零。ReLU 在正半轴导数为 1，对初始化更不敏感，且无需指数。

7.1.2.3 容量控制和预处理

全连接上的暂退（第 4.6 节）写成 Hadamard 积。训练时 $p = 1/2$,

$$\mathbf{h}' = \frac{1}{1-p} \mathbf{M} \odot \mathbf{h}, \quad M_j \stackrel{\text{iid}}{\sim} \text{Bernoulli}(1-p).$$

$\mathbf{M} \in \{0, 1\}^{4096}$ 与 $\mathbf{h}$ 同维：0 丢弃该隐单元，1 保留；除以 $1-p$ 使 $\mathbb{E}[\mathbf{h}' | \mathbf{h}] = \mathbf{h}$ 。测试时 $\mathbf{M} = \mathbf{1}$ ，故 $\mathbf{h}' = \mathbf{h}$ 。输入再经随机变换 T ，在增广分布上最小化

$$\mathbb{E}_T[\ell(f_{\theta}(T(\mathbf{X})), y)].$$

$T(\mathbf{X})$ 与 $\mathbf{X}$ 同形状，格点仍是亮度或颜色； ℓ 是标量分类损失。

7.1.3 读取数据集

原论文在 ImageNet 上训练。演示把 Fashion-MNIST 的 $\mathbf{X} \in \mathbb{R}^{28 \times 28}$ 重采样为 $\mathbf{X} \in \mathbb{R}^{1 \times 224 \times 224}$ ，以便套用同一套 $\mathbf{K}_{\ell}$ 与步幅。改变的是 n_h, n_w 这两个轴长度。

7.1.4 训练 AlexNet

小批量特征展平后的矩阵为 $\mathbf{Z} \in \mathbb{R}^{m \times 6400}$ ，全连接段与第 4 章相同：

$$\begin{aligned} \mathbf{H}_6 &= \text{dropout}_p(\text{ReLU}(\mathbf{Z}\mathbf{W}_6^{\top} + \mathbf{b}_6^{\top})), \\ \mathbf{H}_7 &= \text{dropout}_p(\text{ReLU}(\mathbf{H}_6\mathbf{W}_7^{\top} + \mathbf{b}_7^{\top})), \\ \mathbf{O} &= \mathbf{H}_7\mathbf{W}_o^{\top} + \mathbf{b}_o^{\top} \in \mathbb{R}^{m \times q}. \end{aligned}$$

$\mathbf{O}$ 的第 i 行是第 i 个样本的 logit。行 wise softmax

$$\hat{\mathbf{Y}} = \text{softmax}(\mathbf{O}), \quad \hat{Y}_{ik} = \frac{\exp(O_{ik})}{\sum_{k'=1}^q \exp(O_{ik'})}$$

给出类概率（每行在单纯形上）。交叉熵

$$L = -\frac{1}{m} \sum_{i=1}^m \mathbf{y}_i^{\top} \log \hat{\mathbf{y}}_i$$

是标量平均负对数似然； $\mathbf{y}_i$ 为 one-hot。各矩阵沿梯度下降

$$\mathbf{W} \leftarrow \mathbf{W} - \eta \nabla_{\mathbf{W}} L.$$

η 是步长； $\nabla_{\mathbf{W}} L$ 与 $\mathbf{W}$ 同形状，每个条目是该权重增大时 L 大约增加多少。书中取 $\eta = 0.01$ 。

7.1.5 小结

AlexNet 把 LeNet 的 $\sigma(\cdot \star K)$ 换成 $\text{ReLU}(\cdot \star K)$ ，加深加密后再接

$$\mathbf{o} = \mathbf{W}_o \text{ dropout}_p(\text{ReLU}(\mathbf{W}_7 \text{ dropout}_p(\text{ReLU}(\mathbf{W}_6 \mathbf{z} + \mathbf{b}_6)) + \mathbf{b}_7)) + \mathbf{b}_o.$$

卷积条目是局部模式分数，汇聚条目是最强响应， $\mathbf{o}$ 是类别 logit。形状由填充-步幅公式决定； $\mathbf{W}_\ell$ 的条目才是权重。

7.1.6 练习

比较增加轮数后与 LeNet 的 L 下降；核验主要显存是否在 $\mathbf{W}_6 \in \mathbb{R}^{4096 \times 6400}$ 与 $\mathbf{W}_7 \in \mathbb{R}^{4096 \times 4096}$ ，主要乘加是否在前几层大分辨率的 $X \star K$ 。 L 是标量平均损失；4096, 6400 是矩阵的行列维。改 n_h, n_w, c, k, s 后须重新代入形状公式，并相应改 $\mathbf{W}_6$ 的列数。

7.2 使用块的网络（VGG）




图 7.2.1 从 AlexNet 到 VGG，它们本质上都是块设计。

符号：VGG 块：若干卷积后接汇聚；深度由块重复次数决定

AlexNet 证明深度有效，但未给出可复用的设计单元。VGG 把“卷积-激活-汇聚”抽象成块，用重复块堆出不同深度。

7.2.1 VGG 块

经典序列是：填充以保持分辨率的卷积、非线性、汇聚。VGG 块由若干 3×3 、填充 1 的卷积（各接 ReLU）再接 2×2 、步幅 2 的最大汇聚组成。填充 1 时

$$n - 3 + 2 \cdot 1 + 1 = n,$$

左边按填充-步幅公式计算输出高度（或宽度），右边的 n 表示该空间尺寸与输入相同，单位是格点数，不是响应强度。故块内空间尺寸不变，块末汇聚使高宽减半：减半的是位置个数。记卷积层数为 n 、输出通道为 c ，则一块是映射

$$\text{VGG-block}(\mathbf{X}; n, c) = \text{MaxPool}_{2,2}((\text{ReLU} \circ \text{Conv}_{3 \times 3})^n(\mathbf{X})).$$

输入 $\mathbf{X}$ 经 n 次“局部模式打分再 ReLU”，再在每个 2×2 窗口取最强响应。输出每个条目仍是（更深的）局部模式摘要；形状中通道数为 c ，高宽约为输入之半。

7.2.2 VGG 网络

网络仍分卷积段与全连接段。超参数 `conv_arch` 给出每块的 (n, c) 。 n 是块内卷积层数， c 是该块输出通道数，二者都是计数。原始 VGG-11 含五块：前两块各一层卷积，后三块各两层，通道 64, 128, 256, 512, 512，故八层卷积加三层全连接。后续块将 c 翻倍直至 512。

7.2.3 训练模型

完整 VGG-11 计算量大于 AlexNet。演示中减小各块通道数，仍在 Fashion-MNIST 上按同一损失训练，学习率可略高。损失仍是分类交叉熵：模型输出经 softmax 后第 k 个分量是属于类 k 的概率。

7.2.4 小结

VGG-11 由可复用块 $\text{VGG-block}(\cdot; n, c)$ 串联；更深更窄的 3×3 栈优于更浅更宽的大核。块输出的数是局部模式摘要，块参数 (n, c) 是层数与通道个数。

7.2.5 练习

打印形状时卷积层计数为 8 而非 11，核验其余三层是否为全连接；并把输入从 224 改为 96 后代入步幅公式，看每块输出高宽如何减半。代入后得到的整数是各块特征图的空间高宽。

7.3 网络中的网络 (NiN)




图 7.3.1 对比 VGG 和 NiN 及它们的块之间主要架构差异。

符号：NiN 块： 1×1 卷积代替全连接做通道混合

LeNet、AlexNet、VGG 都是卷积提取空间特征再接全连接。NiN 在每个空间位置的通道上再放多层感知机，即 1×1 卷积，而不在早期展平。

7.3.1 NiN 块

四维张量轴为样本、通道、高、宽。把每个像素当作样本、通道当作特征，则逐位置全连接即 1×1 卷积。NiN 块为

$$\text{NiN-block} = (\text{ReLU} \circ \text{Conv}_{1 \times 1})^2 \circ (\text{ReLU} \circ \text{Conv}_{k \times k}),$$

先用 $k \times k$ 提取局部模式分数，再用两个 1×1 在每个像素的通道维上做非线性混合。设某位置通道向量为 $\mathbf{x}_{ij}$ ，两个 1×1 即

$$\mathbf{h}_{ij} = \text{ReLU}(\mathbf{W}_1 \mathbf{x}_{ij} + \mathbf{b}_1), \quad \mathbf{y}_{ij} = \text{ReLU}(\mathbf{W}_2 \mathbf{h}_{ij} + \mathbf{b}_2).$$

$\mathbf{W}_1, \mathbf{W}_2$ 的形状为 $c \times c$ (通道进、通道出)，对应核 $c \times c \times 1 \times 1$ ； $\mathbf{h}_{ij}, \mathbf{y}_{ij}$ 与 $\mathbf{x}_{ij}$ 同为该格的通道向量，不是把权重指数化。若去掉 ReLU，则 $\mathbf{W}_2 \mathbf{W}_1 \mathbf{x}_{ij}$ 并成一次线性通道变换，两层与一层等价。块内两个 1×1 通常保持通道数不变 (如 $96 \rightarrow 96$)，目的不是加

宽通道，而是给逐像素 MLP 加一层隐表示；空间混合只发生在块首的 $k \times k$ 卷积。每个输出条目是该位置、该通道上经过逐像素 MLP 后的特征响应；空间高宽由 $k \times k$ 卷积的填充与步幅决定。

7.3.2 NiN 模型

卷积窗口取 11×11 、 5×5 、 3×3 ，通道设置平行于 AlexNet。每块后接 3×3 、步幅 2 的最大汇聚，输出每个条目是窗口内最强响应，空间高宽按公式缩小。取消末端全连接：最后一块输出通道数等于类别数 q ，再全局平均汇聚

$$o_c = \frac{1}{hw} \sum_{i=1}^h \sum_{j=1}^w [H]_{c,ij}, \quad c = 1, \dots, q.$$

$H_{c,ij}$ 是类别通道 c 在位置 (i, j) 的响应； o_c 是该通道在整张图上的平均响应，作为类 c 的 logit（未归一化打分）。 h, w 是该特征图的空间高宽（格点数）， $1/(hw)$ 把总和变成平均，不改变“这是类 c 的整体分数”这一含义。参数量显著小于大全连接，但有时增加达到相同训练误差的时间。

7.3.3 训练模型

在 Fashion-MNIST 上的目标与 AlexNet、VGG 相同，只是 f_θ 换成 NiN 块加全局平均汇聚。softmax($\mathbf{o}$) 的分量才是各类概率。

7.3.4 小结

NiN 用 $k \times k$ 后接两个 1×1 的块提供逐像素 MLP（非线性来自 ReLU），并用全局平均汇聚代替全连接输出。两个 1×1 通常不增加通道数。 o_c 是类 c 在空间上的平均响应，不是空间尺寸。

7.3.5 练习

去掉块中一个 1×1 层，核验逐像素非线性深度如何改变：少一层 ReLU 后，逐像素 MLP 变浅，通道组合能力下降，不是参数指数化失败。并估计参数量主要来自各 Conv_k 的 $c_o c_i k^2$ 。该乘积是单个核的参数个数（计数）；两个 1×1 各贡献约 c^2 个参数。一次性把 $384 \times 5 \times 5$ 用单次线性映到 $10 \times 5 \times 5$ ，缺少中间隐层，分类头过陡。全局平均汇聚把每张类别图在空间上平均成一个 logit，不把 10 个通道加总成一张图。

7.4 含并行连结的网络（GoogLeNet）




图 7.4.1 Inception 块的架构。

符号：四条支路：不同核尺寸的卷积/汇聚，输出在通道维拼接




图 7.4.2 GoogLeNet 架构。

符号：Inception 块堆叠成 GoogLeNet；辅分类器：中间监督

不同任务上“最佳”核宽并不唯一。Inception 在同一层并行使用多种窗口，再沿通道连结。

7.4.1 Inception 块

四条路径并行，输出在通道维连结：

$$\begin{aligned} P_1 &= \text{Conv}_{1 \times 1}(X), \\ P_2 &= \text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}(X)), \\ P_3 &= \text{Conv}_{5 \times 5}(\text{Conv}_{1 \times 1}(X)), \\ P_4 &= \text{Conv}_{1 \times 1}(\text{MaxPool}_{3 \times 3}(X)), \\ H &= [P_1, P_2, P_3, P_4]. \end{aligned}$$

各 P_r 的每个空间-通道条目是该路径检出的局部模式分数（或对汇聚摘要再混合后的分数）；连结 H 不产生新数值，只把四路已有特征在通道维拼在一起。中间路径的 1×1 先把通道数降为 c' ， c' 是降维后的通道个数，再做 3×3 或 5×5 ，以降低乘加次数 $c_o c_i k^2 n'_h n'_w$ ，其中 n'_h, n'_w 是输出特征图的空间高宽。各路径输出高宽相同（靠填充），通道数相加：相加的是通道个数，不是把分数加在一起。

7.4.2 GoogLeNet 模型

九个 Inception 块与其间的最大汇聚堆叠，末端用全局平均汇聚而非大全连接。第一模块：64 通道、 7×7 卷积，64 是通道个数， 7×7 是核的空间尺寸。第二模块： 1×1 扩到 64 通道再 3×3 把通道乘三，对应 Inception 第二条路径。其后模块串联 Inception 块，块间汇聚降维：降的是空间格点数。通道分配比由实验选定。

7.4.3 训练模型

输入先变成 96×96 ，再在 Fashion-MNIST 上最小化同一分类损失。96 是空间边长（格点数）；损失仍是交叉熵。

7.4.4 小结

Inception 把多尺度 $\text{Conv}_{1,3,5}$ 与汇聚并行后连结，并用 1×1 降维；GoogLeNet 将其重复九次。连结后每个条目仍是某一路径的局部模式分数。

7.4.5 练习

比较删去部分路径后的 Inception 与残差块的关系；并核验通道分配改变时 H 的通道维 $c_1 + c_2 + c_3 + c_4$ 。该和是四条路径输出通道个数之和，决定特征图有几条通道。

7.5 批量规范化

深层网难以在短时间内收敛。批量规范化 (batch normalization) 用小批量统计量校正中间表示，并可与残差块一起支持很深的 f 。

7.5.1 训练深层网络

对小批量 $\mathcal{B}$ 中的向量，

$$\begin{aligned}\hat{\boldsymbol{\mu}}_{\mathcal{B}} &= \frac{1}{|\mathcal{B}|} \sum_{\mathbf{x} \in \mathcal{B}} \mathbf{x}, \\ \hat{\boldsymbol{\sigma}}_{\mathcal{B}}^2 &= \frac{1}{|\mathcal{B}|} \sum_{\mathbf{x} \in \mathcal{B}} (\mathbf{x} - \hat{\boldsymbol{\mu}}_{\mathcal{B}})^2 + \epsilon, \\ \text{BN}(\mathbf{x}) &= \boldsymbol{\gamma} \odot \frac{\mathbf{x} - \hat{\boldsymbol{\mu}}_{\mathcal{B}}}{\hat{\boldsymbol{\sigma}}_{\mathcal{B}}} + \boldsymbol{\beta}.\end{aligned}$$

$\hat{\boldsymbol{\mu}}_{\mathcal{B}}$ 是该批量上每个通道（或特征）的样本均值，与激活同量纲，表示这一批里该通道的平均响应。 $\hat{\boldsymbol{\sigma}}_{\mathcal{B}}^2$ 是对应的样本方差（加 $\epsilon > 0$ 避免除零），量纲是激活的平方，表示该通道在这一批里起伏有多大。中间量 $(\mathbf{x} - \hat{\boldsymbol{\mu}}_{\mathcal{B}})/\hat{\boldsymbol{\sigma}}_{\mathcal{B}}$ 是按通道标准化后的激活：在这一批内该通道近似均值 0、方差 1，无量纲。再经 $\boldsymbol{\gamma}, \boldsymbol{\beta}$ 做可学习仿射： $\boldsymbol{\gamma}_c$ 恢复该通道的尺度， $\boldsymbol{\beta}_c$ 恢复偏移，使层不必被钉死在标准正态。初始化通常 $\boldsymbol{\gamma} = 1$ 、 $\boldsymbol{\beta} = 0$ ，此时 BN 接近纯标准化。除以 $\hat{\boldsymbol{\sigma}}$ 会把起伏过大的通道压小、把起伏过小的通道放大，目标是把各层、各通道拧到相近量级，从而使同一学习率 η 在不同通道上效果接近；不是把类间特征差距故意拉大。拉开类间距离是后面分类层与交叉熵的事。 η 是参数更新步长；激活尺度被拉齐后， ∇L 的量级更一致。标准化针对的是激活值，不是空间高宽那些整数。 $|\mathcal{B}| = 1$ 时减去自身均值后激活全为 0，故批量不能过小。

7.5.2 批量规范化层

BN 依赖整个小批量，不能在公式中把批量大小当作 1 而忽略。全连接与卷积上的归约轴不同。

7.5.2.1 全连接层

放在仿射与激活之间：

$$\mathbf{h} = \phi(\text{BN}(\mathbf{W}\mathbf{x} + \mathbf{b})).$$

$\mathbf{W}\mathbf{x} + \mathbf{b}$ 的每个分量是线性打分；BN 先把它在批量维上按特征标准化成均值 0、方差 1，再仿射，最后 ϕ 给出非线性激活。 $\boldsymbol{\gamma}, \boldsymbol{\beta}$ 与特征同维。

7.5.2.2 卷积层

同样放在卷积之后、 ϕ 之前。每个输出通道一套标量 γ_c, β_c 。若批量大小为 m 、空间为 $p \times q$ ，则第 c 通道在 $m \cdot p \cdot q$ 个元素上共用同一 $\hat{\mu}_c, \hat{\sigma}_c$ 。 m, p, q 是样本数与空间高宽（计数）； $\hat{\mu}_c$ 是这 $m \cdot p \cdot q$ 个激活的平均， $\hat{\sigma}_c$ 是其标准差。标准化后该通道在整批、全空间上均值约 0、方差约 1；每个空间位置上的数仍是（已校正尺度的）局部模式响应。

7.5.2.3 预测过程中的批量规范化

预测时不再使用当前微批的噪声统计，且可能 $|\mathcal{B}| = 1$ 。用训练期移动平均 μ, σ 代替 $\hat{\mu}_B, \hat{\sigma}_B$ ，使 BN 成为确定映射。 μ, σ 是训练中见到的通道均值与标准差的平滑估计，含义与批量矩相同，只是不再随当前批抖动。因此训练与预测的计算公式不同。

7.5.3 从零实现

实现对应上面的 $\text{BN}_{\gamma, \beta}$ ：训练时用批量矩并更新移动平均，预测时用移动平均。 γ, β 是参数；特征数在从零实现中需预先给出，该数是通道或特征的个数。

7.5.4 使用批量规范化层的 LeNet

在每个卷积或全连接之后、激活之前插入 BN。训练目标不变，但中间表示被校正为（仿射前）按通道均值 0、方差 1，通常允许更大的 η 。第一层 BN 学到的 γ, β 可直接读出： γ_c 是该通道被允许的尺度， β_c 是偏移。

7.5.5 简明实现

框架中的 BN 与从零公式同一映射，只是核在编译后端上计算。同一超参数下应得到同构的 f_θ 。读出的标准化激活同样是按通道均值 0、方差 1 后再仿射的结果。

7.5.6 争议

BN 常使优化更平滑，并有正则化副作用。将其解释为减少“内部协变量偏移”并不严谨：该说法与标准协变量偏移不是同一对象，也未构成对泛化的完整证明。

7.5.7 小结

训练时

$$\text{BN}(\mathbf{x}) = \gamma \odot (\mathbf{x} - \hat{\mu}_B) / \hat{\sigma}_B + \beta;$$

括号内是按通道标准化后的激活（批量内均值 0、方差 1），再由 γ, β 恢复尺度与偏移。预测改用全局移动矩。全连接与卷积的归约轴不同，但标准化的都是激活值，不是空间尺寸。

7.5.8 练习

核验仿射层在 BN 前是否仍需要偏置 b （BN 已含 β ）；并比较有无 BN 时可用的 η 上界。 β 已经是标准化后的加性偏移，与 b 角色重叠。

7.6 残差网络（ResNet）




图 7.6.1 对于非嵌套函数类，较复杂（由较大区域表示）的函数类不能保证更接近“真”函数（ f^* ）。这种现象在嵌套函数类中不会发生。

符号： f^* ：目标函数；嵌套类：更大的函数族包含更小的




图 7.6.2 一个正常块（左图）和一个残差块（右图）。

符号： $f(x)$ ：残差支路； x ：快捷连接； 输出： $f(x) + x$




图 7.6.3 包含以及不包含 1×1 卷积层的残差块。

符号： 1×1 ：通道匹配； 实线：空间尺寸不变； 虚线：下采样




图 7.6.4 ResNet-18 架构

符号：conv1：首卷积；stage：残差阶段；GAP：全局平均汇聚

加深时必须保证新层不会把已有函数类变差。残差连接把恒等映射作为默认分量。

7.6.1 函数类

在函数类 $\mathcal{F}$ 中选

$$f_{\mathcal{F}}^* := \operatorname{argmin}_{f \in \mathcal{F}} L(\mathbf{X}, \mathbf{y}, f).$$

L 是标量训练损失； $f_{\mathcal{F}}^*$ 是该类里使损失最小的那个映射。若 $\mathcal{F}_1 \subset \mathcal{F}_2$ ，则

$$\min_{f \in \mathcal{F}_2} L \leq \min_{f \in \mathcal{F}_1} L.$$

两边都是最小可达损失（非负标量）；嵌套类使更深模型至少能表示更浅模型。构造上需让恒等容易实现。

7.6.2 残差块

设理想映射为 $f(\mathbf{x})$ 。直接拟合 $f(\mathbf{x})$ 改为拟合残差 $F(\mathbf{x}) := f(\mathbf{x}) - \mathbf{x}$ ，则

$$f(\mathbf{x}) = \mathbf{x} + F(\mathbf{x}).$$

输入 $\mathbf{x}$ 是上一层传来的信号（激活或特征图）； $F(\mathbf{x})$ 是残差分支算出的修正量，与 $\mathbf{x}$ 同形状、同量纲。相加后每个条目是原信号加上残差修正：若某处不需要改，最优是 $F \approx 0$ ，输出就等于原来的 $\mathbf{x}$ 。该和是特征响应，不是空间尺寸相加。若最优为恒等 $f(\mathbf{x}) = \mathbf{x}$ ，只需 $F \approx \mathbf{0}$ 。形状相同用恒等捷径；通道或步幅改变时用 1×1 投影 $\mathbf{W}_s$ ：

$$\mathbf{y} = \phi(\mathbf{x} + F(\mathbf{x})) \quad \text{or} \quad \phi(\mathbf{W}_s \mathbf{x} + F(\mathbf{x})).$$

$\mathbf{W}_s \mathbf{x}$ 把捷径上的原信号改到与 $F(\mathbf{x})$ 相同的通道与空间尺寸，再逐元素相加； ϕ 通常是 ReLU，输出每个条目仍是“校正后的信号再经非线性”。块内 F 通常为两层 $\text{Conv} \circ \text{BN} \circ \text{ReLU}$ 。前向实现上，相加发生在第二个 ReLU 之前： F 的末层是 BN，与（可能经 $\mathbf{W}_s$ 的） $\mathbf{x}$ 相加后再 ϕ 。捷径上的 1×1 只为对齐形状，不是 NiN 那种两层逐像素 MLP。这样做是为了让更深的网能够被训练：新层默认可以接近恒等，再学残差修正；不是换了一种与 SGD 不同的学习算法。

7.6.3 ResNet 模型

前两层同 GoogLeNet 风格：64 通道、 7×7 卷积（步幅 2），再 3×3 最大汇聚（步幅 2），每卷积后接 BN。64 是通道个数；7,3 是核或窗口边长；步幅 2 使空间高宽约减半。其后四个模块由残差块组成：第一模块不降空间尺寸，之后每模块在首块把通道翻倍、高宽减半。演示中每模块两个残差块。末端全局平均汇聚加全连接，得到类别打分。

7.6.4 训练模型

在 Fashion-MNIST 上最小化同一分类损失；前向为嵌套的 $\mathbf{x} \mapsto \mathbf{x} + F(\mathbf{x})$ 。每一层输出的每个数都是原特征加上该层学到的残差修正。

7.6.5 小结

残差块实现 $f(\mathbf{x}) = \mathbf{x} + F(\mathbf{x})$ ，输出中每个条目是原信号加残差修正，使更深 $\mathcal{F}$ 容易包含恒等。浅网本来不必残差；残差是为了让加层之后训练误差仍能下降，从而深度从负担变成可用的容量。

7.6.6 练习

比较 Inception 多路径连结与 $\mathbf{x} + F(\mathbf{x})$ 相加的差别；并说明即使 $\mathcal{F}$ 嵌套，仍要限制 F 的复杂度以免过拟合。连结拼的是通道，相加要求形状相同并把对应位置的响应加在一起。

7.7 稠密连接网络 (DenseNet)




图 7.7.1 ResNet (左) 与 DenseNet (右) 在跨层连接上的主要区别：使用相加和使用连结。

符号：ResNet：相加；DenseNet：拼接； x ：输入特征




图 7.7.2 稠密连接。

符号：稠密块：特征在通道维拼接；过渡层：压缩通道并下采样

DenseNet 把残差的加法换成通道维连结，使第 ℓ 层看见之前所有层的特征。

7.7.1 从 ResNet 到 DenseNet

泰勒展开

$$f(x) = f(0) + f'(0)x + \frac{f''(0)}{2!}x^2 + \frac{f'''(0)}{3!}x^3 + \dots$$

把 f 拆成不同阶项。 $f(0)$ 是常数项， $f'(0)x$ 是一阶项，其余为高阶；每一项与 $f(x)$ 同量纲。ResNet 的一阶切分是

$$f(\mathbf{x}) = \mathbf{x} + g(\mathbf{x}),$$

即原信号加一份修正。DenseNet 把“加上 $g(\mathbf{x})$ ”换成与此前所有映射的连结

$$\mathbf{x} \longrightarrow [\mathbf{x}, f_1(\mathbf{x}), f_2([\mathbf{x}, f_1(\mathbf{x})]), f_3([\mathbf{x}, f_1(\mathbf{x}), f_2([\mathbf{x}, f_1(\mathbf{x})])]), \dots].$$

连结不把响应相加，只增加通道：后面的层同时读到原始特征与各层新算出的特征，每个条目仍是各自的模式响应。信息以拼接而非求和跨层传递。

7.7.2 稠密块体

块内使用 $\text{BN} \circ \text{ReLU} \circ \text{Conv}$ 。第 i 个卷积块输出 k 个通道（增长率 growth rate），并与输入在通道维连结。 k 是每次新增加的通道个数。若输入通道为 c_0 、块内 m 个卷积块，则输出通道

$$c_0 + mk.$$

该和是通道个数（轴长度），例如 $c_0 = 3$ 、 $m = 2$ 、 $k = 10$ 时输出 $3 + 20 = 23$ 条通道，不是把 23 加到像素上。连结 cat 本身不混合特征，只沿通道维堆叠；下一卷积块以 $c_0 + ik$ 为输入通道数，按多输入通道互相关把已拼接的通道加权求和，才长出新的 k 张图。非线性仍来自块内 ReLU，不是来自拼接。拼接的效果是特征复用：后面层可以直接读到前面每一层的特征图，而不是把旧通道与新变换加进同一组通道里。

7.7.3 过渡层

稠密块使通道单调增加。过渡层用 1×1 卷积把通道压到 c' ，再用步幅 2 的平均汇聚减半高宽：

$$\mathbf{X} \mapsto \text{AvgPool}_{2,2}(\text{Conv}_{1 \times 1}(\mathbf{X})).$$

1×1 卷积每个输出条目是逐像素通道混合后的分数； c' 是压缩后的通道个数。平均汇聚每个条目是 2×2 窗口的平均响应，空间高宽减半指格点数减半。从而控制模型复杂度。稠密连接只发生在同一稠密块内部；过渡层之后开始新的一段，不再与上一块的每一层直接连结。块间用 1×1 处理 cat 得到的厚通道，块内则由下一个卷积处理。

7.7.4 DenseNet 模型

茎部与 ResNet 相同：卷积加最大汇聚。随后四个稠密块，演示中每块 4 层、增长率 32，故每块增加 128 通道。4、32、128 都是计数（层数、每层新增通道、块内总新增通道）。块间用过渡层减半空间并减半通道。末端全局汇聚加全连接，得到类别打分。

7.7.5 训练模型

网络较深时把输入高宽从 224 降到 96 以减小 chw 带来的显存，再在 Fashion-MNIST 上训练。 c, h, w 分别是通道数与空间高宽，其乘积正比于特征张量的元素个数，不是激活的数值大小。

7.7.6 小结

ResNet 用 $\mathbf{x} + F(\mathbf{x})$ ，输出是原信号加残差修正；DenseNet 用通道连结 $[\mathbf{x}, f_1(\mathbf{x}), f_2([\mathbf{x}, f_1(\mathbf{x})]), \dots]$ ，每个通道上的数仍是该层的特征响应，并由过渡层控制维数。

7.7.7 练习

解释参数量相对 ResNet 更小（核看到已拼接特征，无需再学一份副本）；并核验输入改为 224×224 时连结张量的显存如何随层数线性增长。224 是空间边长；显存随通道个数 $c_0 + mk$ 线性增加。

第八章 循环神经网络

序列把观测写成按时间排列的随机变量。语言模型把联合分布因式分解为条件概率 $P(x_1, \dots, x_T)$ ，循环神经网络用共享参数的隐状态压缩历史，并通过时间反向传播计算梯度。正文保留原书标题，内容以公式为主。

8.1 序列模型




图 8.1.1 近 30 年的富时 100 指数

符号：见图中标注；各块含义见题注。




图 8.1.2 隐变量自回归模型

符号: x_t : 序列值; $\hat{x}_{t+1}$: 下一步预测

记观测序列为 $x_1, \dots, x_T$ 。每个时间步的合法预测只能依赖已经发生的历史, 而不能依赖未来。下面先固定条件分布, 再写成可训练的特征-标签对。

8.1.1 统计工具

对任意 t , 当前项的生成规律是条件分布

$$x_t \sim P(x_t \mid x_{t-1}, \dots, x_1).$$

右边是在已经见到前 $t-1$ 项的条件下, x_t 取各个合法值的概率, 每个概率在 $[0, 1]$ 且对 x_t 求和为 1。联合分布由这些条件依次相乘得到。不同的条件独立性假设对应不同的模型类。

8.1.1.1 自回归模型

链规则给出精确分解

$$P(x_1, \dots, x_T) = \prod_{t=1}^T P(x_t \mid x_{t-1}, \dots, x_1).$$

左边是整条序列同时出现的联合概率, 在 $[0, 1]$; 右边每一因子是下一步的条件概率。自回归模型直接估计右侧每个条件分布, 输入是过去观测本身。隐变量自回归则另设 $h_t = f(x_t, h_{t-1})$, 再用 $P(x_t \mid h_{t-1})$ 近似条件。 h_t 是到时刻 t 为止的压缩摘要: 固定长度的向量, 用来代替越来越长的原始历史 $(x_1, \dots, x_t)$ 。

8.1.1.2 马尔可夫模型

若只依赖最近一项，则得到一阶马尔可夫模型

$$P(x_1, \dots, x_T) = \prod_{t=1}^T P(x_t | x_{t-1}), \quad P(x_1 | x_0) = P(x_1).$$

每个 $P(x_t | x_{t-1})$ 是“前一项为 x_{t-1} 时当前项为 x_t ”的概率，仍在 $[0, 1]$ 。此时隔一步的条件可由全概率公式消去中间变量：

$$\begin{aligned} P(x_{t+1} | x_{t-1}) &= \frac{\sum_{x_t} P(x_{t+1}, x_t, x_{t-1})}{P(x_{t-1})} \\ &= \sum_{x_t} P(x_{t+1} | x_t) P(x_t | x_{t-1}). \end{aligned}$$

$P(x_{t+1} | x_{t-1})$ 是隔一步的转移概率，把所有可能的中间 x_t 按路径概率加权求和，结果仍在 $[0, 1]$ 。更高阶只是把条件窗口从 1 换成 τ ， τ 是回看的步数（正整数），不是观测值。

8.1.1.3 因果关系

时间向前时，用过去解释现在。若强行反过来因式分解，

$$P(x_1, \dots, x_T) = \prod_{t=T}^1 P(x_t | x_{t+1}, \dots, x_T),$$

则每个因子变成“由未来推断过去”的条件概率，数值上仍在 $[0, 1]$ ，但估计对象不再是因果生成过程。因果序列上正向条件通常比反向更容易稳定估计。

8.1.2 训练

用正弦加噪声生成 $x_t = \sin t + \epsilon_t$ ， $t = 1, \dots, 1000$ 。 x_t 与 $\sin t$ 同量纲，是该时刻的观测； ϵ_t 是加性噪声。嵌入窗口长度 τ 后，监督对为

$$y_t = x_t, \quad \mathbf{x}_t = (x_{t-\tau}, \dots, x_{t-1}).$$

y_t 是要预测的当前观测； $\mathbf{x}_t \in \mathbb{R}^\tau$ 的分量是紧邻的过去 τ 个观测，不是时间下标本身。前 τ 项没有完整历史，故丢弃；训练只用前 600 个对，600 是样本个数。于是回归映射是

$$\hat{x}_t = f(\mathbf{x}_t).$$

$\hat{x}_t$ 是与 x_t 同量纲的点预测，不是概率。

8.1.3 预测

单步预测把真实历史送入 f 。多步则把已有预测再送回去。以 $\tau = 4$ 为例，

$$\hat{x}_{605} = f(x_{601}, x_{602}, x_{603}, x_{604}),$$

$$\hat{x}_{606} = f(x_{602}, x_{603}, x_{604}, \hat{x}_{605}),$$

$$\hat{x}_{607} = f(x_{603}, x_{604}, \hat{x}_{605}, \hat{x}_{606}).$$

每个 $\hat{x}_t$ 仍是该时刻观测的点预测。当输入窗口全部换成 $\hat{x}$ 后，误差沿时间累积，这就是 k 步预测； k 是向前看的步数。

8.1.4 小结

序列模型的核心对象是

$$P(x_1, \dots, x_T) = \prod_{t=1}^T P(x_t \mid x_{t-1}, \dots, x_1),$$

每个因子是下一步取值的条件概率；训练必须尊重时间顺序； k 步预测把估计误差迭代送入同一映射 f 。

8.1.5 练习

核验对象是窗口长度 τ 、噪声为零时正弦的最小充分历史，以及把已有 $\hat{x}$ 反馈后 k 步误差如何放大。误差 $\hat{x}_t - x_t$ 与观测同量纲，表示预测偏了多少。

8.2 文本预处理

文本是离散序列。预处理把它映成整数下标序列，供后面的语言模型计算 $P(x_1, \dots, x_T)$ 。

8.2.1 读取数据集

语料是字符串行的列表。清洗后每行是小写字母与空格组成的序列，标点与大小写差异被抹掉，得到原始字符流。这里还没有数值，只有符号。

8.2.2 词元化

词元化是映射

$$\text{tokenize} : \text{string} \longrightarrow (z_1, \dots, z_L), \quad z_\ell \in \mathcal{Z},$$

其中 $\mathcal{Z}$ 是词元集合，可取单词或字符。输出是词元列表的列表。 L 是一条文本被切成的词元个数； z_ℓ 是符号，尚未变成整数。

8.2.3 词表

词表是单射

$$\text{Vocab} : \mathcal{Z} \cup \{\text{<unk>}\} \longrightarrow \{0, 1, \dots, |\mathcal{V}| - 1\}.$$

每个词元被映成一个整数下标，取值于 0 到 $|\mathcal{V}| - 1$ ； $|\mathcal{V}|$ 是词表大小（有多少个不同词元），不是某个词的频率。先统计语料频率 $n(z)$ ， $n(z)$ 是非负整数，表示词元 z 出现了多少次。丢掉 $n(z) < m$ 的低频项， m 是频次阈值；剩余按频次分配下标。未见或已删词元映到 <unk> 。可选地加入填充 <pad> 、开始 <bos> 、结束 <eos> 。

8.2.4 整合所有功能

把读入、词元化与查表合成

$$\text{text} \longmapsto (\text{corpus}, \text{vocab}),$$

其中 $\text{corpus} = (x_1, \dots, x_T)$ 且 $x_t \in \{0, \dots, |\mathcal{V}| - 1\}$ 。每个 x_t 是词元在词表中的整数编号，不是该词的嵌入向量，也不是概率。后续字符级语言模型把整本语料当作一条长序列，而不是按行切成多条。

8.2.5 小结

预处理的终点是整数序列 $(x_1, \dots, x_T)$ 与词表 Vocab ，后面所有概率都定义在这套下标上： x_t 是类别编号。

8.2.6 练习

核验词元粒度（字符或词）以及最低频次 m 如何改变 $|\mathcal{V}|$ 。 $|\mathcal{V}|$ 变大表示词表更宽，输出层要预测的类别数随之增加。

8.3 语言模型和数据集

the time machine by h g wells
 the time machine by h g wells
 the time machine by h g wells
 the time machine by h g wells
 the time machine by h g wells
 the time machine by h g wells

图 8.3.1 分割文本时，不同的偏移量会导致不同的子序列

符号：见图中标注；各块含义见题注。

语言模型的对象是词元序列的联合分布

$$P(x_1, x_2, \dots, x_T).$$

该数是整句同时出现的概率，在 $[0, 1]$ 。估计该分布后，就能给任意句子打分，也能逐项生成后续词元。

8.3.1 学习语言模型

链规则仍然成立：

$$P(x_1, x_2, \dots, x_T) = \prod_{t=1}^T P(x_t \mid x_1, \dots, x_{t-1}).$$

每个条件因子是“历史已定时下一个词元为 x_t ”的概率。例如

$$\begin{aligned} &P(\text{deep, learning, is, fun}) \\ &= P(\text{deep}) P(\text{learning} \mid \text{deep}) P(\text{is} \mid \text{deep, learning}) \\ &\quad \cdot P(\text{fun} \mid \text{deep, learning, is}). \end{aligned}$$

四个因子都在 $[0, 1]$ ，乘积是这四个词按该顺序出现的联合概率。计数估计是

$$\hat{P}(\text{learning} \mid \text{deep}) = \frac{n(\text{deep, learning})}{n(\text{deep})}.$$

分子是二元组出现次数，分母是前一词出现次数；商是相对频率，作为条件概率的估计，在 $[0, 1]$ 。低频组合用拉普拉斯平滑：

$$\begin{aligned}\hat{P}(x) &= \frac{n(x) + \epsilon_1/m}{n + \epsilon_1}, \\ \hat{P}(x' | x) &= \frac{n(x, x') + \epsilon_2 \hat{P}(x')}{n(x) + \epsilon_2}, \\ \hat{P}(x'' | x, x') &= \frac{n(x, x', x'') + \epsilon_3 \hat{P}(x'')}{n(x, x') + \epsilon_3}.\end{aligned}$$

各式分子分母都在计次上加伪计数 ϵ ，得到的仍是 $[0, 1]$ 上的概率估计，避免零频导致条件概率为 0。

8.3.2 马尔可夫模型与 n 元语法

截断条件窗口得到 n 元语法。对长度为 4 的序列，

$$\begin{aligned}P(x_1, x_2, x_3, x_4) &= P(x_1)P(x_2)P(x_3)P(x_4), \\ P(x_1, x_2, x_3, x_4) &= P(x_1)P(x_2 | x_1)P(x_3 | x_2)P(x_4 | x_3), \\ P(x_1, x_2, x_3, x_4) &= P(x_1)P(x_2 | x_1)P(x_3 | x_1, x_2)P(x_4 | x_2, x_3).\end{aligned}$$

三式分别是一元、二元、三元语法：每一因子仍是（条件）概率，只是条件里记住的历史长度不同。

8.3.3 自然语言统计

词频近似服从齐普夫定律。按降序排列后

$$n_i \propto \frac{1}{i^\alpha}, \quad \log n_i = -\alpha \log i + c.$$

n_i 是第 i 高频词的出现次数（非负整数）； $\alpha > 0$ 是幂律指数，无量纲； c 是对数坐标下的截距。该幂律不仅出现在一元语法，也出现在更高阶 n 元计数上，因此长片段的经验频率会迅速变得极稀。

8.3.4 读取长序列数据

语料长度 T 通常远大于一次能送入网络的步数 n 。 T, n 都是词元个数。把长序列切成长度为 n 的子序列，标签是整体左移一项后的序列，即用 $(x_t, \dots, x_{t+n-1})$ 预测 $(x_{t+1}, \dots, x_{t+n})$ 。每个 x 仍是词表下标。

8.3.4.1 随机采样

每个小批量在长序列上独立抽取起点。相邻两个批量的子序列在原文中不必相邻。长度为 35、步数 5 时可切出

$$\lfloor (35 - 1)/5 \rfloor = 6$$

个特征-标签对；批量大小为 2 时得到 3 个批量。6 和 3 都是条数或批次数（计数），不是词元编号。

8.3.4.2 顺序分区

相邻批量的第 i 条子序列在原文中也相邻。隐状态可以跨批量延续；随机采样则每个批量必须重新初始化隐状态。两种读法都输出形状为 $(\text{batch size}, n)$ 的 $(\mathbf{X}, \mathbf{Y})$ ：第一维是批量中有几条序列，第二维是每条有几个时间步；每个条目是词表下标。

8.3.5 小结

语言模型估计 $P(x_1, \dots, x_T)$ ； n 元语法用马尔可夫截断使计数可行，长序列则按随机采样或顺序分区切成固定长度窗口。窗口长度 n 是时间步个数，窗口里的数是词元编号。

8.3.6 练习

核验四元语法在词表大小 10^5 时要存储的计数规模，以及随机偏移是否让窗口起点在文档上接近均匀。 10^5 是 $|\mathcal{V}|$ ，计数规模是需要记住的 n 元组个数。

8.4 循环神经网络




图 8.4.1 具有隐状态的循环神经网络

符号: x_t : 时刻 t 输入; h_t : 隐状态; o_t : 输出




图 8.4.2 基于循环神经网络的字符级语言模型: 输入序列和标签序列分别为 “machin” 和 “achine”

符号: 输入: 前缀字符; 标签: 下一字符; h : 跨步共享隐状态

用一个隐状态压缩全部历史, 把变长条件改成固定形状的递推:

$$P(x_t | x_{t-1}, \dots, x_1) \approx P(x_t | h_{t-1}), \quad h_t = f(x_t, h_{t-1}).$$

h_{t-1} 是到 $t-1$ 为止整段序列的压缩摘要, 长度固定, 用来代替变长历史。 $P(x_t | h_{t-1})$ 是在该摘要下下一个词元的条件概率。 $h_t = f(x_t, h_{t-1})$ 把当前词元并入摘要, 得到“到当前为止”的新摘要。参数不随 t 增加。

8.4.1 无隐状态的神经网络

把一个时间步的批量输入 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 送入普通隐层

$$\begin{aligned} \mathbf{H} &= \phi(\mathbf{X}\mathbf{W}_{xh} + \mathbf{b}_h), \\ \mathbf{O} &= \mathbf{H}\mathbf{W}_{hq} + \mathbf{b}_q. \end{aligned}$$

n 是批量大小, d 是每条样本的特征维。 $\mathbf{H}$ 的每一行是该样本的隐激活; $\mathbf{O}$ 的每一行是词表上的打分。不同时间步的 $\mathbf{H}$ 互不传递, 因此无法携带 t 之前的信息, 行向量不是序列摘要。

8.4.2 有隐状态的循环神经网络

加入跨时间的循环项 $\mathbf{W}_{hh}$:

$$\mathbf{H}_t = \phi(\mathbf{X}_t \mathbf{W}_{xh} + \mathbf{H}_{t-1} \mathbf{W}_{hh} + \mathbf{b}_h),$$

$$\mathbf{O}_t = \mathbf{H}_t \mathbf{W}_{hq} + \mathbf{b}_q.$$

其中 $\mathbf{X}_t \in \mathbb{R}^{n \times d}$, $\mathbf{H}_t \in \mathbb{R}^{n \times h}$, $\mathbf{O}_t \in \mathbb{R}^{n \times q}$. $\mathbf{H}_t$ 的第 i 行是第 i 条序列到时刻 t 的压缩摘要: 当前 $\mathbf{X}_t$ 与上一摘要 $\mathbf{H}_{t-1}$ 各经线性变换后相加, 不是 $\mathbf{H}$ 直接乘在 $\mathbf{X}$ 上。 $\mathbf{O}_t$ 的第 i 行是在该摘要下对词表各词元的线性打分, 经 softmax 后才是概率。同一套 $(\mathbf{W}_{xh}, \mathbf{W}_{hh}, \mathbf{W}_{hq})$ 在所有 t 上共享。

8.4.3 基于循环神经网络的字符级语言模型

词元取字符。批量大小为 1 时, 序列如 “machine” 的每个字符先映成向量, 再按时间送入上式。时刻 t 的标签是下一个字符, 输出 $\mathbf{O}_t$ 经 softmax 得到 $P(x_{t+1} | h_t)$: 向量每个分量在 $[0, 1]$ 且和为 1, 表示下一个字符是该类的概率。 h_t 此时是 “machine” 中前 t 个字符的压缩摘要。训练目标仍是

$$P(x_1, \dots, x_T) = \prod_{t=1}^T P(x_t | h_{t-1}).$$

每个因子用对应时刻的摘要代替完整历史, 乘积仍是整句联合概率的模型估计。

8.4.4 困惑度 (Perplexity)

平均负对数似然

$$\frac{1}{n} \sum_{t=1}^n -\log P(x_t | x_{t-1}, \dots, x_1)$$

是每个位置上交叉熵的平均, 单位是 nat (若 $\log$ 为自然对数): 越大表示模型给真实下一词的概率越低。再指数化, 得到困惑度

$$\exp\left(-\frac{1}{n} \sum_{t=1}^n \log P(x_t | x_{t-1}, \dots, x_1)\right).$$

它是模型在每个位置上有效分支数的几何平均: 均匀乱猜约为 $|\mathcal{V}|$, 完美预测为 1。该数无量纲, 越小越好。

8.4.5 小结

循环计算

$$\mathbf{H}_t = \phi(\mathbf{X}_t \mathbf{W}_{xh} + \mathbf{H}_{t-1} \mathbf{W}_{hh} + \mathbf{b}_h)$$

使 h_t 成为到当前为止的序列压缩摘要, 并用困惑度衡量 $P(x_t | h_{t-1})$ 的质量。

8.4.6 练习

核验下一字符的输出维必须等于 $|\mathcal{V}|$ ，以及沿很长的 t 反传时乘积 $\prod_j \partial h_j / \partial h_{j-1}$ 的尺度。每个 $\partial h_j / \partial h_{j-1}$ 是摘要对上一摘要的局部敏感度；乘积决定早期词对最终损失的影响有多大。

8.5 循环神经网络的从零开始实现

把上一节的映射在字符语料上展开：独热输入、共享循环核、裁剪后的梯度更新，以及用困惑度衡量的生成。

8.5.1 独热编码

词表大小为 N 时，下标 i 映到单位向量 $\mathbf{e}_i \in \{0, 1\}^N$ ， $(\mathbf{e}_i)_j = [i = j]$ 。第 j 个分量是 1 表示“该词元就是类 j ”，0 表示不是；各分量互斥，和为 1。小批量时间步 $\mathbf{X}_t$ 的每一行都是某个 $\mathbf{e}_x$ ，因而 $\mathbf{X}_t \in \mathbb{R}^{n \times N}$ ，且 $\mathbf{X}_t \mathbf{W}_{xh}$ 选出 $\mathbf{W}_{xh}$ 的第 x 行，即该类的嵌入式线性特征。实现里先把词元编号矩阵 $\mathbf{X} \in \mathbb{Z}^{n \times n_{\text{steps}}}$ 转置再独热，得到

$$\text{one_hot}(\mathbf{X}^\top) \in \mathbb{R}^{n_{\text{steps}} \times n \times N}.$$

输入是整数下标；输出第三维是独热，第一维是时间。沿时间切开后每步仍是 $n \times N$ ，不是 $n_{\text{steps}} \times N$ ：一步同时吃 n 条样本各自的一个符号，再循环 n_{steps} 次。字符级《时光机器》上常见取值是 $n = 32$ 、 $n_{\text{steps}} = 35$ 、 $N \approx 28$ 。

8.5.2 初始化模型参数

隐藏宽度 h 与词表大小 N 决定可训练的五块

$$\mathbf{W}_{xh} \in \mathbb{R}^{N \times h}, \mathbf{W}_{hh} \in \mathbb{R}^{h \times h}, \mathbf{b}_h \in \mathbb{R}^h, \mathbf{W}_{hq} \in \mathbb{R}^{h \times N}, \mathbf{b}_q \in \mathbb{R}^N.$$

这些形状中的 N, h 是轴长度： N 是词表有多大， h 是摘要向量有几维。输入层与输出层共用同一词表，故两边维度都是 N 。 h 是容量超参数，与 n 、 n_{steps} 、 N 无公式关系；实验取 $h = 512$ 。权重用 $\mathcal{N}(0, 0.01^2)$ 初始化，偏置为零。 $\mathbf{H}$ 不在此列：它是状态，不是参数。

8.5.3 循环神经网络模型

初始隐状态 $\mathbf{H}_0 = \mathbf{0} \in \mathbb{R}^{n \times h}$ ，表示“还没有任何历史”的空摘要。一个时间步是

$$\mathbf{H}_t = \tanh(\mathbf{X}_t \mathbf{W}_{xh} + \mathbf{H}_{t-1} \mathbf{W}_{hh} + \mathbf{b}_h),$$

$$\mathbf{O}_t = \mathbf{H}_t \mathbf{W}_{hq} + \mathbf{b}_q.$$

$\mathbf{X}_t \mathbf{W}_{xh}$ 与 $\mathbf{H}_{t-1} \mathbf{W}_{hh}$ 都是 $n \times h$ ，再相加； $\mathbf{H}$ 并不直接乘在 $\mathbf{X}$ 上。 $\tanh$ 把摘要各维限制在 $(-1, 1)$ ； $\mathbf{H}_t$ 仍是到 t 为止的压缩摘要。 $\mathbf{O}_t \in \mathbb{R}^{n \times N}$ 是词表上的 logits，尚未是概率。第 i 行只由第 i 条样本的 $\mathbf{X}_t$ 与 $\mathbf{H}_{t-1}$ 决定，行与行不混合； $n \times h$ 是 n 份彼此独立的 h 维记忆。代码用同一变量覆盖 $\mathbf{H}$ ：留下的只有最新 $\mathbf{H}_t$ ， $\mathbf{H}_{t-1}$ 已被 $\mathbf{W}_{hh}$ 压进 $\mathbf{H}_t$ ，模型不并排保存两份。最外层按 $t = 1, \dots, n_{\text{steps}}$ 循环，把全部 $\mathbf{O}_t$ 在第 0 维拼接，得到 $n_{\text{steps}} n \times N$ 的打分矩阵。一层循环只有这一套共享权重：展开 n_{steps} 次、梯度加 n_{steps} 次、参数改一次。

8.5.4 预测

生成时批量大小为 1， $\mathbf{H} \in \mathbb{R}^{1 \times h}$ ，每步输入是 1×1 的词元编号。给定前缀。预热期把前缀中已有字符依次送入只更新 h_t ，丢掉 $\mathbf{O}_t$ ，目的是先把前缀压进摘要；outputs 追加的是前缀里真正的下一字符。预热结束时 $\mathbf{H}$ 已读过前缀除最后一词外的部分。之后每步取

$$\hat{x}_{t+1} = \underset{x}{\operatorname{argmax}} P(x | h_t)$$

或按该分布抽样，再把 $\hat{x}_{t+1}$ 作为下一输入。 $P(x | h_t)$ 由 $\mathbf{O}_t$ 经 softmax 得到，各分量在 $[0, 1]$ 且和为 1；argmax 得到的是概率最大的那个词元编号，不是概率值本身。生成路径不算梯度。

8.5.5 梯度裁剪

若目标函数 f 是 L -利普希茨连续的，则

$$|f(\mathbf{x}) - f(\mathbf{y})| \leq L \|\mathbf{x} - \mathbf{y}\|.$$

此处 L 是利普希茨常数（输入距离增加 1，输出最多变 L ），不是训练损失，也不是要调的超参数。沿梯度走一步后

$$|f(\mathbf{x}) - f(\mathbf{x} - \eta \mathbf{g})| \leq L \eta \|\mathbf{g}\|.$$

$\|\mathbf{g}\|$ 是把全部参数梯度拼成一个向量后的欧氏长度； $\eta \|\mathbf{g}\|$ 是这一步参数移动的尺度。真正裁剪用的超参数是半径 θ （实现里取 1）：

$$\mathbf{g} \leftarrow \min\left(1, \frac{\theta}{\|\mathbf{g}\|}\right) \mathbf{g}.$$

若 $\|\mathbf{g}\| \leq \theta$ 则不动，否则按比例缩短，方向不变。位置在一次 backward 之后、改参数之前。用来抑制爆炸，不修复消失。 θ 与 $\|\mathbf{g}\|$ 同量纲。

8.5.6 训练

一个迭代周期内：随机采样则每批量重置 h （空摘要）；顺序分区则延续 h 的数值，但 detach 切断对上一批量的计算图。最后一个批量若 n 对不上当前 H 的行数，也重新 begin_state。标签 $\mathbf{Y}$ 转置拉平后与拼接的 $\hat{\mathbf{Y}}$ 对齐，共 $n_{\text{steps}}n$ 个位置。逐步损失是交叉熵：对一行 logits 先 softmax 得 p ，再 $l = -\log p_{\text{真}}$ 。对打分的梯度是

$$\frac{\partial l}{\partial \mathbf{o}} = p - \text{onehot}(y).$$

输入是该行概率与真类编号；输出与 $\mathbf{o}$ 同形。真类维为 $p_k - 1 \leq 0$ （应抬高该分），其余维为 $p_i \geq 0$ （应压低）。批量上再对 $n_{\text{steps}}n$ 行取平均得到标量 L ，然后 backward 一次、裁剪一次、更新一次，不是按 n 或 n_{steps} 更新多次。从输出层回到隐藏层：

$$\frac{\partial L}{\partial \mathbf{W}_{hq}} = \sum_t \mathbf{H}_t^\top \frac{\partial L}{\partial \mathbf{O}_t}, \quad \frac{\partial L}{\partial \mathbf{H}_t} = \frac{\partial L}{\partial \mathbf{O}_t} \mathbf{W}_{hq}^\top.$$

左边分别是共享输出权重的梯度，以及该步摘要各维对 L 的敏感度。 $\partial L / \partial \mathbf{H}_t$ 再穿过 tanh 与 $\mathbf{W}_{hh}$ 沿时间倒走，这才是 BPTT。困惑度把全周期平均交叉熵再指数化：

$$\text{ppl} = \exp\left(\overline{-\log p_{\text{真}}}\right).$$

它是有效分支数的几何平均，下限为 1，均匀乱猜约为 N 。

8.5.7 小结

从零实现把

$$(\mathbf{e}_{x_t}, h_{t-1}) \mapsto (h_t, \mathbf{O}_t)$$

写成可训练循环核： h_t 是更新后的序列摘要， $\mathbf{O}_t$ 是下一词打分。预热提供可用的 h ，裁剪保证 $\|\mathbf{g}\|$ 有上界。

8.5.8 练习

核验独热与嵌入层第一层等价、去掉裁剪后 $\|\mathbf{g}\|$ 是否发散，以及用 $P(x)^\alpha$ 抽样如何改变生成分布。 $\alpha > 1$ 会让概率更集中在高频词， $\alpha < 1$ 更平坦； α 无量纲。

8.6 循环神经网络的简洁实现

同一套映射改由框架中的循环层一次性求值，输出层仍需单独写出。

8.6.1 定义模型

循环层接收 $\mathbf{X}_{1:T}$ 与 $\mathbf{H}_0$ ，返回

$$(\mathbf{H}_{1:T}, \mathbf{H}_T) = \text{RNN}(\mathbf{X}_{1:T}, \mathbf{H}_0).$$

$\mathbf{H}_{1:T}$ 的每个时间切片都是对应时刻的序列摘要， $\mathbf{H}_T$ 是读完整段后的最终摘要。这里的 $\mathbf{H}_{1:T}$ 还不是词表上的 logits；完整模型是

$$\mathbf{O}_t = \mathbf{H}_t \mathbf{W}_{hq} + \mathbf{b}_q.$$

$\mathbf{O}_t$ 的每个分量是该词元的线性打分。多层时，上一层的 $\mathbf{H}_t^{(\ell-1)}$ 作为下一层输入，仍是摘要，只是抽象层级更高。

8.6.2 训练与预测

随机初始化时前缀续写接近均匀乱猜，即 $P(x | h_t) \approx 1/|\mathcal{V}|$ 。训练目标、裁剪与困惑度与从零实现相同，只是 RNN 的逐步递推由编译后的算子完成。

8.6.3 小结

简洁实现不改变

$$\mathbf{H}_t = \phi(\mathbf{X}_t \mathbf{W}_{xh} + \mathbf{H}_{t-1} \mathbf{W}_{hh} + \mathbf{b}_h),$$

只把该递包装成层； h_t 的含义仍是到 t 为止的压缩摘要。词表上的 $\mathbf{O}_t$ 仍由单独的线性映射给出。

8.6.4 练习

核验增加隐藏层数是否仍收敛，以及用同一循环核拟合序列节中的自回归窗口 f 。更深只改变摘要的层数，不改变“ h_t 概括迄今历史”这一含义。

8.7 通过时间反向传播

the time machine by h g well




图 8.7.1 比较 RNN 中计算梯度的策略，3 行自上而下分别为：随机截断、常规截断、完整计算

符号：截断长度：反向传播的时间步数；阴影：本段求梯度的边




图 8.7.2 上图表示具有三个时间步的循环神经网络模型依赖关系的计算图。未着色的方框表示变量，着色的方框表示参数，圆表示运算符

符号：白箭头：前向；灰箭头：反向；圆：变量节点

损失对共享参数 w_h 的梯度必须沿 $h_T \rightarrow h_{T-1} \rightarrow \dots \rightarrow h_1$ 反传，这称为通过时间反向传播（BPTT）。

8.7.1 循环神经网络的梯度分析

一步映射与逐步损失为

$$h_t = f(x_t, h_{t-1}, w_h),$$

$$o_t = g(h_t, w_o),$$

$$L = \frac{1}{T} \sum_{t=1}^T l(y_t, o_t).$$

h_t 是时刻 t 的序列摘要； o_t 是由该摘要算出的输出打分； l 是该步损失； L 是各步平均，标量。对 w_h 求偏导：

$$\frac{\partial L}{\partial w_h} = \frac{1}{T} \sum_{t=1}^T \frac{\partial l(y_t, o_t)}{\partial o_t} \frac{\partial g(h_t, w_o)}{\partial h_t} \frac{\partial h_t}{\partial w_h}.$$

左边是共享循环参数增大时平均损失大约增加多少。隐状态本身对参数的依赖是递推

$$\frac{\partial h_t}{\partial w_h} = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial w_h} + \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial w_h}.$$

第一项是本步直接敏感度；第二项是经上一摘要间接传来的敏感度。令

$$a_t = \frac{\partial h_t}{\partial w_h}, \quad b_t = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial w_h},$$

$$c_t = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial h_{t-1}},$$

则 $a_t = b_t + c_t a_{t-1}$ ，展开为

$$a_t = b_t + \sum_{i=1}^{t-1} \left(\prod_{j=i+1}^t c_j \right) b_i.$$

c_j 是摘要对上一摘要的雅可比矩阵：第 (p, q) 元是 $\partial(h_t)_p / \partial(h_{t-1})_q$ 。带 $\tanh$ 时

$$J_t = \text{diag}(1 - H_t^2) W_{hh}^\top,$$

输入是上一摘要，输出是本步摘要对它的全部偏导，形状 $h \times h$ 。链式法则把向量对向量的敏感度写成雅可比相乘，故

$$\frac{\partial L}{\partial H_k} = \frac{\partial L}{\partial H_t} \prod_{i=k+1}^t J_i.$$

左边是早期摘要各维对总损失的梯度；连乘约 n_{steps} 次同一类 J 。 W_{hh} 最大奇异值 $\sigma > 1$ 则 $\|J\|^{n_{\text{steps}}}$ 爆炸， $\sigma < 1$ 或 $\tanh$ 饱和 ($1 - H^2 \approx 0$) 则消失。这与批量大小 n 无关，发生在时间维。代回原变量，

$$\frac{\partial h_t}{\partial w_h} = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial w_h}$$

$$+ \sum_{i=1}^{t-1} \left(\prod_{j=i+1}^t \frac{\partial f(x_j, h_{j-1}, w_h)}{\partial h_{j-1}} \right) \frac{\partial f(x_i, h_{i-1}, w_h)}{\partial w_h}.$$

乘积项决定梯度爆炸或消失。

8.7.1.1 完全计算

把上式中 $i = 1$ 到 $t - 1$ 的和全部保留，得到精确 BPTT。计算量随 t 增长，且 $\prod c_j$ 对初值极度敏感，实践中几乎不用。

8.7.1.2 截断时间步

在 τ 步后切断求和，即把 $\partial h_{t-\tau} / \partial w_h$ 视为 0。 τ 是反传的最大时间跨度，实现里等于 n_{steps} 。前向仍可把 H 的数值带入下一批量；detach 只剪断计算图，因此一次 backward 最多穿过当前窗口，不会穿过整个迭代周期。这给出真实梯度的近似，使模型更关注短期依赖。它限制的是回传链有多长，与把 g 缩短到半径 θ 的梯度裁剪不是同一操作。

8.7.1.3 随机截断

每步用随机变量 ξ_t 决定是否把梯度传向 $t-1$ 。取 $0 \leq \pi_t \leq 1$ ，令

$$P(\xi_t = 0) = 1 - \pi_t, \quad P(\xi_t = \pi_t^{-1}) = \pi_t,$$

则 $\mathbb{E}[\xi_t] = 1$ 。替换递推中的循环项：

$$z_t = \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial w_h} + \xi_t \frac{\partial f(x_t, h_{t-1}, w_h)}{\partial h_{t-1}} \frac{\partial h_{t-1}}{\partial w_h}.$$

$\xi_t = 0$ 时在该步切断； $\xi_t = \pi_t^{-1}$ 时链继续并把该段放大，以补上少见长链。 z_t 是对 $\partial h_t / \partial w_h$ 的无偏随机估计，但方差更大。片段长度不再固定为 τ 。

8.7.1.4 比较策略

随机截断把序列切成不等长片段；规则截断切成等长窗口；完全反传保留整条链。规则截断在偏差、方差与计算之间最常用。

8.7.2 通过时间反向传播的细节

去掉激活后的线性循环为

$$\mathbf{h}_t = \mathbf{W}_{hx} \mathbf{x}_t + \mathbf{W}_{hh} \mathbf{h}_{t-1},$$

$$\mathbf{o}_t = \mathbf{W}_{qh} \mathbf{h}_t,$$

$$L = \frac{1}{T} \sum_{t=1}^T l(\mathbf{o}_t, y_t).$$

$\mathbf{h}_t$ 仍是线性摘要； $\mathbf{o}_t$ 是打分； L 是平均逐步损失。输出梯度

$$\frac{\partial L}{\partial \mathbf{o}_t} = \frac{\partial l(\mathbf{o}_t, y_t)}{T \cdot \partial \mathbf{o}_t} \in \mathbb{R}^q.$$

每个分量是该 logit 增大时平均损失大约增加多少。输出权重

$$\frac{\partial L}{\partial \mathbf{W}_{qh}} = \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{o}_t} \mathbf{h}_t^\top.$$

每个条目是对应输出权重增大时 L 的敏感度，由各时刻外积累加。终端隐状态

$$\frac{\partial L}{\partial \mathbf{h}_T} = \mathbf{W}_{qh}^\top \frac{\partial L}{\partial \mathbf{o}_T}.$$

这是最终摘要各维增大时损失大约增加多少。对 $t < T$ 反向递推

$$\frac{\partial L}{\partial \mathbf{h}_t} = \mathbf{W}_{hh}^\top \frac{\partial L}{\partial \mathbf{h}_{t+1}} + \mathbf{W}_{qh}^\top \frac{\partial L}{\partial \mathbf{o}_t}.$$

第一项来自未来摘要，第二项来自本步输出；和是“本步摘要”对总损失的敏感度。展开后

$$\frac{\partial L}{\partial \mathbf{h}_t} = \sum_{i=t}^T (\mathbf{W}_{hh}^\top)^{T-i} \mathbf{W}_{qh}^\top \frac{\partial L}{\partial \mathbf{o}_{T+t-i}}.$$

$(\mathbf{W}_{hh}^\top)^{T-i}$ 把未来敏感度乘上 $T-i$ 次循环核，特征值模长决定放大或衰减。于是

$$\begin{aligned} \frac{\partial L}{\partial \mathbf{W}_{hx}} &= \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{h}_t} \mathbf{x}_t^\top, \\ \frac{\partial L}{\partial \mathbf{W}_{hh}} &= \sum_{t=1}^T \frac{\partial L}{\partial \mathbf{h}_t} \mathbf{h}_{t-1}^\top. \end{aligned}$$

这两个矩阵的每个条目仍是对应权重增大时 L 大约增加多少。 $\mathbf{W}_{hh}^\top$ 的高次幂使特征值 $|\lambda| > 1$ 时爆炸、 $|\lambda| < 1$ 时消失； $|\lambda|$ 无量纲。

8.7.3 小结

BPTT 的核心是

$$\frac{\partial h_t}{\partial w_h} = b_t + \sum_{i < t} \left(\prod_{j=i+1}^t c_j \right) b_i,$$

左边是摘要对共享参数的敏感度；乘积是沿时间链的放大倍数。截断把乘积长度限制在 τ ； $\mathbf{W}_{hh}$ 的谱半径决定梯度尺度。

8.7.4 练习

对称 $M\mathbf{v}_i = \lambda_i \mathbf{v}_i$ 则 $M^k \mathbf{v}_i = \lambda_i^k \mathbf{v}_i$ ，故 M^k 的特征值是 λ_i^k ：把第 i 个放大系数连乘 k 次。随机 $\mathbf{x} = \sum c_i \mathbf{v}_i$ 且 $c_1 \neq 0$ 、 $|\lambda_1| > |\lambda_2|$ 时，

$$M^k \mathbf{x} = \lambda_1^k \left(c_1 \mathbf{v}_1 + \sum_{i \geq 2} c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{v}_i \right)$$

与主导特征向量 $\mathbf{v}_1$ 渐近共线。BPTT 中雅可比连乘类似 M^k ： $|\lambda_1| > 1$ 爆炸， $|\lambda_1| < 1$ 消失，梯度被主导特征方向吞没。除裁剪外，还可用截断时间步、约束 $\mathbf{W}_{hh}$ 的谱半径、减小学习率，或换 GRU/LSTM 与残差以缩短有效连乘。

第九章 现代循环神经网络

门控让隐状态学会何时写入、何时遗忘。GRU 与 LSTM 用可学习的门缓解长程梯度问题，再堆成深层或双向结构。编码器-解码器把变长输入映成变长输出，束搜索在词表上近似最大似然序列。

9.1 门控循环单元（GRU）




图 9.1.1 在门控循环单元模型中计算重置门和更新门

符号： R_t ：重置门； Z_t ：更新门； $\mathbf{h}_{t-1}$ ：上一隐状态




图 9.1.2 在门控循环单元模型中计算候选隐状态

符号：见图中标注；各块含义见题注。




图 9.1.3 计算门控循环单元模型中的隐状态

符号：见图中标注；各块含义见题注。

普通循环中 $\prod_j \partial h_j / \partial h_{j-1}$ 容易消失或爆炸。若早期词元必须影响很晚的预测，就需要能够长期保存 h 的机制；若中间词元无关，则应学会跳过更新。GRU 用重置门与更新门实现这两种行为。

9.1.1 门控隐状态

门的取值在 $(0, 1)$ 中，由当前输入与上一隐状态共同决定，因此何时重置、何时拷贝都可以学习。每个门分量表示对该维摘要“放行多少”：靠近 1 几乎全放，靠近 0 几乎全挡。

9.1.1.1 重置门和更新门

对批量输入 $\mathbf{X}_t$ 与上一隐状态 $\mathbf{H}_{t-1}$,

$$\begin{aligned}\mathbf{R}_t &= \sigma(\mathbf{X}_t \mathbf{W}_{xr} + \mathbf{H}_{t-1} \mathbf{W}_{hr} + \mathbf{b}_r), \\ \mathbf{Z}_t &= \sigma(\mathbf{X}_t \mathbf{W}_{xz} + \mathbf{H}_{t-1} \mathbf{W}_{hz} + \mathbf{b}_z).\end{aligned}$$

sigmoid 把线性打分压到 $(0, 1)$ 。 $\mathbf{R}_t$ 的每个分量是重置比例：靠近 0 表示几乎忘掉上一摘要的该维，靠近 1 表示几乎原样用于计算候选。 $\mathbf{Z}_t$ 的每个分量是更新比例：靠近 1 表示本维倾向原样保留 $\mathbf{H}_{t-1}$ ，靠近 0 表示倾向换成新候选。二者都不是隐状态本身，而是 $[0, 1]$ 上的开关程度。

9.1.1.2 候选隐状态

重置后的历史再与当前输入混合：

$$\tilde{\mathbf{H}}_t = \tanh(\mathbf{X}_t \mathbf{W}_{xh} + (\mathbf{R}_t \odot \mathbf{H}_{t-1}) \mathbf{W}_{hh} + \mathbf{b}_h).$$

$\mathbf{R}_t \odot \mathbf{H}_{t-1}$ 是按维缩放后的旧摘要； $\tilde{\mathbf{H}}_t$ 的分量在 $(-1, 1)$ ，是“若完全改写，新摘要该写成什么”。 $\mathbf{R}_t = \mathbf{1}$ 时退化为普通候选隐状态； $\mathbf{R}_t = \mathbf{0}$ 时候选只看 $\mathbf{X}_t$ ，旧历史不进入候选。

9.1.1.3 隐状态

更新门在旧状态与候选之间插值：

$$\mathbf{H}_t = \mathbf{Z}_t \odot \mathbf{H}_{t-1} + (1 - \mathbf{Z}_t) \odot \tilde{\mathbf{H}}_t.$$

$\mathbf{H}_t$ 仍是到时刻 t 为止的序列压缩摘要，与 GRU 的 h 同形状。每个分量是旧摘要与新候选的凸组合： $\mathbf{Z}_t$ 靠近 1 则几乎拷贝旧摘要，靠近 0 则几乎采用候选。 $\mathbf{Z}_t = \mathbf{1}$ 时 $\mathbf{H}_t = \mathbf{H}_{t-1}$ ，梯度可沿时间原路回传； $\mathbf{Z}_t = \mathbf{0}$ 时完全改写。

9.1.2 从零开始实现

门控递推与上一章字符语言模型相同，只是 h_t 的更新换成上面三式，输出层仍是 $\mathbf{O}_t = \mathbf{H}_t \mathbf{W}_{hq} + \mathbf{b}_q$ 。 $\mathbf{O}_t$ 的分量是词表上的 logits；softmax 后才是下一词概率。

9.1.2.1 初始化模型参数

高斯初始化权重、零偏置。需要实例化 $(\mathbf{W}_{xr}, \mathbf{W}_{hr}, \mathbf{b}_r)$ 、 $(\mathbf{W}_{xz}, \mathbf{W}_{hz}, \mathbf{b}_z)$ 、 $(\mathbf{W}_{xh}, \mathbf{W}_{hh}, \mathbf{b}_h)$ 以及输出层 $(\mathbf{W}_{hq}, \mathbf{b}_q)$ 。隐藏宽度仍由 h 给出， h 是摘要向量的维数。

9.1.2.2 定义模型

$\mathbf{H}_0 = \mathbf{0}$ ，表示空摘要。逐步计算 $(\mathbf{R}_t, \mathbf{Z}_t, \tilde{\mathbf{H}}_t, \mathbf{H}_t, \mathbf{O}_t)$ ，参数在所有 t 上共享。映射与定义式逐项相同：门在 $(0, 1)$ ，摘要在 $(-1, 1)$ 量级，logits 无界。

9.1.2.3 训练与预测

损失、裁剪、困惑度与前缀续写均沿用循环神经网络从零实现中的流程。训练后比较训练集困惑度（有效分支数）以及给定前缀时的续写序列。

9.1.3 简洁实现

框架中的 GRU 层实现同一组门。前向仍是

$$(\mathbf{H}_{1:T}, \mathbf{H}_T) = \text{GRU}(\mathbf{X}_{1:T}, \mathbf{H}_0),$$

$\mathbf{H}_{1:T}$ 的每个切片是对应时刻的压缩摘要， $\mathbf{H}_T$ 是读完整段后的最终摘要。再接输出层；数值上应与从零实现一致，只是算子被编译。

9.1.4 小结

GRU 的状态更新

$$\mathbf{H}_t = \mathbf{Z}_t \odot \mathbf{H}_{t-1} + (1 - \mathbf{Z}_t) \odot \tilde{\mathbf{H}}_t$$

用 $\mathbf{Z}_t \in (0, 1)$ 决定保留多少旧摘要、用 $\mathbf{R}_t \in (0, 1)$ 决定候选里用多少旧历史； $\mathbf{H}_t$ 仍是迄今序列的压缩摘要。两门全开或全关时分别覆盖拷贝与普通 RNN。

9.1.5 练习

核验仅用 x_t 预测更晚输出时 $\mathbf{R}, \mathbf{Z}$ 的理想取值，以及只保留一扇门时递推如何退化。长期记忆应对应 $\mathbf{Z} \approx \mathbf{1}$ （少改写摘要），忽略一段历史应对应 $\mathbf{R} \approx \mathbf{0}$ 。

9.2 长短期记忆网络 (LSTM)




图 9.2.1 长短期记忆模型中的输入门、遗忘门和输出门

符号: I_t, F_t, O_t : 输入/遗忘/输出门; $\tilde{C}_t$: 候选记忆




图 9.2.2 长短期记忆模型中的候选记忆元

符号：见图中标注；各块含义见题注。




图 9.2.3 在长短期记忆网络模型中计算记忆元

符号：见图中标注；各块含义见题注。




图 9.2.4 在长短期记忆模型中计算隐状态

符号：见图中标注；各块含义见题注。

LSTM 在隐状态之外再设记忆元 C_t ，用三扇门分别控制写入、遗忘与读出。

9.2.1 门控记忆元

记忆元与 $\mathbf{H}_t$ 同形，但不直接进入输出层。输入门决定吸收候选，遗忘门决定丢弃旧记忆，输出门决定暴露多少记忆给 h_t 。三扇门的每个分量都在 $(0, 1)$ ：数值就是“做该操作的比例”。

9.2.1.1 输入门、忘记门和输出门

$$\begin{aligned} \mathbf{I}_t &= \sigma(\mathbf{X}_t \mathbf{W}_{xi} + \mathbf{H}_{t-1} \mathbf{W}_{hi} + \mathbf{b}_i), \\ \mathbf{F}_t &= \sigma(\mathbf{X}_t \mathbf{W}_{xf} + \mathbf{H}_{t-1} \mathbf{W}_{hf} + \mathbf{b}_f), \\ \mathbf{O}_t &= \sigma(\mathbf{X}_t \mathbf{W}_{xo} + \mathbf{H}_{t-1} \mathbf{W}_{ho} + \mathbf{b}_o). \end{aligned}$$

三者均在 $(0, 1)$ 中逐元素取值。 $I_{t,j}$ 是第 j 维写入多少新候选：1 表示全部写入，0 表示不写入。 $F_{t,j}$ 是第 j 维遗忘多少旧记忆：1 表示全部保留旧记忆，0 表示全部忘掉。注意：遗忘门靠近 1 是“少忘”，靠近 0 是“多忘”。 $O_{t,j}$ 是第 j 维向外输出多少记忆：1 表示该维记忆充分暴露给隐状态，0 表示对外隐藏。

9.2.1.2 候选记忆元

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{X}_t \mathbf{W}_{xc} + \mathbf{H}_{t-1} \mathbf{W}_{hc} + \mathbf{b}_c).$$

$\tanh$ 把候选限制在 $(-1, 1)$ 。每个分量是“若输入门打开，打算写入记忆的新内容”，不是门。

9.2.1.3 记忆元

$$\mathbf{C}_t = \mathbf{F}_t \odot \mathbf{C}_{t-1} + \mathbf{I}_t \odot \tilde{\mathbf{C}}_t.$$

$\mathbf{C}_t$ 是内部记忆：旧记忆按遗忘门缩放，新候选按输入门缩放，再相加。每个分量仍是记忆内容（可正可负），不是 $(0, 1)$ 的门。 $\mathbf{F}_t = \mathbf{1}, \mathbf{I}_t = \mathbf{0}$ 时记忆原样传递，梯度可沿 $\mathbf{C}$ 传播。

9.2.1.4 隐状态

$$\mathbf{H}_t = \mathbf{O}_t \odot \tanh(\mathbf{C}_t).$$

先把记忆压到 $(-1, 1)$ ，再按输出门决定对外暴露多少。 $\mathbf{H}_t$ 是对外可见的序列压缩摘要，供输出层使用； $\mathbf{C}_t$ 是内部状态，不直接解码。只有 $\mathbf{H}_t$ 进入 $\mathbf{O}_t^{\text{out}} = \mathbf{H}_t \mathbf{W}_{hq} + \mathbf{b}_q$ ，后者是词表 logits。

9.2.2 从零开始实现

隐状态现在是二元组 $(\mathbf{H}_t, \mathbf{C}_t)$ ，其余训练回路不变。 $\mathbf{H}_t$ 是摘要， $\mathbf{C}_t$ 是记忆。

9.2.2.1 初始化模型参数

除三扇门与候选记忆的权重偏置外，输出层维度仍等于词表大小。权重取标准差 0.01 的高斯，偏置为零。0.01 是初始权重的标准差，使初始打分接近 0。

9.2.2.2 定义模型

初始化 $(\mathbf{H}_0, \mathbf{C}_0) = (\mathbf{0}, \mathbf{0})$ ，表示空摘要与空记忆。逐步计算 $(\mathbf{I}_t, \mathbf{F}_t, \mathbf{O}_t, \tilde{\mathbf{C}}_t, \mathbf{C}_t, \mathbf{H}_t)$ ，仅把 $\mathbf{H}_t$ 映到词表 logits。门在 $(0, 1)$ ，候选与 $\tanh(\mathbf{C}_t)$ 在 $(-1, 1)$ 。

9.2.2.3 训练和预测

与 GRU 相同的困惑度目标与前缀生成。记忆元在预测时随 $\mathbf{H}$ 一起递推，但不直接解码。困惑度仍是每个位置有效分支数的几何平均。

9.2.3 简洁实现

$$((\mathbf{H}_{1:T}, \mathbf{C}_T), \mathbf{H}_T) = \text{LSTM}(\mathbf{X}_{1:T}, (\mathbf{H}_0, \mathbf{C}_0)).$$

返回的 $\mathbf{H}_{1:T}$ 是各时刻对外摘要， $\mathbf{C}_T$ 是最终内部记忆。这是带状态控制的隐变量自回归模型；长程依赖仍使逐步展开代价随 T 增长， T 是时间步数。

9.2.4 小结

LSTM 用

$$\mathbf{C}_t = \mathbf{F}_t \odot \mathbf{C}_{t-1} + \mathbf{I}_t \odot \tilde{\mathbf{C}}_t, \quad \mathbf{H}_t = \mathbf{O}_t \odot \tanh(\mathbf{C}_t)$$

把长期记忆与对外隐状态分开。 $\mathbf{F}_t, \mathbf{I}_t, \mathbf{O}_t \in (0, 1)$ 分别是遗忘、写入、读出的比例； $\mathbf{H}_t$ 是迄今序列的压缩摘要。从而缓解梯度消失。

9.2.5 练习

核验 $\tilde{C}_t$ 已经过 $\tanh$ 后输出为何再套 $\tanh$ ，以及在相同 h 下 GRU、LSTM 与普通 RNN 的逐步乘法次数。第二次 $\tanh$ 把记忆幅度限制在 $(-1, 1)$ 再交给输出门； h 是摘要维数。

9.3 深度循环神经网络




图 9.3.1 深度循环神经网络结构

符号：见图中标注；各块含义见题注。

单层循环的 ϕ 可能不够灵活。把若干循环层堆叠，使不同层刻画不同时间尺度。

9.3.1 函数依赖关系

令 $H_t^{(0)} = X_t$ 。第 $\ell = 1, \dots, L$ 层

$$H_t^{(\ell)} = \phi_{\ell}(H_t^{(\ell-1)}W_{xh}^{(\ell)} + H_{t-1}^{(\ell)}W_{hh}^{(\ell)} + b_h^{(\ell)}).$$

$H_t^{(\ell)}$ 是第 ℓ 层在时刻 t 的压缩摘要：它混合了下层同一时刻的摘要与本层上一时刻的摘要。 L 是层数。顶层再接到输出

$$O_t = H_t^{(L)}W_{hq} + b_q.$$

O_t 是词表打分。于是信息同时沿时间传到 $H_{t+1}^{(\ell)}$ ，并沿深度传到 $H_t^{(\ell+1)}$ 。

9.3.2 简洁实现

以 LSTM 为例，仅增加层数 L 。词表大小决定输入输出维，隐藏宽度仍取 h ，层间按上式串联。GRU 或普通 RNN 只需更换 ϕ_ℓ 所对应的单元。每层仍有自己的门（若用 LSTM），门值含义不变：(0,1) 上的遗忘/写入/读出比例。

9.3.3 训练与预测

多层逐步展开使每步代价约为单层的 L 倍，收敛对学习率与裁剪更敏感。预测时逐层递推全部 $H_t^{(\ell)}$ ，每一层都维护到当前为止的摘要。

9.3.4 小结

深度循环的依赖是

$$H_t^{(\ell)} = \phi_\ell(H_t^{(\ell-1)} W_{xh}^{(\ell)} + H_{t-1}^{(\ell)} W_{hh}^{(\ell)} + b_h^{(\ell)}),$$

$H_t^{(\ell)}$ 是第 ℓ 层对迄今历史的压缩摘要。同一套门控单元可以替换 ϕ_ℓ 。

9.3.5 练习

核验两层从零展开时 $H_t^{(1)}$ 如何作为 $H_t^{(2)}$ 的输入，以及用 GRU 替换 LSTM 后困惑度与逐步代价如何变化。下层摘要是上层的输入特征，不是词表概率。

9.4 双向循环神经网络




图 9.4.1 隐马尔可夫模型

符号：见图中标注；各块含义见题注。




图 9.4.2 双向循环神经网络架构

符号：前向 $\vec{h}$ ；后向 $\overleftarrow{h}$ ；拼接为上下文

单向循环只能看过去。填空、标注等任务需要未来上下文，因此再设一条反向循环。

9.4.1 隐马尔可夫模型中的动态规划

隐状态与观测的联合分布为

$$P(x_1, \dots, x_T, h_1, \dots, h_T) = \prod_{t=1}^T P(h_t | h_{t-1}) P(x_t | h_t),$$

其中 $P(h_1 | h_0) = P(h_1)$ 。每个因子是转移概率或发射概率，均在 $[0, 1]$ ；乘积是隐链与观测同时出现的联合概率。边际化全部 h 时，前向量

$$\pi_{t+1}(h_{t+1}) = \sum_{h_t} \pi_t(h_t) P(x_t | h_t) P(h_{t+1} | h_t)$$

把过去的贡献压缩成关于 h_{t+1} 的函数： $\pi_{t+1}(h)$ 是“到 $t+1$ 为止、隐状态为 h ”的非归一化质量，非负。最终

$$P(x_1, \dots, x_T) = \sum_{h_T} \pi_T(h_T) P(x_T | h_T).$$

该和是观测序列的边际似然，在 $[0, 1]$ 。后向量

$$\rho_{t-1}(h_{t-1}) = \sum_{h_t} P(h_t | h_{t-1}) P(x_t | h_t) \rho_t(h_t)$$

压缩未来: $\rho_{t-1}(h)$ 是从 $h_{t-1} = h$ 出发解释后续观测的质量。两者合起来给出缺省位置的条件

$$P(x_j | x_{-j}) \propto \sum_{h_j} \pi_j(h_j) \rho_j(h_j) P(x_j | h_j).$$

归一化后是“已知其余观测时, 位置 j 取各词元”的概率, 在 $[0, 1]$ 且对 x_j 求和为 1。

9.4.2 双向模型

用一条前向 RNN 扮演 π , 一条后向 RNN 扮演 ρ , 在每个 t 拼接两边的隐状态。

9.4.2.1 定义

$$\begin{aligned}\vec{H}_t &= \phi(\mathbf{X}_t \mathbf{W}_{xh}^{(f)} + \vec{H}_{t-1} \mathbf{W}_{hh}^{(f)} + \mathbf{b}_h^{(f)}), \\ \overleftarrow{H}_t &= \phi(\mathbf{X}_t \mathbf{W}_{xh}^{(b)} + \overleftarrow{H}_{t+1} \mathbf{W}_{hh}^{(b)} + \mathbf{b}_h^{(b)}).\end{aligned}$$

$\vec{H}_t$ 是只看 $x_1, \dots, x_t$ 的压缩摘要; $\overleftarrow{H}_t$ 是只看 $x_t, \dots, x_T$ 的压缩摘要。拼接 $\mathbf{H}_t = [\vec{H}_t; \overleftarrow{H}_t]$ 后

$$\mathbf{O}_t = \mathbf{H}_t \mathbf{W}_{hq} + \mathbf{b}_q.$$

$\mathbf{H}_t$ 是双向上下文的联合摘要; $\mathbf{O}_t$ 是该位置的标签打分。

9.4.2.2 模型的计算代价及其应用

每个 t 的输出同时依赖 $x_1, \dots, x_T$, 因此不能用于“只根据过去预测下一个词元”。前向需要跑完反向递归, 反向传播的链大约加倍, 训练代价高。适用场合是编码整句或双向上下文标注。

9.4.3 双向循环神经网络的错误应用

若把双向模型当作语言模型训练, 训练时未来词元可见, 测试时不可见, 条件分布 $P(x_t | x_{<t})$ 被错误地换成 $P(x_t | x_{\neq t})$, 续写会崩溃。前者是因果下一词概率, 后者是填空概率, 二者都在 $[0, 1]$ 但条件不同。

9.4.4 小结

双向更新

$$\mathbf{O}_t = [\vec{H}_t; \overleftarrow{H}_t] \mathbf{W}_{hq} + \mathbf{b}_q$$

对应 HMM 中的前向-后向量；左右两段都是压缩摘要，合起来编码双向上下文，而不能当作因果语言模型。

9.4.5 练习

核验两个方向隐藏宽度不同时 $\mathbf{H}_t$ 的拼接维，以及如何用双向上下文表示多义词在句中的向量。拼接维是两方向摘要维数之和，该整数是向量长度，不是概率。

9.5 机器翻译与数据集

机器翻译把源语言序列映到目标语言序列，是变长到变长的序列转换。后续编码器-解码器都在这对平行语料上训练。

9.5.1 下载和预处理数据集

英-法句对经制表符分隔。预处理把不间断空格换成普通空格、字母小写，并在单词与标点之间插入空格，得到可切分的字符串对 (s, t) 。此时仍是文本，不是张量。

9.5.2 词元化

与字符级语言模型不同，这里按单词（及标点）切分。第 i 对变成

$$\text{source}^{(i)} = (x_1, \dots, x_T), \quad \text{target}^{(i)} = (y_1, \dots, y_{T'}).$$

每个 x, y 稍后会被映成词表下标； T, T' 是源、目标词元个数。多数句对的词元数小于 20，20 是长度阈值。

9.5.3 词表

源、目标各建一个词表。单词级使 $|\mathcal{V}|$ 远大于字符级，故把频次小于 2 的项并入 $\langle \text{unk} \rangle$ ，并加入 $\langle \text{pad} \rangle$ 、 $\langle \text{bos} \rangle$ 、 $\langle \text{eos} \rangle$ 。2 是最低频次； $|\mathcal{V}|$ 是词表大小，决定 softmax 有几类。

9.5.4 加载数据集

句长不同。截断与填充把每条序列补/切到固定 n_{steps} ，同时记录有效长度 $T_{\text{valid}} \leq n_{\text{steps}}$ ，以便后面的损失与注意力忽略填充。 n_{steps} 与 T_{valid} 都是词元个数（轴长度），填充位置上的下标是 $\langle \text{pad} \rangle$ 的编号，不是语义词。

9.5.5 训练模型

数据迭代器每次返回一个小批量的源下标、源有效长度、目标下标与目标有效长度，以及两个词表。这给出监督学习对 $(\mathbf{X}, \mathbf{Y})$ ：每个条目是词元编号，有效长度是有几个非填充位置。

9.5.6 小结

平行语料经过词元化与填充后，每个样本是长度同为 n_{steps} 的整数对 $(\mathbf{x}, \mathbf{y})$ ，低频率词并入未知词元以控制 $|\mathcal{V}|$ 。这些整数是类别下标，不是嵌入坐标。

9.5.7 练习

核验句对数如何改变两个词表大小，以及无空格语言上单词切分是否仍有良定义的 $\mathcal{Z}$ 。句对数是样本个数； $|\mathcal{V}|$ 随词种增加。

9.6 编码器-解码器架构




图 9.6.1 编码器-解码器架构

符号：Encoder：源序列 $\rightarrow$ 状态；Decoder：状态 $\rightarrow$ 目标词

输入长度 T 与输出长度 T' 都可以变。编码器把变长输入压成固定形状的状态，解码器再把该状态展开成变长输出。

9.6.1 编码器

编码器是映射

$$\text{Enc} : \mathcal{X}^T \rightarrow \mathcal{C}, \quad \mathbf{X} \mapsto \mathbf{c}.$$

$\mathbf{X}$ 是长度为 T 的源词元（或嵌入）序列； $\mathbf{c}$ 是固定形状的上下文向量（或张量），不随 T 改变轴长度，含义是整句源序列的压缩摘要。任何具体网络只要实现这一接口即可。

9.6.2 解码器

解码器在每步消费已经生成的词元与编码状态：

$$\text{Dec} : \mathcal{C} \times \mathcal{Y}^{t'-1} \rightarrow \mathcal{Y}, \quad (\mathbf{c}, y_{1:t'-1}) \mapsto y_{t'}.$$

输出 $y_{t'}$ 是目标词表上的下一个词元（或先给出该词的概率再取样）。init_state 把编码器输出转换成解码器的初始状态，必要时使用源序列有效长度。

9.6.3 合并编码器和解码器

前向先算 $\mathbf{c} = \text{Enc}(\mathbf{X})$ ，再逐步

$$y_{t'} = \text{Dec}(\mathbf{c}, y_{1:t'-1}), \quad t' = 1, \dots, T'.$$

每步 $y_{t'}$ 是一个目标词元； T' 是目标长度。具有隐状态的网络自然适合携带 $\mathbf{c}$ 。下一节用两个循环网络实现该架构。

9.6.4 小结

编码器-解码器把变长到变长写成

$$\mathbf{c} = \text{Enc}(\mathbf{X}), \quad y_{1:T'} = \text{Dec}(\mathbf{c}),$$

$\mathbf{c}$ 是源句摘要， $y_{1:T'}$ 是目标词元序列。因此适用于机器翻译这类序列转换。

9.6.5 练习

核验 Enc 与 Dec 不必同一类网络，以及哪些其他变长到变长任务可用同一接口。接口约束的是输入输出对象，不是内部用卷积还是循环。

9.7 序列到序列学习 (seq2seq)




图 9.7.1 使用循环神经网络编码器和循环神经网络解码器的序列到序列学习

符号： h ：编码器隐状态； s ：解码器状态； y_t ：输出词




图 9.7.2 循环神经网络编码器-解码器模型中的层

符号：见图中标注；各块含义见题注。




图 9.7.3 使用循环神经网络编码器-解码器逐词元地预测输出序列。

符号：见图中标注；各块含义见题注。

用循环神经网络实现上一节的两个映射：编码器消费 $x_{1:T}$ ，解码器生成 $y_{1:T'}$ 。

9.7.1 编码器

逐步

$$h_t = f(x_t, h_{t-1}).$$

$\mathbf{h}_t$ 是源序列读到第 t 个词元时的压缩摘要。上下文变量把全部隐状态汇总为固定向量

$$\mathbf{c} = q(\mathbf{h}_1, \dots, \mathbf{h}_T).$$

$\mathbf{c}$ 是整句源端摘要。最常见的取法是 q 只保留 $\mathbf{h}_T$ ，或取多层最终隐状态的拼接；拼接增加的是向量长度，不是把摘要数值加总。

9.7.2 解码器

解码器隐状态

$$\mathbf{s}_{t'} = g(y_{t'-1}, \mathbf{c}, \mathbf{s}_{t'-1}),$$

$\mathbf{s}_{t'}$ 是目标端到 t' 为止的压缩摘要，同时注入源摘要 $\mathbf{c}$ 。再由 $\mathbf{s}_{t'}$ 产生 $P(y_{t'} | y_{1:t'-1}, \mathbf{c})$ ：词表上的条件概率，在 $[0, 1]$ 且和为 1。训练时 $y_{t'-1}$ 来自真实标签，预测时来自上一时刻的输出。

9.7.3 损失函数

每步在词表上做 softmax 交叉熵。填充位置不应计入损失。有效长度掩码把越界项置零，等价于

$$L = \frac{1}{\sum_{t'} \mathbb{I}\{t' \leq T'_{\text{valid}}\}} \sum_{t'=1}^{n_{\text{steps}}} \mathbb{I}\{t' \leq T'_{\text{valid}}\} \ell(y_{t'}, \hat{y}_{t'}).$$

指示函数取值 $\{0, 1\}$ ：1 表示该步是真实词元。 L 是有效位置上交叉熵的平均，标量，单位与逐步负对数概率相同；越小表示给正确目标词的概率越高。

9.7.4 训练

解码器输入是 `<bos>` 与去掉 `<eos>` 的真实目标序列拼接，即强制教学。也可以改用模型自己的 $\hat{y}_{t'-1}$ 。编码器可多层，解码器初始 $\mathbf{s}_0$ 由 $\mathbf{c}$ 给出，即用源摘要初始化目标端摘要。

9.7.5 预测

从 `<bos>` 开始，每步把 $\hat{y}_{t'}$ 送回解码器，直到输出 `<eos>` 或达到最大长度。这是贪心生成；下一节讨论束搜索。每步选出的是词元编号，其依据是 $P(y_{t'} | \cdot)$ 最大。

9.7.6 预测序列的评估

BLEU 比较预测与标签的 n 元匹配率 p_n ，并惩罚过短输出：

$$\exp\left(\min\left(0, 1 - \frac{\text{len}_{\text{label}}}{\text{len}_{\text{pred}}}\right)\right) \prod_{n=1}^k p_n^{1/2^n}.$$

$p_n \in [0, 1]$ 是长度为 n 的片段命中率；长度比无量纲。整个 BLEU 在 $[0, 1]$ 附近（指数惩罚项 ≤ 1 ），越接近 1 表示 n 元重叠越好且长度不过短。

9.7.7 小结

seq2seq 用

$$\mathbf{c} = q(\mathbf{h}_{1:T}), \quad \mathbf{s}_{t'} = g(y_{t'-1}, \mathbf{c}, \mathbf{s}_{t'-1})$$

实现编码器-解码器： $\mathbf{c}$ 与 $\mathbf{s}_{t'}$ 分别是源、目标侧的压缩摘要。训练用强制教学，评价用 BLEU。

9.7.8 练习

核验去掉掩码后填充位置如何污染 L ，以及编码器与解码器隐藏宽度不同时 $\mathbf{s}_0$ 应如何由 $\mathbf{c}$ 初始化。填充位置的交叉熵不对应真实词，会把平均损失这一标量拉偏。

9.8 束搜索

时间步	1	2	3	4
A	0.5	0.1	0.2	0.0
B	0.2	0.4	0.2	0.2
C	0.2	0.3	0.4	0.2
<eos>	0.1	0.2	0.2	0.6

图 9.8.1 在每个时间步，贪心搜索选择具有最高条件概率的词元

符号：见图中标注；各块含义见题注。

时间步	1	2	3	4
A	0.5	0.1	0.1	0.1
B	0.2	0.4	0.6	0.2
C	0.2	0.3	0.2	0.1
<eos>	0.1	0.2	0.1	0.6

图 9.8.2 在时间步 2，选择具有第二高条件概率的词元“C”（而非最高条件概率的词元）

符号：见图中标注；各块含义见题注。




图 9.8.3 束搜索过程（束宽：2，输出序列的最大长度：3）。候选输出序列是 A 、 C 、 AB 、 CE 、 ABD 和 CED

符号： k ：束宽；每步保留分数最高的 k 条部分序列

解码要在词表 $\mathcal{Y}$ 上找一条序列最大化 $P(y_1, \dots, y_{T'} | \mathbf{c})$ 。该目标是整条目标序列在给定源摘要下的联合概率，在 $[0, 1]$ 。逐步取最大是贪心；枚举全部序列是穷举；束搜索在二者之间保留 k 条候选。

9.8.1 贪心搜索

每步

$$y_{t'} = \operatorname{argmax}_{y \in \mathcal{Y}} P(y | y_1, \dots, y_{t'-1}, \mathbf{c}).$$

右边每个 P 是下一词条件概率； argmax 返回概率最大的那个词元，不是把概率当作词。计算量 $\mathcal{O}(|\mathcal{Y}|T')$ ，但不能改正早期错误，整体不必最优。

9.8.2 穷举搜索

枚举 $\mathcal{Y}^{T'}$ 中全部序列并取联合概率最大者。计算量 $\mathcal{O}(|\mathcal{Y}|^{T'})$ 。例如 $|\mathcal{Y}| = 10^4$ 、 $T' = 10$ 时约 10^{40} 条，不可行。 10^{40} 是候选序列条数。

9.8.3 束搜索

束宽为 k 时，每步只保留条件概率最高的 k 条前缀。 k 是条数。例如 $k = 2$ 时，若第一步留下 A, C ，则第二步比较

$$P(A, y_2 | \mathbf{c}) = P(A | \mathbf{c})P(y_2 | A, \mathbf{c}),$$

$$P(C, y_2 | \mathbf{c}) = P(C | \mathbf{c})P(y_2 | C, \mathbf{c}),$$

再留下两条。左边是长度为 2 的前缀的联合概率，等于逐步条件概率之积，仍在 $[0, 1]$ 。第三步同理，

$$P(A, B, y_3 | \mathbf{c}) = P(A, B | \mathbf{c})P(y_3 | A, B, \mathbf{c}),$$

$$P(C, E, y_3 | \mathbf{c}) = P(C, E | \mathbf{c})P(y_3 | C, E, \mathbf{c}).$$

最终在候选完整序列上用长度归一化分数

$$\frac{1}{L^\alpha} \log P(y_1, \dots, y_L | \mathbf{c}) = \frac{1}{L^\alpha} \sum_{t'=1}^L \log P(y_{t'} | y_{1:t'-1}, \mathbf{c})$$

选出输出。 $\log P(y_1, \dots, y_L | \mathbf{c})$ 是该词元序列的对数概率（nat 或 bit，随对数底而定），通常为负，越大（越接近 0）表示整句越可能。右边把逐步 $\log P(y_{t'} | \cdot)$ 相加，每项是该步真实（或候选）词的对数条件概率。 L^α 用长度惩罚过短句， α 无量纲。 $k = 1$ 退化为贪心； $k = |\mathcal{Y}|$ 恢复穷举。

9.8.4 小结

束搜索用宽度 k 在

$$\max_{y_{1:L}} P(y_{1:L} | \mathbf{c})$$

的精度与 $\mathcal{O}(k|\mathcal{Y}|T')$ 的代价之间折中。比较时所依据的束分数是词元序列的（长度归一化）对数概率，不是单个词的下标。

9.8.5 练习

核验穷举是否为 $k = |\mathcal{Y}|$ 的束搜索，以及 k 如何改变机器翻译的速度与 BLEU。 k 增大则每步保留的前缀更多，搜索更接近最大对数概率，计算按 k 近似线性增加。

第十章 注意力机制

注意力把查询与键的相似度变成权，再对值加权求和。从 Nadaraya–Watson 核回归出发，经过加性与缩放点积评分、多头与自注意力，得到完全基于注意力的 Transformer：线性投射给出 Q, K, V ，再计算 $\text{softmax}(QK^\top/\sqrt{d})$ 。

10.1 注意力提示




图 10.1.1 由于突出性的非自主性提示（红杯子），注意力不自主地指向了咖啡杯
符号：见图中标注；各块含义见题注。




图 10.1.2 依赖于任务的意志提示（想读一本书），注意力被自主引导到书上

符号：见图中标注；各块含义见题注。




图 10.1.3 注意力机制通过注意力汇聚将 * 查询 *（自主性提示）和 * 键 *（非自主性提示）结合在一起，实现对 * 值 *（感官输入）的选择倾向

符号： q ：查询； k_i ：键； v_i ：值；输出：值的加权和

注意力是有限资源。神经网络若只有汇聚或全连接，选择不依赖当前任务；加入查询后，权可以随任务改变。

10.1.1 生物学中的注意力提示

非自主性提示由刺激的突出性驱动，例如场景中唯一的红色物体会抓住注视。自主性提示由当前目标驱动，例如要读论文时目光转向纸张。二者共同决定焦点。这里还没有可学习的数值，只固定“查询决定看哪里”这一对象。

10.1.2 查询、键和值

查询 $\mathbf{q}$ 对应自主提示。键 $\mathbf{k}_i$ 对应非自主提示，值 $\mathbf{v}_i$ 对应感官输入。注意力汇聚是

$$f(\mathbf{q}, (\mathbf{k}_1, \mathbf{v}_1), \dots, (\mathbf{k}_m, \mathbf{v}_m)) = \sum_{i=1}^m \alpha(\mathbf{q}, \mathbf{k}_i) \mathbf{v}_i.$$

$\alpha(\mathbf{q}, \mathbf{k}_i) \in [0, 1]$ 且 $\sum_{i=1}^m \alpha(\mathbf{q}, \mathbf{k}_i) = 1$ ：第 i 个权表示从值 $\mathbf{v}_i$ 取多少——1 表示几乎只取该值，0 表示完全不用。 f 与每个 $\mathbf{v}_i$ 同形状，是值的凸组合，不是权本身，也不是键。没有查询时，权与任务无关，退化为平均或最大汇聚。

10.1.3 注意力的可视化

权矩阵的条目是 $\alpha(\mathbf{q}_i, \mathbf{k}_j)$ 。每个条目在 $[0, 1]$ ，第 i 行对 j 求和为 1，表示查询 i 把多少比例分给键 j 所对应的值。对角情形下

$$\alpha(\mathbf{q}_i, \mathbf{k}_j) = [i = j],$$

即只把与查询相同的键所对应的值取出：权为 1 或 0，不是相似度分数的连续值。后续各节都用同一张权矩阵观察汇聚偏向。

10.1.4 小结

注意力与汇聚的差别在于查询：权 $\alpha(\mathbf{q}, \mathbf{k}_i) \in [0, 1]$ 且对 i 求和为 1，由查询-键交互决定，表示从 $\mathbf{v}_i$ 取多少；加权和才是汇聚结果。

10.1.5 练习

核验翻译解码中查询、键、值分别对应哪些向量，以及行归一化后的随机矩阵是否构成合法注意力权。行和为 1 且非负时，每个条目都可以读成“从该值取多少”。

10.2 注意力汇聚：Nadaraya-Watson 核回归

Nadaraya-Watson 核回归是完整的注意力实例：查询是自变量 x ，键是训练输入 x_i ，值是训练输出 y_i 。

10.2.1 生成数据集

$$y_i = 2 \sin(x_i) + x_i^{0.8} + \epsilon,$$

ϵ 为噪声。 y_i 与右边各函数项同量纲，是第 i 个训练输出。回归目标是估计 $f(x) = \mathbb{E}[y | x]$ ，即在该 x 处 y 的条件均值，与 y 同量纲。

10.2.2 平均汇聚

忽略查询，对全部值取平均

$$f(x) = \frac{1}{n} \sum_{i=1}^n y_i.$$

这是与 x 无关的常数估计，等于训练集标签的算术平均，不是某个 x 处的局部均值。

10.2.3 非参数注意力汇聚

核 K 把查询与键的距离变成权：

$$f(x) = \sum_{i=1}^n \frac{K(x - x_i)}{\sum_{j=1}^n K(x - x_j)} y_i = \sum_{i=1}^n \alpha(x, x_i) y_i.$$

$\alpha(x, x_i)$ 是归一化后的核值，在 $[0, 1]$ 且对 i 求和为 1，表示预测 $f(x)$ 时从训练输出 y_i 取多少。 $f(x)$ 是这些 y_i 的加权平均，与 y 同量纲。高斯核

$$K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right)$$

是标准正态密度： $u = x - x_i$ 为查询与键的差， $K(u)$ 越大表示越近，但它本身不是概率权（尚未归一化，且可以看作密度）。给出

$$\begin{aligned} f(x) &= \sum_{i=1}^n \frac{\exp\left(-\frac{1}{2}(x - x_i)^2\right)}{\sum_{j=1}^n \exp\left(-\frac{1}{2}(x - x_j)^2\right)} y_i \\ &= \sum_{i=1}^n \text{softmax}\left(-\frac{1}{2}(x - x_i)^2\right) y_i. \end{aligned}$$

softmax 的第 i 个分量就是 $\alpha(x, x_i)$ ：距离越小（平方差越小）权越大，该权仍是“从 y_i 取多少”。

10.2.4 带参数注意力汇聚

引入可学习带宽 w ，距离改成 $(x - x_i)w$ ：

$$f(x) = \sum_{i=1}^n \text{softmax}\left(-\frac{1}{2}((x - x_i)w)^2\right)y_i.$$

$|w|$ 越大，权越集中在最近的键上：某些 $\alpha(x, x_i)$ 接近 1，其余接近 0，表示几乎只取最近那一个 y_i 。 w 是尺度参数，无量纲若 x 已标准化，否则量纲为 $1/x$ 。

10.2.4.1 批量矩阵乘法

形状 (n, a, b) 与 (n, b, c) 的批量乘满足

$$(XY)_n = \mathbf{X}_n \mathbf{Y}_n \in \mathbb{R}^{a \times c}.$$

第 n 个切片是普通矩阵乘：每个 c_{ij} 是第 i 行与第 j 列的点积。注意力里常用它一次算完整批查询对全部键的评分；评分还不是权，经 softmax 后才是 α 。

10.2.4.2 定义模型

把训练对 $\{(x_i, y_i)\}$ 作为键-值，查询为 x 。评分向量经 softmax 后与值向量做批量乘，实现上一段的 $f(x)$ 。softmax 输出的每个分量在 $[0, 1]$ 且和为 1，表示从对应 y_i 取多少。

10.2.4.3 训练

平方损失加随机梯度更新 w 。每个样本的查询不与自身键配对，以免平凡自匹配。学得的 $|w|$ 较大时，权热图在邻近区域更尖锐，拟合曲线也更不平滑。平方损失 $(\hat{y} - y)^2$ 是预测误差的平方，与 y 的量纲平方相同。

10.2.5 小结

Nadaraya-Watson 把回归写成

$$f(x) = \sum_i \alpha(x, x_i) y_i,$$

$\alpha(x, x_i) \in [0, 1]$ 且求和为 1，表示从训练值 y_i 取多少； $f(x)$ 是点预测。非参数核与带参数核只差评分函数是否含 w 。

10.2.6 练习

核验增大 n 是否改进非参数估计，以及 w 如何改变 $\alpha(x, x_i)$ 的尖锐程度。 n 是训练点数；尖锐指少数权接近 1、其余接近 0。

10.3 注意力评分函数




图 10.3.1 计算注意力汇聚的输出为值的加权和

符号：见图中标注；各块含义见题注。

一般地，

$$f(\mathbf{q}, (\mathbf{k}_1, \mathbf{v}_1), \dots, (\mathbf{k}_m, \mathbf{v}_m)) = \sum_{i=1}^m \alpha(\mathbf{q}, \mathbf{k}_i) \mathbf{v}_i \in \mathbb{R}^v,$$

$$\alpha(\mathbf{q}, \mathbf{k}_i) = \text{softmax}(a(\mathbf{q}, \mathbf{k}_i)) = \frac{\exp(a(\mathbf{q}, \mathbf{k}_i))}{\sum_{j=1}^m \exp(a(\mathbf{q}, \mathbf{k}_j))}.$$

$a(\mathbf{q}, \mathbf{k}_i)$ 是未归一化评分（可正可负，无界）； $\alpha(\mathbf{q}, \mathbf{k}_i)$ 是 softmax 后的权，在 $[0, 1]$ 且对 i 求和为 1，表示从值 $\mathbf{v}_i$ 取多少。 f 是这些值的加权和，与 $\mathbf{v}_i$ 同维。不同的评分 a 给出不同的汇聚。

10.3.1 掩蔽 softmax 操作

填充位置不应进入汇聚。有效长度之外的评分置为 $-\infty$ ，再做 softmax，于是对应权为 0，表示从该填充值取 0；加权和只落在合法键上，合法权仍非负且和为 1。

10.3.2 加性注意力

查询与键维数可以不同。令

$$a(\mathbf{q}, \mathbf{k}) = \mathbf{w}_v^\top \tanh(\mathbf{W}_q \mathbf{q} + \mathbf{W}_k \mathbf{k}) \in \mathbb{R}.$$

输入 $\mathbf{q}, \mathbf{k}$ 先线性变换到同一隐宽再相加、经 $\tanh$ ，最后用 $\mathbf{w}_v$ 收成一个标量评分。该标量越大表示查询与该键越匹配，但它还不是权；softmax 之后才得到 $\alpha \in [0, 1]$ 。这是一层隐层宽度为 h 的加性评分， h 是隐单元个数，适用于编码器—解码器中两边维数不一致的情形。

10.3.3 缩放点积注意力

当 $\mathbf{q}, \mathbf{k} \in \mathbb{R}^d$ 时，

$$a(\mathbf{q}, \mathbf{k}) = \frac{\mathbf{q}^\top \mathbf{k}}{\sqrt{d}}.$$

分子是点积，表示方向有多一致（若已标准化则近于余弦）； $\sqrt{d}$ 抵消点积方差随 d 线性增长，避免 softmax 进入饱和。 d 是向量维数，是轴长度不是权。批量形式为

$$\text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right)\mathbf{V} \in \mathbb{R}^{n \times v},$$

其中 $\mathbf{Q} \in \mathbb{R}^{n \times d}$ ， $\mathbf{K} \in \mathbb{R}^{m \times d}$ ， $\mathbf{V} \in \mathbb{R}^{m \times v}$ 。 $\mathbf{Q}\mathbf{K}^\top/\sqrt{d}$ 的 (i, j) 条目是查询 i 对键 j 的评分；softmax 在键维上作用后，第 i 行是权 $\alpha_{ij} \in [0, 1]$ 且行和为 1，表示查询 i 从每个值 $\mathbf{v}_j$ 取多少。再乘 $\mathbf{V}$ 得到加权后的值，第 i 行是查询 i 的汇聚结果。

10.3.4 小结

汇聚总是值的加权平均；权 $\alpha_i \in [0, 1]$ 且和为 1，表示从 $\mathbf{v}_i$ 取多少。维数不同用加性评分，维数相同时缩放点积 $\mathbf{q}^\top \mathbf{k}/\sqrt{d}$ 更省计算；评分本身不是权。

10.3.5 练习

核验改键之后加性与点积权是否仍重合，以及同维时求和评分与点积的几何差异。权重重合指每个 α_i 相同，因而从各 $\mathbf{v}_i$ 取的比例相同。

10.4 Bahdanau 注意力




图 10.4.1 一个带有 Bahdanau 注意力的循环神经网络编码器-解码器模型

符号：见图中标注；各块含义见题注。

seq2seq 里每个解码步都使用同一个 $\mathbf{c}$ 。Bahdanau 注意力让上下文随解码状态变化，在源隐状态上做加性汇聚。

10.4.1 模型

解码时刻 t' 的上下文为

$$\mathbf{c}_{t'} = \sum_{t=1}^T \alpha(\mathbf{s}_{t'-1}, \mathbf{h}_t) \mathbf{h}_t,$$

其中 α 由加性评分给出，查询是上一解码状态 $\mathbf{s}_{t'-1}$ ，键和值都是编码器隐状态 $\mathbf{h}_t$ 。 $\alpha(\mathbf{s}_{t'-1}, \mathbf{h}_t) \in [0, 1]$ 且对 t 求和为 1：表示生成第 t' 个目标词时，从源位置 t 的摘要 $\mathbf{h}_t$ 取多少。 $\mathbf{c}_{t'}$ 是这些源摘要的加权和，与 $\mathbf{h}_t$ 同维，是该解码步专用的源端上下文，不是单个词元。随后

$$\mathbf{s}_{t'} = g(y_{t'-1}, \mathbf{c}_{t'}, \mathbf{s}_{t'-1}).$$

$\mathbf{s}_{t'}$ 是目标端更新后的压缩摘要。

10.4.2 定义注意力解码器

解码器状态由三部分初始化：全部时间步的顶层 $\mathbf{h}_{1:T}$ （作键和值）、编码器各层最终隐状态（作 $\mathbf{s}_0$ ）、源有效长度（供掩蔽 softmax）。每步用当前 $\mathbf{s}_{t'-1}$ 作查询，把注意力输出与输入嵌入拼接后送入循环单元。掩蔽使填充位置的 $\alpha = 0$ ，即从填充值取 0。

10.4.3 训练

编码器仍是循环网络，解码器换成上一小节。训练目标与 BLEU 与 seq2seq 相同。学成后，每个查询在源位置上的权 $\alpha(\mathbf{s}_{t'-1}, \mathbf{h}_t)$ 随 t' 改变，即不同输出词对齐到不同的输入片段：权大的源位置就是“这一步从那里取了多少值”。

10.4.4 小结

Bahdanau 把固定 $\mathbf{c}$ 换成

$$\mathbf{c}_{t'} = \sum_t \alpha(\mathbf{s}_{t'-1}, \mathbf{h}_t) \mathbf{h}_t,$$

$\alpha_t \in [0, 1]$ 且求和为 1，表示从源隐状态（值） $\mathbf{h}_t$ 取多少。查询来自解码器，键值来自编码器，评分取加性注意力。

10.4.5 练习

核验把 GRU 换成 LSTM、把加性评分换成缩放点积后，对齐权与训练代价如何变化。对齐权仍应满足 $[0, 1]$ 且对源位置求和为 1。

10.5 多头注意力




图 10.5.1 多头注意力：多个头连结然后线性变换

符号：头：独立的 Q, K, V 投影；拼接后再线性变换

同一组 $(\mathbf{q}, \mathbf{k}, \mathbf{v})$ 经 h 组不同线性投射，得到 h 种汇聚，再拼起来。

10.5.1 模型

第 i 头

$$\mathbf{h}_i = f(\mathbf{W}_i^{(q)}\mathbf{q}, \mathbf{W}_i^{(k)}\mathbf{k}, \mathbf{W}_i^{(v)}\mathbf{v}) \in \mathbb{R}^{p_v},$$

f 为注意力汇聚：内部仍先算评分，再 softmax 得到该头的 $\alpha \in [0, 1]$ （和为 1），再对投射后的值加权。 $\mathbf{h}_i$ 是第 i 头的加权值，与该头的值同维。输出再经

$$\mathbf{W}_o \begin{bmatrix} \mathbf{h}_1 \\ \vdots \\ \mathbf{h}_h \end{bmatrix} \in \mathbb{R}^{p_o}.$$

拼接不改变各头已算出的数，只把它们排成更长向量； $\mathbf{W}_o$ 再混成 p_o 维输出。各头落在不同子空间，可分别捕获短程与长程依赖。这里的 h 是头数（个数），不是 RNN 隐状态。

10.5.2 实现

每个头用缩放点积注意力。取 $p_q = p_k = p_v = p_o/h$ ，并把各头的投射输出宽度设为 $p_q h = p_o$ ，即可把 h 个头排在批量维上一次算完。这些 p 都是向量维数。 p_o 对应隐藏宽度。映射在数学上仍是上一小节，只是张量轴被重排以便并行。每个头自己的权仍表示该头从对应值取多少。

10.5.3 小结

多头把 h 组 $(\mathbf{W}_i^{(q)}, \mathbf{W}_i^{(k)}, \mathbf{W}_i^{(v)})$ 的汇聚拼起来再乘 $\mathbf{W}_o$ ，用同一查询-键-值的不同子空间表示。每个头内部 α_i 仍在 $[0, 1]$ 且和为 1。

10.5.4 练习

核验各头权矩阵是否学到不同对齐，以及去掉某头对预测的影响如何度量该头的重要性。不同对齐表现为各头的 α 把质量分给不同的值下标。

10.6 自注意力和位置编码




图 10.6.1 比较卷积神经网络（填充词元被忽略）、循环神经网络和自注意力三种架构符号：见图中标注；各块含义见题注。

若查询、键、值来自同一组输入，就得到自注意力。它本身置换等变，必须另加位置编码才能感知次序。

10.6.1 自注意力

对 $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$,

$$\mathbf{y}_i = f(\mathbf{x}_i, (\mathbf{x}_1, \mathbf{x}_1), \dots, (\mathbf{x}_n, \mathbf{x}_n)) \in \mathbb{R}^d,$$

即第 i 个查询关注整组键-值。（实现里键和值通常各做一次线性投射，上式强调它们来自同一组 $\mathbf{x}$ 。） $\mathbf{y}_i$ 是位置 i 的输出向量，等于各 $\mathbf{x}_j$ 经值投射后的加权和。用线性投射写出矩阵形式：

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V,$$

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right)\mathbf{V}.$$

softmax 矩阵第 i 行第 j 列是 $\alpha_{ij} \in [0, 1]$ ，行和为 1，表示位置 i 从位置 j 的值 $\mathbf{v}_j$ 取多少。乘 $\mathbf{V}$ 后第 i 行就是 $\sum_j \alpha_{ij} \mathbf{v}_j$ 。

10.6.2 比较卷积神经网络、循环神经网络和自注意力

把长 n 、宽 d 的序列映到同形序列。 n 是时间或位置个数， d 是通道或特征维。卷积核宽 k 时，计算复杂度 $\mathcal{O}(knd^2)$ ，顺序操作 $\mathcal{O}(1)$ ，最长路径 $\mathcal{O}(n/k)$ 。循环网络复杂度 $\mathcal{O}(nd^2)$ ，顺序操作 $\mathcal{O}(n)$ ，最长路径 $\mathcal{O}(n)$ 。自注意力复杂度 $\mathcal{O}(n^2d)$ ，顺序操作 $\mathcal{O}(1)$ ，最长路径 $\mathcal{O}(1)$ 。这些大 O 中的量都是运算次数或步数，不是注意力权。因此自注意力最利于并行与长程依赖，但序列很长时二次代价占优。

10.6.3 位置编码

绝对位置编码 $\mathbf{P} \in \mathbb{R}^{n \times d}$ 与输入相加： $\mathbf{X} \leftarrow \mathbf{X} + \mathbf{P}$ ，其中

$$\begin{aligned} p_{i,2j} &= \sin\left(\frac{i}{10000^{2j/d}}\right), \\ p_{i,2j+1} &= \cos\left(\frac{i}{10000^{2j/d}}\right). \end{aligned}$$

i 是位置下标（从 0 或 1 起的整数）， j 是特征维对的编号。 $p_{i,2j}$ 与 $p_{i,2j+1}$ 落在 $[-1, 1]$ ，是该位置在该频率上的正弦/余弦坐标，不是注意力权。相加后每个输入条目变成“内容特征加位置特征”。

10.6.3.1 绝对位置信息

第 j 维的角频率随 j 下降，类似二进制中高比特翻转更慢。连续三角函数比比特编码更省空间，并使相邻位置的表示平滑变化。相邻 i 的 $p_{i,\cdot}$ 在欧氏距离上接近，该距离无量纲。

10.6.3.2 相对位置信息

令 $\omega_j = 10000^{-2j/d}$ 。位移 δ 对应二维旋转：

$$\begin{aligned} &\begin{bmatrix} \cos(\delta\omega_j) & \sin(\delta\omega_j) \\ -\sin(\delta\omega_j) & \cos(\delta\omega_j) \end{bmatrix} \begin{bmatrix} p_{i,2j} \\ p_{i,2j+1} \end{bmatrix} \\ &= \begin{bmatrix} p_{i+\delta,2j} \\ p_{i+\delta,2j+1} \end{bmatrix}. \end{aligned}$$

左边矩阵是平面旋转，把位置 i 的编码转到位置 $i + \delta$ 的编码。因此相对位置可由绝对编码的线性变换得到； δ 是位置差（整数格点数）。

10.6.4 小结

自注意力用同一 $\mathbf{X}$ 生成 $(\mathbf{Q}, \mathbf{K}, \mathbf{V})$; 权 α_{ij} 表示位置 i 从位置 j 的值取多少。位置编码 $\mathbf{P}$ 把次序注入表示, 否则模型对置换不变。

10.6.5 练习

核验只堆叠带位置编码的自注意力层可能出现的秩与长度外推问题, 以及如何把 $\mathbf{P}$ 改成可学习矩阵。可学习的 P_{ij} 仍是位置 i 、维 j 上的加性特征, 不是 α 。

10.7 Transformer




图 10.7.1 transformer 架构

符号: 多头自注意力; 前馈; 残差 + 层归一化; 位置编码

Transformer 是编码器-解码器, 但子层只有多头注意力与位置前馈网络, 不含卷积或循环。

10.7.1 模型

源序列与目标序列先做词嵌入，乘 $\sqrt{d}$ 后加上位置编码，再分别送入 N 层编码器与解码器。 $\sqrt{d}$ 把嵌入缩放到与位置编码相近的幅度； d 是模型宽。编码器每层是多头自注意力加前馈；解码器每层是掩蔽自注意力、编码器-解码器注意力与前馈。子层都包在残差与层规范化中。注意力内部仍是

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \mathbf{K} = \mathbf{X}\mathbf{W}_K, \mathbf{V} = \mathbf{X}\mathbf{W}_V, \quad \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right)\mathbf{V}.$$

softmax 给出的每个 $\alpha_{ij} \in [0, 1]$ 且行和为 1，表示该查询从对应值取多少；乘 $\mathbf{V}$ 得到加权值。残差把该加权值加回原信号：输出条目是原表示加上注意力修正。

10.7.2 基于位置的前馈网络

同一两层感知机作用于每个位置：

$$\text{FFN}(\mathbf{x}) = \phi(\mathbf{x}\mathbf{W}_1 + \mathbf{b}_1)\mathbf{W}_2 + \mathbf{b}_2,$$

ϕ 取 ReLU。输入 $\mathbf{x} \in \mathbb{R}^d$ ，隐宽 n_{ffn} ，输出仍在 $\mathbb{R}^d$ 。每个输出分量是该位置上通道混合后的非线性特征，不是注意力权。形状 (n_{batch}, n, d) 的张量只在最后一维上被映射到 n_{ffn} 再映回 d ；位置之间不混合。相同输入给出相同输出。

10.7.3 残差连接和层规范化

层规范化沿特征维标准化。对 $\mathbf{x} \in \mathbb{R}^d$,

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i, \quad \sigma^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2,$$

$$\text{LN}(\mathbf{x}) = \gamma \odot \frac{\mathbf{x} - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta.$$

μ 是该向量 d 个特征的均值， σ^2 是方差；中间量是按特征标准化后均值 0、方差 1 的激活。 γ, β 再恢复尺度与偏移。与批量规范化不同，它不依赖批量大小，适合变长序列。子层包装为

$$\text{AddNorm}(\mathbf{x}, \text{Sublayer}) = \text{LN}(\mathbf{x} + \text{Dropout}(\text{Sublayer}(\mathbf{x}))).$$

$\mathbf{x} + \text{Sublayer}(\mathbf{x})$ 的每个条目是原信号加上子层修正（与 ResNet 相同含义），再标准化。残差要求 Sublayer 输入输出同形状。

10.7.4 编码器

第 ℓ 个编码器块不改变形状：

$$\begin{aligned}\mathbf{X} &\leftarrow \text{AddNorm}(\mathbf{X}, \text{MHAtt}(\mathbf{X}, \mathbf{X}, \mathbf{X})), \\ \mathbf{X} &\leftarrow \text{AddNorm}(\mathbf{X}, \text{FFN}).\end{aligned}$$

第一式：自注意力权 α_{ij} 表示源位置 i 从源位置 j 取多少，加权值加回原 $\mathbf{X}$ 再 LN。第二式：逐位置前馈修正再加回。嵌入先乘 $\sqrt{d}$ 再加 $\mathbf{P}$ ，然后堆叠 N 个上述块。自注意力的 $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ 都来自同一层输入。

10.7.5 解码器

每个解码器块三步：

$$\begin{aligned}\mathbf{Y} &\leftarrow \text{AddNorm}(\mathbf{Y}, \text{MaskedMHAtt}(\mathbf{Y}, \mathbf{Y}, \mathbf{Y})), \\ \mathbf{Y} &\leftarrow \text{AddNorm}(\mathbf{Y}, \text{MHAtt}(\mathbf{Y}, \mathbf{X}, \mathbf{X})), \\ \mathbf{Y} &\leftarrow \text{AddNorm}(\mathbf{Y}, \text{FFN}).\end{aligned}$$

第一项是掩蔽自注意力：时刻 t' 只能看见 $y_{\leq t'}$ ，被掩位置的 $\alpha = 0$ （从未来值取 0），以保持自回归。第二项是编码器-解码器注意力：查询来自解码器，键值来自编码器输出 $\mathbf{X}$ ，此时 $\alpha_{t',t}$ 表示生成目标位置 t' 时从源位置 t 的值取多少。第三项是逐位置非线性修正。预测阶段词元逐个生成，训练阶段可用后续掩蔽一次算完全序列。

10.7.6 训练

编码器与解码器各 N 层、 h 头，在英-法数据上最小化带掩码的交叉熵。交叉熵是正确词元负对数概率的平均，标量。编码器自注意力权形状为 $(\text{layers}, \text{heads}, n_{\text{steps}}, n_{\text{steps}})$ ，查询与键都来自源序列；每个 $n_{\text{steps}} \times n_{\text{steps}}$ 切片的条目是 α_{ij} ，行和为 1。解码器交叉注意力的键则来自源、查询来自目标。

10.7.7 小结

Transformer 用

$$\text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right)\mathbf{V}, \quad \text{FFN}, \quad \text{LN}(\mathbf{x} + \text{Sublayer}(\mathbf{x}))$$

堆成编码器-解码器。softmax 权 $\alpha_i \in [0, 1]$ 且和为 1，表示从值 v_i 取多少；残差和是原信号加修正；位置编码提供次序，掩蔽自注意力保持自回归。

10.7.8 练习

核验加深 N 对速度与 BLEU 的影响、长序列下 n^2 注意力的代价，以及语言模型应使用编码器、掩蔽解码器或二者的组合。 n^2 是查询-键对数，决定评分矩阵有多少个条目；BLEU 仍是 n 元重叠质量。

第十一章 优化算法

训练把经验风险写成可微标量 $f(\mathbf{x})$ ，再用迭代 $\mathbf{x} \leftarrow \mathbf{x} - \eta \widehat{\nabla} f(\mathbf{x})$ 更新参数。右边减去的 $\eta \widehat{\nabla} f(\mathbf{x})$ 与参数同形：第 j 个分量是第 j 个权重本步要移动的量，不是概率。 η 是步长（学习率），只控制这次移动有多远。深度学习要的是泛化，优化只直接压训练误差；二者目标不同。下面先写凸性与梯度下降，再写随机、动量与自适应方法。

11.1 优化和深度学习

记训练目标为 $f(\mathbf{x})$ 。最大化等价于最小化 $-f$ 。优化求 f 的数值极小；深度学习还要求该极小对应的模型在未见数据上风险低。

11.1.1 优化的目标

经验风险与风险分别为

$$R_{\text{emp}}(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \ell(f_{\mathbf{x}}(\mathbf{z}^{(i)}), y^{(i)}), \quad R(\mathbf{x}) = \mathbb{E}_{(\mathbf{z}, y)}[\ell(f_{\mathbf{x}}(\mathbf{z}), y)].$$

左边是把 n 个训练样本上的损失取算术平均，得到一个与单条损失同量纲的标量，表示“当前参数在训练集上的平均误差”。右边是对真实数据分布求期望，表示“在未见样本上的平均误差”。优化算法直接减小 R_{emp} ；泛化要求 R 小。过拟合时 $R_{\text{emp}} \ll R$ ，故仅压训练误差不够。

11.1.2 深度学习中的优化挑战

多数深度目标无解析解，只能用数值迭代。梯度为零的点可以是局部极小、鞍点，或因梯度消失而停滞。

11.1.2.1 局部最小值

在 $[-1, 2]$ 上

$$f(x) = x \cos(\pi x)$$

对每个实数 x 算出一个标量函数值。该函数有多个局部极小：在某个邻域内它比附近点都小，但不一定是全局最小。梯度下降停在哪一个，取决于初值与步长。

11.1.2.2 鞍点

$f(x) = x^3$ 在 $x = 0$ 处 $f'(0) = f''(0) = 0$ ，但不是极小： $f'(0) = 0$ 只说明此处切线水平，不是“已经到谷底”。 $f(x, y) = x^2 - y^2$ 在 $(0, 0)$ 是鞍点：沿 x 极小、沿 y 极大。Hessian 的特征值全正为局部极小，全负为局部极大，有正有负则为鞍点。特征值本身是曲率，不是参数该移动的距离。

11.1.2.3 梯度消失

若 $f(x) = \tanh(x)$ ，则

$$f'(x) = 1 - \tanh^2(x), \quad f'(4) \approx 0.0013.$$

$f'(x)$ 是切线斜率：输入增加 1 时输出大约增加这么多。 $f'(4) \approx 0.0013$ 表示在 $x = 4$ 处几乎平坦。从 $x = 4$ 出发，参数改变量 $\eta f'(x)$ 接近零，迭代长时间几乎不动。这里 $\eta f'(x)$ 是本步 x 要减去的数，仍不是概率。

11.1.3 小结

优化压 R_{emp} 这个训练平均误差，不自动压真实风险 R 。局部极小、鞍点与 $f' \approx 0$ 都会使 $x \leftarrow x - \eta f'(x)$ 停滞：被减去的那一项太小，参数几乎不移动。

11.1.4 练习

核验：隐藏层宽度为 d 时局部极小的置换对称、对称随机矩阵特征值分布是否关于零对称。特征值是曲率符号与大小，不是学习率。

11.2 凸性




图 11.2.1 第一组是非凸的，另外两组是凸的。

符号：见图中标注；各块含义见题注。




图 11.2.2 两个凸集的交集是凸的。

符号：见图中标注；各块含义见题注。




图 11.2.3 两个凸集的并集不一定是凸的。

符号：见图中标注；各块含义见题注。




图 11.2.4 Convex Projections.

符号：见图中标注；各块含义见题注。

若算法在凸问题上失败，非凸上更难指望。深度目标整体非凸，但局部常近似凸。

11.2.1 定义

先固定凸集，再固定凸函数。

11.2.1.1 凸集

集合 $\mathcal{X}$ 凸，当且仅当对任意 $a, b \in \mathcal{X}$ 与 $\lambda \in [0, 1]$,

$$\lambda a + (1 - \lambda)b \in \mathcal{X}.$$

左边是两点之间的线段上的点： λ 是混合比例，取值 $[0, 1]$ ，不是概率模型里的类概率，只表示“离 a 有多近”。凸性要求这条线段整段落在集合内。

11.2.1.2 凸函数

f 在凸集上凸，当且仅当

$$\lambda f(x) + (1 - \lambda)f(x') \geq f(\lambda x + (1 - \lambda)x').$$

左边是两端函数值的加权平均，右边是中点处的函数值。不等式表示弦在函数图像上方：中点的 f 不会高于两端的平均。

11.2.1.3 詹森不等式

对 $\alpha_i \geq 0$ 、 $\sum_i \alpha_i = 1$,

$$\begin{aligned} \sum_i \alpha_i f(x_i) &\geq f\left(\sum_i \alpha_i x_i\right), \\ \mathbb{E}_X[f(X)] &\geq f(\mathbb{E}_X[X]). \end{aligned}$$

α_i 是凸组合系数，和为 1；左边是函数值的加权平均，右边是“先平均输入再算 f ”。取 $f = -\log$ 得

$$\mathbb{E}_{Y \sim P(Y)}[-\log P(X | Y)] \geq -\log P(X).$$

左边是条件交叉熵（nats 或 bits，视对数底而定），右边是无条件码长；不等式表示：先对 Y 平均再编码，不会比直接编码 X 更短。

11.2.2 性质

凸性把局部信息变成全局信息。

11.2.2.1 局部极小值是全局极小值

设 x^* 局部极小而 $f(x') < f(x^*)$ 。对充分小的 $\lambda \in (0, 1)$,

$$\begin{aligned} f(\lambda x^* + (1 - \lambda)x') &\leq \lambda f(x^*) + (1 - \lambda)f(x') \\ &< \lambda f(x^*) + (1 - \lambda)f(x^*) = f(x^*), \end{aligned}$$

与局部极小矛盾。故凸函数的局部极小即全局极小：在该点算得的 $f(x^*)$ 就是全域最小的那个标量目标值。

11.2.2.2 凸函数的下水平集是凸的

下水平集

$$\mathcal{S}_b := \{x \in \mathcal{X} : f(x) \leq b\}$$

是所有“函数值不超过阈值 b ”的点； b 与 f 同量纲。对凸 f 该集合是凸的：若 $x, x' \in \mathcal{S}_b$, 则

$$f(\lambda x + (1 - \lambda)x') \leq \lambda f(x) + (1 - \lambda)f(x') \leq b.$$

中点的函数值仍不超过 b , 所以线段上的点仍在水平集里。

11.2.2.3 凸性和二阶导数

一维时, 凸性蕴含

$$\frac{1}{2}f(x + \epsilon) + \frac{1}{2}f(x - \epsilon) \geq f(x),$$

左右都是函数值：两端平均不低于中点。从而

$$f''(x) = \lim_{\epsilon \rightarrow 0} \frac{f(x + \epsilon) + f(x - \epsilon) - 2f(x)}{\epsilon^2} \geq 0.$$

$f''(x)$ 是曲率：正表示局部上凸（碗口朝上），不是步长。若 f' 单调，由中值定理

$$f'(\alpha) = \frac{f(x) - f(a)}{x - a}, \quad f'(\beta) = \frac{f(b) - f(x)}{b - x},$$

这两个数都是割线斜率。再令 $\lambda = (x - a)/(b - a)$ 得

$$\lambda f(b) + (1 - \lambda)f(a) \geq f((1 - \lambda)a + \lambda b).$$

高维时定义

$$g(z) \stackrel{\text{def}}{=} f(z\mathbf{x} + (1 - z)\mathbf{y}), \quad z \in [0, 1].$$

对每个 z 算出线段上那一点的函数值。 f 凸当且仅当每个这样的 g 凸，当且仅当 Hessian $\nabla^2 f$ 半正定。Hessian 的条目 $\partial^2 f / \partial x_i \partial x_j$ 表示：第 i 个梯度分量再对 x_j 的敏感度，量纲是目标对参数的二阶变化率。

11.2.3 约束

约束问题写成

$$\begin{aligned} & \underset{\mathbf{x}}{\text{minimize}} && f(\mathbf{x}) \\ & \text{subject to} && c_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, N. \end{aligned}$$

$f(\mathbf{x})$ 是要压小的标量； $c_i(\mathbf{x}) \leq 0$ 表示第 i 条约束成立， c_i 本身一般不是概率。

11.2.3.1 拉格朗日函数

乘子 $\alpha_i \geq 0$,

$$L(\mathbf{x}, \alpha_1, \dots, \alpha_n) = f(\mathbf{x}) + \sum_{i=1}^n \alpha_i c_i(\mathbf{x}).$$

L 与 f 同量纲：把每条约束违反量 c_i 用非负权重 α_i 加进目标。 α_i 越大，越不能容忍 $c_i > 0$ 。

11.2.3.2 惩罚

把 $\alpha_i c_i(\mathbf{x})$ 加进目标，近似强制 $c_i(\mathbf{x}) \leq 0$ 。权重衰减 $\frac{\lambda}{2} \|\mathbf{w}\|^2$ 对应约束 $\|\mathbf{w}\|^2 - r^2 \leq 0$ 。 $\|\mathbf{w}\|^2$ 是参数欧氏长度的平方，表示权重整体有多大； λ 是惩罚强度，不是学习率。

11.2.3.3 投影

梯度裁剪

$$\mathbf{g} \leftarrow \mathbf{g} \cdot \min(1, \theta / \|\mathbf{g}\|)$$

输入梯度 $\mathbf{g}$ ，输出与 $\mathbf{g}$ 同形。若 $\|\mathbf{g}\| > \theta$ ，则把长度缩到 θ ；各坐标仍表示“该参数方向上损失的斜率”，只是整体步被限制在半径 θ 的球上。一般投影为

$$\text{Proj}_{\mathcal{X}}(\mathbf{x}) = \underset{\mathbf{x}' \in \mathcal{X}}{\text{argmin}} \|\mathbf{x} - \mathbf{x}'\|.$$

输出是可行集里离 $\mathbf{x}$ 最近的点，距离与 $\mathbf{x}$ 同量纲。

11.2.4 小结

凸函数满足 $\lambda f(x) + (1 - \lambda)f(x') \geq f(\lambda x + (1 - \lambda)x')$ ，局部极小即全局极小，Hessian 半正定。约束经 L 或惩罚进入目标，可行点由 $\text{Proj}_{\mathcal{X}}$ 拉回。

11.2.5 练习

核验： p 范数球的凸性、 $\max(f, g)$ 保持凸而 $\min(f, g)$ 不必、Softmax 规范化的凸性。

11.3 梯度下降

全梯度下降很少直接用于深度模型，但它给出步长、曲率与预处理的原型。

11.3.1 一维梯度下降

泰勒展开

$$f(x + \epsilon) = f(x) + \epsilon f'(x) + \mathcal{O}(\epsilon^2).$$

$f(x)$ 是当前位置的目标值； $\epsilon f'(x)$ 是沿扰动 ϵ 的一阶改变量。取 $\epsilon = -\eta f'(x)$,

$$f(x - \eta f'(x)) = f(x) - \eta f'(x)^2 + \mathcal{O}(\eta^2 f'(x)^2).$$

η 充分小时 f 下降。更新为

$$x \leftarrow x - \eta f'(x).$$

$\eta f'(x)$ 就是本步参数改变量：从 x 里减去它。 $f'(x)$ 是“ x 增加 1 时 f 大约增加多少”，乘上步长 η 后，得到 x 实际要移动的距离。 η 是步长，取值通常为实数，不是 $[0, 1]$ 上的概率。

11.3.1.1 学习率

η 过小则每步改变量 $|\eta f'(x)|$ 太小，参数几乎不动； $|\eta f'(x)|$ 过大则二阶余项不可忽略， f 不必下降。学习率只决定“沿负梯度走多远”，不表示某事件发生的机会。

11.3.1.2 局部最小值

$f(x) = x \cos(cx)$ 有无穷多个局部极小。过大的 η 可把迭代送进较差的谷：每步移动距离 $|\eta f'(x)|$ 跨过了近处的小坑。

11.3.2 多元梯度下降

$$\nabla f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_d} \right]^\top,$$

第 j 个分量 $\partial f / \partial x_j$ 表示： x_j 增加 1 个单位时，标量 f 大约增加多少。整个向量与 $\mathbf{x}$ 同形。

$$f(\mathbf{x} + \boldsymbol{\epsilon}) = f(\mathbf{x}) + \boldsymbol{\epsilon}^\top \nabla f(\mathbf{x}) + \mathcal{O}(\|\boldsymbol{\epsilon}\|^2),$$

内积 $\boldsymbol{\epsilon}^\top \nabla f(\mathbf{x})$ 是沿 $\boldsymbol{\epsilon}$ 走一步后 f 的一阶改变量。

$$\mathbf{x} \leftarrow \mathbf{x} - \eta \nabla f(\mathbf{x}).$$

$\eta \nabla f(\mathbf{x})$ 与 $\mathbf{x}$ 逐坐标相减：第 j 个权重本步移动 $-\eta \partial f / \partial x_j$ ，正梯度坐标减小该权重，负梯度坐标增大该权重。

11.3.3 自适应方法

合适的 η 难选。二阶方法用曲率自动定步，计算贵，但给出预处理的直觉。

11.3.3.1 牛顿法

$$f(\mathbf{x} + \boldsymbol{\epsilon}) = f(\mathbf{x}) + \boldsymbol{\epsilon}^\top \nabla f(\mathbf{x}) + \frac{1}{2} \boldsymbol{\epsilon}^\top \nabla^2 f(\mathbf{x}) \boldsymbol{\epsilon} + \mathcal{O}(\|\boldsymbol{\epsilon}\|^3).$$

二次项用 Hessian 度量沿 $\boldsymbol{\epsilon}$ 的弯曲程度。令 $\mathbf{H} = \nabla^2 f(\mathbf{x})$ ，驻点条件

$$\nabla f(\mathbf{x}) + \mathbf{H}\boldsymbol{\epsilon} = 0 \quad \Rightarrow \quad \boldsymbol{\epsilon} = -\mathbf{H}^{-1} \nabla f(\mathbf{x}).$$

$\boldsymbol{\epsilon}$ 是牛顿步：每个坐标仍是参数应移动的量，只是按曲率重新缩放过，不再是单纯的 $-\eta \nabla f$ 。

11.3.3.2 收敛性分析

一维牛顿误差 $e^{(k)} = x^{(k)} - x^*$ 满足

$$\begin{aligned} 0 &= f'(x^{(k)} - e^{(k)}) \\ &= f'(x^{(k)}) - e^{(k)} f''(x^{(k)}) + \frac{1}{2} (e^{(k)})^2 f'''(\xi^{(k)}), \end{aligned}$$

$e^{(k)}$ 是当前参数离最优点的差，与 x 同量纲。从而

$$|e^{(k+1)}| = \frac{1}{2} (e^{(k)})^2 \frac{|f'''(\xi^{(k)})|}{f''(x^{(k)})} \leq c (e^{(k)})^2.$$

右边是误差的平方量级，表示接近最优点后误差按平方收缩。在凸且 f'' 有下界时为二次收敛。

11.3.3.3 预处理

对角近似

$$\mathbf{x} \leftarrow \mathbf{x} - \eta \operatorname{diag}(\mathbf{H})^{-1} \nabla f(\mathbf{x})$$

按坐标缩放步长：第 j 个权重的改变量是 $-\eta(\partial f / \partial x_j) / H_{jj}$ ，曲率大的坐标步更短。避免直接求 $\mathbf{H}^{-1}$ 。

11.3.3.4 梯度下降和线搜索

沿 $-\nabla f(\mathbf{x})$ 对 η 做一维搜索，使 $f(\mathbf{x} - \eta \nabla f(\mathbf{x}))$ 最小。被选中的 η 仍是步长：使这一步参数改变量 $\eta \nabla f$ 对应的目标下降最多。每步需在全数据上求值，深度模型上通常不可行。

11.3.4 小结

更新 $\mathbf{x} \leftarrow \mathbf{x} - \eta \nabla f(\mathbf{x})$ 中， $\eta \nabla f$ 是本步每个权重的位移； η 过大则位移过大而发散、过小则几乎不动。牛顿步 $-\mathbf{H}^{-1} \nabla f$ 在凸问题上快，非凸上 Hessian 不定时不能直接用。

11.3.5 练习

核验：不同 η 下 f 是否单调下降、线搜索是否需要导数、对角 Hessian 预处理对坐标尺度不均问题的作用。

11.4 随机梯度下降

全梯度每次用全部 n 个样本；随机梯度每次用一个样本。

11.4.1 随机梯度更新

$$f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}), \quad \nabla f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}).$$

f_i 是第 i 个样本上的损失； f 是它们的平均，与单条损失同量纲。 ∇f_i 与参数同形，第 j 分量是该样本损失对第 j 个权重的敏感度。随机更新

$$\mathbf{x} \leftarrow \mathbf{x} - \eta \nabla f_i(\mathbf{x})$$

同样把 $\eta \nabla f_i$ 当作本步参数改变量，只是梯度来自一个样本而非全平均。无偏：

$$\mathbb{E}_i[\nabla f_i(\mathbf{x})] = \nabla f(\mathbf{x}).$$

左边是随机梯度的期望，等于全梯度：平均意义上指的仍是同一组斜率。

11.4.2 动态学习率

$$\eta(t) = \eta_i$$

$$t_i \leq t \leq t_{i+1}$$

分段常数，

$$\eta(t) = \eta_0 e^{-\lambda t}$$

指数衰减,

$$\eta(t) = \eta_0 (\beta t + 1)^{-\alpha}$$

多项式衰减.

$\eta(t)$ 始终是第 t 步的步长, 单位与“参数位移 / 梯度”一致, 不是概率。分段常数在一段时间内保持同一位移尺度; 指数与多项式让后期 $|\eta \nabla f_i|$ 变小, 以便在最优点附近细调。

11.4.3 凸目标的收敛性分析

$$\mathbf{x}_{t+1} = \mathbf{x}_t - \eta_t \partial_{\mathbf{x}} f(\boldsymbol{\xi}_t, \mathbf{x}), \quad R(\mathbf{x}) = \mathbb{E}_{\boldsymbol{\xi}}[f(\boldsymbol{\xi}, \mathbf{x})].$$

$\eta_t \partial_{\mathbf{x}} f$ 仍是参数改变量; $R(\mathbf{x})$ 是随机损失的期望, 表示总体平均误差。展开距离

$$\begin{aligned} \|\mathbf{x}_{t+1} - \mathbf{x}^*\|^2 &= \|\mathbf{x}_t - \mathbf{x}^*\|^2 + \eta_t^2 \|\partial_{\mathbf{x}} f(\boldsymbol{\xi}_t, \mathbf{x})\|^2 \\ &\quad - 2\eta_t \langle \mathbf{x}_t - \mathbf{x}^*, \partial_{\mathbf{x}} f(\boldsymbol{\xi}_t, \mathbf{x}) \rangle. \end{aligned}$$

$\|\mathbf{x}_t - \mathbf{x}^*\|^2$ 是当前参数离最优点的平方欧氏距离, 越大表示越远。若梯度有界 $\|\partial_{\mathbf{x}} f\| \leq L$, 则 $\eta_t^2 \|\partial_{\mathbf{x}} f\|^2 \leq \eta_t^2 L^2$ 。凸性给出

$$f(\boldsymbol{\xi}_t, \mathbf{x}^*) \geq f(\boldsymbol{\xi}_t, \mathbf{x}_t) + \langle \mathbf{x}^* - \mathbf{x}_t, \partial_{\mathbf{x}} f(\boldsymbol{\xi}_t, \mathbf{x}_t) \rangle,$$

于是

$$\|\mathbf{x}_t - \mathbf{x}^*\|^2 - \|\mathbf{x}_{t+1} - \mathbf{x}^*\|^2 \geq 2\eta_t (f(\boldsymbol{\xi}_t, \mathbf{x}_t) - f(\boldsymbol{\xi}_t, \mathbf{x}^*)) - \eta_t^2 L^2.$$

左边是距离平方的减少量; 右边第一项是本步目标下降与步长的乘积。取期望并累加, 加权平均

$$\bar{\mathbf{x}} \stackrel{\text{def}}{=} \frac{\sum_{t=1}^T \eta_t \mathbf{x}_t}{\sum_{t=1}^T \eta_t}$$

是用步长加权的参数平均, 仍在参数空间里。满足

$$\mathbb{E}[R(\bar{\mathbf{x}})] - R^* \leq \frac{r^2 + L^2 \sum_{t=1}^T \eta_t^2}{2 \sum_{t=1}^T \eta_t}.$$

左边是平均风险相对最优的超出量, 与损失同量纲; 右边给出该超出量的上界。

11.4.4 随机梯度和有限样本

有放回时, 一轮中某样本被抽到的概率

$$1 - (1 - 1/n)^n \approx 1 - e^{-1} \approx 0.63.$$

这是 $[0, 1]$ 上的概率: 约 63% 的样本至少出现一次。恰好抽一次的概率约为 $e^{-1} \approx 0.37$ 。无放回遍历则每个样本每轮恰好一次。

11.4.5 小结

凸时 SGD 对广泛的 $\{\eta_t\}$ 收敛到最优；深度目标非凸，无同样保证。 n 大时全梯度每步代价高，故用 ∇f_i ；每次减去的仍是 $\eta \nabla f_i$ 这份参数位移。

11.4.6 练习

核验： η_t 衰减过快或过慢时 $\|\mathbf{x}_t - \mathbf{x}^*\|$ 的轨迹，以及有放回与无放回采样对无偏性的影响。

11.5 小批量随机梯度下降

全梯度数据效率低，单样本计算效率低。小批量在二者之间。

11.5.1 向量化和缓存

一次处理 $|\mathcal{B}|$ 个样本，使矩阵乘与缓存命中摊薄解释器与内存延迟。 $|\mathcal{B}|$ 是正整数，表示本步用了几条样本，不是学习率。多 GPU 时每卡至少一张图，有效批量随设备数放大。

11.5.2 小批量

单样本

$$\mathbf{g}_t = \partial_{\mathbf{w}} f(\mathbf{x}_t, \mathbf{w}),$$

与 $\mathbf{w}$ 同形，第 j 分量是该样本损失对 w_j 的斜率。小批量

$$\mathbf{g}_t = \partial_{\mathbf{w}} \frac{1}{|\mathcal{B}_t|} \sum_{i \in \mathcal{B}_t} f(\mathbf{x}_i, \mathbf{w}).$$

先把批量内损失取平均得到一个标量，再对 $\mathbf{w}$ 求导： $\mathbf{g}_t$ 是平均损失的梯度，各坐标含义与全梯度相同，只是用 $|\mathcal{B}_t|$ 条样本估计。 $\mathcal{B}_t$ 来自数据的随机排列，每轮每样本一次。

11.5.3 读取数据集

对已标准化的设计矩阵 $\mathbf{X} \in \mathbb{R}^{n \times d}$ 、响应 $\mathbf{y}$ ，迭代器输出 $(\mathbf{X}_{\mathcal{B}}, \mathbf{y}_{\mathcal{B}})$ ， X_{ij} 仍是第 i 个样本第 j 个特征； y_i 是对应目标值。 $|\mathcal{B}|$ 为批量大小。

11.5.4 从零开始实现

线性模型 $\hat{y} = \mathbf{w}^\top \mathbf{x} + b$, $\hat{y}$ 是与 y 同量纲的点预测, 不是类别概率。损失在批量上先平均再反传, 故更新中 $\mathbf{g}_t$ 不再除 $|\mathcal{B}|$ 。更新 $\mathbf{w} \leftarrow \mathbf{w} - \eta \mathbf{g}_t$ 里, $\eta \mathbf{g}_t$ 的每一维是该权重本步移动多少。 $|\mathcal{B}| = n$ 退化为批量梯度下降。

11.5.5 简洁实现

框架优化器实现同一映射 $\mathbf{w} \leftarrow \mathbf{w} - \eta \mathbf{g}_t$, 状态为空。 η 仍只是步长。

11.5.6 小结

小批量梯度 $\mathbf{g}_t = \partial_{\mathbf{w}} \frac{1}{|\mathcal{B}_t|} \sum_{i \in \mathcal{B}_t} f(\mathbf{x}_i, \mathbf{w})$ 同时利用向量化与噪声梯度。训练中降低 η 是缩小每步参数位移, 有助于后期收敛。

11.5.7 练习

核验: $|\mathcal{B}|$ 与 η 如何改变目标下降速度, 以及数据被复制一倍时三种梯度估计的偏差。

11.6 动量法

噪声梯度上 η 难选。动量用过去梯度的泄漏平均代替当前梯度。

11.6.1 基础

先写平均, 再写更新。

11.6.1.1 泄漏平均值

$$\mathbf{g}_{t,t-1} = \partial_{\mathbf{w}} \frac{1}{|\mathcal{B}_t|} \sum_{i \in \mathcal{B}_t} f(\mathbf{x}_i, \mathbf{w}_{t-1}).$$

这是当前批量上的梯度, 与参数同形。

$$\mathbf{v}_t = \beta \mathbf{v}_{t-1} + \mathbf{g}_{t,t-1} = \sum_{\tau=0}^{t-1} \beta^\tau \mathbf{g}_{t-\tau,t-\tau-1}.$$

$\mathbf{v}_t$ 是动量缓冲：过去梯度的指数加权和（速度），与 $\mathbf{g}$ 同形。第 j 个分量是第 j 个权重对应的“惯性”：近期该方向上斜率的泄漏平均，不是学习率，也不是概率。 $\beta \in [0, 1)$ 是衰减系数，越大则越看重更早的梯度。

11.6.1.2 条件不佳的问题

$$f(\mathbf{x}) = 0.1x_1^2 + 2x_2^2$$

对 (x_1, x_2) 算出一个非负标量，两个方向曲率相差 20 倍。固定 η 的梯度下降在窄谷中振荡： $\eta \partial f / \partial x_2$ 过大而 $\eta \partial f / \partial x_1$ 过小。

11.6.1.3 动量法

$$\mathbf{v}_t \leftarrow \beta \mathbf{v}_{t-1} + \mathbf{g}_{t,t-1},$$

$$\mathbf{x}_t \leftarrow \mathbf{x}_{t-1} - \eta_t \mathbf{v}_t.$$

先把当前梯度并入速度 $\mathbf{v}_t$ ，再让参数减去 $\eta_t \mathbf{v}_t$ 。 $\eta_t \mathbf{v}_t$ 才是本步每个权重的位移； $\mathbf{v}_t$ 本身是速度缓冲，不是参数。

11.6.1.4 有效样本权重

$\sum_{\tau=0}^{\infty} \beta^\tau = 1/(1 - \beta)$ ，有效步长约为 $\eta/(1 - \beta)$ ： $\beta = 0.9$ 时位移大约相当于把 η 放大 10 倍。 $\beta = 0.9$ 相当于约 10 个梯度的加权平均。这仍是步长尺度，不是概率。

11.6.2 实际实验

速度 $\mathbf{v}$ 与 $\mathbf{g}$ 同形，需额外状态。

11.6.2.1 从零开始实现

维护 $\mathbf{v}$ ，按上式更新。增大 β 时应略降 η ，以免有效位移 $\eta/(1 - \beta)$ 过大。

11.6.2.2 简洁实现

框架求解器在同一 (β, η) 下实现同一 $\mathbf{v}, \mathbf{x}$ 递推。

11.6.3 理论分析

二次凸目标把动量写成线性递推。

11.6.3.1 二次凸函数

$$h(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{x}^\top \mathbf{c} + b.$$

$h(\mathbf{x})$ 是一个标量二次目标。配平方后经 $\mathbf{Q} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$ 变成

$$h(\mathbf{z}) = \frac{1}{2} \mathbf{z}^\top \mathbf{\Lambda} \mathbf{z} + b'.$$

对角元 Λ_{ii} 是该坐标的曲率。无动量时

$$\mathbf{z}_t = (\mathbf{I} - \mathbf{\Lambda}) \mathbf{z}_{t-1}.$$

每步把第 i 坐标乘以 $1 - \eta \lambda_i$ ，即沿该方向收缩。有动量时

$$\begin{aligned} \mathbf{v}_t &= \beta \mathbf{v}_{t-1} + \mathbf{\Lambda} \mathbf{z}_{t-1}, \\ \mathbf{z}_t &= (\mathbf{I} - \eta \mathbf{\Lambda}) \mathbf{z}_{t-1} - \eta \beta \mathbf{v}_{t-1}. \end{aligned}$$

$\mathbf{v}_t$ 仍是速度； $\eta \beta \mathbf{v}_{t-1}$ 是惯性贡献的额外位移。

11.6.3.2 标量函数

无动量 $x_{t+1} = (1 - \eta \lambda) x_t$ 。有动量

$$\begin{bmatrix} v_{t+1} \\ x_{t+1} \end{bmatrix} = \begin{bmatrix} \beta & \lambda \\ -\eta \beta & 1 - \eta \lambda \end{bmatrix} \begin{bmatrix} v_t \\ x_t \end{bmatrix} = \mathbf{R}(\beta, \eta, \lambda) \begin{bmatrix} v_t \\ x_t \end{bmatrix}.$$

v_t 是该坐标的速度， x_t 是参数本身。谱半径 $\rho(\mathbf{R}) < 1$ 时该坐标收敛： ρ 是无量纲的收缩因子，小于 1 表示误差会缩小。

11.6.4 小结

动量用速度 $\mathbf{v}_t = \sum_{\tau} \beta^\tau \mathbf{g}_{t-\tau}$ 替代当前梯度：它是过去梯度的指数平均，再经 $\eta \mathbf{v}_t$ 变成每个权重的位移。有效梯度个数为 $1/(1 - \beta)$ ，并多存一个状态 $\mathbf{v}$ 。

11.6.5 练习

核验： $h(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{x}^\top \mathbf{c} + b$ 的最小点，以及 β, η 对 $\rho(\mathbf{R})$ 的影响。

11.7 AdaGrad 算法

稀疏特征上，全局递减的 η 对常见坐标过慢、对罕见坐标过快。

11.7.1 稀疏特征和学习率

语言模型中罕见词的参数只在该词出现时更新。若 $\eta_t = \mathcal{O}(t^{-1/2})$ 已很小，罕见坐标尚未被充分观测。这里变小的是步长，不是该词出现的概率。

11.7.2 预处理

二次型经坐标缩放后

$$f(\mathbf{x}) = \bar{f}(\bar{\mathbf{x}}) = \frac{1}{2} \bar{\mathbf{x}}^\top \Lambda \bar{\mathbf{x}} + \bar{\mathbf{c}}^\top \bar{\mathbf{x}} + b,$$

条件数 $\kappa = \Lambda_1/\Lambda_d$ 是最大与最小曲率之比，无量纲，越大表示各坐标尺度越不均。对角预处理

$$\tilde{\mathbf{Q}} = \text{diag}^{-1/2}(\mathbf{Q}) \mathbf{Q} \text{diag}^{-1/2}(\mathbf{Q})$$

把各坐标曲率拉近。梯度

$$\partial_{\bar{\mathbf{x}}} \bar{f}(\bar{\mathbf{x}}) = \Lambda(\bar{\mathbf{x}} - \bar{\mathbf{x}}_0)$$

幅度随坐标变化，可用 $|g|$ 代理曲率： $|g_j|$ 大表示该权重方向更陡。

11.7.3 算法

$$\begin{aligned} \mathbf{g}_t &= \partial_{\mathbf{w}} \ell(y_t, f(\mathbf{x}_t, \mathbf{w})), \\ \mathbf{s}_t &= \mathbf{s}_{t-1} + \mathbf{g}_t^2, \\ \mathbf{w}_t &= \mathbf{w}_{t-1} - \frac{\eta}{\sqrt{\mathbf{s}_t} + \epsilon} \cdot \mathbf{g}_t. \end{aligned}$$

$\mathbf{g}_t$ 是当前梯度； $\mathbf{s}_t$ 与参数同形，第 j 个分量是迄今 $\partial \ell / \partial w_j$ 的平方和，表示该坐标历史斜率有多大（非中心二阶累积），不是方差概率。平方与除法按坐标逐元素。第 j 个权重的改变量是 $-\eta g_{t,j} / \sqrt{s_{t,j}} + \epsilon$ ：历史梯度大的坐标步更短。 η 仍是全局步长。测试函数仍用 $f(\mathbf{x}) = 0.1 x_1^2 + 2 x_2^2$ 。

11.7.4 从零开始实现

状态 $\mathbf{s}$ 与 $\mathbf{w}$ 同形，按上式更新。因 $\sqrt{s_t}$ 单调增，后期每步位移自动变小，故可用比 SGD 更大的初始 η 。

11.7.5 简洁实现

框架 AdaGrad 实现同一 $(\mathbf{s}, \mathbf{w})$ 递推。

11.7.6 小结

AdaGrad 用 $\mathbf{s}_t = \sum_{\tau=1}^t \mathbf{g}_\tau^2$ 按坐标缩小步长：大梯度坐标走得慢，稀疏坐标保持相对大的有效学习率。深度非凸上 $\mathbf{s}_t$ 可能累积过快，使后期 $\eta/\sqrt{\mathbf{s}_t}$ 过早接近零。

11.7.7 练习

核验：正交变换下 $\|\mathbf{U}\mathbf{c} - \mathbf{U}\mathbf{\delta}\|_2 = \|\mathbf{c} - \mathbf{\delta}\|_2$ ，以及旋转 $f(\mathbf{x}) = 0.1(x_1 + x_2)^2 + 2(x_1 - x_2)^2$ 后轨迹是否改变。

11.8 RMSProp 算法

AdaGrad 的 $\mathbf{s}_t$ 无界累积，等价于 η 按 $\mathcal{O}(t^{-1/2})$ 下降，非凸上往往过早停滞。

11.8.1 算法

$$\begin{aligned}\mathbf{s}_t &\leftarrow \gamma \mathbf{s}_{t-1} + (1 - \gamma) \mathbf{g}_t^2, \\ \mathbf{x}_t &\leftarrow \mathbf{x}_{t-1} - \frac{\eta}{\sqrt{\mathbf{s}_t + \epsilon}} \odot \mathbf{g}_t.\end{aligned}$$

$\mathbf{s}_t$ 是梯度平方的指数移动平均（未中心化的二阶矩），与参数同形。第 j 分量估计“该权重的梯度最近有多剧烈”，用来按坐标缩放步长。展开

$$\mathbf{s}_t = (1 - \gamma)(\mathbf{g}_t^2 + \gamma \mathbf{g}_{t-1}^2 + \gamma^2 \mathbf{g}_{t-2}^2 + \cdots).$$

η 由实验者单独调度，仍是步长； γ 控制历史窗口，有效长度约 $1/(1 - \gamma)$ 。本步第 j 个权重的位移是 $-\eta g_{t,j} / \sqrt{s_{t,j} + \epsilon}$ 。

11.8.2 从零开始实现

同一二次函数上，AdaGrad 在 $\eta = 0.4$ 后期几乎不动；RMSProp 因泄漏平均不让 $\mathbf{s}_t$ 无限增长。深度网络常用 $\eta = 0.01$ 、 $\gamma = 0.9$ 。这里 0.01 是步长，0.9 是二阶矩的衰减系数。

11.8.3 简洁实现

框架 RMSProp 实现同一更新。

11.8.4 小结

RMSProp 用泄漏平均 $\mathbf{s}_t \leftarrow \gamma \mathbf{s}_{t-1} + (1 - \gamma) \mathbf{g}_t^2$ 做按坐标预处理，并把全局 η 从累积平方和中分离。 $\mathbf{s}_t$ 是梯度的未中心化二阶矩，不是分类概率。

11.8.5 练习

核验： $\gamma = 1$ 时 $\mathbf{s}_t$ 不再更新的后果，以及旋转二次面上的收敛。

11.9 Adadelta

Adadelta 进一步取消显式 η ，用参数变化量校准更新幅度。

11.9.1 Adadelta 算法

梯度二阶矩

$$\mathbf{s}_t = \rho \mathbf{s}_{t-1} + (1 - \rho) \mathbf{g}_t^2.$$

$\mathbf{s}_t$ 仍是各坐标梯度平方的泄漏平均。重缩放梯度与参数更新

$$\begin{aligned} \mathbf{g}'_t &= \frac{\sqrt{\Delta \mathbf{x}_{t-1} + \epsilon}}{\sqrt{\mathbf{s}_t + \epsilon}} \odot \mathbf{g}_t, \\ \mathbf{x}_t &= \mathbf{x}_{t-1} - \mathbf{g}'_t, \\ \Delta \mathbf{x}_t &= \rho \Delta \mathbf{x}_{t-1} + (1 - \rho) \mathbf{g}'_t{}^2. \end{aligned}$$

$\mathbf{g}'_t$ 与参数同形，就是本步每个权重的位移（不再乘单独的 η ）。 $\Delta \mathbf{x}_t$ 是过去参数改变量平方的泄漏平均，用来让位移与近期实际走动的尺度匹配。需两个状态 $\mathbf{s}_t$ 、 $\Delta \mathbf{x}_t$ 。 $\rho = 0.9$ 对应约 10 个半衰期。

11.9.2 代码实现

每坐标维护 $(\mathbf{s}, \Delta \mathbf{x})$ ，按上式递推；框架 API 实现同一映射。

11.9.3 小结

Adadelta 用 $\sqrt{\Delta \mathbf{x}_{t-1}}/\sqrt{\mathbf{s}_t}$ 代替 η ，分子是近期参数位移的均方根，分母是近期梯度的均方根；二者之比仍是步长尺度。

11.9.4 练习

核验：能否不显式形成 $\mathbf{g}'_t$ 而得到同一 $\mathbf{x}_t$ ，以及与 AdaGrad、RMSProp 轨迹的差别。

11.10 Adam 算法

Adam 把动量的一阶矩与 RMSProp 的二阶矩合在同一更新里，并做偏差校正。

11.10.1 算法

$$\begin{aligned}\mathbf{v}_t &\leftarrow \beta_1 \mathbf{v}_{t-1} + (1 - \beta_1) \mathbf{g}_t, \\ \mathbf{s}_t &\leftarrow \beta_2 \mathbf{s}_{t-1} + (1 - \beta_2) \mathbf{g}_t^2.\end{aligned}$$

$\mathbf{v}_t$ 是梯度的指数移动均值（一阶矩）：第 j 分量估计 $\partial \ell / \partial w_j$ 最近的平均斜率。 $\mathbf{s}_t$ 是梯度的未中心化方差（二阶矩）：第 j 分量估计该斜率平方的平均水平，用来衡量该坐标梯度有多剧烈。二者都与参数同形，都不是概率。因 $\mathbf{v}_0 = \mathbf{s}_0 = \mathbf{0}$,

$$\hat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_1^t}, \quad \hat{\mathbf{s}}_t = \frac{\mathbf{s}_t}{1 - \beta_2^t}.$$

除以 $1 - \beta^t$ 是偏差校正：早期 $\mathbf{v}, \mathbf{s}$ 被零初始化拉低，校正后才是无偏的均值与未中心化方差估计。

$$\mathbf{g}'_t = \frac{\eta \hat{\mathbf{v}}_t}{\sqrt{\hat{\mathbf{s}}_t} + \epsilon}, \quad \mathbf{x}_t \leftarrow \mathbf{x}_{t-1} - \mathbf{g}'_t.$$

$\mathbf{g}'_t$ 是本步参数改变量：第 j 个权重移动 $-\eta \hat{v}_{t,j} / (\sqrt{\hat{s}_{t,j}} + \epsilon)$ 。 η 是全局步长，不是概率；分母把位移按该坐标的梯度尺度归一。

11.10.2 实现

状态为 $(\mathbf{v}, \mathbf{s}, t)$ 。常用 $\eta = 0.01$, $\beta_1 = 0.9$, $\beta_2 = 0.999$ 。 β_1 控制均值记忆长度， β_2 控制二阶矩记忆长度； t 只用于偏差校正的幂次。

11.10.3 Yogi

Adam 中 $\mathbf{s}_t$ 在梯度突变时可能被大正项拉动。把

$$\mathbf{s}_t \leftarrow \mathbf{s}_{t-1} + (1 - \beta_2)(\mathbf{g}_t^2 - \mathbf{s}_{t-1})$$

改成

$$\mathbf{s}_t \leftarrow \mathbf{s}_{t-1} + (1 - \beta_2)\mathbf{g}_t^2 \odot \text{sgn}(\mathbf{g}_t^2 - \mathbf{s}_{t-1})$$

使增量幅度受当前 $\mathbf{s}$ 限制：二阶矩仍表示“梯度有多剧烈”，但不再一次跳到过大。

11.10.4 小结

Adam 的更新是偏差校正后的 $\mathbf{x}_t \leftarrow \mathbf{x}_{t-1} - \eta \hat{\mathbf{v}}_t / (\sqrt{\hat{\mathbf{s}}_t} + \epsilon)$ 。 $\hat{\mathbf{v}}_t$ 是梯度均值， $\hat{\mathbf{s}}_t$ 是梯度未中心化方差， $\eta \hat{\mathbf{v}}_t / (\sqrt{\hat{\mathbf{s}}_t} + \epsilon)$ 才是每个权重本步移动的量。梯度尺度差异大时可用更大批量或 Yogi 的 $\mathbf{s}_t$ 。

11.10.5 练习

核验：去掉偏差校正后早期步长、以及何种 $\mathbf{g}_t$ 序列使 Adam 发散而 Yogi 收敛。

11.11 学习率调度器

更新规则确定方向， η_t 确定步长。过大发散，过小停滞或次优；条件数大时更敏感。 η_t 始终是“本步沿更新方向走多远”，不是分类或采样概率。

11.11.1 一个问题

在 Fashion-MNIST 上用固定 $\eta = 0.3$ 训练修改后的 LeNet。0.3 是每步参数位移的全局尺度。训练精度可继续升而测试精度停滞，间隙对应过拟合：训练误差这个数已经很小，测试误差那个数不再下降。

11.11.2 学习率调度器

调度器是映射 $t \mapsto \eta_t$ 。例如

$$\eta_t = \eta_0(t + 1)^{-1/2}.$$

η_t 随 t 减小，表示后期每步移动距离变短。比固定 η 更平滑，过拟合间隙往往更小。

11.11.3 策略

常用多项式、分段常数、余弦与预热。

11.11.3.1 单因子调度器

乘法衰减

$$\eta_{t+1} \leftarrow \eta_t \cdot \alpha, \quad \alpha \in (0, 1),$$

并加下限

$$\eta_{t+1} \leftarrow \max(\eta_{\min}, \eta_t \cdot \alpha).$$

α 是步长的折扣比例，例如 0.1 表示下次步长变为现在的十分之一； $\eta_{\min}$ 是最小步长，防止位移完全停住。

11.11.3.2 多因子调度器

在预定时刻 $s = \{5, 10, 20\}$ 上 $\eta_{t+1} \leftarrow \eta_t \cdot \alpha$ 。直觉是：先用较大 η 走到驻点附近（每步位移较大），再减小 η 降低参数噪声。

11.11.3.3 余弦调度器

$$\eta_t = \eta_T + \frac{\eta_0 - \eta_T}{2} (1 + \cos(\pi t/T)).$$

输入时刻 t 与总长 T ，输出仍是步长。 $\cos$ 从 1 降到 -1 ，使 η_t 从 η_0 平滑降到 η_T ；两端都是位移尺度，不是角度概率。

11.11.3.4 预热

先把 η 从接近 0 线性升到 η_0 ，再接入余弦或其他衰减，避免深度网络初期过大步长导致发散：初期 $\|\eta g\|$ 被故意限制得很小。

11.11.4 小结

η_t 应随训练下降，因为它是步长。余弦调度为 $\eta_t = \eta_T + \frac{\eta_0 - \eta_T}{2} (1 + \cos(\pi t/T))$ ；预热限制初期参数改变量 $\|\eta g\|$ 。

11.11.5 练习

核验：固定 η 能达到的最优训练误差、多项式指数如何改变收敛，以及预热长度对初期损失的影响。

第十二章 计算性能

前向与反向都是计算图上的算子序列。性能取决于图如何编译、设备如何重叠计算与通信、以及参数如何在多卡多机上同步。命令式便于写控制流，符号式便于整图优化。下面把二者写成同一套映射。出现的时间、带宽与梯度都给出单位或形状：时间是墙钟秒，带宽是每秒字节，梯度与参数同形。

12.1 编译器和解释器




图 12.1.1 命令式编程中的数据流

符号：见图中标注；各块含义见题注。

命令式编程按语句改状态。Python 解释执行，每步都经过前端。

12.1.1 符号式编程

先定义计算流程，再编译成可执行程序，最后喂入输入。记命令式求值为

$$(a, b, c, d) \mapsto e = a + b, f = c + d, g = e + f,$$

输入四个标量，中间 e, f 是两两之和， g 是四个数的总和，与加数同量纲。符号式先构造图 G ，再

$$G \mapsto P = \text{compile}(G), \quad P(a, b, c, d) = g.$$

P 是可执行程序：喂入同样的 (a, b, c, d) ，得到的 g 必须与命令式相同。编译器可见全图，可消去中间量，甚至把常量折叠成 $P \equiv 10$ ；这里的 10 仍是那次加法的数值结果，不是新的统计量。

12.1.2 混合式编程

PyTorch 默认动态图。TorchScript 把已追踪的命令式模型编译成静态图，开发仍用 Python，部署用 $P = \text{script}(f)$ 。对任意合法输入 $\mathbf{x}$ ，要求 $P(\mathbf{x}) = f(\mathbf{x})$ ：每个输出条目仍是原来的预测或特征，只是求值路径变了。

12.1.3 Sequential 的混合式编程

L 层序列 $f = f_L \circ \cdots \circ f_1$ 。解释器对每层单独发指令；多 GPU 时多线程前端成为瓶颈。把 Sequential 脚本化后，整条复合映射一次下发。输出张量的形状与数值含义不变：仍是最后一层的激活或 logits。

12.1.3.1 通过混合式编程加速

同一输入 $\mathbf{x}$ ，比较 $f(\mathbf{x})$ 与 $\text{script}(f)(\mathbf{x})$ 的墙钟时间。两个时间都是秒，表示“算出同一个输出花了多久”；编译后减少 Python 往返，输出值不变。

12.1.3.2 序列化

$$(f, \theta) \mapsto \text{save}(P, \theta) \mapsto \text{其他设备或语言上的 } P.$$

θ 仍是原来的权重；序列化的是编译后的图与这些数值，不是 Python 源。加载后 $P(\mathbf{x})$ 的每个分量含义与保存前相同。

12.1.4 小结

命令式写 f ；符号式把计算图 G 编译成 P 。混合式在 $f \mapsto P$ 后加速，且 $P(\mathbf{x}) = f(\mathbf{x})$ ：加速改变的是耗时，不是预测值。

12.1.5 练习

核验：对已有模型做 $f \mapsto \text{script}(f)$ 后，前向时延是否下降、数值是否一致。时延是秒；数值一致指每个输出条目相差在浮点误差内。

12.2 异步计算




图 12.2.1 编程语言前端和深度学习框架后端

符号：见图中标注；各块含义见题注。




图 12.2.2 后端跟踪计算图中各个步骤之间的依赖关系

符号：见图中标注；各块含义见题注。




图 12.2.3 前端和后端的交互

符号：见图中标注；各块含义见题注。

GPU 核函数默认异步：前端插入任务后立即返回，后端在设备上执行。

12.2.1 通过后端异步处理

前端发出 $C = AB$ 后, Python 已继续; 实际 GEMM 在队列中。 C 的条目 $C_{ij} = \mathbf{a}_i^\top \mathbf{b}_j$ 仍是第 i 行与第 j 列的点积 (一次线性响应), 只是这个数可能尚未算完。同步 S 强制

等待队列清空。测时若不调用 S ，测到的是入队时间而非计算时间；二者都以秒计，含义不同：前者是“指令发出有多快”，后者是“矩阵乘真正做完要多久”。

12.2.2 障碍器与阻塞器

障碍 S 使前端与指定设备上所有流对齐：

`sync(device)`：等待该设备队列空。

该操作不产生新的张量条目，只保证此前入队的结果已经写进内存。把结果拷回 CPU 或打印标量也会隐式阻塞：打印出的那个数才是已完成的 C_{ij} 。

12.2.3 改进计算

设前端入队、后端计算、回传分别为 t_1, t_2, t_3 。这三个数都是时间（秒）。同步执行 N 次总时间为 $N(t_1 + t_2 + t_3)$ ；异步且 Nt_2 主导时约为 $t_1 + Nt_2 + t_3$ 。队列过长会堆积中间张量，故常按小批量同步一次。 N 是重复次数，不是学习率。

12.2.4 小结

前端与后端解耦：命令快速入队，计算并行执行。过度填充队列增加显存；每个小批量一次 `sync` 使两侧大致对齐。对齐后读到的梯度或激活，才是这一批真正算完的数。

12.2.5 练习

核验：同一矩阵乘在 CPU 上是否仍能观察到入队与完成之间的时间差。时间差的单位是秒，表示异步重叠了多少等待。

12.3 自动并行




图 12.3.1 在一个 CPU 和两个 GPU 上的两层的多层感知机的计算图及其依赖关系
符号：见图中标注；各块含义见题注。

框架根据计算图上的依赖决定哪些算子可并行。无依赖的子图可同时占用不同设备。

12.3.1 基于 GPU 的并行计算

在 GPU1、GPU2 上各做 10 次矩阵乘。两次 sync 串行测时约为两段之和；去掉中间同步后，墙钟时间接近 $\max(T_1, T_2)$ ，即自动重叠。 T_1, T_2 是各设备上的计算秒数； $\max$ 表示总等待由较慢的那张卡决定，不是把两次点积的数值加起来。

12.3.2 并行计算与通信

计算 $y = f(x)$ 于 GPU，再 $y \mapsto \text{CPU}$ 。 y 的每个分量仍是 f 的输出（激活或预测），搬家不改变这些数。`copy(non_blocking)` 允许尚未完成的后续核与总线传输重叠。反传中先就绪的梯度可提前走 PCI-Express：搬移的是 $\partial L / \partial \theta_j$ 那些斜率，不是新的损失值。

12.3.3 小结

计算图给出依赖：无依赖的计算与通信可并行。设备间搬移与算子执行重叠，才能吃满总线与计算单元。并行改变的是完成时间，不改变每个梯度分量“参数增大时损失增加多少”的含义。

12.3.4 练习

核验：无依赖的多个小算子是否被自动并行，以及 CPU-GPU 同时计算加拷贝的总时延。

12.4 硬件




图 12.4.1 每个程序员都应该知道的延迟数字

符号：见图中标注；各块含义见题注。




图 12.4.2 计算机组件的连接

符号：见图中标注；各块含义见题注。




图 12.4.3 Intel Skylake 消费级四核 CPU

符号：见图中标注；各块含义见题注。




图 12.4.4 ARM Cortex A77 微体系结构

符号：见图中标注；各块含义见题注。




图 12.4.5 128 位 NEON 矢量化

符号：见图中标注；各块含义见题注。




图 12.4.6 错误共享（图片由英特尔提供）

符号：见图中标注；各块含义见题注。




图 12.4.7 NVIDIA Turing 处理块（图片由英伟达提供）

符号：见图中标注；各块含义见题注。



图 12.4.8 NVIDIA Turing 架构（图片由英伟达提供）

符号：见图中标注；各块含义见题注。




图 12.4.9 NVIDIA Turing 架构中的张量核心（图片由英伟达提供）

符号：见图中标注；各块含义见题注。

算法决定统计效率；硬件决定一次 ∇f 要多久。延迟差几个数量级就会使可训练与不可训练对换。下面出现的 GB/s、IOPS、秒都是吞吐或延迟，不是模型输出。

12.4.1 计算机

一台训练机构成映射

(CPU, RAM, GPU, PCIe, NIC, 存储) $\mapsto$ 每秒可完成的迭代.

右边是吞吐：每秒能做完几步 $\theta \leftarrow \theta - \eta g$ ，不是准确率。CPU 跑调度与数据管道；参数与激活放 RAM/显存；PCIe 接加速卡。

12.4.2 内存

带宽与延迟同时约束。DDR 通道峰值约 40-100 GB/s，这个数是每秒最多搬运多少字节，不是某个权重的值。但先发地址再突发读；小块随机访问远低于峰值。深度学习应尽量连续、大批量访问。

12.4.3 存储器

持久存储同样由带宽与 IOPS 刻画，器件间差几个数量级。IOPS 是每秒能完成多少次读写，带宽是每秒字节数。

12.4.3.1 硬盘驱动器

约 7200 RPM，最坏旋转等待约 8 ms，约 10^2 IOPS。8 ms 是一次寻道加旋转可能浪费的时间。顺序带宽远高于随机。

12.4.3.2 固态驱动器

10^5 – 5×10^5 量级 IOPS，带宽 1–3 GB/s。按块擦写，随机小写远慢于读。这些数描述介质快慢，与损失标量无关。

12.4.3.3 云存储

IOPS 与容量可配置。训练若大量小记录，延迟高时应提高 IOPS 配额。配额是“允许多少次每秒读写”，不是学习率。

12.4.4 CPU

核心执行指令，缓存降低访存延迟，向量单元做 SIMD。

12.4.4.1 微体系结构

前端取指、预测、解码；执行端口可同时发射多条独立微操作。整数端口与浮点端口不同，吞吐取决于指令能否并行。吞吐的单位是每秒微操作数，不是梯度。

12.4.4.2 矢量化

SIMD 在一个周期内对向量寄存器做同一运算。FMA 计算 $a \leftarrow a + b \cdot c$ 。 a, b, c 是寄存器里的浮点数；结果 $a + bc$ 仍是同一量纲的数，只是一次算出一条向量里的多条。寄存器可达 512 位，表示一次能装多少个浮点分量。

12.4.4.3 缓存

4 核、2 GHz、每周期 256 位 AVX 约需

$$4 \times 256 \text{ bit} \times 2 \times 10^9 / \text{s} = 256 \text{ GB/s},$$

这是算术单元若持续满载所要求的数据带宽。而内存接口只有数十 GB/s。差额必须由 L1/L2/L3 命中补上。命中率是 $[0, 1]$ 上的比例：有多大一部分访问没落到慢速内存。

12.4.5 GPU 和其他加速卡

训练要存中间激活，常用 FP16/FP32；推断可 INT8 且不必存反传状态。位宽决定每个激活占用多少字节，也影响下溢：过小的数会被读成 0，那时梯度消失不是算法故意为之。GPU 以吞吐换取相对 CPU 高一个数量级的密集线性代数。

12.4.6 网络和总线

PCIe 单链路高带宽、微秒级延迟，通道数有限。NVLink 卡间带宽高于 PCIe；以太网跨机约 10 GB/s 量级，比 NVLink 慢约一个数量级。这些 GB/s 是搬移梯度张量的速度：每秒能同步多少字节的 g 。

12.4.7 更多延迟

缓存命中约纳秒，内存约几十纳秒，PCIe/网络微秒到毫秒，磁盘毫秒。同一迭代里应避免把计算拆成大量高延迟小传输。延迟是“一次传输要等多久”，不是损失值。

12.4.8 小结

量少次多的传输浪费延迟。向量化与对齐决定能否达到峰值。训练精度过低会下溢；算法应让热参数留在缓存带宽内。硬件指标（秒、GB/s）与模型里的预测、概率不是同一类数。

12.4.9 练习

核验：对齐与非对齐访问、固定步幅访问的带宽，以及 FP16 累积是否溢出。溢出指中间和超出该格式能表示的范围，结果不再是正确的点积。

12.5 多 GPU 训练




图 12.5.1 由于 GPU 显存有限，原有 AlexNet 设计中的模型并行

符号：见图中标注；各块含义见题注。




图 12.5.2 在多个 GPU 上并行化。从左到右：原始问题、网络并行、分层并行、数据并行

符号：见图中标注；各块含义见题注。




图 12.5.3 利用两个 GPU 上的数据，并行计算小批量随机梯度下降

符号：数据并行：各卡一份模型、一批数据；梯度再同步

k 张 GPU 增加显存与算力。需把一次小批量上的 ∇f 拆开再聚合。

12.5.1 问题拆分

层并行按层切网络，模型并行按层内切参数，数据并行按样本切批量。前两者要编排激活与梯度的传递；数据并行只同步梯度，实现最直接。同步的对象是与 θ 同形的 g ，每个分量仍是 $\partial L / \partial \theta_j$ 。

12.5.2 数据并行性

k 张卡各持一份完整 θ 。一次迭代：

$$\begin{aligned} \mathcal{B} &= \mathcal{B}_1 \cup \dots \cup \mathcal{B}_k, \\ \mathbf{g}^{(j)} &= \nabla_{\theta} \frac{1}{|\mathcal{B}_j|} \sum_{i \in \mathcal{B}_j} \ell_i, \\ \mathbf{g} &= \text{allreduce}(\mathbf{g}^{(1)}, \dots, \mathbf{g}^{(k)}), \\ \theta &\leftarrow \theta - \eta \mathbf{g} \quad \text{在每张卡上相同.} \end{aligned}$$

$\mathbf{g}^{(j)}$ 是第 j 张卡上局部平均损失的梯度，与 θ 同形。allreduce 把 k 份梯度合成一份（通常先求和再按约定缩放），得到的 $\mathbf{g}$ 近似全批量平均斜率。 $\eta \mathbf{g}$ 是每张卡上相同的参数改变量：第 ℓ 个权重本步移动 $-\eta g_{\ell}$ 。 η 是步长，不是概率。

12.5.3 简单网络

用修改后的 LeNet 作为 f_{θ} ，以便显式写出参数拷贝与 allreduce。 $f_{\theta}(\mathbf{x})$ 的输出仍是类别 logits 或概率，与单卡时相同。

12.5.4 数据同步

`get_params` 把 θ 复制到设备 j 并附加梯度缓冲。复制后每个权重数值不变。allreduce 实现

$$\mathbf{g} \leftarrow \sum_{j=1}^k \mathbf{g}^{(j)},$$

再广播回每张卡。求和后第 ℓ 个分量是各卡该权重斜率之和；若随后除以 k ，则恢复为平均斜率。

12.5.5 数据分发

$$(\mathbf{X}, \mathbf{y}) \mapsto \{(\mathbf{X}^{(j)}, \mathbf{y}^{(j)})\}_{j=1}^k, \quad \sum_j |\mathcal{B}_j| = |\mathcal{B}|.$$

$X_{ab}^{(j)}$ 仍是第 j 张卡上第 a 个样本第 b 个特征； y 仍是标签。切分不产生新测量，只把样本分到不同设备。

12.5.6 训练

每个小批量：分发数据、各卡前向反向、allreduce、本地更新。有效批量变为 $k|\mathcal{B}_j|$ 时， η 通常需略增大：批量更大则 $\mathbf{g}$ 噪声更小，可用更大步长。单卡精度评估可只在一张卡上进行：精度是 $[0, 1]$ 上“预测类等于真类”的比例。

12.5.7 小结

数据并行把 $\mathcal{B}$ 切到 k 张卡，聚合梯度后再广播。 $\eta\mathbf{g}$ 仍是每个权重的位移；更大有效批量需要相应调整这个步长 η 。

12.5.8 练习

核验：批量从 b 扩到 kb 时精度与 η 应如何同扩，以及分块 allreduce 的通信量。通信量以字节计，等于梯度张量体积乘传输次数。

12.6 多 GPU 的简洁实现

高级 API 把上一节的分发、反传与聚合收成同一训练循环。至少两张 GPU。

12.6.1 简单网络

用修改后的 ResNet-18：更小卷积核与步幅，去掉开头最大汇聚，以适应小图。网络输出仍是 K 维 logits，第 k 维是类 k 的未归一化分数。

12.6.2 网络初始化

必须在目标设备上初始化 θ ，再访问该设备上的参数，否则引用落在错误设备。初始化给出的每个权重是该层的起始数值，随后由 ηg 修改。

12.6.3 训练

循环执行：全设备初始化；把 $\mathcal{B}$ 切到各设备；并行求损失与梯度；聚合后更新；并行算精度。损失是批量平均交叉熵 (nats)；精度是正确分类比例。当计算时间明显长于同步时间，加速比接近线性。加速比是无量纲比值：单卡秒数除以多卡秒数。

12.6.4 小结

单卡可自动求 $f_{\theta}(x)$ 。多卡时每设备先初始化，优化器自动 allreduce 梯度。更新公式仍是 $\theta \leftarrow \theta - \eta g$ ，含义与单卡相同。

12.6.5 练习

核验：更多卡、更大 b 与 η 的组合，以及 CPU 与 GPU 算力不均时如何划分前后向。

12.7 参数服务器




图 12.7.1 左图是单 GPU 训练；右图是多 GPU 训练的一个变体：（1）计算损失和梯度，（2）所有梯度聚合在一个 GPU 上，（3）发生参数更新，并将参数重新广播给所有 GPU

符号：GPU：算梯度；参数服务器：聚合并广播新权重




图 12.7.2 一个 4 路 GPU 服务器

符号：见图中标注；各块含义见题注。




图 12.7.3 参数同步策略

符号：见图中标注；各块含义见题注。




图 12.7.4 在 8 台 V100 GPU 服务器上连接 NVLink (图片由英伟达提供)

符号：见图中标注；各块含义见题注。




图 12.7.5 将 NVLink 网络分解为两个环。

符号：见图中标注；各块含义见题注。




图 12.7.6 跨 4 个节点的环同步。每个节点开始向其左邻居发送部分梯度，直到在其右邻居中找到聚合的梯度

符号：见图中标注；各块含义见题注。




图 12.7.7 多机多 GPU 分布式并行训练

符号：见图中标注；各块含义见题注。




图 12.7.8 上图：单参数服务器是一个瓶颈，因为它的带宽是有限的；下图：多参数服务器使用聚合带宽存储部分参数

符号：见图中标注；各块含义见题注。

从单机多卡到多机时，互连带宽从 NVLink、PCIe 降到以太网，同步算法必须适配拓扑。

12.7.1 数据并行训练

各 GPU 算 g_{ijk} ，先机内聚合，再跨机聚合，最后广播新 θ 。 g_{ijk} 是机器 i 、卡 j 、参数块 k 上的局部梯度，形状与该块参数相同。聚合位置可以是某张 GPU、CPU，或按参数块分散到不同设备。

12.7.2 环同步（Ring Synchronization）

k 张卡组成环，每步向邻居发送 $1/k$ 的梯度块并接收一块，共 $2(k-1)$ 步后每卡得到全和。每张卡最终拿到的仍是 $\sum_j g^{(j)}$ ，各坐标含义不变：全批量（或全卡）斜率之和。在 NVLink 带宽远高于 PCIe 的机器上，环同步走 NVLink，避免单点经 PCIe 汇聚。

12.7.3 多机训练

每台机器：读不同批量、卡间切分、本地前向反向、机内聚合，再把梯度发给参数服务器（或对等节点），取回更新后的 θ 。取回的 θ 是已经减去 ηg 之后的新权重。机器间时钟差要求显式同步，否则同步 SGD 会等待最慢的那台。

12.7.4 键值存储

参数服务器把切片 i 上的梯度写成

$$\mathbf{g}_i = \sum_{k \in \text{workers}} \sum_{j \in \text{GPUs}} \mathbf{g}_{ijk}.$$

$\mathbf{g}_i$ 与第 i 块参数同形，是所有工人、所有卡对该块斜率的总和。push 写入 $\mathbf{g}_{ijk}$ ，pull 读回聚合后的 θ_i 。增加服务器个数提高聚合带宽；分层同步先机架内再机架间。

12.7.5 小结

同步时间由拓扑决定。环同步适合 NVLink 稠密连接；多机用参数服务器聚合 $\mathbf{g}_i = \sum_k \sum_j \mathbf{g}_{ijk}$ ，带宽不够就分层。聚合得到的每个分量仍然是“该权重应沿哪个方向、以多大斜率减小损失”。

12.7.6 练习

核验：双向环能否减半延迟、计算尚未结束时异步发送对 f 收敛的影响，以及单机失效时的容错。

第十三章 计算机视觉

图像分类把整图映到类别；检测还要位置，分割还要逐像素类别。增广扩大训练分布，锚框把空间离散成候选框，转置卷积把特征图拉回像素网格。框的四个数是位置（像素或归一化坐标），不是类别分数；IoU 是 $[0, 1]$ 上的重叠比例。

13.1 图像增广

增广是随机映射 T ，使 $T(\mathbf{X})$ 与 $\mathbf{X}$ 同类但统计不同，从而减小对位置、颜色的依赖。 $\mathbf{X}$ 的条目是像素强度，通常在 $[0, 1]$ 或 $[0, 255]$ 。

13.1.1 常用的图像增广方法

多数 T 含随机数。下面在固定示例图上重复采样 T 。每次采样得到的仍是一张图，每个像素仍是强度，不是类别概率。

13.1.1.1 翻转和裁剪

水平翻转 T_{flip} 以 $1/2$ 概率作用。这里 $1/2$ 是“是否翻转”的机会，不是像素值。随机裁剪先采区域再缩放到固定 $H \times W$ ，降低对物体绝对位置的依赖。裁出的 (x_1, y_1, x_2, y_2) 是像素坐标，表示窗口在原图中的位置。

13.1.1.2 改变颜色

亮度、对比度、饱和度、色调各乘以接近 1 的随机因子，例如亮度在 $[1 - \delta, 1 + \delta]$ 。因子是无量纲倍率：大于 1 变亮，小于 1 变暗；乘完后像素仍是强度。

13.1.1.3 结合多种图像增广方法

复合 $T = T_k \circ \dots \circ T_1$ ，对每张训练图独立采样一次。最终张量形状仍是 (C, H, W) （或带批量），含义仍是像素。

13.1.2 使用图像增广进行训练

训练用随机 T , 预测用确定性预处理 T_{det} (如 ToTensor)。输入形状为 (批量, C, H, W), 像素在 $[0, 1]$: 0 表示该通道最暗, 1 表示最亮, 不是“属于某类的概率”。

13.1.2.1 多 GPU 训练

在 CIFAR-10 上训练 ResNet-18。优化器为 Adam。增广只作用于训练集; 多卡按数据并行切批量。分类头输出 10 维 logits, 经 softmax 后第 k 个分量才是属于类 k 的概率。

13.1.3 小结

训练分布是 $\{T(\mathbf{X})\}$, 测试分布仍是原始 $\mathbf{X}$ 。随机 T 只出现在训练; 它改变像素强度与几何, 不改变标签 y 的类别含义。

13.1.4 练习

核验: 去掉 T 后训练-测试间隙是否增大, 以及复合多种 T 是否降低测试误差。间隙是两个 $[0, 1]$ 误差 (或精度) 之差。

13.2 微调




图 13.2.1 微调。

符号：源域预训练权重；目标域：替换输出层后继续训练

源数据集大、目标数据集小。微调把源模型的特征层参数当目标模型的初值。

13.2.1 步骤

源模型 $f_{\theta_{\text{src}}}$ 在源数据上预训练。目标模型复制除输出层外的结构与参数，换上类别数为 K_{tgt} 的新输出层并随机初始化，再在目标数据上以较小 η 更新全部（或大部分）参数。 η 是步长：特征层用更小的 η ，表示每步权重移动更少，以免冲掉预训练特征。新输出层的 logits 维数是 K_{tgt} ，第 k 维是目标任务类 k 的分数。

13.2.2 热狗识别

在热狗/非热狗二分类上微调 ImageNet 预训练的 ResNet-18。输出两个分数，softmax 后得到“是热狗”的概率，取值 $[0, 1]$ 。

13.2.2.1 获取数据集

正负类各约 1400 张，每类 1000 张训练。这些整数是样本个数。训练时随机裁剪并缩放到 224×224 ；测试用确定性中心裁剪。224 是像素边长，不是类别数。

13.2.2.2 定义和初始化模型

源模型最后线性层 $\mathbb{R}^d \rightarrow \mathbb{R}^{1000}$ 。1000 维是 ImageNet 各类的 logits。目标模型改为 $\mathbb{R}^d \rightarrow \mathbb{R}^2$ ，特征层参数 $\theta_{\text{feat}} \leftarrow \theta_{\text{src}}$ ，输出层随机。复制的是特征权重的数值；新的 2 维才对应当前任务的两类分数。

13.2.2.3 微调模型

特征层用小 η ，输出层可用更大 η 。对照实验把全部参数随机初始化并用更大 η 从头训练。更大 η 表示每步 ηg 位移更大，不是更高的分类概率。

13.2.3 小结

除输出层外 $\theta_{\text{tgt}} \leftarrow \theta_{\text{src}}$ ，输出层从头学。微调 η 小于从头训练，因为要限制特征权重的移动量。

13.2.4 练习

核验：只训练输出层（冻结 θ_{feat} ）时精度，以及提高微调 η 是否破坏预训练特征。精度是正确分类比例，在 $[0, 1]$ 。

13.3 目标检测和边界框

检测输出类别与位置。位置用矩形边界框。框的坐标是空间位置，类别分数才是“属于某类的把握”。

13.3.1 边界框

两角表示 (x_1, y_1, x_2, y_2) 与中心表示 (x, y, w, h) 互转：

$$x = \frac{x_1 + x_2}{2}, \quad y = \frac{y_1 + y_2}{2}, \quad w = x_2 - x_1, \quad h = y_2 - y_1,$$

$$x_1 = x - w/2, \quad x_2 = x + w/2, \quad y_1 = y - h/2, \quad y_2 = y + h/2.$$

(x_1, y_1) 是左上角像素（或归一化到 $[0, 1]$ 的图像比例）坐标， (x_2, y_2) 是右下角； (x, y) 是中心位置， w, h 是宽和高，单位与坐标轴相同。这四个数描述框在图上的几何位置，不是分类 logits，也不是 IoU。图像坐标原点在左上，向右为 x 正、向下为 y 正。

13.3.2 小结

检测 = 分类 + 框回归。框在两角与中心宽高两种坐标之间是双射：转换不改变“这个矩形盖住哪一块像素”，只改参数化。

13.3.3 练习

核验：最内维为 4 才能同时存两个角或 (x, y, w, h) 。这 4 个数全是位置，不要把其中一维误当成类别编号。

13.4 锚框




图 13.4.1 交并比是两个边界框相交面积与相并面积之比。

符号：见图中标注；各块含义见题注。




图 13.4.2 将真实边界框分配给锚框。

符号：见图中标注；各块含义见题注。

以像素为中心放置多尺度、多宽高比的候选框，再预测其类别与偏移。

13.4.1 生成多个锚框

给定尺度 $s_1 > \dots > s_n$ 与宽高比 $r_1, \dots, r_m$ ，每个中心生成

$$(s_1, r_1), \dots, (s_1, r_m), (s_2, r_1), \dots, (s_n, r_1)$$

共 $n + m - 1$ 个锚框。宽高由 $s\sqrt{r}$ 与 $s/\sqrt{r}$ 确定。 s 是相对图像尺寸的尺度（无量纲或相对宽高）， r 是宽高比 w/h ，都不是类别分数。生成的每个锚仍用四个坐标描述位置。

13.4.2 交并比 (IoU)

$$J(\mathcal{A}, \mathcal{B}) = \frac{|\mathcal{A} \cap \mathcal{B}|}{|\mathcal{A} \cup \mathcal{B}|} \in [0, 1].$$

分子是两框重叠区域的面积，分母是并集面积，单位一致故 IoU 无量纲。 $J = 1$ 表示两框完全重合（相同位置与大小）； $J = 0$ 表示没有重叠。它度量几何重合程度，不是“属于某类的概率”，尽管取值也落在 $[0, 1]$ 。

13.4.3 在训练数据中标注锚框

每个锚框需要类别与相对真实框的偏移。预测时对所有锚框回归后再筛选。类别是离散标签；偏移是位置修正量，与框坐标相关。

13.4.3.1 将真实边界框分配给锚框

锚框 $A_1, \dots, A_{n_a}$ ，真实框 $B_1, \dots, B_{n_b}$ ， $n_a \geq n_b$ 。矩阵 $\mathbf{X} \in \mathbb{R}^{n_a \times n_b}$ ， $x_{ij} = J(A_i, B_j)$ 。 $x_{ij} \in [0, 1]$ 就是锚 i 与真实框 j 的重叠比例。反复取剩余子阵的最大元 (i^*, j^*) ，把 B_{j^*} 分给 A_{i^*} 并删去该行该列；然后对未分配锚框，若 $\max_j x_{ij}$ 超过阈值则赋予对应真实框，否则标为背景。阈值（如 0.5）仍是 IoU，表示“至少重叠一半才算正例”。

13.4.3.2 标记类别和偏移量

正锚框类别为所赋真实框类别。偏移（标准化后）为

$$\left(\frac{\frac{x_b - x_a}{w_a} - \mu_x}{\sigma_x}, \frac{\frac{y_b - y_a}{h_a} - \mu_y}{\sigma_y}, \frac{\log \frac{w_b}{w_a} - \mu_w}{\sigma_w}, \frac{\log \frac{h_b}{h_a} - \mu_h}{\sigma_h} \right).$$

(x_a, y_a, w_a, h_a) 是锚框中心与宽高， (x_b, y_b, w_b, h_b) 是真实框；前两维是中心相对偏移（相对锚宽高），后两维是宽高比的对数。四个数都是位置回归目标，不是类别分数； μ, σ 只做标准化，使回归量纲约为 1。

13.4.3.3 一个例子

给定若干 A_i 与 B_j ，上述分配输出类别张量（0 为背景）与偏移张量。类别张量的条目是整数类编号；偏移张量的条目是上面那四个几何量。

13.4.4 使用非极大值抑制预测边界框

由锚框与预测偏移经逆变换得预测框 B ，并带类别概率 p 。 B 的坐标是像素或归一化位置； $p \in [0, 1]$ 才是“该框属于所报类别”的概率。NMS：按 p 排序，保留当前最高，删去与其 IoU 超过阈值的其余框，重复直到空。这里用来删框的阈值是 IoU（重叠多大算重复），不是把 p 再当位置用。

13.4.5 小结

锚框是候选；IoU 是两框面积交集除以并集，在 $[0, 1]$ ，1 表示框完全相同；训练标签是类别加位置偏移；预测用 NMS 去掉重叠框。

13.4.6 练习

核验：IoU = 0.5 的两框如何重叠，以及 NMS 阈值如何改变保留集合。0.5 表示交集面积等于并集的一半，两框既不完全重合也不相离。

13.5 多尺度目标检测

对每个像素生成锚框数量为 $H \times W \times a$ ，输入稍大就会上百万。需在特征图网格上采样中心。

13.5.1 多尺度锚框

小目标可能位置多，用密而小的锚；大目标用疏而大的锚。特征图尺寸 (h, w) 决定中心网格：每个网格点是一组锚的中心像素（映射回原图后的位置）。

13.5.2 多尺度检测

某尺度特征图 $Y \in \mathbb{R}^{c \times h \times w}$ 生成 hwa 个锚框。 $Y_{c,i,j}$ 是通道 c 、位置 (i, j) 上的特征响应，不是框坐标。该单元的感受野内信息用于预测对应锚的类别与偏移。深层特征图感受野更大，对应更大锚。

13.5.3 小结

尺度 s 上锚框数由特征图 $h \times w$ 与每单元 a 决定。类别与偏移从该感受野的特征预测：一类输出是类分数，一类输出是位置修正。

13.5.4 练习

核验：形状 $1 \times c \times h \times w$ 的特征如何映到类别与偏移，输出形状是什么。类别分支最后一维是 $q + 1$ 类的 logits；偏移分支最后一维是 4 个坐标修正。

13.6 目标检测数据集

用小型香蕉检测集演示：图像加框标签，而非仅类别。

13.6.1 下载数据集

图像与 CSV 标签（类别、左上、右下）成对出现。CSV 里的 (x_1, y_1, x_2, y_2) 是框角坐标，类别列才是物体类。

13.6.2 读取数据集

小批量图像形状 (B, C, H, W) ；标签形状 $(B, m, 5)$ ， m 为每图最大目标数，每条为 (类, x_1, y_1, x_2, y_2)。第一项是类别编号；后四项是像素或归一化位置，不要把它们读成四个类分数。

13.6.3 演示

香蕉的旋转、尺度与位置在图间变化；真实框随目标走。框跟着物体中心与大小变，标签的几何维同步更新。

13.6.4 小结

检测加载器多返回真实框。类别分类没有这第五维几何：那四个数始终表示框在哪里、有多大。

13.6.5 练习

核验：随机裁剪若只留下目标的一小块，框标签应如何同步变换。变换后的坐标仍是裁剪图上的位置，不是新的类别。

13.7 单发多框检测（SSD）




图 13.7.1 单发多框检测模型主要由一个基础网络块和若干多尺度特征块串联而成。

符号：多尺度特征图：预测不同大小目标的类别与框

SSD 用基础网络加若干多尺度特征块，一次前向预测所有锚的类与偏移。

13.7.1 模型

基础网输出较大 $h \times w$ 以检小目标；后续块反复减半空间尺寸、扩大感受野以检大目标。空间尺寸是特征图像素数，不是 IoU。

13.7.1.1 类别预测层

q 个物体类加背景共 $q + 1$ 。特征图 $h \times w$ 、每单元 a 个锚，需 hwa 个分类。用保持空间尺寸的卷积，输出通道 $a(q + 1)$ ，使位置 (x, y) 的通道对应该中心全部锚的类别。这些通道是 logits：softmax 后才是各类概率，和为 1。

13.7.1.2 边界框预测层

同样卷积，输出通道 $4a$ ，每锚 4 个偏移。这 4 个数是对锚框中心与宽高的修正，单位是标准化后的位置量，不是类概率。

13.7.1.3 连结多尺度的预测

不同尺度的 (C, H, W) 不同。把批量维保留，将其余维展平后在锚维上拼接，得到整图全部预测。拼接不改变每个锚上“类 logits + 4 维偏移”的含义。

13.7.1.4 高和宽减半块

两个填充 1 的 3×3 卷积加步幅 2 的 2×2 最大汇聚，空间减半。输出单元相对输入有 6×6 感受野。 6×6 是感受野覆盖的输入像素块大小。

13.7.1.5 基本网络块

串联三个减半块并倍增通道。 256×256 输入得到 32×32 特征图。 256 与 32 都是空间像素数。

13.7.1.6 完整的模型

五块：基础网、三个减半块、全局最大汇聚到 1×1 。每块输出特征图、该尺度锚框、类别与偏移。较深层生成更大锚。锚的大小是几何尺度；类别头仍输出类分数。

13.7.2 训练模型

前向生成多尺度锚并预测；用真实框标注；类损失加偏移损失。

13.7.2.1 读取数据集和初始化

香蕉数据集 $q = 1$ 。随机初始化后选优化算法。 $q = 1$ 表示只有一类物体加背景，类别头输出 2 维。

13.7.2.2 定义损失函数和评价函数

类别用交叉熵。正锚偏移用 L_1 ：

$$\ell_{\text{bbox}} = \sum_{k=1}^4 |\hat{o}_k - o_k|,$$

$\hat{o}_k$ 与 o_k 是预测与真实的第 k 个位置偏移，和是四个坐标误差的绝对值和，与偏移同量纲，不是分类交叉熵。负锚与填充锚由掩码不计入。总损失为两类之和。分类看准确率（ $[0, 1]$ 比例），框看平均绝对误差（位置量纲）。

13.7.2.3 训练模型

每个批量：生成锚框，预测类别与偏移，由 Y 标出标签，再求损失。 Y 中的框坐标是真值位置；预测偏移经解码后也应落在像素或归一化坐标系里。

13.7.3 预测目标

图像缩放到训练尺寸，得预测框后 NMS，再保留置信度不低于阈值（如 0.9）的框。0.9 是类别概率阈值：只留下“模型认为至少九成是该类”的框；NMS 另用 IoU 阈值去重，二者不要混用。

13.7.4 小结

SSD 在多尺度特征上生成锚并预测类与偏移。损失是交叉熵与正锚 L_1 之和：前者压的是类概率误差，后者压的是位置误差。

13.7.5 练习

练习中的 Smooth L_1 与焦点损失分别为

$$f(x) = \begin{cases} (\sigma x)^2/2, & |x| < 1/\sigma^2, \\ |x| - 0.5/\sigma^2, & \text{否则}, \end{cases}$$

$$\ell = -\alpha(1 - p_j)^\gamma \log p_j.$$

$f(x)$ 中的 x 是偏移残差（位置误差）； $p_j \in [0, 1]$ 是预测为正确类的概率。焦点损失里 $(1 - p_j)^\gamma$ 降低易分样本的权重，不改变 p_j 作为类概率的含义。核验二者相对 L_1 与交叉熵如何改变难例权重。

13.8 区域卷积神经网络（R-CNN）系列




图 13.8.1 R-CNN 模型

符号：见图中标注；各块含义见题注。





图 13.8.2 Fast R-CNN 模型

符号：见图中标注；各块含义见题注。

图 13.8.3 一个 2×2 的兴趣区域汇聚层

符号：见图中标注；各块含义见题注。




图 13.8.4 Faster R-CNN 模型

符号：见图中标注；各块含义见题注。




图 13.8.5 Mask R-CNN 模型

符号：见图中标注；各块含义见题注。

R-CNN 先提区域再分类；后续工作共享卷积并学习提议。

13.8.1 R-CNN

选择性搜索得到约 2000 个提议；对每个提议独立卷积抽特征；再用分类器与回归器预测类和框。每个提议是一个候选矩形（四坐标位置）；分类器输出类分数，回归器输出框修正。重复卷积是主要瓶颈。

13.8.2 Fast R-CNN

整图只卷积一次，得 $Y \in \mathbb{R}^{c \times h_1 \times w_1}$ 。 $Y_{c,i,j}$ 是特征响应。兴趣区域汇聚把每个提议映射到固定 $h \times w$ 特征，再经全连接预测类与框。类头输出各类 logits；框头输出位置偏移。

13.8.3 Faster R-CNN

用区域提议网络代替选择性搜索：在特征图上 3×3 卷积后分出物体性分数与框回归，生成较少且可学习的提议，其余与 Fast R-CNN 相同。物体性分数经 sigmoid 后是 $[0, 1]$ 上“这里有物体”的概率；框回归仍是坐标修正。

13.8.4 Mask R-CNN

兴趣区域对齐用双线性插值保留空间。对齐特征除预测类与框外，再经全卷积支路输出该区域的像素掩码。掩码每个像素是该类前景的分数或概率，空间网格对应框内位置，不是整图分类的单一 logit。

13.8.5 小结

R-CNN：每区域独立卷积。Fast：整图卷积加 RoI 汇聚。Faster：RPN 学提议。Mask：对齐加像素掩码。全程框坐标是位置，类/物体性才是概率。

13.8.6 练习

核验：把检测写成一次回归（如 YOLO）与多阶段提议在输出形式上的差别。二者都要同时给出位置与类别，不要把坐标维解释成 softmax 概率。

13.9 语义分割和数据集




图 13.9.1 语义分割中图像有关狗、猫和背景的标签

符号：见图中标注；各块含义见题注。

语义分割给每个像素一个类别，边界是像素级的，不是框。

13.9.1 图像分割和实例分割

图像分割按像素相似性分区，不必有语义标签。实例分割还要区分同类的不同物体；语义分割把同类像素标成同一类。标签图每个位置的整数是该类编号，不是 RGB 强度本身的含义（尽管常用颜色来显示）。

13.9.2 Pascal VOC2012 语义分割数据集

输入 JPEG 与同尺寸的彩色标签图，同色像素同类。

13.9.2.1 预处理数据

缩放会错位像素类别。改为对图像与标签做同一随机裁剪到固定 $H \times W$ 。裁剪窗口的 (x, y, w, h) 是像素位置，图像与标签必须用同一窗口，否则监督错位。

13.9.2.2 自定义语义分割数据集类

索引 i 返回 $(X^{(i)}, Y^{(i)})$ ， Y 是像素类别。 $X_{c,h,w}$ 是强度； $Y_{h,w}$ 是位置 (h, w) 的类编号。过小图过滤；RGB 按通道标准化。

13.9.2.3 读取数据集

裁剪 320×480 后统计保留样本。标签小批量是三维数组 (B, H, W) 。每个条目是类索引，取值 $\{0, \dots, K - 1\}$ ，不是 $[0, 1]$ 概率。

13.9.2.4 整合所有组件

加载器返回训练与测试迭代器。

13.9.3 小结

分割标签与输入像素一一对应，故用同步裁剪而非缩放。每个空间位置一对 $(X_{\cdot,h,w}, Y_{h,w})$ ：前者是观测强度，后者是要预测的类。

13.9.4 练习

核验：分类里常用的颜色抖动若不同步改标签，分割监督是否失效。标签必须保持类编号，不能跟着亮度一起被乘上随机因子。

13.10 转置卷积




图 13.10.1 卷积核为 2×2 的转置卷积。阴影部分是中间张量的一部分，也是用于计算的输入和卷积核张量元素。

符号：见图中标注；各块含义见题注。




图 13.10.2 卷积核为 2×2 ，步幅为 2 的转置卷积。阴影部分是中间张量的一部分，也是用于计算的输入和卷积核张量元素。

符号：见图中标注；各块含义见题注。

普通卷积缩小空间。转置卷积把特征图放大，便于像素级输出。

13.10.1 基本操作

输入 $n_h \times n_w$ 、核 $k_h \times k_w$ 、步幅 1、无填充。每个输入标量乘核，放到与该输入位置对应的输出块，所有块相加。输出空间为 $(n_h + k_h - 1) \times (n_w + k_w - 1)$ 。每个输出条目是若干“输入值 $\times$ 核权重”之和，仍是特征响应，空间尺寸变大。

13.10.2 填充、步幅和多通道

填充作用在输出上：两侧填充 1 会删掉输出最外一行一列。步幅作用在中间结果的间距上，步幅 2 使输出更稀、更大。多通道与普通卷积相同： c_i 入、 c_o 出。 c_o 个输出通道仍是特征，不是自动变成类概率；分割里常把 c_o 设为类别数后才接 softmax。

13.10.3 与矩阵变换的联系

卷积 $Y = f(X)$ 可写成 $\text{vec}(Y) = \mathbf{W} \text{vec}(X)$ 。 $\mathbf{W}$ 的条目是核权重按滑动位置展开后的系数。转置卷积对应 $\text{vec}(X') = \mathbf{W}^\top \text{vec}(Y)$ ，故正向与反向在卷积与转置卷积之间对换。若 g 与 f 超参数对应且通道对齐，则 $g(f(X))$ 与 X 同空间形状：形状相同只说明网格对齐，每个像素值一般并不等于原图。

13.10.4 小结

转置卷积经核广播输入，增大空间。它是卷积矩阵的转置作用在向量化特征上。输出网格上的数是上采样后的特征或 logits。

13.10.5 练习

核验： X 与 $g(f(X))$ 形状相同是否蕴含数值相同。通常不相同：形状是几何尺寸，数值是特征响应。

13.11 全卷积网络




图 13.11.1 全卷积网络

符号：卷积骨干：特征；转置卷积：上采样到像素类别

FCN 把分类网改成像素分类：特征、 1×1 卷积改通道、转置卷积恢复 $H \times W$ 。

13.11.1 构造模型

预训练 ResNet-18 去掉全局平均汇聚与全连接。 1×1 卷积把通道变为类别数 K ，再转置卷积使空间回到输入尺寸。输出 $\hat{Y} \in \mathbb{R}^{K \times H \times W}$ ，通道维是逐像素 logits：位置 (h, w) 上的 K 维向量经 softmax 后，第 k 个分量是该像素属于类 k 的概率，在 $[0, 1]$ 且和为 1。

13.11.2 初始化转置卷积层

双线性上采样：把输出坐标 (x, y) 映到输入实坐标 (x', y') ，用最近四像素按距离加权。该核可作为转置卷积的初值。 (x, y) 是像素位置；权重是插值系数，和为 1，表示“从哪四个邻居各借多少”，不是分类概率。

13.11.3 读取数据集

VOC 随机裁剪 320×480 ，使高宽可被 32 整除（与步幅一致）。320 与 480 是像素边长。

13.11.4 训练

损失是逐像素交叉熵，在通道维上做 Softmax。每个像素贡献一项 $-\log \hat{p}_{Y_{h,w}}$ ， $\hat{p}$ 是该像素正确类的预测概率。准确率是像素类别是否正确的平均，取值 $[0, 1]$ 。

13.11.5 预测

输入标准化为四维。类别映回调色板颜色。若 H 或 W 不能被 32 整除，切多块可整除区域，重叠像素对 logits 取平均再分类。平均的是未归一化分数，然后再变成类概率；颜色只是显示，不是模型输出。

13.11.6 小结

FCN: $\hat{Y} = g_{H,W}(h_{1 \times 1}(f(X)))$ ， g 为转置卷积，可用双线性核初始化。 $\hat{Y}_{k,h,w}$ 是像素 (h, w) 上类 k 的 logit。

13.11.7 练习

核验：转置卷积改 Xavier 随机初始化对分割精度的影响。精度仍是像素正确比例。

13.12 风格迁移



图 13.12.1 输入内容图像和风格图像，输出风格迁移后的合成图像

符号：见图中标注；各块含义见题注。




图 13.12.2 基于卷积神经网络的风格迁移。实线箭头和虚线箭头分别表示前向传播和反向传播

符号：见图中标注；各块含义见题注。

内容图 X_c 与风格图 X_s 。合成图 X 是唯一优化变量；预训练 CNN 只抽特征。

13.12.1 方法

初始化 $\mathbf{X} \leftarrow \mathbf{X}_c$ 。选若干层作内容层、若干层作风格层。最小化内容损失、风格损失与全变分损失的加权和，只更新 $\mathbf{X}$ 。更新的是合成图像的像素，不是分类头的权重。

13.12.2 阅读内容和风格图像

两图空间尺寸一般不同，后续会缩放到同一训练尺寸。像素仍是强度。

13.12.3 预处理和后处理

预处理：RGB 标准化并变成卷积输入格式。后处理：反标准化并把像素裁到 $[0, 1]$ 。 $[0, 1]$ 是合法强度范围，裁剪防止溢出成无意义的亮度。

13.12.4 抽取图像特征

VGG-19。内容层取较深卷积以去细节；风格层取各块较浅卷积以同时匹配局部与全局纹理。层输出 $\phi(\mathbf{X})$ 是特征响应，不是该类图像的分类概率。

13.12.5 定义损失函数

三项加权。

13.12.5.1 内容损失

内容层输出 $\phi_c(\mathbf{X})$ 与 $\phi_c(\mathbf{X}_c)$ 的平方误差。该标量衡量合成图与内容图在深层特征上有多远，与像素同层特征的平方差量纲，不是“属于某类”的交叉熵。

13.12.5.2 风格损失

风格层输出整形为 $\mathbf{X} \in \mathbb{R}^{c \times hw}$ ，格拉姆矩阵

$$\mathbf{G} = \mathbf{X} \mathbf{X}^T \in \mathbb{R}^{c \times c}.$$

$G_{ij} = \sum_p X_{ip} X_{jp}$ 是通道 i 与通道 j 在空间上的内积，描述各通道纹理的共现统计（哪些滤波一起被激活），不是分类分数矩阵。风格损失为 $\|\mathbf{G}(\mathbf{X}) - \mathbf{G}(\mathbf{X}_s)\|_F^2$ （对各风格层求和）。这个非负标量是两张 Gram 矩阵的平方欧氏距离：越大表示纹理统计差得越远，它不是分类误差，也不给出“像哪一类物体”的概率。

13.12.5.3 全变分损失

$$\sum_{i,j} (|x_{i,j} - x_{i+1,j}| + |x_{i,j} - x_{i,j+1}|)$$

对相邻像素强度差取绝对值再求和，鼓励相邻像素接近，减少噪点。单位与像素强度相同（差的绝对值之和）。

13.12.5.4 损失函数

$$\ell = \alpha \ell_{\text{content}} + \beta \ell_{\text{style}} + \gamma \ell_{\text{TV}}.$$

α, β, γ 是三项的权重（无量纲倍率），用来折中保内容、迁风格与去噪。 ℓ 本身是标量训练目标，对 $\mathbf{X}$ 求梯度后， $\eta \nabla_{\mathbf{X}} \ell$ 是每个像素本步要改变的强度，不是类概率。

13.12.6 初始化合成图像

把 $\mathbf{X}$ 当作模型参数，前向即返回该参数。风格图的格拉姆在训练前算一次：那张 $\mathbf{G}(\mathbf{X}_s)$ 是固定的纹理统计目标。

13.12.7 训练模型

反复抽 $\mathbf{X}$ 的内容/风格特征，求 ℓ ，对 $\mathbf{X}$ 求梯度并更新。每步改变的是合成图像素值，使 Gram 距离与内容特征距离下降。

13.12.8 小结

$\ell = \alpha \ell_{\text{content}} + \beta \ell_{\text{style}} + \gamma \ell_{\text{TV}}$ ，风格由 $\mathbf{G} = \mathbf{X} \mathbf{X}^T$ 表达：风格损失是 Gram 矩阵之间的距离（纹理统计），不是分类误差。只更新合成图像。

13.12.9 练习

核验：改内容/风格层集合或 (α, β, γ) 时， $\mathbf{X}$ 更贴近哪一张输入。贴近程度分别看内容特征差与 Gram 距离这两个标量。

13.13 实战 Kaggle 比赛：图像分类 (CIFAR-10)

从原始 PNG 组织数据，再用卷积与增广做十分类。

13.13.1 获取并组织数据集

训练 5×10^4 张，测试 3×10^5 张（其中 10^4 用于评分）。这些是图像张数。图为 32×32 RGB，十类。32 是像素边长；十类对应 10 维 logits。

13.13.1.1 下载数据集

`train/`、`test/` 与 `trainLabels.csv`。标签文件里的条目是类名或类编号，不是框坐标。

13.13.1.2 整理数据集

按标签分文件夹。验证比例 r ，每类验证张数为 $\max(\lfloor nr \rfloor, 1)$ ， n 为最小类的训练张数。 $r \in (0, 1)$ 是划分比例，表示拿多少训练图去验证，不是分类概率。

13.13.2 图像增广

训练：随机水平翻转与 RGB 标准化。测试：仅标准化。标准化后每个通道的像素是减去均值再除标准差后的强度。

13.13.3 读取数据集

训练加载器施用随机 T ；验证与最终训练（训练 + 验证）用确定性变换。批量输出 $(\mathbf{X}, \mathbf{y})$ ： $\mathbf{X}$ 是像素， $y_i \in \{0, \dots, 9\}$ 是类编号。

13.13.4 定义模型

ResNet-18，输出 10 类。第 k 个 logit 经 softmax 后是属于类 k 的概率。

13.13.5 定义训练函数

按验证集指标选超参。学习率可每 T 个周期乘衰减因子。 T 是周期数；衰减因子是步长 η 的折扣，不是准确率。

13.13.6 训练和验证模型

可调批量、周期、 η 、衰减周期与因子。演示可用较少周期。记录的训练/验证精度都是正确分类比例，取值 $[0, 1]$ 。

13.13.7 在 Kaggle 上对测试集进行分类并提交结果

用全部有标签数据重训，对测试集写类别，生成提交表。提交的是预测类编号（或概率向量），不是边界框。

13.13.8 小结

文件数据集 → 按类目录 → 增广加载器 → f_{θ} 的十分类。模型输出的 10 个数（softmax 后）是各类概率，和为 1。

13.13.9 练习

核验：完整数据与给定超参下的测试精度，以及去掉增广后的精度差。精度差是两个 $[0, 1]$ 比例之差。

13.14 实战 Kaggle 比赛：狗的品种识别（ImageNet Dogs）

120 类犬种，图像大于 CIFAR，且尺寸不一，来自 ImageNet 子集。

13.14.1 获取和整理数据集

训练约 10^4 张，测试约 10^4 张 JPEG。 10^4 是图像个数；120 才是类别数。

13.14.1.1 下载数据集

labels.csv 与 train/、test/。标签是品种名或编号。

13.14.1.2 整理数据集

与 CIFAR 相同：读标签、拆验证、按类建目录。

13.14.2 图像增广

更大图上用随机裁剪缩放到网络输入尺寸，测试用确定性缩放与裁剪。裁剪框是像素位置；缩放后的 $H \times W$ 是网络输入边长。

13.14.3 读取数据集

加载器构造与 CIFAR 一节相同，只是 T 不同。 $y_i \in \{0, \dots, 119\}$ 是品种编号。

13.14.4 微调预训练模型

ResNet-34 在 ImageNet 上预训练，冻结特征，只训练小型输出头（如两层全连接，120 类）。不反传主干以省计算与显存。头输出 120 维 logits，softmax 后第 k 个分量是品种 k 的概率。

13.14.5 定义训练函数

train 只迭代输出头参数。按验证指标选头。被更新的是头权重；每次减去 ηg ，与第十一章相同。

13.14.6 训练和验证模型

η 每若干周期乘衰减。周期与衰减可调。 η 是步长；验证误差是错误分类比例。

13.14.7 对测试集分类并在 Kaggle 提交结果

用全部有标签数据训练输出头，对测试集写 120 维概率或类别。提交的概率第 k 维是该图为品种 k 的机会，在 $[0, 1]$ 且通常和为 1。

13.14.8 小结

大图子集上，冻结 ImageNet 主干 f ，只学 $\mathbb{R}^d \rightarrow \mathbb{R}^{120}$ 的头，并配以更强的空间增广。头给出的是品种概率，不是框坐标。

13.14.9 练习

核验：更大主干与不同 (η, T_{decay}) 是否降低验证误差。 η 改的是步长， T_{decay} 是多少周期后缩小步长。

第十四章 自然语言处理：预训练

词是离散符号。预训练把词或词元映到向量，使共现与上下文进入内积。先写 word2vec 与 GloVe，再写子词与 BERT 的掩蔽语言建模、下一句预测。Softmax 给出的 $P(w_o | w_c)$ 是“附近出现某词”的概率；负采样的 σ 是“这对是真上下文”的概率。

14.1 词嵌入 (word2vec)




图 14.1.1 跳元模型考虑了在给定中心词的情况下生成周围上下文词的条件概率

符号：中心词：条件；上下文词：被预测的周围词




图 14.1.2 连续词袋模型考虑了给定周围上下文词生成中心词条件概率

符号：上下文词：条件；中心词：被预测

词向量 $\mathbf{v} \in \mathbb{R}^d$ 是词的特征。词嵌入是映射 $w \mapsto \mathbf{v}_w$ 。 $\mathbf{v}_w$ 的各分量没有单独的类含义，整体用来通过内积表达共现。

14.1.1 为何独热向量是一个糟糕的选择

词表 $\mathcal{V}$ 上的独热 $\mathbf{e}_w$ 两两正交，余弦

$$\frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} \in [-1, 1]$$

是两个向量方向的一致性： ± 1 表示同向或反向，0 表示正交。对任何不同词的独热，该数都是 0，无法表达相似。

14.1.2 自监督的 word2vec

跳元 (skip-gram) 用中心词预测上下文；连续词袋 (CBOW) 用上下文预测中心词。二者都用语料中的共现，不另需标签。预测的对象是词表上的概率分布，不是回归房价那种实数。

14.1.3 跳元模型 (Skip-Gram)

由 “loves” 生成两侧词的联合，并假定条件独立：

$$\begin{aligned} P(\text{the, man, his, son} \mid \text{loves}) \\ \approx P(\text{the} \mid \text{loves}) P(\text{man} \mid \text{loves}) P(\text{his} \mid \text{loves}) P(\text{son} \mid \text{loves}). \end{aligned}$$

每个因子都是 $[0, 1]$ 上的条件概率：中心词固定为 “loves” 时，窗口里出现该词的机会。一般地，中心词向量 $\mathbf{v}_c$ 、上下文向量 $\mathbf{u}_o$,

$$P(w_o \mid w_c) = \frac{\exp(\mathbf{u}_o^\top \mathbf{v}_c)}{\sum_{i \in \mathcal{V}} \exp(\mathbf{u}_i^\top \mathbf{v}_c)}.$$

分子分母里的 $\mathbf{u}^\top \mathbf{v}$ 是打分（可正可负的实数）；softmax 之后 $P(w_o \mid w_c) \in [0, 1]$ 且对 o 求和为 1，表示“在中心词 w_c 附近，上下文词恰好是 w_o 的概率”，不是中心词本身的词频。长度为 T 、窗口 m 的语料似然

$$\prod_{t=1}^T \prod_{\substack{-m \leq j \leq m \\ j \neq 0}} P(w^{(t+j)} \mid w^{(t)}).$$

每个因子仍是“窗口内那个邻居词”的条件概率；整个乘积是整段语料被该模型生成的可能性。

14.1.3.1 训练

最小化

$$-\sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log P(w^{(t+j)} \mid w^{(t)}).$$

这是负对数似然：真实邻居的概率越接近 1，该项越接近 0；概率小则损失大，单位是 nats（自然对数）。对数条件概率

$$\log P(w_o \mid w_c) = \mathbf{u}_o^\top \mathbf{v}_c - \log \sum_{i \in \mathcal{V}} \exp(\mathbf{u}_i^\top \mathbf{v}_c).$$

第一项是正例打分，第二项是配分函数的对数，用来把打分变成对数概率。对 $\mathbf{v}_c$ 的梯度

$$\frac{\partial \log P(w_o \mid w_c)}{\partial \mathbf{v}_c} = \mathbf{u}_o - \sum_{j \in \mathcal{V}} P(w_j \mid w_c) \mathbf{u}_j.$$

结果与 $\mathbf{v}_c$ 同形：第 ℓ 个分量是“中心向量第 ℓ 维增加时，对数概率大约增加多少”。每步与 $|\mathcal{V}|$ 成正比。

14.1.4 连续词袋 (CBOW) 模型

$$P(\text{loves} \mid \text{the, man, his, son}).$$

这是给定窗口词时中心词为“loves”的概率，取值 $[0, 1]$ 。上下文平均 $\bar{\mathbf{v}}_o = \frac{1}{2m}(\mathbf{v}_{o_1} + \dots + \mathbf{v}_{o_{2m}})$ ， $\bar{\mathbf{v}}_o$ 与单个词向量同形，表示窗口的平均语义。

$$P(w_c \mid \mathcal{W}_o) = \frac{\exp(\mathbf{u}_c^\top \bar{\mathbf{v}}_o)}{\sum_{i \in \mathcal{V}} \exp(\mathbf{u}_i^\top \bar{\mathbf{v}}_o)}.$$

softmax 的第 c 个分量是“中心词是 w_c ”的概率，在 $[0, 1]$ 且对词表求和为 1。序列似然

$$\prod_{t=1}^T P(w^{(t)} \mid w^{(t-m)}, \dots, w^{(t-1)}, w^{(t+1)}, \dots, w^{(t+m)}).$$

每个因子是该位置中心词的条件概率。

14.1.4.1 训练

$$-\sum_{t=1}^T \log P(w^{(t)} \mid w^{(t-m)}, \dots, w^{(t+m)}).$$

仍是负对数似然，压的是中心词概率。

$$\log P(w_c \mid \mathcal{W}_o) = \mathbf{u}_c^\top \bar{\mathbf{v}}_o - \log \sum_{i \in \mathcal{V}} \exp(\mathbf{u}_i^\top \bar{\mathbf{v}}_o).$$

$$\frac{\partial \log P(w_c \mid \mathcal{W}_o)}{\partial \mathbf{v}_{o_i}} = \frac{1}{2m} \left(\mathbf{u}_c - \sum_{j \in \mathcal{V}} P(w_j \mid \mathcal{W}_o) \mathbf{u}_j \right).$$

梯度再除以 $2m$ ，因为平均把每个上下文向量的贡献摊薄；各分量仍是“该上下文向量坐标增加时对数概率如何变”。

14.1.5 小结

跳元: $P(w_o \mid w_c) \propto \exp(\mathbf{u}_o^\top \mathbf{v}_c)$, $P(w_o \mid w_c)$ 是附近出现上下文词 w_o 的概率。CBOW: $P(w_c \mid \mathcal{W}_o) \propto \exp(\mathbf{u}_c^\top \bar{\mathbf{v}}_o)$ ，是由窗口预测中心词的概率。Softmax 分母扫过整个 $\mathcal{V}$ 。

14.1.6 练习

核验：梯度对 $|\mathcal{V}|$ 的复杂度，以及 $\mathbf{u}^\top \mathbf{v}$ 与余弦的关系。内积是打分；除以范数后才是 $[-1, 1]$ 的余弦相似度。

14.2 近似训练




图 14.2.1 用于近似训练的分层 softmax，其中树的每个叶节点表示词表中的一个词符号：见图中标注；各块含义见题注。

精确 Softmax 每步求和 $|V|$ 项。负采样与层序 Softmax 把代价降到常数或对数。

14.2.1 负采样

把“中心-上下文是否共现”当成二分类

$$P(D = 1 \mid w_c, w_o) = \sigma(\mathbf{u}_o^\top \mathbf{v}_c), \quad \sigma(x) = \frac{1}{1 + \exp(-x)}.$$

$\mathbf{u}_o^\top \mathbf{v}_c$ 是该词对的打分；sigmoid 把它压到 $(0, 1)$ 。 $P(D = 1 \mid w_c, w_o)$ 表示“ (w_c, w_o) 是语料里真实上下文对”的概率，不是跳元那种“在全部词表上抽中 w_o ”的多项概率。正对似然再乘 K 个噪声词的负例

$$P(w^{(t+j)} \mid w^{(t)}) = P(D = 1 \mid w^{(t)}, w^{(t+j)}) \prod_{k=1}^K P(D = 0 \mid w^{(t)}, w_k).$$

$P(D = 0) = \sigma(-\mathbf{u}^\top \mathbf{v})$ 是“该噪声对不是真上下文”的概率。损失

$$-\log P(w^{(t+j)} \mid w^{(t)}) = -\log \sigma(\mathbf{u}_{i_{t+j}}^\top \mathbf{v}_{i_t}) - \sum_{k=1}^K \log \sigma(-\mathbf{u}_{h_k}^\top \mathbf{v}_{i_t}).$$

第一项要求真邻居的 sigmoid 接近 1，其余项要求噪声对的 sigmoid 接近 0。每步与 K 线性，与 $|V|$ 无关。

14.2.2 层序 Softmax

词表做成二叉树。从根到叶 w_o 的路径长度为 $L(w_o)$,

$$P(w_o | w_c) = \prod_{j=1}^{L(w_o)-1} \sigma(\mathbb{I}[n(w_o, j+1) = \text{leftChild}(n(w_o, j))] \mathbf{u}_{n(w_o, j)}^\top \mathbf{v}_c).$$

路径上每一步的 σ 是“向左或向右走”的概率；整条路径的乘积才是词 w_o 的概率，仍在 $[0, 1]$ 。向左与向右对应 $+\mathbf{u}^\top \mathbf{v}$ 与 $-\mathbf{u}^\top \mathbf{v}$ 。对任意 w_c 有 $\sum_{w \in \mathcal{V}} P(w | w_c) = 1$ 。代价为 $O(\log |\mathcal{V}|)$ 。

14.2.3 小结

负采样用 $1+K$ 次 $\sigma(\mathbf{u}^\top \mathbf{v})$ ：每次 σ 给出“这对是（或不是）真上下文”的概率。层序 Softmax 用根到叶的 $O(\log |\mathcal{V}|)$ 次，乘积给出 $P(w_o | w_c)$ 。

14.2.4 练习

核验： $\sum_w P(w | w_c) = 1$ 在二叉树上是否成立，以及噪声分布 $P(w)$ 如何取。噪声 $P(w)$ 是抽负例的概率，与模型输出的 $\sigma(\mathbf{u}^\top \mathbf{v})$ 不是同一个数。

14.3 用于预训练词嵌入的数据集

把 PTB 文本变成跳元 + 负采样所需的小批量。

14.3.1 读取数据集

一行一句、空格分词。频次低于阈值的词并入未知词元。频次是出现次数（非负整数）；阈值是最小保留次数。

14.3.2 下采样

词 w_i 被丢弃的概率

$$P(w_i) = \max\left(1 - \sqrt{\frac{t}{f(w_i)}}, 0\right),$$

f 为相对频率（该词次数除以总词数，在 $[0, 1]$ ）， t 为阈值。 $P(w_i)$ 是“这次不把该词放进训练”的概率，高频词更常被丢掉。

14.3.3 中心词和上下文词的提取

对每个中心位置均匀抽窗口半径 1 到 m ，距离不超过该半径的词为上下文。半径是词距离（整数），不是概率。

14.3.4 负采样

噪声 w 的抽样概率正比于 $f(w)^{0.75}$ 。每对正例抽 K 个噪声词。这个抽样概率用来生成负对；模型随后用 $\sigma(\mathbf{u}^\top \mathbf{v})$ 判断它们不像真上下文。

14.3.5 小批量加载训练实例

第 i 个样本有 n_i 个上下文与 m_i 个噪声。拼接到长度 $\max_i(n_i + m_i)$ 并补零；掩码标出非填充；标签区分正负例。标签 1 表示真上下文对，0 表示噪声对；掩码 1 表示该位置计入损失。

14.3.6 整合代码

迭代器一次产出中心词、上下文加噪声、掩码与标签。中心与上下文是词表下标（整数），不是向量本身；嵌入表再用下标取出 $\mathbf{v}, \mathbf{u}$ 。

14.3.7 小结

下采样降高频；批量用掩码对齐变长的正负例。正例标签对应“真是附近词”，负例对应“不是”。

14.3.8 练习

核验：关闭下采样对每个 epoch 词元数与墙钟时间的影响。词元数是整数计数；时间是秒。

14.4 预训练 word2vec

在 PTB 上用负采样训练跳元。

14.4.1 跳元模型

两个嵌入：中心与上下文（含噪声）。

14.4.1.1 嵌入层

权重 $\mathbf{E} \in \mathbb{R}^{|\mathcal{V}| \times d}$ 。索引 i 取第 i 行。第 i 行 $\mathbf{e}_i \in \mathbb{R}^d$ 就是词 i 的向量。批量索引形状 (B, L) 时输出 (B, L, d) ：每个位置一个 d 维词向量。

14.4.1.2 定义前向传播

中心 $(B, 1, d)$ 与上下文-噪声 $(B, \text{max_len}, d)$ 做批量点积，得 $(B, 1, \text{max_len})$ ，每个元素是 $\mathbf{v}_c^\top \mathbf{u}$ 。该标量是词对打分：越大越像真上下文；再经 sigmoid 才变成 $[0, 1]$ 概率。

14.4.2 训练

损失只在非填充位置上平均。

14.4.2.1 二元交叉熵损失

对每个正负位置用 $-[y \log \sigma(s) + (1 - y) \log(1 - \sigma(s))]$ ，再按掩码平均，与负采样公式一致。 $s = \mathbf{v}_c^\top \mathbf{u}$ 是打分； $\sigma(s)$ 是“该对为真上下文”的概率； $y \in \{0, 1\}$ 是标签。损失是 nats，不是准确率。

14.4.2.2 初始化模型参数

两张嵌入表，行数为 $|\mathcal{V}|$ ，例如 $d = 100$ 。 d 是向量维数，每个分量初始化为小随机数，尚无语义。

14.4.2.3 定义训练阶段代码

每个批量：前向点积、掩码交叉熵、反传更新两张表。更新量 $\eta \partial L / \partial E_{i\ell}$ 是词 i 第 ℓ 维本步移动多少。

14.4.3 应用词嵌入

查询词 $\mathbf{v}$ ，在词表中取余弦最大的 k 个 $\mathbf{v}'$ 。余弦在 $[-1, 1]$ ，越接近 1 表示方向越一致，常被当作语义相近。

14.4.4 小结

跳元前向是 $\mathbf{v}_c^\top \mathbf{u}$ (打分); 训练是掩码二元交叉熵, 其中 $\sigma(\mathbf{v}_c^\top \mathbf{u})$ 是真上下文概率。下游用余弦找近邻。

14.4.5 练习

核验: 同一中心词在不同轮次重抽上下文与噪声, 对更新方差的影响。方差刻画各维更新量有多抖, 与词向量本身的语义分量不是一回事。

14.5 全局向量的词嵌入 (GloVe)

用全局共现计数 x_{ij} 解释跳元, 再用平方损失拟合 $\log x_{ij}$ 。

14.5.1 带全局语料统计的跳元模型

$$q_{ij} = \frac{\exp(\mathbf{u}_j^\top \mathbf{v}_i)}{\sum_{k \in \mathcal{V}} \exp(\mathbf{u}_k^\top \mathbf{v}_i)},$$

$q_{ij} = P(w_j | w_i)$ 仍是“中心为 i 时上下文为 j ”的概率。共现加权交叉熵

$$-\sum_{i \in \mathcal{V}} \sum_{j \in \mathcal{V}} x_{ij} \log q_{ij} = -\sum_{i \in \mathcal{V}} x_i \sum_{j \in \mathcal{V}} p_{ij} \log q_{ij},$$

其中 $x_i = \sum_j x_{ij}$ 是词 i 的共现总数 (计数), $p_{ij} = x_{ij}/x_i$ 是经验条件概率, 在 $[0, 1]$ 。 x_{ij} 本身是窗口内共现次数, 不是概率。

14.5.2 GloVe 模型

$$\sum_{i \in \mathcal{V}} \sum_{j \in \mathcal{V}} h(x_{ij}) (\mathbf{u}_j^\top \mathbf{v}_i + b_i + c_j - \log x_{ij})^2.$$

括号内是“内积加偏置”与“共现次数的对数”之差: $\log x_{ij}$ 是计数的对数, 量纲是无量纲的对数计数; 拟合它不是在拟合分类误差。 h 对大计数截断, 避免极高频对支配损失。中心向量与上下文向量在此目标下地位对称。

14.5.3 从条件概率比值理解 GloVe 模型

希望

$$f(\mathbf{u}_j, \mathbf{u}_k, \mathbf{v}_i) \approx \frac{p_{ij}}{p_{ik}}.$$

p_{ij}/p_{ik} 是两个经验条件概率之比，表示“相对 k ，词 j 与 i 共现得有多频繁”。取指数内积比

$$\frac{\exp(\mathbf{u}_j^\top \mathbf{v}_i)}{\exp(\mathbf{u}_k^\top \mathbf{v}_i)} \approx \frac{p_{ij}}{p_{ik}},$$

从而

$$\mathbf{u}_j^\top \mathbf{v}_i + b_i + c_j \approx \log x_{ij}.$$

左边是可学习的打分加偏置，右边是观测到的对数计数。

14.5.4 小结

GloVe 用加权平方损失拟合 $\log x_{ij}$ ，而不是对整个 $\mathcal{V}$ 做 Softmax。比值 p_{ij}/p_{ik} 由内积差解释；这些比值是频率比，不是单个词的出现概率。

14.5.5 练习

核验：用窗口内距离重加权 p_{ij} 后目标如何变，以及 b_i 与 c_i 是否可对换。 b_i, c_j 是对数计数分解里的偏置，吸收与单个词相关的频率水平。

14.6 子词嵌入

变形、复合词共享字符片段。把词向量写成子词向量之和。

14.6.1 fastText 模型

词 w 的字符 n -gram 集合 $\mathcal{G}_w$ （含词本身），

$$\mathbf{v}_w = \sum_{g \in \mathcal{G}_w} \mathbf{z}_g.$$

每个 $\mathbf{z}_g \in \mathbb{R}^d$ 是子词向量；求和后 $\mathbf{v}_w$ 仍是词的 d 维表示。跳元仍用 $\mathbf{u}_o^\top \mathbf{v}_c$ ，但 $\mathbf{v}_c$ 可加性分解。未见词只要子词在词表中即可表示。点积的含义不变：仍是中心-上下文打分，softmax 或 sigmoid 后仍是概率。

14.6.2 字节对编码 (Byte Pair Encoding)

从单字符开始，反复合并当前语料中最频的相邻符号对，得到可变长子词，词表大小预先固定。不跨词边界合并。每次合并依据的是相邻对的出现次数（计数），不是模型概率。

14.6.3 小结

fastText: $\mathbf{v}_w = \sum_{g \in \mathcal{G}_w} \mathbf{z}_g$, 各 $\mathbf{z}_g$ 相加得到词向量。BPE 贪心合并最频对, 得到固定词表上的可变长子词。

14.6.4 练习

核验: 从 n 个初始符号得到词表大小 m 需要多少次合并。合并次数是 $m - n$ 这个整数。

14.7 词的相似性和类比任务

大语料上预训练的向量可直接用于近邻与类比。

14.7.1 加载预训练词向量

GloVe 有 50/100/300 维; fastText 有 300 维英文向量。这些整数是 d , 即每个词几个实数分量。词表含四十万词加未知词元。

14.7.2 应用预训练词向量

相似度用余弦; k 近邻在词表上穷举。

14.7.2.1 词相似度

对查询 w , 返回 $\arg \max_{w' \neq w} \cos(\mathbf{v}_w, \mathbf{v}_{w'})$ 的前 k 个。 $\cos \in [-1, 1]$ 越大表示越相似; k 是要列出的邻居个数。

14.7.2.2 词类比

$a : b :: c : d$ 中求

$$d = \underset{w}{\operatorname{argmin}} \|\mathbf{v}_w - (\mathbf{v}_c + \mathbf{v}_b - \mathbf{v}_a)\|$$

(或最大余弦)。例如性别与首都-国家。 $\mathbf{v}_c + \mathbf{v}_b - \mathbf{v}_a$ 是向量算术: 在嵌入空间里“从 a 到 b 的位移”加到 c 上。距离越小表示越接近这个类比目标, 不是分类概率。

14.7.3 小结

近邻是 $\cos(\mathbf{v}, \mathbf{v}')$; 类比是 $\mathbf{v}_c + \mathbf{v}_b - \mathbf{v}_a$ 的最近邻。余弦是方向一致性, 取值 $[-1, 1]$ 。

14.7.4 练习

核验：词表很大时如何用近似近邻代替全表扫描。

14.8 来自 Transformers 的双向编码器表示（BERT）




图 14.8.1 ELMo、GPT 和 BERT 的比较

符号：见图中标注；各块含义见题注。




图 14.8.2 BERT 输入序列的嵌入是词元嵌入、片段嵌入和位置嵌入的和

符号：token/segment/position：三种嵌入求和为 BERT 输入

word2vec/GloVe 的 $\mathbf{v}_w$ 与上下文无关。BERT 用双向 Transformer 编码器，使表示依赖整句。

14.8.1 从上下文无关到上下文敏感

上下文无关： $f(x)$ 只摄入词元 x 。多义词在不同句中应不同； $f(x, \text{上下文})$ 才能区分。输出仍是 d 维向量，但同一词的向量随句子变。

14.8.2 从特定于任务到不可知任务

ELMo 双向但下游仍要定制结构；GPT 任务无关但从左到右。微调时 GPT 更新全部解码器参数，ELMo 常冻结。更新的是权重，步长仍是 η 。

14.8.3 BERT：把两个最好的结合起来

双向编码 + 下游只加一个浅输出层，并微调全部编码器参数。

14.8.4 输入表示

单句： $\langle \text{cls} \rangle + \text{词元} + \langle \text{sep} \rangle$ 。句对： $\langle \text{cls} \rangle + A + \langle \text{sep} \rangle + B + \langle \text{sep} \rangle$ 。输入嵌入为词元嵌入、片段嵌入与位置嵌入之和。三个 d 维向量逐元素相加，得到的仍是该位置的输入特征，不是概率。

14.8.5 预训练任务

编码器输出每个词元（含特殊词元）的向量，供两个自监督头使用。

14.8.5.1 掩蔽语言模型（Masked Language Modeling）

随机选 15% 词元做预测。对被选词元：以 80% 换成 $\langle \text{mask} \rangle$ ，10% 换成随机词，10% 保持原词，再用双向上下文预测原词。15%, 80%, 10% 是采样比例。MLM 头在词表上做 softmax，第 v 个分量是“被掩位置原来是词 v ”的概率，在 $[0, 1]$ 且和为 1。避免微调阶段从未见过 $\langle \text{mask} \rangle$ 导致的不一致。

14.8.5.2 下一句预测（Next Sentence Prediction）

句对一半为真实邻句（正），一半第二句随机（负）。 $\langle \text{cls} \rangle$ 的表示经单隐层 MLP 做二分类。输出两个 logits，softmax（或 sigmoid）后得到 $P(B \text{ 紧跟 } A) \in [0, 1]$ ：这是“句子 B 是否紧接在 A 后面”的概率，不是某个掩词的概率。

14.8.6 整合代码

总损失为 MLM 与 NSP 损失的和。前向返回编码、MLM logits 与 NSP logits。MLM logits 形状约为（批量，掩位数，词表大小），每行 softmax 后是掩词分布；NSP logits 形状为（批量，2），softmax 后是“是否下一句”的二类概率。

14.8.7 小结

BERT 输入是三类嵌入之和。预训练

$$\ell = \ell_{\text{MLM}} + \ell_{\text{NSP}},$$

ℓ_{MLM} 是掩词负对数概率的平均， ℓ_{NSP} 是句对二分类交叉熵。MLM 给双向上下文，NSP 给句对关系。

14.8.8 练习

核验：MLM 相对从左到右 LM 需要更多还是更少步才能收敛，以及 GELU 与 ReLU 的差别。步数是优化迭代次数；损失值是 nats。

14.9 用于预训练 BERT 的数据集

在 WikiText-2 上生成 MLM 与 NSP 样本。保留标点、大小写与数字。

14.9.1 为预训练任务定义辅助函数

从段落造句对，再对 BERT 序列做掩蔽。

14.9.1.1 生成下一句预测任务的数据

以 1/2 概率取下句为真邻句，否则从语料随机抽一句。截断使总长不超过 `max_len`。1/2 是抽正/负句对的机会；NSP 标签 1 表示 B 真的跟在 A 后，0 表示不是。`max_len` 是词元个数上限。

14.9.1.2 生成遮蔽语言模型任务的数据

在非特殊词元中抽约 15% 位置；按 80/10/10 替换；返回改写后的词元、预测位置与原词标签。原词标签是词表下标，训练时要让 MLM 分布在這些下标上的概率尽量接近 1。

14.9.2 将文本转换为预训练数据集

填充到固定长，附片段下标、有效长度掩码、MLM 标签与 NSP 标签。一条样本对应一对句子上的两个任务。片段下标 0/1 区分句子 A 与 B；掩码 1 表示该位置是真实词元而非填充。

14.9.3 小结

WikiText-2 样本是填充后的 (词元, 片段, MLM 位置与标签, NSP 标签)。MLM 标签是被掩词的编号；NSP 标签是“B 是否跟随 A”的 0/1。

14.9.4 练习

核验：不用句号切句、不过滤稀有词元时词表有多大。词表大小是不同词元的个数。

14.10 预训练 BERT

用上一节样本训练小型 BERT，再用编码器表示文本。

14.10.1 预训练 BERT

原论文 BERT_{BASE}：12 层、768 隐、12 头，约 1.1×10^8 参数；BERT_{LARGE}：24 层、1024、16 头，约 3.4×10^8 。这些是层数、隐维、头数与参数个数。演示用 2 层、128 隐、2 头。批量损失为该批量 MLM 与 NSP 损失之和：MLM 项来自掩词概率的交叉熵，NSP 项来自“B 是否跟随 A”的交叉熵。

14.10.2 用 BERT 表示文本

单句或句对加上特殊词元后编码。⟨cls⟩ 位是整段表示；同一词元（如 crane）在不同句中的向量不同。这些向量是实数特征，下游再线性映射成各类 logits 或概率。

14.10.3 小结

预训练后 $f_{\text{BERT}}(x, \text{上下文})$ 随上下文变。⟨cls⟩ 与各词元向量都可作下游输入。MLM 头给出掩词概率，NSP 头给出“B 跟随 A”的概率；下游任务通常去掉这两头。

14.10.4 练习

核验：为何实验中 MLM 损失高于 NSP，以及 $\text{max_len} = 512$ 配大模型时显存是否溢出。MLM 在大词表上做多项分类，随机猜的交叉熵约为 $\log |\mathcal{V}|$ ，通常大于二分类 NSP。

第十五章 自然语言处理：应用

预训练向量或 BERT 编码器提供 $w \mapsto \boldsymbol{v}$ 或序列 $\mapsto \mathbf{H}$ 。下游把可变长文本映到固定标签：情感、句对关系、词元标签或问答跨度。情感模型的 logit 经 softmax/sigmoid 后，正类分量是“评论为正面”的概率，取值 $[0, 1]$ 。

15.1 情感分析及数据集

情感分析是文本分类：序列 $\boldsymbol{w}_{1:T}$ 映到极性 $y \in \{0, 1\}$ 。数据为 IMDb 影评，正负标签。 $y = 1$ 表示正面， $y = 0$ 表示负面；它们是类编号，还不是模型输出的概率。

15.1.1 读取数据集

每个样本是评论文本与 $y \in \{0, 1\}$ 。文本稍后变成词元下标； y 保持为极性标签。

15.1.2 预处理数据集

词元为词，低频过滤后建词表。长度直方图显示 T 变化大；截断或填充到固定 $L = 500$ 。 T 与 L 是词元个数；直方图的纵轴是具有该长度的样本数。

15.1.3 创建数据迭代器

每个批量返回 $(\boldsymbol{X}, \boldsymbol{y})$ ， $\boldsymbol{X} \in \mathbb{Z}^{B \times L}$ 为词元下标。 X_{bi} 是第 b 条评论第 i 个词在词表中的编号，不是嵌入分量； $y_b \in \{0, 1\}$ 是极性。

15.1.4 整合代码

加载函数返回训练/测试迭代器与词表。

15.1.5 小结

情感是 $\{w_t\}_{t=1}^T \mapsto y \in \{0, 1\}$ 。变长 T 经截断填充变成固定 L 。模型稍后输出的正类概率才是“这条评论为正面”的机会。

15.1.6 练习

核验：哪些预处理超参缩短每个 epoch，以及如何把另一评论语料映到同一迭代器接口。epoch 时间以秒计；标签仍须是 $\{0, 1\}$ 极性。

15.2 情感分析：使用循环神经网络




图 15.2.1 将 GloVe 送入基于循环神经网络的架构，用于情感分析

符号：见图中标注；各块含义见题注。

小数据集上用冻结的预训练词向量，再用双向 RNN 把序列压成一个向量。

15.2.1 使用循环神经网络表示单个文本

嵌入 $\mathbf{e}_t = \mathbf{E}[w_t]$ (GloVe)。 $\mathbf{e}_t \in \mathbb{R}^d$ 是第 t 个词的向量。双向 LSTM 最后一层的初始与最终时刻隐状态拼接为 $\mathbf{h}$ ，再

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{W}\mathbf{h} + \mathbf{b}) \in \mathbb{R}^2.$$

$\mathbf{W}\mathbf{h} + \mathbf{b}$ 是二维 logits：第一维对应负面，第二维对应正面（或相反约定）。softmax 后 $\hat{y}_1 + \hat{y}_2 = 1$ ，且 $\hat{y}_k \in [0, 1]$ 。正类那一个分量就是“该评论为正面”的概率，不是打分本身，也不是词向量坐标。

15.2.2 加载预训练的词向量

$\mathbf{E}$ 用 100 维 GloVe 初始化，训练中不更新，使 $\mathbf{e}_t$ 固定。100 是嵌入维数；冻结表示这些坐标不随 ηg 移动。

15.2.3 训练和评估模型

最小化交叉熵。第 i 个样本的损失是 $-\log \hat{y}_{y(i)}$ ：真类概率越接近 1，损失越接近 0。推理时把新句词元化、填充后取 $\hat{y} = \arg \max \hat{\mathbf{y}}$ 。 $\arg \max$ 选出概率更大的那一类；若需要“有多正面”，应读正类那一个概率值。

15.2.4 小结

$$\mathbf{h} = [\vec{\mathbf{h}}_1; \overleftarrow{\mathbf{h}}_T], \quad \hat{\mathbf{y}} = \text{softmax}(\mathbf{W}\mathbf{h} + \mathbf{b}),$$

其中 $\mathbf{e}_t$ 来自冻结 GloVe。 $\hat{\mathbf{y}}$ 的正类分量是正面情感的概率，取值 $[0, 1]$ 。

15.2.5 练习

核验：增大周期或改用 300 维 GloVe 是否降低测试误差。测试误差是错分比例；嵌入维数 300 不是类别数。

15.3 情感分析：使用卷积神经网络




图 15.3.1 将 GloVe 放入卷积神经网络架构进行情感分析

符号：见图中标注；各块含义见题注。




图 15.3.2 一维互相关运算。阴影部分是第一个输出元素以及用于输出计算的输入和核张量元素： $0 \times 1 + 1 \times 2 = 2$

符号：见图中标注；各块含义见题注。




图 15.3.3 具有 3 个输入通道的一维互相关运算。阴影部分是第一个输出元素以及用于输出计算的输入和核张量元素： $2 \times (-1) + 3 \times (-3) + 1 \times 3 + 2 \times 4 + 0 \times 1 + 1 \times 2 = 2$

符号：见图中标注；各块含义见题注。




图 15.3.4 具有单个输入通道的二维互相关操作。阴影部分是第一个输出元素以及用于输出计算的输入和内核张量元素： $2 \times (-1) + 3 \times (-3) + 1 \times 3 + 2 \times 4 + 0 \times 1 + 1 \times 2 = 2$

符号：见图中标注；各块含义见题注。




图 15.3.5 textCNN 的模型架构

符号：多核宽一维卷积：n-gram 特征；max-over-time：汇聚

把序列看成一维“图像”，用卷积抽 n 元语法，再用时间最大汇聚得到定长向量。

15.3.1 一维卷积

核 k 在序列上滑动，输出

$$y_i = \sum_{j=0}^{k-1} x_{i+j} k_j.$$

x 是嵌入或通道值， k_j 是核权重； y_i 是位置 i 上的局部打分（特征响应），还不是情感概率。多通道时等价于把嵌入维当作二维卷积的通道。

15.3.2 最大时间汇聚层

每个通道在时间维取 max，得到与通道数相同的向量，允许各通道有效长度不同。max 取出的是该通道最强的局部响应，仍是特征，不是 $[0, 1]$ 概率。

15.3.3 textCNN 模型

输入形状视为宽 n 、高 1、通道 d 。若干不同宽度的一维核抽局部特征；各通道时间最大汇聚后拼接；全连接加 Dropout 得到两类。最后线性层输出二维 logits, softmax 后正类分量是正面概率。

15.3.3.1 定义模型

两套嵌入：一套可训练，一套固定 GloVe；通道上拼接后再卷积。例如核宽 $\{3, 4, 5\}$ ，每类 100 个输出通道。3, 4, 5 是窗口词数；100 是通道数，不是 100 类情感。

15.3.3.2 加载预训练词向量

可训练表与固定表都用 100 维 GloVe 初始化，后者不更新。

15.3.3.3 训练和评估模型

交叉熵训练。推理同 RNN 节：logits $\rightarrow$ softmax $\rightarrow$ 正类概率为“评论正面”的机会，再 $\arg \max$ 得标签。

15.3.4 小结

一维卷积抽 n 元，时间最大汇聚得 $\mathbf{z} = \text{concat}_c \max_t(\mathbf{Y}_{c,t})$ ，再线性分类。分类层给出情感 logits；softmax 后才是正/负类概率。

15.3.5 练习

核验：与双向 LSTM 在精度和吞吐上的差别，以及加上位置编码是否改变 $\hat{y}$ 。 $\hat{y}$ 若指正类概率，应看 $[0, 1]$ 上那个数是否变化；精度是正确率。

15.4 自然语言推断与数据集

NLI 判断假设能否由前提推出。标签为蕴涵、矛盾、中性。

15.4.1 自然语言推断

前提 A 、假设 B 都是词元序列。输出

$$y \in \{\text{蕴涵}, \text{矛盾}, \text{中性}\}.$$

y 是三个离散关系之一。模型将输出三维概率，第 k 维是属于该关系的机会。

15.4.2 斯坦福自然语言推断 (SNLI) 数据集

约 5×10^5 带标签英文句对。 5×10^5 是样本个数。

15.4.2.1 读取数据集

抽取 (A, B, y) 。打印可见三类在训练与测试上大致均衡。均衡指三类频率都接近 $1/3$ ，这是数据里的经验比例。

15.4.2.2 定义用于加载数据集的类

长度统一为 `num_steps`：超长截断，不足填充词元。`num_steps` 是词元个数。下标 i 返回一对前提、假设与标签。

15.4.2.3 整合代码

词表只由训练集构建。批量里有两个输入张量，分别是前提与假设。两个张量存的都是词元下标，不是关系概率。

15.4.3 小结

NLI 是句对分类 $y = f(A, B)$ 。SNLI 提供三类均衡的监督。 f 的 `softmax` 输出在单纯形上，三个分量是三种关系的概率。

15.4.4 练习

核验：用 NLI 模型给机器翻译候选打“是否蕴涵参考”的分数是否可行。若用蕴涵类概率作为分数，该分数在 $[0, 1]$ ，表示“假设被前提蕴涵”的机会。

15.5 自然语言推断：使用注意力




图 15.5.1 将预训练 GloVe 送入基于注意力和 MLP 的自然语言推断架构

符号：见图中标注；各块含义见题注。




图 15.5.2 利用注意力机制进行自然语言推断

符号：见图中标注；各块含义见题注。

可分解注意力：对齐、比较、聚合，无循环、无卷积。

15.5.1 模型

前提词向量 $\mathbf{a}_1, \dots, \mathbf{a}_m$ ，假设 $\mathbf{b}_1, \dots, \mathbf{b}_n$ 。每个 $\mathbf{a}_i, \mathbf{b}_j \in \mathbb{R}^d$ 是词嵌入。

15.5.1.1 注意 (Attending)

$$e_{ij} = f(\mathbf{a}_i)^\top f(\mathbf{b}_j).$$

e_{ij} 是词对打分 (实数), 表示前提第 i 词与假设第 j 词有多对齐, 还不是概率。软对齐

$$\begin{aligned}\beta_i &= \sum_{j=1}^n \frac{\exp(e_{ij})}{\sum_{k=1}^n \exp(e_{ik})} \mathbf{b}_j, \\ \alpha_j &= \sum_{i=1}^m \frac{\exp(e_{ij})}{\sum_{k=1}^m \exp(e_{kj})} \mathbf{a}_i.\end{aligned}$$

$\exp(e_{ij}) / \sum_k \exp(e_{ik})$ 是对假设词的注意力权, 在 $[0, 1]$ 且对 j 求和为 1: 它是“解释 $\mathbf{a}_i$ 时应看假设哪几个词”的比例, 不是 NLI 三类概率。 β_i 是按这些权加权后的假设表示, 与嵌入同维。 f 先把向量映到较低维再做内积, 复杂度对 m, n 是线性而非二次深层交互。

15.5.1.2 比较

$$\begin{aligned}\mathbf{v}_{A,i} &= g([\mathbf{a}_i, \beta_i]), \quad i = 1, \dots, m, \\ \mathbf{v}_{B,j} &= g([\mathbf{b}_j, \alpha_j]), \quad j = 1, \dots, n.\end{aligned}$$

g 输出比较向量: 描述“该词与其对齐上下文是否一致”, 仍是特征, 不是标签。

15.5.1.3 聚合

$$\mathbf{v}_A = \sum_{i=1}^m \mathbf{v}_{A,i}, \quad \mathbf{v}_B = \sum_{j=1}^n \mathbf{v}_{B,j},$$

两个和把变长序列压成定长向量。

$$\hat{\mathbf{y}} = h([\mathbf{v}_A, \mathbf{v}_B]).$$

h 输出三类 logits。softmax 之后 $\hat{y}_k$ 才是关系 k 的概率, 和为 1。

15.5.1.4 整合代码

注意、比较、聚合联合训练, 参数即 f, g, h 中的 MLP。梯度更新仍是 η 乘各权重的偏导。

15.5.2 训练和评估模型

在 SNLI 上优化交叉熵。损失 $-\log \hat{y}_y$ 使用的是真实关系那一类的预测概率。

15.5.2.1 读取数据集

批量 256，序列长 50。256 是样本数，50 是词元数。

15.5.2.2 创建模型

$f(\mathbf{a}_i)$ 与词向量 100 维； f, g 输出 200 维。GloVe 初始化词表。100 与 200 是特征维，最终分类维数才是 3。

15.5.2.3 训练和评估模型

句对作为两个输入分到多卡。记录训练与测试准确率。准确率是预测关系等于真关系的比例，在 $[0, 1]$ 。

15.5.2.4 使用模型

新的 (A, B) 词元化后取 $\arg \max \hat{\mathbf{y}}$ 。若需要“有多像蕴涵”，应读蕴涵类那一个概率，而不是 $\arg \max$ 的类编号本身。

15.5.3 小结

对齐 $e_{ij} = f(\mathbf{a}_i)^\top f(\mathbf{b}_j)$ ，比较 $g([\mathbf{a}_i, \beta_i])$ ，聚合后 $h([\mathbf{v}_A, \mathbf{v}_B])$ 得三类 logits。三类 softmax 概率才是蕴涵/矛盾/中性的机会。

15.5.4 练习

核验：该分解无法对高阶跨句交互建模时误差如何表现，以及如何改成输出 $[0, 1]$ 相似度。相似度可以是蕴涵概率，或单独的 sigmoid 标量，二者都在 $[0, 1]$ 但含义不同。

15.6 针对序列级和词元级应用微调 BERT




图 15.6.1 微调 BERT 用于单文本分类应用，如情感分析和测试语言可接受性（这里假设输入的单个文本有六个词元）

符号：见图中标注；各块含义见题注。




图 15.6.2 文本对分类或回归应用的 BERT 微调，如自然语言推断和语义文本相似性（假设输入文本对分别有两个词元和三个词元）

符号：见图中标注；各块含义见题注。




图 15.6.3 文本标记应用的 BERT 微调，如词性标记。假设输入的单个文本有六个词元。
符号：见图中标注；各块含义见题注。




图 15.6.4 对问答进行 BERT 微调（假设输入文本对分别有两个和三个词元）
符号：见图中标注；各块含义见题注。

BERT 编码后只加浅层。序列级用 $\langle \text{cls} \rangle$ ；词元级用每个位置的向量。额外层从头学，编码器全部微调。

15.6.1 单文本分类

输入一条序列。 $\langle \text{cls} \rangle$ 向量经线性层得 K 类，如情感或语法可接受性。情感时 $K = 2$ ：正类 logit 经 softmax 后是正面概率。语法可接受性时正类概率是“句子合法”的机会。

15.6.2 文本对分类或回归

句对打包进一条 BERT 序列，片段嵌入区分两句。分类：NLI 三类，softmax 给出三种关系概率。回归：语义相似度分数，例如 $[0, 5]$ 上的实数，损失用平方误差。该实数与评分量表同量纲，不是概率；只有显式缩放到 $[0, 1]$ 后才能当概率读。

15.6.3 文本标注

每个词元的 BERT 向量送到共享（或位置共享）的分类头，如词性。位置 t 的 softmax 给出该词元各词性的概率。 $\langle \text{cls} \rangle$ 、 $\langle \text{sep} \rangle$ 通常不预测标签。

15.6.4 问答

段落与问题拼成句对。在段落词元上预测答案起点与终点的两个分类器，答案跨度为 $\arg \max_{s \leq e} P_{\text{start}}(s)P_{\text{end}}(e)$ 。 $P_{\text{start}}(s)$ 是“答案从位置 s 开始”的概率，对段落位置求和为 1； $P_{\text{end}}(e)$ 同理。乘积是“跨度为 $[s, e]$ ”的联合（在起点终点独立假设下）。 s, e 是词元下标，不是情感标签。

15.6.5 小结

序列级： $\hat{y} = h(\mathbf{h}_{\langle \text{cls} \rangle})$ ，softmax 后是整句标签概率。词元级： $\hat{y}_t = h(\mathbf{h}_t)$ ，每个位置一组类概率。问答再加起点终点两个头，输出的是位置上的概率，不是框的像素坐标。

15.6.6 练习

核验：检索中如何用负采样与 BERT 打分，以及 BERT 作编码器时 MLM 头如何改回标准 LM。检索打分经 sigmoid 可变成“该对相关”的概率；LM 头则是下一个词的词表分布。

15.7 自然语言推断：微调 BERT




图 15.7.1 将预训练 BERT 提供给基于多层感知机的自然语言推断架构

符号：见图中标注；各块含义见题注。

把 SNLI 当作文本对分类，在预训练 BERT 上加 MLP。

15.7.1 加载预训练的 BERT

小模型便于演示；base 与原 BERT 基础规模相当。加载词表与预训练参数。参数是编码器权重；此时尚未接 NLI 分类头。

15.7.2 微调 BERT 的数据集

前提与假设打包为 BERT 输入，片段下标区分两句。超长时轮流删较长一句的末词元直到不超过 `max_len`。`max_len` 是词元数上限；NSP 预训练里的“B 是否跟随 A”与这里的蕴涵标签不是同一件事。

15.7.3 微调 BERT

`<cls>` 表示经两层全连接得三类。编码器与嵌入参与微调；仅与预训练 MLM/NSP 头相关、且未接入该分类器的参数不更新。三类 logits 经 softmax 得到蕴涵、矛盾、中性的概率，和为 1。交叉熵使用真实关系对应的那一个概率。

15.7.4 小结

$$\hat{\mathbf{y}} = \text{MLP}(\mathbf{h}_{\langle \text{cls} \rangle}(A, B)) \in \mathbb{R}^3.$$

$\hat{\mathbf{y}}$ 在 softmax 前是 logits，之后才是三类关系概率。BERT 成为下游模型的子图，预训练任务头不再前向：不再输出掩词概率或“B 跟随 A”的 NSP 概率，改输出 NLI 关系概率。

15.7.5 练习

核验：按两句长度比截断与轮流删末词元哪种更少切断前提或假设的关键词。被删的是词元下标位置，不影响三类概率的数学含义，只影响模型看见哪些词。

附录 A 深度学习工具

附录把运行环境写成可重复的映射：笔记本、云实例、硬件选择与贡献流程。计算仍落在同一套张量运算上；差别在于谁提供 CPU/GPU 以及代码如何进入仓库。本节出现的秒、美元、瓦特、GB 是资源量，与模型里的概率、损失不是同一类数。

A.1 使用 Jupyter Notebook

笔记本是交错的叙述单元与代码单元。本地或远程内核执行单元，返回张量与打印。打印出的标量若来自模型，其含义仍由该张量在公式中的角色决定（预测、损失或梯度）。

A.1.1 在本地编辑和运行代码

工作目录指向本书代码后启动笔记本服务，浏览器连到本地端口。打开 `.ipynb` 即可按单元求值。端口号是整数网络端口，不是学习率。

A.1.2 高级选项

原生笔记本含大量运行期元数据，不利于版本合并。可用 Markdown 源编辑；远程机器则用端口转发。

A.1.2.1 Jupyter 中的 Markdown 文件

贡献应改 Markdown 源而非 `.ipynb`。插件把 `.md` 当作笔记本打开，使公式与代码单元可原地运行。公式里的符号含义与正文各章相同。

A.1.2.2 在远程服务器上运行 Jupyter Notebook

SSH 把远程内核端口映到本机同一或另一端口，浏览器仍访问 `localhost`。映射的是端口整数；远程算出的张量数值与本地内核相同。

A.1.2.3 执行时间

对每个代码单元记录墙钟时间，便于比较 $A^T B$ 与 AB 等运算。墙钟时间的单位是秒，表示“算出该矩阵乘花了多久”。 $A^T B$ 的条目仍是行点列得到的打分或内积，与耗时无关。

A.1.3 小结

本地或经端口转发远程编辑单元。源文件用 Markdown 时，版本记录的是文本而不是输出缓存。缓存里的数字若被清空，并不改变公式所定义的映射。

A.1.4 练习

核验：在 $\mathbb{R}^{1024 \times 1024}$ 上 $A^T B$ 与 AB 哪一个更快。1024 是矩阵边长；比较的是秒，不是哪个乘积在数值上更大。

A.2 使用 Amazon SageMaker

当本地算力不够时，用托管笔记本实例跑 GPU 密集型单元。

A.2.1 注册

创建云账户并打开 SageMaker 控制台。建议打开计费警报，避免实例忘记停止。警报阈值是金额（货币），不是训练损失。

A.2.2 创建 SageMaker 实例

选定实例类型即选定 (CPU 核数, GPU)。例如单卡 V100 加多核 CPU，足以覆盖本书大部分训练。核数与 GPU 个数是硬件计数；显存以 GB 计，限制能装下的批量与激活。

A.2.3 运行和停止实例

实例就绪后在浏览器打开笔记本。停止实例停止按计算计费；忘记停止会持续产生费用。计费按实例小时，单位是货币/小时，与 η 无关。

A.2.4 更新 Notebook

在实例终端向远程仓库取更新。若有本地改动，先提交或丢弃再拉取，以免合并冲突。Git 记录的是文本差异，不是张量。

A.2.5 小结

SageMaker 把“开 GPU 笔记本”变成创建-打开-停止。更新走实例上的 Git。实例上执行的前向、损失与第十一章同一套公式，只是设备换成云上的 GPU。

A.2.6 练习

核验：任选一节 GPU 代码在实例上能否跑通，以及终端是否指向笔记本目录。跑通指前向给出与公式一致的形状与有限数值（非 NaN）。

A.3 使用 Amazon EC2 实例

相对托管笔记本，自建虚拟机通常更便宜。步骤：申请 GPU 机、装 CUDA、装框架、端口转发。

A.3.1 创建和运行 EC2 实例

在 EC2 控制台启动实例。下面按位置、配额、映像与登录展开。

A.3.1.1 预置位置

选邻近区域以降低控制面延迟。需确认该区域提供所需 GPU 机型。延迟以毫秒计，是控制请求的往返时间，不是反向传播的 $\partial L / \partial \theta$ 。

A.3.1.2 增加限制

新账户对 GPU 机型常有配额 0。先申请提高限额，再启动。配额 0 表示当前一个 GPU 实例都不允许开，是账户限制整数，不是损失为零。

A.3.1.3 启动实例

选 Ubuntu 类映像与 GPU 机型。不同代号对应不同 GPU 个数与显存，按任务选。显存 GB 决定 $\mathbf{X}$ 与激活能有多大。

A.3.1.4 连接到实例

用密钥文件 SSH。密钥权限必须仅本人可读，否则握手失败。权限位是文件系统模式，不是模型权重。

A.3.2 安装 CUDA

先更新驱动，再按发行说明安装与框架匹配的 CUDA 工具包。安装包 URL 与文件名随版本变，以厂商当前仓库为准。CUDA 版本号是软件标识，需与 PyTorch 构建匹配，否则核函数无法运行。

A.3.3 安装库以运行代码

按本书安装章在远程 Linux 上建隔离环境并安装 PyTorch 与辅助包。无图形界面时，下载器用命令行取安装脚本，初始化后再加载 shell 配置。安装完成后，`torch.randn` 给出的张量与本地含义相同：独立正态噪声样本。

A.3.4 远程运行 Jupyter 笔记本

云主机无显示器。从本地 SSH 并转发端口，使浏览器连本机端口即连上远程内核。端口转发必须在本地命令行发起：本地端口映到远程笔记本端口。激活环境后启动笔记本，把给出的 URL 中的端口改成本地转发端口再打开。远程内核算出的 $\hat{y}$ 、损失、梯度，含义与在本地跑同一单元相同。

A.3.5 关闭未使用的实例

停止：盘仍在，可再开机，收少量存储费。终止：盘与数据删除，不可恢复。存储费按 GB-月计；需要模板时先做映像再终止。

A.3.6 小结

按需启动 GPU 机；框架前先装 CUDA；用本地发起的端口转发跑笔记本。云上每个训练步仍执行 $\theta \leftarrow \theta - \eta g$ ， ηg 仍是参数位移。

A.3.7 练习

核验：竞价实例相对按需的价格，以及多卡机上数据并行能扩到几张卡。价格比是无量纲比值；卡数 k 进入第十二章的 `allreduce`。

A.4 选择服务器和 GPU




图 A.4.1 浮点计算能力和价格比较

符号：见图中标注；各块含义见题注。




图 A.4.2 浮点计算能力和能耗

符号：见图中标注；各块含义见题注。

训练受 GPU 小时约束。单机可到数张卡；再多通常用云，因供电与散热。GPU 小时是“卡数 $\times$ 时间”，用来估计预算，不是准确率。

A.4.1 选择服务器

算力在 GPU 上，CPU 核数不必最多，但多线程频率在多卡加 Python 时仍重要。频率以 GHz 计，表示每秒时钟周期数。电源按每卡峰值（可到数百瓦）留余量；机箱与风道必须容下长卡。瓦特是功耗，不是学习率。PCIe 通道数限制满速 GPU 个数。

A.4.2 选择 GPU

加速库对其中一家的通用计算接口支持更成熟，故训练卡多选该路线。消费级与企业级算力接近，企业级多为被动散热、更大显存与 ECC，单价高一个数量级。实验室规模常用消费级；上百台则考虑企业级或云。新一代卡通常能效更好。低精度（如 FP16）提高吞吐，但训练需防止下溢。下溢把过小的梯度读成 0，于是该坐标本步位移 ηg_j 变成 0，参数不更新。

A.4.3 小结

电源、通道、多线程 CPU 与散热决定能插几张卡。大部署用云；核对机械尺寸与功耗是否匹配机箱。硬件选择改变的是每秒能完成多少次 ∇f ，不改变 f 与 ∇f 的数学含义。

A.5 为本书做贡献

改正笔误、链接与表述通过向源仓库提交拉取请求完成。持续集成会跑改动过的代码。CI 比较的是代码能否算出有限数值，以及是否与预期测试一致。

A.5.1 提交微小更改

在网页上打开对应 Markdown，改一句，写说明并开拉取请求。

A.5.2 大量文本或代码修改

源为 Markdown 加书籍扩展（公式、图、交叉引用）。改代码时用笔记本跑通，提交前清空输出，由 CI 重算。多框架章节用标记区分代码块所属框架。跑通意味着前向输出形状与公式一致，例如分类头给出 K 维 logits。

A.5.3 提交主要更改

标准 Git：派生、克隆、本地改、推送、开拉取请求。

A.5.3.1 安装 Git

在本机安装 Git 并注册托管账户。

A.5.3.2 登录 GitHub

在浏览器打开本书仓库，派生到自己的命名空间。

A.5.3.3 克隆存储库

用派生仓库的地址在本地做副本，再按安装章建环境。克隆地址中的用户名必须换成派生后的账户名，否则指向的不是可写副本。副本里的 `.tex/.md` 是文本源，不是训练好的 θ 。

A.5.3.4 编辑和推送

改文件后查看差异，提交到自己的分支并推送。差异是行级文本变化。

A.5.3.5 提交 Pull 请求

在派生仓库上对新改动开拉取请求，写清改了什么。可能被直接合并、要求修改或拒绝。请求应小，便于审阅。

A.5.4 小结

小改动可网页编辑；大改动走派生-本地-拉取请求。避免巨型请求。贡献改的是叙述与代码，不在本附录里引入新的章标题。

A.5.5 练习

核验：完成一次派生，并尝试用新分支提交最小改动。

A.6 d2l API 文档

辅助包把模型、数据、训练循环与公用函数收成可复用映射。实现见源文件。

A.6.1 模型

网络模块： f_θ 的层、块与常见骨干，前向为张量到张量。输出张量的每个条目含义由具体模型决定：回归是点预测，分类是 logits 或概率。

A.6.2 数据

数据集与加载器： $(\mathcal{D}) \mapsto$ 小批量迭代器，含词表、增广与填充。迭代器给出的 $\mathbf{X}$ 是特征或词元下标， $\mathbf{y}$ 是标签（实数、类编号或框坐标，视任务而定）。

A.6.3 训练

训练循环：给定 f_θ 、迭代器与优化器，执行前向、损失、反传与评估。优化器内部仍计算 $\mathbf{g} = \nabla_{\theta} L$ ，再减去 $\eta \mathbf{g}$ （或 Adam 的 $\mathbf{g}'$ ）：每个坐标是该权重本步移动的量； η 是步长，不是概率。

A.6.4 公用

作图、计时、设备选择与累加器等与任务无关的工具函数。计时返回秒；累加器把损失或正确个数加总，再除以样本数得到平均损失或精度。精度在 $[0, 1]$ ，表示预测正确的比例。