

《动手学深度学习》

PyTorch 版学习笔记

内容提炼试作

2026 年 9 月 1 日

试作说明

本 PDF 用于检验笔记的内容密度、排版和编译流程，仅提炼原书第二章“预备知识”。章内全部标题的名称、层级与顺序严格沿用 PyTorch 版原始目录。印刷目录与侧栏书签只列出章和七个主要部分，正文仍保留全部原书标题。正文以公式陈述定义、成立条件、关键推导与结论；衔接句只连接相邻公式，代码仅作最小验证。

目录

试作说明	i
第二章 预备知识	1
2.1 数据操作	1
2.2 数据预处理	3
2.3 线性代数	4
2.4 微积分	7
2.5 自动微分	9
2.6 概率	12
2.7 查阅文档	14

第二章 预备知识

本章把后续计算写成同一套对象与映射：数据是张量，前向是线性映射，训练目标是可微标量，自动微分在计算图上实现链式法则，概率把预测写成分布。正文保留原书标题，内容以公式为主。

2.1 数据操作

记 n 阶张量为 $\mathbf{X} \in \mathbb{R}^{d_1 \times \cdots \times d_n}$ 。 $n = 0, 1, 2$ 分别对应标量、向量、矩阵；更高阶用于批量、通道或时间轴。下面先固定形状，再写运算。

2.1.1 入门

形状与元素总数为

$$\text{shape}(\mathbf{X}) = (d_1, \dots, d_n), \quad \text{numel}(\mathbf{X}) = \prod_{i=1}^n d_i.$$

`reshape` 只改变轴的划分，不改变元素值与存储次序。若

$$\prod_{i=1}^n d_i = \prod_{j=1}^m d'_j,$$

则存在把 $\mathbb{R}^{d_1 \times \cdots \times d_n}$ 重新解释为 $\mathbb{R}^{d'_1 \times \cdots \times d'_m}$ 的双射。某个 $d'_k = -1$ 时，由上式唯一确定该轴长度。

```
x = torch.arange(12).reshape(3, 4)
x.shape, x.numel()
```

2.1.2 运算符

形状相同后，二元运算默认逐元素进行。若 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$,

$$(f(\mathbf{u}, \mathbf{v}))_i = f(u_i, v_i), \quad i = 1, \dots, d,$$

其中 f 可取 $+$, $-$, $\odot$, $/$, 或幂。沿轴 k 连接要求除第 k 轴外形状一致:

$$\text{cat}(\mathbf{A}, \mathbf{B}; k) \in \mathbb{R}^{d_1 \times \dots \times (d_k^{(A)} + d_k^{(B)}) \times \dots \times d_n}.$$

比较返回 $\{0, 1\}$ 值张量; 求和是

$$\sum(\mathbf{X}) = \sum_{i_1=1}^{d_1} \cdots \sum_{i_n=1}^{d_n} X_{i_1 \dots i_n}.$$

2.1.3 广播机制

形状不同时, 从末轴向前对齐。第 i 轴可运算当且仅当

$$d_i^{(X)} = d_i^{(Y)} \quad \text{或} \quad d_i^{(X)} = 1 \quad \text{或} \quad d_i^{(Y)} = 1.$$

长度为 1 的轴在逻辑上复制到目标长度。于是

$$\mathbb{R}^{3 \times 1} + \mathbb{R}^{1 \times 2} \longrightarrow \mathbb{R}^{3 \times 2}, \quad (A + B)_{ij} = A_{i1} + B_{1j}.$$

2.1.4 索引和切片

对 $\mathbf{X} \in \mathbb{R}^{m \times n}$, 下标从 0 起算。切片 $[a : b]$ 取 $\{a, a + 1, \dots, b - 1\}$, 即半开区间 $[a, b)$, 且 -1 表示最后一个合法下标。多轴独立作用:

$$\mathbf{X}[i, j] = X_{ij}, \quad \mathbf{X}[a : b, :] \in \mathbb{R}^{(b-a) \times n}.$$

2.1.5 节省内存

记 $\text{id}(\cdot)$ 为对象标识。赋值

$$\mathbf{Y} \leftarrow \mathbf{Y} + \mathbf{X}$$

通常分配新存储后再改引用; 切片写回

$$\mathbf{Y}[:,] \leftarrow \mathbf{Y} + \mathbf{X}$$

保持 $\text{id}(\mathbf{Y})$ 不变。参数规模大或同一映射反复求值时, 减少分配等价于减少临时张量个数。

2.1.6 转换为其他 Python 对象

PyTorch 张量与 NumPy 数组可共享同一块内存, 因此对一侧的原地更新会改变另一侧。标量提取是映射

$$\mathbb{R}^1 \longrightarrow \mathbb{R}, \quad \mathbf{x} \mapsto x = \text{item}(\mathbf{x}).$$

2.1.7 小结

数据操作把 $\mathbf{X}$ 的结构写成 $\text{shape}(\mathbf{X})$ ，把组合写成逐元素映射与广播，把局部访问写成索引，把存储控制写成是否保持 $\text{id}(\mathbf{Y})$ 。

2.1.8 练习

原书练习对应三条约束：由 $\text{numel}(\mathbf{X})$ 反推合法 $(d_1, \dots, d_n)$ 、由广播规则写出结果形状、以及判断共享内存是否蕴含 id 相同。

2.2 数据预处理

原始表通常含缺失与非数值字段，不能直接作为上一节中的 $\mathbf{X}$ 。预处理的目标是构造数值张量 $(\mathbf{X}, \mathbf{y})$ 。

2.2.1 读取数据集

设表有 n 行、 p 列。一行是一个样本，一列是一个属性。划分后

$$\mathbf{x}^{(i)} \in \mathbb{R}^{p-1}, \quad y^{(i)} \in \mathbb{R}, \quad i = 1, \dots, n,$$

缺失在 pandas 中记为 NaN。

2.2.2 处理缺失值

对数值列 j ，令观测指标集 $\mathcal{I}_j = \{i : x_{ij} \text{ 非缺失}\}$ 。样本均值

$$\bar{x}_j = \frac{1}{|\mathcal{I}_j|} \sum_{i \in \mathcal{I}_j} x_{ij}$$

用于填充： $i \notin \mathcal{I}_j$ 时令 $x_{ij} \leftarrow \bar{x}_j$ 。类别列取值于有限集 $\mathcal{C}$ 时，独热映射为

$$c \mapsto \mathbf{e}_c \in \{0, 1\}^{|\mathcal{C}|}, \quad (\mathbf{e}_c)_{c'} = [c = c'].$$

缺失可并入一个额外类别，使编码落在 $\mathbb{R}^{|\mathcal{C}|+1}$ 。

2.2.3 转换为张量格式

全部字段数值化且类型一致后，

$$(\mathbf{x}^{(i)}, y^{(i)})_{i=1}^n \longrightarrow \mathbf{X} \in \mathbb{R}^{n \times d}, \mathbf{y} \in \mathbb{R}^n.$$

实现路径为 $\text{DataFrame} \rightarrow \text{ndarray} \rightarrow \text{Tensor}$ 。

2.2.4 小结

预处理不改变学习目标 y ，只把不完整字段映成模型可计算的 $(\mathbf{X}, y)$ 。

2.2.5 练习

删除缺失最多的列对应投影 $\mathbb{R}^d \rightarrow \mathbb{R}^{d-1}$ ；均值填充则保持维度 d 。二者是不同的缺失处理映射。

2.3 线性代数

张量给出对象；线性代数给出映射。从标量升到矩阵，再由点积与乘法得到层间变换，最后用范数把误差压成标量。

2.3.1 标量

标量 $x \in \mathbb{R}$ 满足域运算

$$x + y, \quad xy, \quad x/y \ (y \neq 0), \quad x^p.$$

2.3.2 向量

n 个标量排成列向量

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n.$$

2.3.2.1 长度、维度和形状

$\mathbf{x} \in \mathbb{R}^n$ 表示分量数（向量维度）为 n ，对应一维张量形状 $(n,)$ 。张量的“维数”还可指轴数 k ，即 $\mathbf{X} \in \mathbb{R}^{d_1 \times \cdots \times d_k}$ 的阶。

2.3.3 矩阵

m 个 $\mathbb{R}^n$ 中的行排成

$$\mathbf{A} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \in \mathbb{R}^{m \times n}.$$

转置定义为 $(\mathbf{A}^\top)_{ij} = a_{ji}$, 因而

$$\mathbf{A}^\top \in \mathbb{R}^{n \times m}.$$

若 $\mathbf{A} = \mathbf{A}^\top$, 则 $\mathbf{A}$ 为对称矩阵, 此时必有 $m = n$ 。

2.3.4 张量

向量、矩阵分别是 1 阶、2 阶张量。图像可写为 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$; 加入批量后为 $\mathbb{R}^{B \times H \times W \times C}$ 。

2.3.5 张量算法的基本性质

同形状逐元素运算保持形状。Hadamard 积

$$(\mathbf{A} \odot \mathbf{B})_{ij} = a_{ij}b_{ij}, \quad \mathbf{A}, \mathbf{B} \in \mathbb{R}^{m \times n}$$

不同于下面的矩阵乘法。标量广播为

$$(\alpha + \mathbf{A})_{ij} = \alpha + a_{ij}, \quad \alpha \in \mathbb{R}.$$

2.3.6 降维

对 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 全求和得到标量

$$\sum_{i=1}^m \sum_{j=1}^n a_{ij}.$$

沿轴归约则降低阶:

$$\left(\sum_{i=1}^m \mathbf{A} \right)_j = \sum_{i=1}^m a_{ij} \in \mathbb{R}^n, \quad \left(\sum_{j=1}^n \mathbf{A} \right)_i = \sum_{j=1}^n a_{ij} \in \mathbb{R}^m.$$

均值为总和除以元素个数:

$$\bar{A} = \frac{1}{mn} \sum_{i=1}^m \sum_{j=1}^n a_{ij}.$$

2.3.6.1 非降维求和

`keepdim=True` 把被求和轴保留为长度 1，从而可广播。行归一化

$$\tilde{a}_{ij} = \frac{a_{ij}}{\sum_{k=1}^n a_{ik}} \quad \left(\sum_k a_{ik} \neq 0 \right)$$

满足 $\sum_j \tilde{a}_{ij} = 1$ 。沿行的累积和保持长度：

$$s_{ij} = \sum_{k=1}^j a_{ik}.$$

2.3.7 点积 (Dot Product)

等长向量的点积是加权求和

$$\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^d x_i y_i = \sum_{i=1}^d (\mathbf{x} \odot \mathbf{y})_i.$$

若 $\|\mathbf{x}\|_2 = \|\mathbf{y}\|_2 = 1$ ，则 $\mathbf{x}^\top \mathbf{y} = \cos \theta$ 。

2.3.8 矩阵-向量积

把 $\mathbf{A}$ 的每一行与 $\mathbf{x}$ 做点积：对 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 、 $\mathbf{x} \in \mathbb{R}^n$ ，

$$\mathbf{Ax} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{a}_m^\top \mathbf{x} \end{bmatrix} \in \mathbb{R}^m.$$

该映射 $f(\mathbf{x}) = \mathbf{Ax}$ 满足

$$f(\alpha \mathbf{x} + \beta \mathbf{z}) = \alpha f(\mathbf{x}) + \beta f(\mathbf{z}),$$

即 $\mathbb{R}^n \rightarrow \mathbb{R}^m$ 的线性变换。

2.3.9 矩阵-矩阵乘法

中间维相等时，矩阵乘法是多个矩阵-向量积并列。若 $\mathbf{A} \in \mathbb{R}^{n \times k}$ 、 $\mathbf{B} \in \mathbb{R}^{k \times m}$ ，则 $\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{n \times m}$ 且

$$c_{ij} = \mathbf{a}_i^\top \mathbf{b}_j = \sum_{\ell=1}^k a_{i\ell} b_{\ell j}.$$

2.3.10 范数

范数 $f: \mathbb{R}^n \rightarrow \mathbb{R}_{\geq 0}$ 满足

$$\begin{aligned} f(\alpha \mathbf{x}) &= |\alpha| f(\mathbf{x}), \\ f(\mathbf{x} + \mathbf{y}) &\leq f(\mathbf{x}) + f(\mathbf{y}), \\ f(\mathbf{x}) &\geq 0, \\ f(\mathbf{x}) = 0 &\iff \mathbf{x} = \mathbf{0}. \end{aligned}$$

L_p 范数为

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, \quad \|\mathbf{x}\|_1 = \sum_i |x_i|, \quad \|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}.$$

矩阵的 Frobenius 范数是把矩阵当作向量后的 L_2 :

$$\|\mathbf{X}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n x_{ij}^2}.$$

2.3.10.1 范数和目标

“预测接近真值”写成距离最小化。平方误差使用 L_2 范数平方:

$$\min_{\boldsymbol{\theta}} \|\mathbf{y} - f_{\boldsymbol{\theta}}(\mathbf{X})\|_2^2.$$

2.3.11 关于线性代数的更多信息

后续章节主要用到 $\mathbf{Ax}$ 、 $\mathbf{AB}$ 与 $\|\cdot\|_p$ 。矩阵分解、低秩与张量分解不在本章推导。

2.3.12 小结

线性代数把数据写成张量，把层写成 $\mathbf{Ax}$ 或 $\mathbf{AB}$ ，把误差写成 $\|\cdot\|$ 。

2.3.13 练习

需要同时核验恒等式与形状，例如 $(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$ 蕴含 $\mathbb{R}^{n \times m}$ 与 $\mathbb{R}^{m \times n}$ 的对应。

2.4 微积分

前向已写成映射 f ；训练要知道参数扰动如何改变标量目标。优化关心 $\min_{\boldsymbol{\theta}} L(\boldsymbol{\theta})$ ，泛化关心所得 $\boldsymbol{\theta}$ 在未见样本上的 L 。训练主要用微分。

2.4.1 导数和微分

若极限存在,

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}.$$

一阶展开为

$$f(x + \Delta x) = f(x) + f'(x)\Delta x + o(\Delta x).$$

等价记号

$$f'(x) = y' = \frac{dy}{dx} = D_x f(x).$$

对 $f(x) = 3x^2 - 4x$,

$$f'(x) = 6x - 4, \quad f'(1) = 2,$$

故 $x = 1$ 附近 $\Delta f \approx 2\Delta x$ 。常用法则:

$$\begin{aligned} (Cf)' &= Cf', \\ (f+g)' &= f' + g', \\ (fg)' &= f'g + fg', \\ \left(\frac{f}{g}\right)' &= \frac{f'g - fg'}{g^2} \quad (g \neq 0). \end{aligned}$$

2.4.2 偏导数

多元函数 $y = f(x_1, \dots, x_n)$ 沿第 i 个坐标的变化率把其余变量视为常数:

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_i + h, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}.$$

等价记号:

$$\frac{\partial y}{\partial x_i} = \frac{\partial f}{\partial x_i} = f_{x_i} = D_{x_i} f.$$

2.4.3 梯度

把全部偏导排成列向量。若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \partial f / \partial x_1 \\ \vdots \\ \partial f / \partial x_n \end{bmatrix}.$$

一阶展开为

$$f(\mathbf{x} + \Delta \mathbf{x}) = f(\mathbf{x}) + \nabla_{\mathbf{x}} f(\mathbf{x})^\top \Delta \mathbf{x} + o(\|\Delta \mathbf{x}\|).$$

原书常用结果：

$$\begin{aligned}\nabla_{\mathbf{x}}(\mathbf{A}\mathbf{x}) &= \mathbf{A}^\top, \\ \nabla_{\mathbf{x}}(\mathbf{x}^\top \mathbf{A}) &= \mathbf{A}, \\ \nabla_{\mathbf{x}}(\mathbf{x}^\top \mathbf{A}\mathbf{x}) &= (\mathbf{A} + \mathbf{A}^\top)\mathbf{x}, \\ \nabla_{\mathbf{x}}\|\mathbf{x}\|_2^2 &= 2\mathbf{x}, \\ \nabla_{\mathbf{X}}\|\mathbf{X}\|_F^2 &= 2\mathbf{X}.\end{aligned}$$

2.4.4 链式法则

复合 $y = f(u)$ 、 $u = g(x)$ 时

$$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}.$$

若 y 依赖 $u_1, \dots, u_m$ ，而每个 u_j 依赖 x_i ，则路径求和：

$$\frac{\partial y}{\partial x_i} = \sum_{j=1}^m \frac{\partial y}{\partial u_j} \frac{\partial u_j}{\partial x_i}.$$

神经网络是复合 $L = f_L \circ \dots \circ f_1$ ，反向传播即沿计算图反向重复该式。

2.4.5 小结

单变量用 $f'(x)$ ，多变量用 $\partial y / \partial x_i$ ，全部偏导组成 $\nabla_{\mathbf{x}} f$ ，复合函数用链式法则把各层 Jacobian 连乘（或按路径求和）。

2.4.6 练习

几何上 $f'(x)$ 是切线斜率；代数上对给定 f 求 f' ，二者应一致。

2.5 自动微分

链式法则给出规则；自动微分对实际执行的程序求数值导数。前向记录计算图 $\mathcal{G}$ ，反向对每个节点应用

$$\frac{\partial L}{\partial u} = \sum_{v: u \rightarrow v} \frac{\partial L}{\partial v} \frac{\partial v}{\partial u}.$$

2.5.1 一个简单的例子

令

$$y = 2\mathbf{x}^\top \mathbf{x} = 2 \sum_i x_i^2.$$

则

$$\frac{\partial y}{\partial x_i} = 4x_i, \quad \nabla_{\mathbf{x}} y = 4\mathbf{x}.$$

```
x = torch.arange(4.0, requires_grad=True)
y = 2 * torch.dot(x, x)
y.backward()
x.grad
```

默认累积：若连续两次反向且不清零，则

$$\nabla_{\mathbf{x}} \leftarrow \nabla_{\mathbf{x}} + 4\mathbf{x}.$$

2.5.2 非标量变量的反向传播

$\mathbf{y} \in \mathbb{R}^m$ 、 $\mathbf{x} \in \mathbb{R}^n$ 时，完整导数是 Jacobian

$$J = \frac{\partial \mathbf{y}}{\partial \mathbf{x}} \in \mathbb{R}^{m \times n}, \quad J_{ij} = \frac{\partial y_i}{\partial x_j}.$$

训练通常计算向量-Jacobian 积 $\mathbf{v}^\top J$ ，而不是显式形成 J 。若 $\mathbf{y} = \mathbf{x} \odot \mathbf{x}$ 且取 $\mathbf{v} = \mathbf{1}$,

$$\nabla_{\mathbf{x}}(\mathbf{1}^\top \mathbf{y}) = \nabla_{\mathbf{x}} \sum_i x_i^2 = 2\mathbf{x}.$$

故 `y.sum().backward()` 与用 $\mathbf{v} = \mathbf{1}$ 调用反向传播等价。

2.5.3 分离计算

设 $\mathbf{y} = \mathbf{x} \odot \mathbf{x}$ ，令 $\mathbf{u} = \text{detach}(\mathbf{y})$ ，即数值相同但切断边 $\mathbf{x} \rightarrow \mathbf{y}$ 。对

$$z = \mathbf{u}^\top \mathbf{x}$$

把 $\mathbf{u}$ 视为常向量，得

$$\nabla_{\mathbf{x}} z = \mathbf{u} = \mathbf{x} \odot \mathbf{x},$$

而完整复合 $z = (\mathbf{x} \odot \mathbf{x})^\top \mathbf{x} = \sum_i x_i^3$ 的梯度本应为 $3\mathbf{x} \odot \mathbf{x}$ 。

2.5.4 Python 控制流的梯度计算

动态图只沿本次前向实际执行的可微路径求导。若该路径上

$$f(a) = ka \quad (k \text{ 依赖本次分支, 但对 } a \text{ 局部为常数}),$$

则

$$\frac{df}{da} = k = \frac{f(a)}{a}, \quad a \neq 0.$$

2.5.5 小结

流程是：对 $\mathbf{x}$ 启用追踪，计算标量 L ，执行

$$L.backward() \implies \mathbf{x}.grad = \nabla_{\mathbf{x}} L.$$

2.5.6 练习

原书练习对应二阶导数、重复反向、非标量输入与控制流。

2.5.7 练习解答

2.5.7.1 1. 为什么二阶导数的开销更大？

一阶梯度 $\nabla L \in \mathbb{R}^n$ 。海森

$$H_{ij} = \frac{\partial^2 L}{\partial x_i \partial x_j}$$

最多含 n^2 个元素，且需在一阶图上再反传一次，故时间与内存都更大。

2.5.7.2 2. 连续运行两次反向传播

默认第一次反传后释放 $\mathcal{G}$ 。保留图后可再求 ∇L ，但梯度累积：

$$\mathbf{g} \leftarrow \mathbf{g} + \nabla_{\mathbf{x}} L.$$

2.5.7.3 3. 将控制流例子中的输入改成向量或矩阵

若输出 $\mathbf{f}(\mathbf{a})$ 非标量，反向目标改为

$$\nabla_{\mathbf{a}}(\mathbf{1}^\top \mathbf{f}(\mathbf{a})) = J^\top \mathbf{1}.$$

对路径 $\mathbf{f}(\mathbf{a}) = k\mathbf{a}$ ，有 $J = kI$ ，因而每个分量的梯度均为 k 。

2.5.7.4 4. 重新设计控制流梯度例子

分段

$$g(x) = \begin{cases} x^2, & x > 0, \\ -x^3, & x \leq 0, \end{cases} \quad g'(x) = \begin{cases} 2x, & x > 0, \\ -3x^2, & x < 0. \end{cases}$$

自动微分对选中分支求导，不对 $[x > 0]$ 这一离散选择求导。

2.6 概率

点估计给出 $\hat{y}$ ；概率把不确定性写成 $P(\cdot \mid \text{观测})$ 。

2.6.1 基本概率论

独立重复抽样下，事件 $\mathcal{A}$ 的经验频率

$$\hat{P}_N(\mathcal{A}) = \frac{1}{N} \sum_{i=1}^N \mathbf{1}\{X_i \in \mathcal{A}\}$$

满足 $\hat{P}_N(\mathcal{A}) \rightarrow P(\mathcal{A})$ （大数定律）。

2.6.1.1 概率论公理

样本空间为 $\mathcal{S}$ ，事件为 $\mathcal{A} \subseteq \mathcal{S}$ 。公理：

$$\begin{aligned} P(\mathcal{A}) &\geq 0, \\ P(\mathcal{S}) &= 1, \\ P\left(\bigcup_{i=1}^{\infty} \mathcal{A}_i\right) &= \sum_{i=1}^{\infty} P(\mathcal{A}_i) \quad (\mathcal{A}_i \text{ 两两不交}). \end{aligned}$$

取 $\mathcal{A}_i = \emptyset$ 得 $P(\emptyset) = 0$ ；互补事件满足 $P(\mathcal{A}^c) = 1 - P(\mathcal{A})$ 。

2.6.1.2 随机变量

随机变量是 $X: \mathcal{S} \rightarrow \mathbb{R}$ 。离散时直接用 $P(X = x)$ ；连续时用密度 p ，

$$P(a \leq X \leq b) = \int_a^b p(x) \mathrm{d}x,$$

因而单点可以有 $P(X = x) = 0$ 。

2.6.2 处理多个随机变量

成对变量由联合分布 $P(A, B)$ 描述。条件化限制到 $\{A = a\}$ ，边际化消去 A 。

2.6.2.1 联合概率

$$P(A = a, B = b) = P(\{A = a\} \cap \{B = b\}) \leq P(A = a).$$

2.6.2.2 条件概率

当 $P(A = a) > 0$,

$$P(B = b | A = a) = \frac{P(A = a, B = b)}{P(A = a)}.$$

乘法法则即 $P(A, B) = P(B | A)P(A)$ 。

2.6.2.3 贝叶斯定理

由 $P(B | A)P(A) = P(A | B)P(B)$ 交换条件方向:

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}, \quad P(B) > 0.$$

其中 $P(A)$ 为先验, $P(B | A)$ 为似然, $P(A | B)$ 为后验。

2.6.2.4 边际化

分母由全概率公式得到。A 离散时

$$P(B) = \sum_A P(A, B) = \sum_A P(B | A)P(A);$$

连续时把求和换成 $\int p(a, b) da$ 。

2.6.2.5 独立性

$$A \perp B \iff P(A, B) = P(A)P(B) \iff P(A | B) = P(A) \quad (P(B) > 0).$$

条件独立:

$$A \perp B | C \iff P(A, B | C) = P(A | C)P(B | C).$$

2.6.2.6 应用

令 $H \in \{0, 1\}$ 表示感染, $D_1 \in \{0, 1\}$ 表示检测阳性。已知

$$P(H = 1) = 0.0015, \quad P(D_1 = 1 | H = 0) = 0.01, \quad P(D_1 = 1 | H = 1) = 1.$$

边际

$$P(D_1 = 1) = 0.01(1 - 0.0015) + 1 \cdot 0.0015 = 0.011485,$$

后验

$$P(H = 1 | D_1 = 1) = \frac{1 \cdot 0.0015}{0.011485} \approx 0.1306.$$

因此高灵敏度并不蕴含高后验: 先验 $P(H = 1)$ 过小时, 一次阳性仍不足。

2.6.3 期望和方差

离散期望

$$\mathbb{E}[X] = \sum_x xP(X=x), \quad \mathbb{E}_{x \sim P}[f(x)] = \sum_x f(x)P(x).$$

方差

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2,$$

标准差 $\sqrt{\text{Var}(X)}$ 与 X 同量纲。函数值的离散程度为

$$\text{Var}[f(x)] = \mathbb{E}[(f(x) - \mathbb{E}[f(x)])^2].$$

2.6.4 小结

公理给出 P ，联合/条件/边际给出多变量关系，贝叶斯给出 $P(A | B) \propto P(B | A)P(A)$ ，期望与方差概括位置与分散。

2.6.5 练习

对应 $\hat{P}_N$ 、条件化、贝叶斯更新、 $A \perp B$ 以及 $\mathbb{E}, \text{Var}$ 。

2.7 查阅文档

接口随版本变化，核验对象本身，而不是记忆映射表。

2.7.1 查找模块中的所有函数和类

`dir(module)` 列出属性。名称 `__.` 属语言机制，`.` 通常为内部实现。

2.7.2 查找特定函数和类的用法

`help(object)` 给出文档字符串。Jupyter 中 `?` 查看帮助，`??` 在可用时给出源码。最终以当前安装版本的官方签名为准。

2.7.3 小结

先 `dir` 得到候选集合，再 `help` 读取参数与返回值。

2.7.4 练习

对选定张量函数核对其数学定义与实现签名是否一致。