

《动手学深度学习》

PyTorch 版学习笔记

内容提炼试作

2026 年 9 月 1 日

试作说明

本 PDF 用于检验笔记的内容密度、排版和编译流程，仅提炼原书第二章“预备知识”。章内全部标题的名称、层级与顺序严格沿用 PyTorch 版原始目录。正文保留定义、成立条件、关键数学推导与结论，仅用极少量代码验证原理。

目录

试作说明	i
第二章 预备知识	1
2.1 数据操作	1
2.1.1 入门	1
2.1.2 运算符	1
2.1.3 广播机制	2
2.1.4 索引和切片	2
2.1.5 节省内存	2
2.1.6 转换为其他 Python 对象	2
2.1.7 小结	2
2.1.8 练习	2
2.2 数据预处理	2
2.2.1 读取数据集	3
2.2.2 处理缺失值	3
2.2.3 转换为张量格式	3
2.2.4 小结	3
2.2.5 练习	3
2.3 线性代数	3
2.3.1 标量	3
2.3.2 向量	4
2.3.2.1 长度、维度和形状	4
2.3.3 矩阵	4
2.3.4 张量	4

2.3.5	张量算法的基本性质	4
2.3.6	降维	5
2.3.6.1	非降维求和	5
2.3.7	点积 (Dot Product)	5
2.3.8	矩阵-向量积	5
2.3.9	矩阵-矩阵乘法	5
2.3.10	范数	6
2.3.10.1	范数和目标	6
2.3.11	关于线性代数的更多信息	6
2.3.12	小结	6
2.3.13	练习	6
2.4	微积分	7
2.4.1	导数和微分	7
2.4.2	偏导数	7
2.4.3	梯度	7
2.4.4	链式法则	8
2.4.5	小结	8
2.4.6	练习	8
2.5	自动微分	8
2.5.1	一个简单的例子	8
2.5.2	非标量变量的反向传播	9
2.5.3	分离计算	9
2.5.4	Python 控制流的梯度计算	9
2.5.5	小结	9
2.5.6	练习	10
2.5.7	练习解答	10
2.5.7.1	1. 为什么二阶导数的开销更大?	10
2.5.7.2	2. 连续运行两次反向传播	10
2.5.7.3	3. 将控制流例子中的输入改成向量或矩阵	10
2.5.7.4	4. 重新设计控制流梯度例子	10
2.6	概率	10

2.6.1	基本概率论	10
2.6.1.1	概率论公理	11
2.6.1.2	随机变量	11
2.6.2	处理多个随机变量	11
2.6.2.1	联合概率	11
2.6.2.2	条件概率	11
2.6.2.3	贝叶斯定理	11
2.6.2.4	边际化	12
2.6.2.5	独立性	12
2.6.2.6	应用	12
2.6.3	期望和方差	12
2.6.4	小结	13
2.6.5	练习	13
2.7	查阅文档	13
2.7.1	查找模块中的所有函数和类	13
2.7.2	查找特定函数和类的用法	13
2.7.3	小结	13
2.7.4	练习	14

第二章 预备知识

本章给出后续深度学习所需的共同语言：张量负责承载数据，线性代数负责表达模型，微积分和自动微分负责训练参数，概率负责描述不确定性。正文严格保留原书标题层级，只提取定义、成立条件、关键推导和结论。

2.1 数据操作

张量是深度学习中统一的数据容器。零轴、一轴、二轴张量分别对应标量、向量和矩阵；更高阶张量可表示批量图像、视频或其他多轴数据。

2.1.1 入门

张量的形状为各轴长度组成的元组，元素总数为各轴长度之积：

$$\text{numel}(\mathbf{X}) = \prod_{i=1}^n d_i, \quad \text{shape}(\mathbf{X}) = (d_1, \dots, d_n).$$

`reshape` 只改变张量的形状解释，不改变元素次序和总数。若其中一个轴写作 -1 ，该轴长度由元素总数和其余轴自动确定。

```
x = torch.arange(12).reshape(3, 4)
x.shape, x.numel()
```

2.1.2 运算符

同形状张量上的加、减、乘、除和幂默认逐元素执行。若 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d$ ，逐元素二元运算写为

$$\mathbf{c}_i = f(u_i, v_i), \quad i = 1, \dots, d.$$

张量连接 `cat` 沿指定轴拼接数据；比较运算返回布尔张量；`sum` 把指定范围内的元素相加。

2.1.3 广播机制

广播使形状不同但相容的张量能够逐元素运算。其规则可概括为：从末轴向前比较，对应轴长度必须相等，或其中一个为 1。长度为 1 的轴在逻辑上复制到目标长度。例如

$$\mathbb{R}^{3 \times 1} + \mathbb{R}^{1 \times 2} \longrightarrow \mathbb{R}^{3 \times 2}.$$

2.1.4 索引和切片

索引从 0 开始，-1 表示最后一个位置；切片 $[a:b]$ 包含 a 而不包含 b 。多轴张量在各轴分别给出索引或切片，冒号表示保留该轴全部元素。

2.1.5 节省内存

赋值 $\mathbf{Y} = \mathbf{Y} + \mathbf{X}$ 通常先创建新结果再改变变量引用；切片写回或原地运算尽量复用内存：

$\text{id}(\mathbf{Y})$ 在 $\mathbf{Y}[:] = \mathbf{Y} + \mathbf{X}$ 前后保持不变。

参数规模很大或同一计算反复执行时，避免无必要分配可减少内存压力。

2.1.6 转换为其他 Python 对象

PyTorch 张量与 NumPy 数组可共享底层内存，因此原地修改可能同时反映在两侧。单元素张量可用 `item()` 转为 Python 标量；NumPy 数组可再转换回张量。

2.1.7 小结

数据操作的核心是：用形状描述张量结构，用逐元素运算和广播组合数据，用索引定位数据，并在必要时通过原地操作控制内存分配。

2.1.8 练习

原书练习集中检验三个能力：由元素数推断合法形状、说明广播后的结果形状、以及判断张量与 NumPy 对象是否共享内存。

2.2 数据预处理

原始数据往往含有缺失项和非数值字段，不能直接送入模型。预处理的目标是把表格转换为形状明确、数值类型一致的张量。

2.2.1 读取数据集

CSV 表中通常一行对应一个样本，一列对应一个属性。读取后先划分输入属性与预测目标，再分别处理。缺失值在 pandas 中通常表示为 NaN。

2.2.2 处理缺失值

数值属性可用该列均值替代缺失值。若第 j 列观测集合为 $\mathcal{I}_j$ ，均值为

$$\bar{x}_j = \frac{1}{|\mathcal{I}_j|} \sum_{i \in \mathcal{I}_j} x_{ij},$$

则缺失位置可暂以 $\bar{x}_j$ 填充。类别属性不能取算术均值，通常改为独热表示，并可把缺失本身编码为一个类别。

2.2.3 转换为张量格式

所有字段数值化且数据类型统一后，表格才可转换为张量：

$$\text{DataFrame} \longrightarrow \text{NumPy array} \longrightarrow \text{PyTorch Tensor}.$$

2.2.4 小结

预处理不是改变学习目标，而是把不完整、异质的原始字段变成模型能够计算的数值表示。

2.2.5 练习

原书练习要求统计缺失最多的列并尝试删除它，用于理解“填充”与“删除”是两类不同策略。

2.3 线性代数

2.3.1 标量

标量是单个实数，记为 $x \in \mathbb{R}$ 。标量之间可进行通常的四则运算。

2.3.2 向量

向量是标量组成的有序列表，本书按列向量书写：

$$\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n.$$

2.3.2.1 长度、维度和形状

$\boldsymbol{x} \in \mathbb{R}^n$ 表示向量含 n 个分量。一维张量的形状为 $(n,)$ 。这里向量的“维度”指分量数；张量语境中的“维度”还可能指轴数。

2.3.3 矩阵

矩阵 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ 含 m 行、 n 列：

$$\boldsymbol{A} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}.$$

转置交换行列，满足 $(\boldsymbol{A}^\top)_{ij} = a_{ji}$ 。若 $\boldsymbol{A} = \boldsymbol{A}^\top$ ，则 $\boldsymbol{A}$ 为对称矩阵。

2.3.4 张量

向量和矩阵分别是一阶、二阶张量。图像常表示为高度、宽度和通道三个轴；增加批量或时间轴后即可形成更高阶张量。

2.3.5 张量算法的基本性质

同形状张量逐元素运算后形状不变。Hadamard 积定义为

$$\boldsymbol{A} \odot \boldsymbol{B} = [a_{ij}b_{ij}]_{m \times n},$$

它不同于矩阵乘法。张量与标量逐元素运算时，标量广播到每个位置。

2.3.6 降维

求和把若干轴聚合掉。对 $\mathbf{A} \in \mathbb{R}^{m \times n}$,

$$\sum_{i=1}^m \sum_{j=1}^n a_{ij}$$

得到标量；沿轴 0 求和得到长度为 n 的向量，沿轴 1 求和得到长度为 m 的向量。平均值由总和除以参与计算的元素数得到。

2.3.6.1 非降维求和

设置 `keepdim=True` 时，被聚合轴保留为长度 1，从而可借助广播做归一化。例如每行除以该行和：

$$\tilde{a}_{ij} = \frac{a_{ij}}{\sum_{k=1}^n a_{ik}}.$$

累积和则保留原轴长度，输出当前位置之前的部分和。

2.3.7 点积 (Dot Product)

两个等长向量的点积为

$$\mathbf{x}^\top \mathbf{y} = \sum_{i=1}^d x_i y_i.$$

它可解释为加权求和；当两个向量均为单位向量时，点积等于夹角余弦。

2.3.8 矩阵-向量积

令 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 、 $\mathbf{x} \in \mathbb{R}^n$ ，则

$$\mathbf{Ax} = \begin{bmatrix} \mathbf{a}_1^\top \mathbf{x} \\ \vdots \\ \mathbf{a}_m^\top \mathbf{x} \end{bmatrix} \in \mathbb{R}^m.$$

因此矩阵可视为从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的线性变换。

2.3.9 矩阵-矩阵乘法

若 $\mathbf{A} \in \mathbb{R}^{n \times k}$ 、 $\mathbf{B} \in \mathbb{R}^{k \times m}$ ，则 $\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{n \times m}$ ，其中

$$c_{ij} = \mathbf{a}_i^\top \mathbf{b}_j = \sum_{\ell=1}^k a_{i\ell} b_{\ell j}.$$

中间维度 k 必须相等；该运算可看作多个矩阵-向量积并列执行。

2.3.10 范数

范数把向量映射为非负标量，并满足绝对齐次性、三角不等式和正定性。 L_p 范数定义为

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

常用形式为

$$\|\mathbf{x}\|_1 = \sum_i |x_i|, \quad \|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}.$$

矩阵的 Frobenius 范数为

$$\|\mathbf{X}\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n x_{ij}^2}.$$

2.3.10.1 范数和目标

训练常把“预测接近真值”写成距离最小化。例如平方误差本质上使用 L_2 范数平方：

$$\min_{\theta} \|\mathbf{y} - f_{\theta}(\mathbf{X})\|_2^2.$$

因此范数把几何上的距离概念转化为可优化目标。

2.3.11 关于线性代数的更多信息

本节只保留阅读后续章节所需内容。矩阵分解、低秩结构和张量分解属于进一步学习范围。

2.3.12 小结

线性代数用张量描述数据和参数，用点积及矩阵乘法描述层间映射，用范数把误差大小转成标量目标。

2.3.13 练习

原书练习要求验证转置、求和、矩阵乘法和范数性质，重点是同时检查公式与输出形状。

2.4 微积分

优化研究怎样调整参数以降低训练目标；泛化研究所得模型能否在未见数据上保持效果。深度学习训练主要依赖微分而非积分。

2.4.1 导数和微分

函数 f 在 x 处的导数定义为

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h},$$

前提是该极限存在。导数同时表示瞬时变化率和曲线切线斜率。

对原书示例 $f(x) = 3x^2 - 4x$,

$$f'(x) = 6x - 4, \quad f'(1) = 2.$$

这说明在 $x = 1$ 附近，输入增加一个很小的 Δx 时，输出的一阶变化约为 $2\Delta x$ 。

常用求导法则为

$$\begin{aligned} (Cf)' &= Cf', \\ (f+g)' &= f' + g', \\ (fg)' &= f'g + fg', \\ \left(\frac{f}{g}\right)' &= \frac{f'g - fg'}{g^2}. \end{aligned}$$

2.4.2 偏导数

对多元函数 $y = f(x_1, \dots, x_n)$ ，关于 x_i 的偏导把其余变量视为常数：

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_i + h, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}.$$

2.4.3 梯度

若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，梯度是全部偏导组成的列向量：

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \dots & \frac{\partial f}{\partial x_n} \end{bmatrix}^T.$$

原书给出的常用结果包括

$$\begin{aligned}\nabla_{\mathbf{x}} \mathbf{Ax} &= \mathbf{A}^\top, \\ \nabla_{\mathbf{x}} \mathbf{x}^\top \mathbf{A} &= \mathbf{A}, \\ \nabla_{\mathbf{x}} \mathbf{x}^\top \mathbf{Ax} &= (\mathbf{A} + \mathbf{A}^\top)\mathbf{x}, \\ \nabla_{\mathbf{x}} \|\mathbf{x}\|_2^2 &= 2\mathbf{x}, \\ \nabla_{\mathbf{X}} \|\mathbf{X}\|_F^2 &= 2\mathbf{X}.\end{aligned}$$

2.4.4 链式法则

若 $y = f(u)$ 且 $u = g(x)$, 则

$$\frac{dy}{dx} = \frac{dy}{du} \frac{du}{dx}.$$

若 y 依赖 $u_1, \dots, u_m$, 而每个 u_j 又依赖 x_i , 则所有路径贡献相加:

$$\frac{\partial y}{\partial x_i} = \sum_{j=1}^m \frac{\partial y}{\partial u_j} \frac{\partial u_j}{\partial x_i}.$$

神经网络是复合函数, 反向传播就是按计算图反向重复应用这条法则。

2.4.5 小结

导数描述单变量局部变化, 偏导描述多变量函数沿单一坐标方向的变化, 梯度汇总所有偏导, 链式法则把复合函数各层导数连接起来。

2.4.6 练习

原书练习要求绘制函数及其切线, 并对给定函数求导, 用于验证解析导数的几何含义。

2.5 自动微分

自动微分在前向计算时记录操作组成的计算图, 在反向阶段逐节点应用链式法则。它计算的是实际程序所表示函数的数值导数, 而不是对表达式做符号化简。

2.5.1 一个简单的例子

令

$$y = 2\mathbf{x}^\top \mathbf{x} = 2 \sum_i x_i^2.$$

逐分量求导得到

$$\frac{\partial y}{\partial x_i} = 4x_i, \quad \nabla_{\mathbf{x}} y = 4\mathbf{x}.$$

最小验证代码如下：

```
x = torch.arange(4.0, requires_grad=True)
y = 2 * torch.dot(x, x)
y.backward()
x.grad
```

PyTorch 默认累积梯度，因此再次反向传播前通常先清零已有梯度。

2.5.2 非标量变量的反向传播

当 $\mathbf{y} \in \mathbb{R}^m$ 、 $\mathbf{x} \in \mathbb{R}^n$ 时， $\partial \mathbf{y} / \partial \mathbf{x}$ 自然是雅可比矩阵。训练通常不显式构造整个雅可比，而计算向量-雅可比积。若 $\mathbf{y} = \mathbf{x} \odot \mathbf{x}$ ，对输出求和后

$$\nabla_{\mathbf{x}} \sum_i y_i = \nabla_{\mathbf{x}} \sum_i x_i^2 = 2\mathbf{x}.$$

因此 `y.sum().backward()` 等价于用全 1 向量聚合各输出分量的梯度。

2.5.3 分离计算

设 $\mathbf{y} = \mathbf{x} \odot \mathbf{x}$ ，令 $\mathbf{u}$ 取与 $\mathbf{y}$ 相同的数值，但通过 `detach()` 与产生 $\mathbf{y}$ 的计算图断开。若

$$\mathbf{z} = \mathbf{u}^\top \mathbf{x},$$

反向传播时 $\mathbf{u}$ 被视为常量，因此

$$\nabla_{\mathbf{x}} \mathbf{z} = \mathbf{u},$$

而不会沿 $\mathbf{u} = \mathbf{x} \odot \mathbf{x}$ 的路径继续求导。

2.5.4 Python 控制流的梯度计算

PyTorch 使用动态计算图。循环次数和条件分支可以依赖输入；反向传播只沿本次前向实际执行的可微路径进行。若某次执行路径上函数化为 $f(a) = ka$ ，则

$$\frac{df}{da} = k = \frac{f(a)}{a}, \quad a \neq 0.$$

2.5.5 小结

自动微分的最小流程为：给变量启用梯度追踪，执行前向计算，把目标标量反向传播，最后读取梯度。其数学基础是计算图上的链式法则。

2.5.6 练习

原书练习围绕二阶导数开销、重复反向传播、非标量输入和控制流函数展开。

2.5.7 练习解答

2.5.7.1 1. 为什么二阶导数的开销更大？

一阶反向传播本身形成新的导数计算。若继续求二阶导数，必须保留并再次遍历一阶导数的计算图，因此时间和内存开销均增加。

2.5.7.2 2. 连续运行两次反向传播

默认反向传播后计算图会释放，直接对同一图再次反向传播会失败。显式保留计算图可以再次反传，但梯度仍会累积，必须按需要清零。

2.5.7.3 3. 将控制流例子中的输入改成向量或矩阵

输入改为向量或矩阵后，若输出也非标量，需要先求和或提供外部梯度，把反向目标转化为向量-雅可比积。

2.5.7.4 4. 重新设计控制流梯度例子

可用依赖输入符号的条件分支构造分段函数。自动微分对被选中的分支求导，不对离散的分支选择操作求导。

2.6 概率

概率用数值表达不确定性。机器学习模型预测的通常不是确定事实，而是给定观测后各结果的可信程度。

2.6.1 基本概率论

从分布中抽取结果称为采样。重复独立采样时，事件 $\mathcal{A}$ 的经验频率

$$\hat{P}_N(\mathcal{A}) = \frac{1}{N} \sum_{i=1}^N \mathbf{1}\{X_i \in \mathcal{A}\}$$

随 N 增大趋近真实概率 $P(\mathcal{A})$ ，这是大数定律在本节中的直观含义。

2.6.1.1 概率论公理

样本空间 $\mathcal{S}$ 包含全部可能结果，事件是 $\mathcal{S}$ 的子集。概率满足

$$\begin{aligned} P(\mathcal{A}) &\geq 0, \\ P(\mathcal{S}) &= 1, \\ P\left(\bigcup_{i=1}^{\infty} \mathcal{A}_i\right) &= \sum_{i=1}^{\infty} P(\mathcal{A}_i) \quad (\mathcal{A}_i \text{ 两两互斥}). \end{aligned}$$

由此可得 $P(\emptyset) = 0$ 。

2.6.1.2 随机变量

随机变量 X 把样本空间中的结果映射到数值。离散变量可直接讨论 $P(X = x)$ ；连续变量用密度描述，单点概率可以为 0，而区间概率仍可为正。

2.6.2 处理多个随机变量

多个变量之间的关系由联合分布描述，条件化和边际化分别表示“已知某变量”与“消去某变量”。

2.6.2.1 联合概率

联合概率 $P(A = a, B = b)$ 表示两个条件同时成立。因为联合事件包含于任一边际事件，

$$P(A = a, B = b) \leq P(A = a).$$

2.6.2.2 条件概率

当 $P(A = a) > 0$ 时，

$$P(B = b \mid A = a) = \frac{P(A = a, B = b)}{P(A = a)}.$$

条件概率是在已知 $A = a$ 的子空间内重新归一化后的概率。

2.6.2.3 贝叶斯定理

由乘法法则

$$P(A, B) = P(B \mid A)P(A) = P(A \mid B)P(B)$$

得到

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}, \quad P(B) > 0.$$

它把先验 $P(A)$ 与似然 $P(B | A)$ 合成为后验 $P(A | B)$ 。

2.6.2.4 边际化

若 A 为离散变量，对它的全部取值求和即可得到 B 的边际分布：

$$P(B) = \sum_A P(A, B).$$

连续变量对应的操作是积分。

2.6.2.5 独立性

若

$$P(A, B) = P(A)P(B),$$

则记为 $A \perp B$ 。给定 C 后的条件独立定义为

$$A \perp B | C \iff P(A, B | C) = P(A | C)P(B | C).$$

2.6.2.6 应用

原书以 HIV 检测说明先验的重要性。若感染率 $P(H = 1) = 0.0015$ ，且第一次检测满足

$$P(D_1 = 1 | H = 0) = 0.01, \quad P(D_1 = 1 | H = 1) = 1,$$

则

$$P(D_1 = 1) = 0.01(1 - 0.0015) + 1(0.0015) = 0.011485,$$

因此一次阳性后的感染概率为

$$P(H = 1 | D_1 = 1) = \frac{1 \times 0.0015}{0.011485} \approx 0.1306.$$

结论是：即使检测灵敏度高，低先验事件的一次阳性也不等于高后验概率。

2.6.3 期望和方差

离散随机变量的期望为

$$\mathbb{E}[X] = \sum_x xP(X = x).$$

对函数 f ,

$$\mathbb{E}_{x \sim P}[f(x)] = \sum_x f(x)P(x).$$

方差衡量变量围绕期望的平方偏离:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

标准差为方差平方根, 与原变量具有相同量纲。

2.6.4 小结

概率从样本空间和事件出发, 用联合、条件、边际和独立性处理多变量关系, 再用期望和方差概括分布的位置与离散程度。

2.6.5 练习

原书练习要求分析抽样频率、条件概率、贝叶斯更新、独立性以及期望和方差。

2.7 查阅文档

框架 API 会随版本变化, 因此应掌握发现和核验接口的方法, 而不是记忆完整函数表。

2.7.1 查找模块中的所有函数和类

`dir(module)` 列出模块中的属性、函数和类。双下划线包围的名称通常属于 Python 特殊机制, 单下划线开头的名称通常是内部实现。

2.7.2 查找特定函数和类的用法

`help(object)` 显示对象的文档字符串; Jupyter 中的 `?` 查看帮助, `??` 在可用时显示 Python 源码。最终应以当前安装版本的官方文档为准。

2.7.3 小结

查阅接口的顺序是: 先用 `dir` 发现候选对象, 再用 `help` 或 Jupyter 帮助查看参数、返回值与示例。

2.7.4 练习

原书练习要求查询张量函数的官方文档并运行示例，以建立独立核验 API 的习惯。