

计算方法与优化

学习笔记

内容提炼

2026 年 9 月 15 日

说明

本笔记对应武汉大学数学与统计学院戴书洋计算方法与优化 (Computational Methods and Optimization), 2026–2027 秋季, 课件 CM+Opt_ch1.pdf。只提炼第 1 章「基础知识」的定义、成立条件与结论; 学期安排见下表, 其余导论页不记。后续各讲待课件后再按同样方式追加。

学期安排:

周次	内容
1	基础
2–4	线性方程直接法、迭代法、梯度法 (最速下降、共轭梯度)
5–6	最小二乘
7–8	非线性方程, SVD
9–10	插值逼近
11–15	优化

目录

说明	i
第一章 基础知识	1
1.1 介绍	1
1.2 误差	2
1.3 浮点数及舍入误差	3
1.4 向量范数与矩阵范数	4
1.5 线性方程组的性态，算法的稳定性	5

第一章 基础知识

课件把本章分成五块：介绍，误差，浮点数与舍入误差，范数，线性方程组的性态与算法稳定性。下面按同一顺序，每块先写对象与公式，再给一两个算例说明公式里的数代表什么。

1.1 介绍

用计算机解题的固定链条是

模型 $\rightarrow$ 数值问题 $\rightarrow$ 算法 $\rightarrow$ 程序.

输出始终是近似值，因此后文只关心三件事：收敛、稳定、运算量。本课遇到的数值问题可以写成三类：

$$Ax = b, \quad (1.1)$$

$$f(x) = 0, \quad (1.2)$$

$$\min_{\theta} L(\theta). \quad (1.3)$$

第一式输入 $A \in \mathbb{R}^{n \times n}$ 、 $b \in \mathbb{R}^n$ ，输出 $x \in \mathbb{R}^n$ ，是未知量本身。第二式输入非线性 f 与初值，输出根 x 。第三式输入参数 θ 与损失 L ，输出使 L 变小的 θ ； $L(\theta)$ 是非负标量风险，不是预测值。

成立条件随问题而变：方形可逆组有唯一解；超定组 $m > n$ 一般无精确解，改成

$$\min_x \|Ax - b\|_2^2 \Leftrightarrow A^T Ax = A^T b;$$

非线性与训练还要算法收敛。形式上写 $x = A^{-1}b$ 并不要求真去求逆：求逆与乘法同为 $O(n^3)$ ，常数更大，实际用 LU、Cholesky、QR 或迭代直接得到一个 x 。

案例 A（线性组）。《九章算术》

$$\begin{pmatrix} 3 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 39 \\ 34 \\ 26 \end{pmatrix}$$

的解是 $x = 9.25$, $y = 4.25$, $z = 2.75$, 单位为斗/乘。这是 $Ax = b$ 的原型。

案例 B (非线性)。 Kepler 方程 $x - \varepsilon \sin x - t = 0$ ($0 < \varepsilon < 1$) 对 x 非线性, $x(t)$ 是偏近点角。水温插值与人口拟合则分别是「穿过已知点」和「点多于参数时的最小二乘」: 人口用 $y \approx \beta_1 t^3 + \beta_2 t^2 + \beta_3 t + \beta_4$, 输入 $\{(t_i, y_i)\}$, 输出系数 β , 再代入新 t 得到预测人口。神经网络把 f_θ 取得更宽, 训练仍是 $\min_\theta L(\theta)$, 梯度步

$$\theta_{k+1} = \theta_k - \eta \nabla L(\theta_k)$$

的 $\eta > 0$ 是步长, ∇L 是损失对参数的梯度。

案例 C (运算量)。 朴素矩阵乘法 $(AB)_{ij} = \sum_{k=1}^n a_{ik} b_{kj}$ 要 n^3 次乘法; $n = 10^5$ 、每秒 10^9 次时约 11.6 天。Strassen 把指数从 3 降到 $\log_2 7 \approx 2.807$, 说明同一问题可以换算法, 但工程上仍受稳定性与缓存制约。

1.2 误差

数值分析假定模型与观测已给定, 只跟踪两类计算误差: 截断 (方法) 误差与舍入误差。设 x^* 为真值, x 为近似值。绝对误差与相对误差为

$$\varepsilon = x - x^*, \quad \xi = \frac{x - x^*}{x^*}. \quad (1.4)$$

ε 与 x^* 同量纲, 可正可负; $|\varepsilon| \leq \varepsilon^*$ 时称 ε^* 为绝对误差限, 常写 $x^* = x \pm \varepsilon^*$ 。 ξ 无量纲, $|\xi| = 10^{-k}$ 大致对应 k 位有效数字。真值未知时改用 $|x^* - x|/|x|$ 。 $|\varepsilon|$ 小并不等于「够准」: 同样差 1, 对 10^6 和对 1 的意义不同, 所以比较精度看 ξ 。

有效数字: 写 $x = \pm 0.a_1 \dots a_n \times 10^m$ ($a_1 \neq 0$), 若

$$|x - x^*| \leq 0.5 \times 10^{m-n},$$

则 x 有 n 位有效数字。 n 是位数, 不是 x 的值。

误差沿函数传播。一元

$$\Delta f(x^*) \approx |f'(x^*)| |x - x^*|,$$

$|f'(x^*)|$ 是绝对误差的局部放大率。二元一阶上界为

$$\Delta f \approx \left| \partial f / \partial u \right| \Delta u + \left| \partial f / \partial v \right| \Delta v.$$

四则运算的估计误差: 加减都是 $\Delta \tilde{u} + \Delta \tilde{v}$; 乘为 $|\tilde{u}| \Delta \tilde{v} + |\tilde{v}| \Delta \tilde{u}$; 除为同一分子除以 $|\tilde{v}|^2$ 。减法的绝对误差限与加法相同, 但真值接近时相对误差会被放大 (相消)。




图 第 41 页 切线把自变量误差变成函数值误差的一阶估计。

符号: $\Delta\tilde{x}$: 自变量绝对误差; 估计误差: $|f'|\Delta\tilde{x}$; 真误差: $|f(x) - f(\tilde{x})|$

案例 A (有效数字)。 $x^* = \pi$, $x = 3.1415 = 0.31415 \times 10^1$, 故 $m = 1$ 。 $|\pi - 3.1415| \approx 9.3 \times 10^{-5}$ 大于 0.5×10^{-5} 、小于 0.5×10^{-4} , 因此只有 4 位有效数字。四舍五入到四位: $42.195 \rightarrow 42.20$, $0.0375551 \rightarrow 0.03756$ 。

案例 B (截断)。 $I = \int_0^1 e^{-x^2} dx$ 无初等原函数。逐项积分

$$I = \sum_{k=0}^{\infty} \frac{(-1)^k}{k! (2k+1)}, \quad I_n = \sum_{k=0}^n \frac{(-1)^k}{k! (2k+1)},$$

交错余项

$$|I - I_n| \leq \frac{1}{(n+1)! (2n+3)}.$$

I_n 是 I 的近似 (真值 ≈ 0.746824); 右端是可事先计算的截断上界, 不是随机误差。 $n = 4$ 时 $I_4 \approx 0.74749$, 上界 $\approx 7.6 \times 10^{-4}$, 真误差 $\approx 6.6 \times 10^{-4}$ 。

1.3 浮点数及舍入误差

浮点系统 $F(\beta, t, m, M)$ 表示

$$x = W\beta^j, \quad W = \pm \sum_{r=1}^t d_r \beta^{-r}, \quad -m \leq j \leq M.$$

β 是基, t 是尾数位, j 是阶码。规格化要求 $d_1 \neq 0$ (二进制即 $d_1 = 1$)。 F 是有限散点集, 不是 $\mathbb{R}$ 。IEEE 单精度 $1 + 8 + 23$ 位, 双精度 $1 + 11 + 52$ 位, 数值为 $(-1)^s W 2^j$ 。

相邻规格化数间距 $\Delta = \beta^{j-t}$ 。四舍五入到最近浮点 x_f 时

$$|x_f - x_R| \leq \frac{1}{2} \beta^{j-t}.$$

结合规格化下界 $|x_R| \geq \beta^{j-1}$ ，得到定理 1.3.1：

$$x_f = x_R(1 + \delta), \quad |\delta| \leq u := \frac{1}{2}\beta^{1-t}. \quad (1.5)$$

δ 是相对舍入，无量纲； u 是单位舍入，只依赖 β, t ，与 $|x_R|$ 无关（不溢出、规格化时）。二进制 $u = 2^{-t}$ ；双精度 $t = 53$ （含隐藏位）时 $u = 2^{-53} \approx 1.11 \times 10^{-16}$ 。




图 第 46 页 由间距与规格化下界推出相对误差界 u 。

符号： Δ ：相邻浮点间距； u ：单位舍入； δ ：相对误差

1.4 向量范数与矩阵范数

$\mathbb{R}^n$ 上的范数满足正定、绝对齐次、三角不等式。常用

$$\|x\|_1 = \sum_i |x_i|, \quad (1.6)$$

$$\|x\|_2 = \left(\sum_i x_i^2 \right)^{1/2}, \quad (1.7)$$

$$\|x\|_\infty = \max_i |x_i|. \quad (1.8)$$

输入向量，输出非负标量，表示长度。有限维上一切范数等价：存在 $c_1, c_2 > 0$ 使 $c_1\|x\|' \leq \|x\| \leq c_2\|x\|'$ ，因此「 $x_k \rightarrow x^*$ 」与「 $\|x_k - x^*\| \rightarrow 0$ 」对任意范数同时成立。 $\|x_k - x^*\|$ 是误差长度，不是某一个坐标。

矩阵范数另要求相容 $\|AB\| \leq \|A\|\|B\|$ 。Frobenius 范数把 A 当成向量做 2-范数。由向量范数诱导的算子范数

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$$

是单位球上的最大拉伸，也是与该向量范数相容的最小矩阵范数，且 $\|I\| = 1$ 。列和、行和与谱范数分别为

$$\|A\|_1 = \max_j \sum_i |a_{ij}|, \quad (1.9)$$

$$\|A\|_\infty = \max_i \sum_j |a_{ij}|, \quad (1.10)$$

$$\|A\|_2 = \sqrt{\rho(A^T A)}. \quad (1.11)$$

谱半径 $\rho(A) \leq \|A\|$ 对任意矩阵范数成立； $\rho(A)$ 是按模最大特征值，控制 A^k 是否趋于零。若某算子范数下 $\|A\| < 1$ ，则 $I \pm A$ 可逆，且

$$\frac{1}{1 + \|A\|} \leq \|(I \pm A)^{-1}\| \leq \frac{1}{1 - \|A\|}.$$

案例。 $x = (1, -2, 3)^T$: $\|x\|_1 = 6$, $\|x\|_2 = \sqrt{14}$, $\|x\|_\infty = 3$ 。 $A = \begin{pmatrix} 1 & -2 \\ -3 & 4 \end{pmatrix}$:

$\|A\|_1 = 6$, $\|A\|_\infty = 7$, $\|A\|_2 = \sqrt{15 + \sqrt{221}}$ 。对任意算子范数还有 $\|A^{-1}\| \geq 1/\|A\|$ ，以及 $\|A^{-1} - B^{-1}\| \leq \|A^{-1}\|\|B^{-1}\|\|A - B\|$ 。

1.5 线性方程组的性态，算法的稳定性

解 $Ax = b$ 。右端扰动 δb 给出

$$\frac{\|\delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|}, \quad \text{cond}(A) = \|A\|\|A^{-1}\|. \quad (1.12)$$

$\text{cond}(A) \geq 1$ ，无量纲， $\text{cond}(kA) = \text{cond}(A)$ ($k \neq 0$)。它是相对误差放大因子：输入相对右端扰动，输出相对解扰动的上界。矩阵扰动 δA 时还多一个分母 $1 - \text{cond}(A)\|\delta A\|/\|A\|$ (需为正)。 $\text{cond}(A) \gg 1$ 称病态，反之为良态。经验上，行列式极小、行近似相关、主元过小、特征值数量级悬殊，都提示病态。算法稳定性说的是舍入在计算过程中被放大多少；病态是问题固有的，稳定算法也不能凭空变出有效位。

案例 A。

$$\begin{cases} x_1 + x_2 = 2, \\ x_1 + 1.001x_2 = 2, \end{cases} \quad \begin{cases} x_1 + x_2 = 2, \\ x_1 + 1.001x_2 = 2.001. \end{cases}$$

解从 $(2, 0)$ 变成 $(1, 1)$ 。右端相对扰动约 5×10^{-4} ，解的相对变化为 $O(1)$ ，放大约 10^3 ，与该 2×2 矩阵的条件数同量级。

案例 B (Hilbert)。

$$H_{ij} = \frac{1}{i+j-1}, \quad i, j = 1, \dots, 15, \quad b = H\mathbf{1}.$$

精确解 $x^* = \mathbf{1}$ 。双精度 $\text{cond}_2(H) \approx 8.72 \times 10^{17}$, $u \cdot \text{cond}_2(H) = O(10^2)$, 有效数字可以全部丢失。浮点解的残差 $\|Hx - b\|_2 / \|b\|_2 \approx 2 \times 10^{-16}$, 相对误差 $\|x - x^*\|_2 / \|x^*\|_2 \approx 4.93$; 分量可偏离到 -8.7 、 12.8 。残差达到机器精度并不表示解对, 这就是病态。

```
import numpy as np
n, i = 15, np.arange(1, 16)
H = 1.0 / (i[:, None] + i[None, :] - 1.0)
x = np.linalg.solve(H, H @ np.ones(n))
```

`solve` 输出满足 $Hx \approx b$ 的 $x \in \mathbb{R}^{15}$, 它不是 x^* 。