

计算方法与优化

学习笔记

内容提炼

2026 年 9 月 15 日

说明

本笔记对应武汉大学数学与统计学院戴书洋老师计算方法与优化 (Computational Methods and Optimization) 2026–2027 秋季课程第 1 讲课件 CM+Opt_ch1.pdf (共 57 页)。每一页课件对应正文一个小节，节号写成「第 n 页」，标题沿用该页课件标题；同名页在标题后用括号标出该页特有主题，不改课件原词。试作版只充实当前这一份课件；后续各讲待提供后再按同样规则追加，此处不编造目录。正文以公式陈述定义、成立条件、关键推导与结论。每一公式后写明：数学上如何由输入算出输出，以及得到的数在问题中的实际含义。有信息量的示意图按课件页码编号插入；表按课件行列重排。

目录

说明	i
第一章 课程导论	1
第 1 页 计算方法与优化	1
第 2 页 课程信息	1
第 3 页 大模型这么强，为什么还要上（数学、编程）课？	1
第 4 页 纯粹数学与应用数学	2
第 5 页 数学重要性：以计算为例（计算古已有之）	2
第 6 页 数学重要性：以计算为例（现代计算自二战开始）	3
第 7 页 数学重要性：以计算为例（计算必须算到目标精度）	3
第 8 页 数学重要性：以计算为例（自己动手从零开始）	3
第 9 页 计算的变革	3
第 10 页 计算的用途：核武器数值模拟	4
第 11 页 计算的用途：大飞机制造	4
第 12 页 计算能力的驱动力	4
第 13 页 基本问题	4
第 14 页 学习方法	4
第 15 页 算法	5
第 16 页 算法（多项式与秦九韶）	5
第 17 页 算法（Basel 问题的直接求和）	6
第 18 页 算法（Basel 问题的加速求和）	7
第 19 页 算法（算法优劣的影响）	7
第 20 页 上课内容	8

第二章 基础知识	9
第 21 页 第一章基础知识	9
第 22 页 1.1 介绍 – 应用问题举例 (《九章算术》)	9
第 23 页 1.1 介绍 – 应用问题举例 (Kepler 方程)	10
第 24 页 1.1 介绍 – 应用问题举例 (水温插值)	10
第 25 页 1.1 介绍 – 应用问题举例 (人口预测)	10
第 26 页 1.1 介绍 – 应用问题举例 (机器学习问题)	12
第 27 页 1.1 介绍 – 应用问题举例 (传染病模型)	12
第 28 页 1.1 介绍 (用计算机解决实际问题的步骤)	13
第 29 页 1.1 介绍: 矩阵乘法	14
第 30 页 1.1 介绍: 矩阵乘法 (Strassen 算法)	14
第 31 页 1.1 介绍: 矩阵乘法 (矩阵乘法指数)	15
第 32 页 1.1 介绍: 线性方程组求解	16
第 33 页 1.1 介绍: 最小二乘	17
第 34 页 1.1 介绍: 神经网络	18
第 35 页 1.2 误差 (来源与分类)	19
第 36 页 1.2 误差 (如何计算高斯型积分)	19
第 37 页 1.2 误差 (用泰勒展开近似积分)	20
第 38 页 1.2 误差 (绝对误差与相对误差)	21
第 39 页 1.2 误差 (相对误差)	22
第 40 页 1.2 误差 (有效数字)	22
第 41 页 1.2 误差 (误差的传播, 单变量)	22
第 42 页 1.2 误差 (误差的传播, 多变量)	23
第 43 页 1.3 浮点数及舍入误差 (计算机浮点数系统)	24
第 44 页 1.3 浮点数及舍入误差 (计算机浮点数表示)	24
第 45 页 1.3 浮点数及舍入误差 (舍入误差)	24
第 46 页 1.3 浮点数及舍入误差 (定理 1.3.1 的证明)	25
第 47 页 1.4 向量范数与矩阵范数 (向量范数)	26
第 48 页 1.4 向量范数与矩阵范数 (主要性质)	26
第 49 页 1.4 向量范数与矩阵范数 (矩阵范数)	26
第 50 页 1.4 向量范数与矩阵范数 (矩阵范数相关性质)	27

第 51 页	1.4 向量范数与矩阵范数（算子范数）	27
第 52 页	1.4 向量范数与矩阵范数（算子范数相关性质）	28
第 53 页	1.5 线性方程组的性态，算法的稳定性（右端扰动）	28
第 54 页	1.5 线性方程组的性态，算法的稳定性（矩阵扰动）	28
第 55 页	1.5 线性方程组的性态，算法的稳定性（病态经验与算法稳定性） . .	29
第 56 页	1.5 线性方程组的性态，算法的稳定性（例题）	29
第 57 页	小结	31

第一章 课程导论

本章对应课件第 1–20 页：课程信息、为什么需要计算数学、算法观念，以及学期内容安排。

第 1 页 计算方法与优化

课程名计算方法与优化，学期为 2026–2027 秋季，主讲戴书洋，单位为武汉大学数学与统计学院。这一页只给出身份信息，没有公式。它规定后续每一页都在同一门课的记号系统下展开：先把连续模型写成有限步可执行的算法，再分析误差、稳定性和运算量。

第 2 页 课程信息

联系与成绩按课件给出：邮箱 `shuyang_dai@whu.edu.cn`，答疑用邮件或 QQ，QQ 群 337413555，办公室雷军科技楼 719。总评

$$\text{总评} = 0.6 \times \text{期末} + 0.4 \times \text{平时}.$$

输入是百分制的期末分与平时分，输出是加权标量，取值通常在 $[0, 100]$ 。0.6 与 0.4 不是物理量，只是成绩权重；期末权重大，表示课程仍以可独立完成的书面与计算考查为主。

第 3 页 大模型这么强，为什么还要上（数学、编程）课？

课件用大模型对话截图提出问题：生成式模型已经能写代码、解算例，为何仍要学数学与编程。这一页没有给出公式，答案在后续页展开：模型把问题翻译成方程之后，真正决定对错的是算法是否收敛、误差如何传播、浮点运算能否稳住。大模型输出的是文本；本课要的是可验证的数值，取值范围由误差限与稳定性定理约束，不能用「看起来合理」代替。

第 4 页 纯粹数学与应用数学




图 第 4 页 数学分成纯粹数学与应用数学两条路线。

符号：纯粹数学：问题来自数学内部；应用数学：问题来自科学与工程，强调建模加求解

课件把数学分成两支。纯粹数学不以应用为目的，强调严格、抽象与结构，问题如哥德巴赫猜想、黎曼猜想；代表人举华罗庚、陈省身、丘成桐、陈景润、张益唐。应用数学关心科学应用，路线是

实际对象 → 数学模型 → 数值问题 → 算法与程序。

输入是物理、工程或数据中的对象，输出是可计算的方程与算法；中间每一步都丢掉一部分细节，因此后面必须估计误差。问题来源举流体力学、材料科学、神经科学；代表人举冯·诺依曼、香农、维纳、纳什、华罗庚。本课落在应用数学一侧：同一位华罗庚同时出现在两支，说明「算得出来」与「证得出来」并不互斥。

第 5 页 数学重要性：以计算为例（计算古已有之）

计算并非计算机发明后才出现。天文用计算研究星球运动与历法，军事用计算分析弹道，航海用计算选择航线。课件用第谷收集观测、开普勒从数据中找规律作为代表：观测给出有限个点 $\{(t_i, x_i)\}$ ，规律是一个待定函数 $x(t)$ 。输入是离散数据，输出是可外推的模型；数据有观测误差，所以后文必须讨论拟合与插值，而不是假设点落在精确曲线上。

第 6 页 数学重要性：以计算为例（现代计算自二战开始）

课件把现代大规模计算的起点放在第二次世界大战：研制核武器需要流体与辐射的数值模拟，破译密码需要对离散结构做穷举与统计。这一页的图是历史场景，不进入公式。它要说明的数量级变化是：问题规模一旦超出手算，就必须把连续方程离散化，并接受截断误差与舍入误差。

第 7 页 数学重要性：以计算为例（计算必须算到目标精度）

课件用课堂板书场景强调：理论公式写完之后，仍要把数值「算到该停的地方」。对一个级数或迭代，停止准则是误差降到事先给定的容许值 $\varepsilon > 0$ ，而不是「公式已经写出来」。输入是算法与 ε ，输出是满足

$$|\text{近似} - \text{真值}| \leq \varepsilon$$

的有限步结果； ε 的量纲与未知量相同，取值由应用精度决定。

第 8 页 数学重要性：以计算为例（自己动手从零开始）

课件用大规模手算的历史画面说明：没有现成黑箱时，必须从最基本的四则运算搭出算法。后文秦九韶算法、浮点舍入、范数与条件数，都是「从零开始」的具体化：先规定运算顺序，再计算运算次数，再估计误差放大倍数。

第 9 页 计算的变革

电子计算机把计算从手算变成自动的有限步算术。ENIAC 于 1946 年 2 月 14 日在美国投入使用，课件称其为世界上第一台通用计算机，占地约 170 平方米，重约 30 英吨，速度为每秒 5000 次加法或 400 次乘法。这些数的输入是历史记载，输出是量级对照：加法比乘法大约快一个数量级，因此后文统计运算量时要把乘法次数单独列出。计算机只改变执行速度，不取消误差：每一步仍是有限位算术。

第 10 页 计算的用途：核武器数值模拟

课件用核装置数值模拟作为计算的用途之一。控制方程是连续的偏微分方程，机器只能解有限维代数问题，因此必须离散。输入是连续场，输出是网格上的有限个未知数；网格越细，截断误差通常越小，未知数个数与运算量同时上升。这一页的照片只说明应用场景，不提供可抄的公式。

第 11 页 计算的用途：大飞机制造

大飞机的气动、结构与控制同样依赖数值模拟。与上一页相同：把偏微分方程变成大规模线性或非线性方程组。输入是几何与工况，输出是可制造、可试验对照的数值预测；预测值的可信区间由网格、模型与舍入共同决定。

第 12 页 计算能力的驱动力

课件的结论是：计算能力的驱动来自需求，而不是先有机器再找问题。国家需要核武器、大飞机、天气预报等能力时，受政治、经济与时效约束，只能靠计算在试验之前给出可检验的数量。需求规定容许误差与时限，时限再反过来规定算法的运算量上限。

第 13 页 基本问题

计算方法要回答的基本问题是：如何把数学模型写成数值问题；如何确定算法的适用范围；如何估计给定算法的精度；误差如何在计算中积累和传播；如何构造精度更高的算法；如何减少存储；如何分析运算量与运算时间。课件把本课内容分成三块：数值线性代数（线性方程组、特征值与特征向量），数值逼近（插值与逼近），优化理论与算法（如何训练神经网络）。这三块对应后文的 $Ax = b$ 、用简单函数代替复杂函数、以及

$$\min_{\theta} L(\theta).$$

最后式的输入是参数 θ 与训练损失 L ，输出是标量损失值；训练要的是使 L 下降的 θ ，而不是把 L 的表达式写得更长。

第 14 页 学习方法

核心是算法的原理及实现。基本任务：理解每个算法的数学背景、原理和线索，对最基本的算法非常熟悉。理论部分：认识算法，并能做收敛性、稳定性分析。实现部分：

各章算法的目的是实际计算，必须能上机并分析结果。因此后文每个公式都要能回答两件事：用哪些输入算出什么输出，以及这个数在原问题里代表误差、残差、步长还是条件数。

第 15 页 算法

算法不是单独一条数学公式，而是由基本运算及其顺序组成的完整求解方案。可用流程图描述；选择算法是数值计算的关键环节，不同算法有不同的优势与劣势。若记基本运算集合为 $\mathcal{O}$ 、顺序为 $\prec$ ，则一个算法是 $(\mathcal{O}, \prec)$ 。输入是问题实例，输出是有限步之后的近似解；运算次数是非负整数，运行时间与它成正比，但不等于墙钟时间。

第 16 页 算法（多项式与秦九韶）

多项式

$$P_n(x) = a_n x^n + a_{n-1} x^{n-1} + \cdots + a_1 x + a_0$$

的输入是系数 $(a_0, \dots, a_n)$ 与求值点 x ，输出是标量 $P_n(x)$ 。 $P_n(x)$ 就是该多项式在 x 处的函数值，量纲与 a_0 相同。

方法一：先算每个 $a_i x^i$ ($i = 0, 1, \dots, n$) 再相加。乘法次数为

$$1 + 2 + \cdots + n = \frac{n(n+1)}{2},$$

加法次数为 n 。左边对 $i = 1, \dots, n$ 统计「 x 连乘 i 次」的乘法；输出是次数，单位是次，取值 $\{0, 1, 2, \dots\}$ 。

方法二：秦九韶算法（1247）/Horner 算法（1819），

$$P_n(x) = (\cdots((a_n x + a_{n-1})x + a_{n-2})x + \cdots + a_1)x + a_0.$$

递归为 $b_n = a_n$,

$$b_i = b_{i+1}x + a_i, \quad i = n-1, n-2, \dots, 0,$$

且 $P_n(x) = b_0$ 。每步输入已有 b_{i+1} 、同一个 x 和系数 a_i ，输出新的标量 b_i ； b_i 是从最高次项看到第 i 次的嵌套值，最后的 b_0 才是多项式值。乘法次数为 n ，加法次数为 n ，比方法一少一个数量级的乘法。

```
def horner(a, x):
    # a[0] = a_0, ..., a[n] = a_n
    b = a[-1]
    for ai in reversed(a[:-1]):
        b = b * x + ai
    return b
```

对 $P(x) = 2x^2 + 3x + 4$ 即 $\mathbf{a}=[4,3,2]$, $\text{horner}(\mathbf{a},5)$ 得到 69, 与 $2 \cdot 25 + 15 + 4$ 相同; 返回值就是 $P(5)$, 不是系数。

第 17 页 算法 (Basel 问题的直接求和)

Basel 问题为

$$\sum_{k=1}^{\infty} \frac{1}{k^2} = \frac{\pi^2}{6}.$$

用部分和

$$P_n = \sum_{k=1}^n \frac{1}{k^2}$$

逼近 $\pi^2/6$ 。输入是截断下标 $n \in \mathbb{N}$, 输出是正标量 $P_n \in (0, \pi^2/6)$; P_n 是前 n 项的数值和, 不是 π 本身。

直接计算的截断误差为

$$\frac{\pi^2}{6} - P_n = \sum_{k=n+1}^{\infty} \frac{1}{k^2}.$$

由

$$\frac{1}{k(k+1)} < \frac{1}{k^2} < \frac{1}{k(k-1)} \quad (k \geq n+1)$$

得到

$$\frac{1}{n+1} < \sum_{k=n+1}^{\infty} \frac{1}{k^2} < \frac{1}{n}.$$

左右两端是误差的可计算上下界, 量纲与 $1/k^2$ 相同, 取值随 n 按 $O(n^{-1})$ 下降。因此要把误差压到 10^{-2m} , 大致需要 $n \sim 10^{2m}$ 项, 直接求和很慢。




图 第 17 页 直接部分和的误差 (左) 与对数误差 (右)。

符号: n : 项数; Error: $\pi^2/6 - P_n$; Log Error: 误差的常用对数; 虚线: 课件给出的 $1/n$ 、 $1/(n+1)$ 界

第 18 页 算法 (Basel 问题的加速求和)

利用

$$\sum_{k=1}^{\infty} \frac{1}{k(k+1)} = 1, \quad \frac{1}{k^2} - \frac{1}{k(k+1)} = \frac{1}{k^2(k+1)},$$

改写

$$\sum_{k=1}^{\infty} \frac{1}{k^2} = 1 + \sum_{k=1}^{\infty} \frac{1}{k^2(k+1)} \approx 1 + \sum_{k=1}^n \frac{1}{k^2(k+1)}.$$

新部分和的输入仍是 n , 输出是

$$Q_n = 1 + \sum_{k=1}^n \frac{1}{k^2(k+1)},$$

它仍是 $\pi^2/6$ 的近似, 但余项满足

$$\sum_{k=n+1}^{\infty} \frac{1}{k^2(k+1)} < \frac{1}{n} \sum_{k=n+1}^{\infty} \frac{1}{k(k+1)} < \frac{1}{n^2}.$$

$1/n^2$ 是余项上界, 比直接法的 $1/n$ 高一阶。同一 n 下 Q_n 比 P_n 更接近 $\pi^2/6$; 对数误差图上加速后的点下降明显更快。




图 第 18 页 加速后的误差 (左) 与对数误差 (右), 绿色点为加速方案。

符号: n : 项数; 蓝点: 直接法; 绿点: 加 $1/(k^2(k+1))$ 后的余项

第 19 页 算法 (算法优劣的影响)

算法优劣直接影响速度和效率。对小型问题, 运算次数与内存似乎无所谓; 对大型问题, 它们起决定作用。不合适的算法还会因为近似性和误差的传播、积累而损害精度, 甚至使计算失败。结合前两页: 同样逼近 $\pi^2/6$, 把余项从 $O(n^{-1})$ 改到 $O(n^{-2})$ 并不改问题, 只改算法; 输出的误差数量级可以差几个 10 的幂。

第 20 页 上课内容

学期按周安排为：第 1 周基础；第 2–4 周线性方程的直接法、迭代法、梯度法（最速下降与共轭梯度）；第 5–6 周最小二乘；第 7–8 周非线性方程与 SVD；第 9–10 周插值逼近；第 11–15 周优化。这一页是后续各讲的课表，不是第 1 章内部小节名。当前笔记只把「第 1 周基础」写完；其余周次等对应课件后再按页追加。

第二章 基础知识

本章对应课件第 21–57 页，即课件「第一章基础知识」。节号与课件页码对齐，从第 21 页续编。

第 21 页 第一章基础知识

课件给出本章五块：介绍；误差；浮点数与舍入误差；范数；线性方程组的性态与算法的稳定性。后文第 22–34 页对应介绍，第 35–42 页对应误差，第 43–46 页对应浮点，第 47–52 页对应范数，第 53–56 页对应性态与稳定性，第 57 页为小结。这一页本身没有新公式，只规定阅读顺序。

第 22 页 1.1 介绍 – 应用问题举例（《九章算术》）

《九章算术》方程：上禾三秉、中禾二秉、下禾一秉，实三十九斗；上禾二秉、中禾三秉、下禾一秉，实三十四斗；上禾一秉、中禾二秉、下禾三秉，实二十六斗。写成

$$\begin{pmatrix} 3 & 2 & 1 \\ 2 & 3 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 39 \\ 34 \\ 26 \end{pmatrix}, \quad (2.1)$$

即 $Ax = b$ 。A 的输入是秉数系数， (x, y, z) 是上、中、下禾每秉的斗数， b 是实测总斗数。课件答曰： $x = 9 + 1/4$ ， $y = 4 + 1/4$ ， $z = 2 + 3/4$ 。一般 n 阶形式为

$$\sum_{j=1}^n a_{ij}x_j = b_i, \quad i = 1, \dots, n,$$

矩阵写法 $Ax = b$ 。输入是 $A \in \mathbb{R}^{n \times n}$ 与 $b \in \mathbb{R}^n$ ，输出是未知向量 $x \in \mathbb{R}^n$ ； x 的每个分量是对应未知量的数值解，不是残差。本课后续大量算法都在解这一类问题。

第 23 页 1.1 介绍 – 应用问题举例（Kepler 方程）

天体力学中的 Kepler 方程

$$x(t) - \varepsilon \sin x(t) - t = 0, \quad 0 < \varepsilon < 1.$$

输入是偏心率 ε 与时间 t , 未知量 $x(t)$ 是行星轨道的偏近点角, 输出是满足该标量方程的 x 。方程对 x 非线性, 不能写成 $Ax = b$, 因此要非线性方程的数值解法（后文第 7–8 周）。 $\varepsilon \in (0, 1)$ 保证正弦扰动小于线性项, 根通常唯一; ε 无量纲, t 与 x 用同一角度单位。

第 24 页 1.1 介绍 – 应用问题举例（水温插值）

已测海洋不同深度处的水温：

深度 (m)	466	741	950	1422	1634
水温 (°C)	7.04	4.28	3.40	2.54	2.13

符号：深度 d_i 单位米；水温 T_i 单位摄氏度。

目标是估计未测深度（如 500, 600, 1000 米）处的水温。这是插值：构造 $T(d)$ 使 $T(d_i) = T_i$, 再求 $T(d_*)$ 。输入是结点 $\{(d_i, T_i)\}$ 与待估深度 d_* , 输出是标量 $T(d_*)$, 含义是该深度的估计水温。成立条件是：认为水温随深度足够光滑, 从而可用多项式或分段多项式穿过已知点。

第 25 页 1.1 介绍 – 应用问题举例（人口预测）

给出中国 1900–2000 年人口, 目标是预测未来（数据量大时尤其如此）。课件表为

年份 t	人口 y
1950	55196
1960	66207
1970	82992
1980	98705
1990	114333
2000	126743

符号： t 为年份； y 为人口数，课件未改写单位，按表中整数使用。

拟合模型

$$y \approx \beta_1 t^3 + \beta_2 t^2 + \beta_3 t + \beta_4.$$

输入是数据对 $\{(t_i, y_i)\}$ ，输出是系数 $\beta = (\beta_1, \beta_2, \beta_3, \beta_4)$ ；代入新的 t 得到预测人口 $\hat{y}(t)$ 。
 $\hat{y}$ 与 y 同一量纲；因为点数多于 4，一般不能让所有点精确落在三次多项式上，所以用最小二乘。




图 第 25 页 三次多项式对人口数据的最小二乘拟合与外推。

符号：横轴：年份；纵轴：人口（ $\times 10^8$ 量级的课件刻度）；圆点：数据；实线：拟合曲线；星号：外推点

第 26 页 1.1 介绍 – 应用问题举例（机器学习问题）

5. 机器学习问题




图 第 26 页 左：两类样本的间隔分类；右：多层网络把 x 映射到 $\mathcal{F}(x)$ 。

符号：Gap：分类间隔； x_0, x_1 ：输入； $\mathcal{L}^{0,1,2,\text{out}}$ ：各层映射； $y_{\ell,j}$ ：隐单元； $\mathcal{F}(x)$ ：网络输出

左图把病人分成 Normal 与 Cancer 两类，中间直线是分类边界，Gap 是间隔。输入是特征平面上的点，输出是类别标签；间隔越大，边界对小扰动越不敏感。右图是前馈网

$$x \xrightarrow{\mathcal{L}^0} y_0 \xrightarrow{\mathcal{L}^1} y_1 \xrightarrow{\mathcal{L}^2} y_2 \xrightarrow{\mathcal{L}^{\text{out}}} \mathcal{F}(x).$$

每层输入是上一层向量，输出是下一层向量； $\mathcal{F}(x)$ 是预测值或各类得分。训练这些映射就是后文的优化问题。

第 27 页 1.1 介绍 – 应用问题举例（传染病模型）

SIR 模型

$$\begin{aligned} \frac{dS}{dt} &= -\beta \frac{I}{N} S, \\ \frac{dI}{dt} &= \beta \frac{I}{N} S - \gamma I, \\ \frac{dR}{dt} &= \gamma I. \end{aligned} \tag{2.2}$$

输入是总人数 N 、传染率 β 、恢复率 γ 以及初值 $(S(0), I(0), R(0))$ ，输出是三条关于 t 的函数。 S, I, R 分别是易感、感染、恢复人数，取值在 $[0, N]$ ，且 $S + I + R = N$ 。 $\beta IS/N$ 是单位时间新感染人数， γI 是单位时间恢复人数。连续时间 ODE 在机器上只能逐步积分，因此需要常微分方程数值解法。




图 第 27 页 SIR 模型三条轨线随时间的演化。

符号：Susceptible: $S(t)$; Infectious: $I(t)$; Recovered: $R(t)$; 横轴：时间

第 28 页 1.1 介绍（用计算机解决实际问题的步骤）

步骤是：建立数学模型；选择数值方法；编写程序计算结果。特点是：结果是近似的；需要可靠的理论以保证收敛性与稳定性；需要良好的计算复杂度；必须与应用结合。若精确解为 x^* 、计算解为 x ，则

$$x = x^* + e_{\text{model}} + e_{\text{trunc}} + e_{\text{round}},$$

其中三项分别是模型、截断与舍入贡献的误差向量。输出 x 仍表示原问题的未知量，但其可信范围由这三项控制。

第 29 页 1.1 介绍：矩阵乘法

给定 $A, B \in M_n$ ，标准算法对每个 (i, j) 计算

$$(AB)_{ij} = \sum_{k=1}^n a_{ik} b_{kj}.$$

输入是两个 $n \times n$ 矩阵，输出是 $n \times n$ 矩阵 AB ；每个元素是对应行与列的内积。共需 n^3 次数字乘法。若 $n = 10^5$ ，则乘法次数为 10^{15} ；若机器每秒 10^9 次乘法，需要 10^6 秒 ≈ 11.6 天。 n^3 是运算次数，不是矩阵元素的值；它说明朴素乘法在大规模时不可行，从而提出「能否更快」的问题。

第 30 页 1.1 介绍：矩阵乘法（Strassen 算法）

Strassen 算法把 $n \times n$ 块分成 2×2 块，用 7 次半尺寸乘法代替 8 次，复杂度

$$O(n^{\log_2 7}), \quad \log_2 7 \approx 2.807.$$

输入仍是 A, B ，输出仍是 AB ；改变的只是乘法次数的指数。课件给出块公式

$$\begin{aligned} M_1 &= (A_{11} + A_{22})(B_{11} + B_{22}), \\ M_2 &= (A_{21} + A_{22})B_{11}, \\ M_3 &= A_{11}(B_{12} - B_{22}), \\ M_4 &= A_{22}(B_{21} - B_{11}), \\ M_5 &= (A_{11} + A_{12})B_{22}, \\ M_6 &= (A_{21} - A_{11})(B_{11} + B_{12}), \\ M_7 &= (A_{12} - A_{22})(B_{21} + B_{22}), \end{aligned}$$

以及

$$\begin{pmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{pmatrix} = \begin{pmatrix} M_1 + M_4 - M_5 + M_7 & M_3 + M_5 \\ M_2 + M_4 & M_1 - M_2 + M_3 + M_6 \end{pmatrix}.$$

每个 M_k 是半尺寸矩阵， C_{ij} 拼回 AB 的块。课件同时提问：实际在用的算法是什么？——理论指数与工程实现（分块、缓存、数值稳定性）不是同一件事。

The Strassen algorithm partitions A , B and C into equally sized [block matrices](#)

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}, \quad B = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}, \quad C = \begin{bmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{bmatrix},$$

with $A_{ij}, B_{ij}, C_{ij} \in \text{Mat}_{2^{n-1} \times 2^{n-1}}(\mathcal{R})$. The naive algorithm would be:

$$\begin{bmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{bmatrix} = \begin{bmatrix} A_{11} \times B_{11} + A_{12} \times B_{21} & A_{11} \times B_{12} + A_{12} \times B_{22} \\ A_{21} \times B_{11} + A_{22} \times B_{21} & A_{21} \times B_{12} + A_{22} \times B_{22} \end{bmatrix}.$$

This construction does not reduce the number of multiplications: 8 multiplications of matrix blocks are still needed to calculate the C_{ij} matrices, the same number of multiplications needed when using standard matrix multiplication.

The Strassen algorithm defines instead new values:

$$M_1 = (A_{11} + A_{22}) \times (B_{11} + B_{22});$$

$$M_2 = (A_{21} + A_{22}) \times B_{11};$$

$$M_3 = A_{11} \times (B_{12} - B_{22});$$

$$M_4 = A_{22} \times (B_{21} - B_{11});$$

$$M_5 = (A_{11} + A_{12}) \times B_{22};$$

$$M_6 = (A_{21} - A_{11}) \times (B_{11} + B_{12});$$

$$M_7 = (A_{12} - A_{22}) \times (B_{21} + B_{22}),$$

using only 7 multiplications (one for each M_k) instead of 8. We may now express the C_{ij} in terms of M_k :

$$\begin{bmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{bmatrix} = \begin{bmatrix} M_1 + M_4 - M_5 + M_7 & M_3 + M_5 \\ M_2 + M_4 & M_1 - M_2 + M_3 + M_6 \end{bmatrix}.$$

图 第 30 页 Strassen 把 8 次块乘法减为 7 次。

符号: A_{ij}, B_{ij}, C_{ij} : 半尺寸块; M_k : 七个中间积

第 31 页 1.1 介绍：矩阵乘法（矩阵乘法指数）

两个 $n \times n$ 矩阵相乘的复杂度写成 $O(n^\omega)$, ω 称为矩阵乘法指数 (matrix multiplication exponent)。若存在常数 $C > 0$ 使乘法可在 Cn^ω 次算术运算内完成, 则该 ω 合法。朴素算法 $\omega = 3$; Strassen $\omega = \log_2 7 \approx 2.807$; 其后 Pan、Bini、Coppersmith–Winograd、Stothers、Williams、Le Gall, 直到 2023 年 Alman–Vassilevska Williams $\omega \approx 2.371866$ 。开放问题: 能否 $\omega = 2$? 经典计算模型下最优值是多少? 当 $n = 10^5$ 时, $n^3 = 10^{15}$ 而 $n^{2.372} \approx 10^{11.86}$, 约 3000 倍。这些 ω 是复杂度指数, 无量纲, 取值区间 $[2, 3]$; 它不是一次具体乘法的误差。




图 第 31 页 矩阵乘法指数的定义、历史与复杂度曲线。

符号： ω ：矩阵乘法指数； n ：矩阵阶；纵轴：运算次数（对数）

第 32 页 1.1 介绍：线性方程组求解

形式上 $Ax = b \Rightarrow x = A^{-1}b$ ，但有三个问题。

求 A^{-1} 与做矩阵乘法在渐近阶上都是 $O(n^3)$ 次浮点运算，求逆的常数更大，且通常不必显式形成 A^{-1} 。实际计算直接解 $Ax = b$ ：高斯消元/LU， $A = LU$ ；若 A 对称正定则 Cholesky；还有 QR；以及 Jacobi、Gauss-Seidel、共轭梯度等迭代法。直接解一个右端，比先求逆再相乘更省、更稳。

若 A 或 b 被噪声干扰，解不一定可靠。条件数

$$\kappa(A) = \|A\| \|A^{-1}\|$$

输入是可逆矩阵 A 与选定的算子范数，输出是 $\kappa(A) \geq 1$ 的标量。 $\kappa(A)$ 大称为病态，微小扰动可导致巨大误差； $\kappa(A)$ 小称为良态。因此不仅问「是否有解」，还问「解能否被可靠地算出来」。

线性方程组求解: $Ax = b \Rightarrow x = A^{-1}b$

线性方程组求解

$Ax = b \Rightarrow x = A^{-1}b$

$A \in \mathbb{R}^{n \times n}, b \in \mathbb{R}^n$

1 求 A^{-1} 所需的时间和矩阵乘法所需的时间是一样的吗?

矩阵乘法

$C = AB$

×=

通常需要 $O(n^3)$ 次浮点运算

矩阵求逆

$X = A^{-1}$

=

通常也需要 $O(n^3)$ 次浮点运算

两者在数量级上是相同的, 但求逆的常数更大, 且通常没有必要显式求出 A^{-1} 。

2 是否一定需要求 A^{-1} ?

不需要。

在实际计算中, 通常直接求解 $Ax = b$, 而不是先计算 A^{-1} 。

常用方法:

- 高斯消元 (LU 分解): $A = LU$
- Cholesky 分解 (当 A 对称正定)
- QR 分解
- 迭代法 (如 Jacobi、Gauss-Seidel、共轭梯度法等)

直接求解更加高效、稳定, 并且只需要计算一个解, 而无需得到整个 A^{-1} 。

3 如果 A 或 b 被噪声干扰了, 所得到的解是否仍然可靠?

不一定。

当 A 或 b 有微小的扰动时, 解可能发生很大的变化, 这取决于问题的条件数。

$\kappa(A) = \|A\| \|A^{-1}\|$

- 如果 $\kappa(A)$ 很大 (病态问题), 微小的扰动可能导致解的巨大误差。
- 如果 $\kappa(A)$ 较小 (良态问题), 解对扰动相对稳定。

不仅要关心“是否有解”, 还要关心“解是否能够被可靠地计算出来”。

图 第 32 页 解 $Ax = b$: 不必求逆, 且要看条件数。符号: $\kappa(A)$: 条件数; n : 阶数; $O(n^3)$: 浮点运算次数

第 33 页 1.1 介绍: 最小二乘

若未知量个数远小于方程个数, 精确的 $Ax = b$ 通常无解, 要找最「合适」的 x 。监督学习是: 给定带标签数据, 找分类器并预测新样本的标签。课件把这条链写成五步。

精确方程组: $Ax = b, x = A^{-1}b$ 。超定组: $m > n$, 一般不存在 x 使 $Ax = b$ 。最小二乘:

$$\min_x \|Ax - b\|_2^2,$$

一阶条件 $A^T Ax = A^T b$ 。输入是 $A \in \mathbb{R}^{m \times n}$ 、 $b \in \mathbb{R}^m$, 输出是使残差欧氏范数平方最小的 $x \in \mathbb{R}^n$; $\|Ax - b\|_2^2$ 是拟合误差的能量, 非负。

线性回归: $f(x) = w^T x + b$,

$$\min_{w, b} \sum_{i=1}^m (y_i - w^T x_i - b)^2.$$

更一般模型 $f_\theta(x)$ (多项式、神经网络) 把目标改成

$$\min_{\theta} \frac{1}{m} \sum_{i=1}^m \ell(f_\theta(x_i), y_i).$$

回归可用 $\ell(\hat{y}, y) = (\hat{y} - y)^2$, 分类可用 $\ell(\hat{y}, y) = -y \log \hat{y}$ 。核心思想：用数学模型描述问题，用高效稳定的算法求解，用数据驱动改进模型。

线性方程组求解： $Ax = b \Rightarrow x = A^{-1}b$

- 问题：如果方程的未知量个数远小于方程的个数，怎么找到最“合适”的解？
- 监督学习：给定带标签的数据集，找到分类器并预测新的数据的标签




图 第 33 页 从精确线性组到最小二乘再到一般监督学习。

符号： m, n ：方程数与未知数； w, b, θ ：模型参数； ℓ ：损失函数

第 34 页 1.1 介绍：神经网络

真实规律复杂，线性模型往往太简单，于是用神经网络。输入 $x \in \mathbb{R}^d$ 是特征向量。第 ℓ 层

$$h^{(\ell)} = \sigma(W^{(\ell)}h^{(\ell-1)} + b^{(\ell)}), \quad \ell = 1, \dots, L,$$

输出 $\hat{y} = f_\theta(x) = W^{(L)}h^{(L-1)} + b^{(L)}$ 。输入是 x 与参数 $\theta = \{W^{(\ell)}, b^{(\ell)}\}$ ，输出 $\hat{y}$ 是预测； σ 是逐元非线性， $h^{(\ell)}$ 是隐表示。

损失

$$L(\theta) = \frac{1}{m} \sum_{i=1}^m \ell(f_\theta(x_i), y_i)$$

是标量，衡量 m 条样本上的平均风险，取值通常非负。梯度下降

$$\theta_{k+1} = \theta_k - \eta \nabla L(\theta_k)$$

的输入是当前参数、步长 $\eta > 0$ 与梯度，输出是下一步参数； η 是无穷小或按梯度量纲缩放的步长。常用 SGD、Mini-batch SGD、Momentum、Adam。对新输入 x ，预测 $\hat{y} = f_{\theta^*}(x)$ 。

- 真实的规律很复杂，线性模型太简单
- 神经网络




图 第 34 页 神经网络：从输入、模型、损失、优化到预测。

符号： θ ：全体参数； η ：步长； ∇L ：损失梯度； $\hat{y}$ ：预测

第 35 页 1.2 误差（来源与分类）

误差用来描述数值计算中近似解的精确程度。来源分成四类。从实际问题抽象出数学模型：模型误差（modeling error）。测量得到模型参数：观测误差（measurement error）。求近似解（级数截断、网格离散、迭代早停）：方法误差/截断误差（truncation error）。机器字长有限：舍入误差（round-off error）。数值分析假定数学模型准确，因而不考虑模型误差和观测误差，主要研究截断误差和舍入误差对计算结果的影响。后两类的输出都是「计算值与该模型真解之差」，量纲与未知量相同。

第 36 页 1.2 误差（如何计算高斯型积分）

思考：如何计算

$$I = \int_0^1 e^{-x^2} dx.$$

被积函数没有初等原函数，不能靠牛顿-莱布尼茨写出闭形式，因此 I 只能近似。输入是区间 $[0, 1]$ 与 $f(x) = e^{-x^2}$ ，输出是标量 $I \in (0, 1)$ ，含义是该正函数在单位区间上的面积。下一页用泰勒展开给出可计算的截断格式。

第 37 页 1.2 误差（用泰勒展开近似积分）

e^{-x^2} 的泰勒级数

$$e^{-x^2} = \sum_{k=0}^{\infty} \frac{(-1)^k x^{2k}}{k!} = 1 - x^2 + \frac{x^4}{2!} - \frac{x^6}{3!} + \frac{x^8}{4!} - \dots$$

在整个 $\mathbb{R}$ 上收敛。逐项积分

$$I = \int_0^1 e^{-x^2} dx = \sum_{k=0}^{\infty} \frac{(-1)^k}{k!} \int_0^1 x^{2k} dx = \sum_{k=0}^{\infty} \frac{(-1)^k}{k! (2k+1)}.$$

截断

$$I_n = \sum_{k=0}^n \frac{(-1)^k}{k! (2k+1)}.$$

输入是截断下标 n ，输出是标量 I_n ；例如 $n = 4$ 时

$$I_4 = 1 - \frac{1}{3} + \frac{1}{2! \cdot 5} - \frac{1}{3! \cdot 7} + \frac{1}{4! \cdot 9} \approx 0.7474868.$$

I_n 是 I 的近似值，不是误差本身。余项

$$R_n = I - I_n = \sum_{k=n+1}^{\infty} \frac{(-1)^k}{k! (2k+1)}.$$

因 $a_k = 1/(k!(2k+1))$ 单调趋于 0，交错级数给出

$$|R_n| \leq \frac{1}{(n+1)!(2n+3)}.$$

右端是可计算的误差上界，随 n 阶乘下降。课件表（真值 $I \approx 0.7468241328$ ）：

n	近似值 I_n	误差估计 $\frac{1}{(n+1)!(2n+3)}$	实际误差 $ I - I_n $
0	1.0000000	$1/3 \approx 3.33 \times 10^{-1}$	2.53×10^{-1}
1	0.6666667	$1/10 = 1.00 \times 10^{-1}$	8.02×10^{-2}
2	0.7666667	$1/42 \approx 2.38 \times 10^{-2}$	1.98×10^{-2}
3	0.7428571	$1/216 \approx 4.63 \times 10^{-3}$	3.97×10^{-3}
4	0.7474868	$1/1320 \approx 7.58 \times 10^{-4}$	6.63×10^{-4}
5	0.7467293	$1/9360 \approx 1.07 \times 10^{-4}$	9.48×10^{-5}

符号： n 为截断阶； I_n 为部分和； $I - I_n$ 为真误差，符号可正可负，表中取绝对值。

结论：泰勒展开可以得到积分的高精度近似，并且可以显式估计截断误差。




图 第 37 页 用 e^{-x^2} 的泰勒多项式逐项积分，并核对误差表。

符号： T_n ：截断到 x^{2n} 的部分和； I_n ：对应积分近似

第 38 页 1.2 误差（绝对误差与相对误差）

设 x^* 为精确值， x 为 x^* 的近似值。绝对误差

$$\varepsilon = x - x^*.$$

输入是近似值与真值，输出是标量 ε ，量纲与 x^* 相同； $\varepsilon = 0$ 表示没有偏差，可正可负。其上限记为 ε^* ，称为绝对误差限，工程上常写

$$x^* = x \pm \varepsilon^*,$$

即真值落在 $[x - \varepsilon^*, x + \varepsilon^*]$ 。绝对误差越小越有参考价值，但不能单独表示「精确到什么程度」：测 10^6 时差 1 与测 1 时差 1 的意义不同。

第 39 页 1.2 误差（相对误差）

相对误差

$$\xi = \frac{x - x^*}{x^*}$$

更能反映近似程度。输入同上，输出是无量纲标量； $|\xi| = 10^{-k}$ 大致对应 k 位有效数字。真值难以求出时，课件也使用

$$\xi = \left| \frac{x^* - x}{x} \right|,$$

分母改成近似值 x 。近似值的精确程度取决于相对误差；实际计算中能得到的是相对误差限。

第 40 页 1.2 误差（有效数字）

用科学计数法写

$$x = \pm 0.a_1a_2 \dots a_n \times 10^m, \quad a_1 \neq 0.$$

若

$$|x - x^*| \leq 0.5 \times 10^{m-n}$$

（即 a_n 按四舍五入截取），则称 x 有 n 位有效数字，精确到小数点后第 $m - n$ 位。输入是近似值的十进制写法与真值，输出是整数 $n \geq 1$ ； n 是有效位数，不是 x 本身。

例：设 $x^* = \pi$, $x = 3.1415$ 。 $x = 0.31415 \times 10^1$, 故 $m = 1$ 。 $|\pi - 3.1415| \approx 9.27 \times 10^{-5}$ 。 $0.5 \times 10^{1-5} = 5 \times 10^{-5}$, 不等式不成立； $0.5 \times 10^{1-4} = 5 \times 10^{-4}$ 成立，因此 3.1415 作为 π 的近似有 4 位有效数字。

练习：对 42.195、0.0375551，按四舍五入写出四位有效数字的近似数，分别为 42.20 与 0.03756。

第 41 页 1.2 误差（误差的传播，单变量）

单变量函数 $f(x)$ ，设 x^* 是 x 的近似值。课件写

$$\Delta f(x^*) = |f(x) - f(x^*)|.$$

在 x^* 处泰勒展开

$$f(x) - f(x^*) \approx f'(x^*)(x - x^*),$$

从而

$$\Delta f(x^*) \approx |f'(x^*)| |x - x^*|.$$

输入是点 x^* 、导数 $f'(x^*)$ 与自变量误差 $|x - x^*|$ ，输出是函数值误差的一阶估计。 $|f'(x^*)|$ 是绝对误差的局部放大倍数：导数大的地方，同样的 Δx 会造成更大的 Δf 。图中切线给出「估计误差」，曲线给出「真误差」，二者之差是泰勒余项。




图 第 41 页 用切线把自变量误差变成函数值误差的一阶估计。

符号： $\Delta \tilde{x} = |x - \tilde{x}|$ ：自变量绝对误差；估计误差： $|f'| \Delta \tilde{x}$ ；真误差： $|f(x) - f(\tilde{x})|$

第 42 页 1.2 误差（误差的传播，多变量）

多变量 $f(u, v)$ ， (u^*, v^*) 是 (u, v) 的近似值。

$$f(u, v) - f(u^*, v^*) \approx \frac{\partial f}{\partial u}(u - u^*) + \frac{\partial f}{\partial v}(v - v^*),$$

$$\Delta f(u^*, v^*) \approx \left| \frac{\partial f}{\partial u} \right| \Delta u^* + \left| \frac{\partial f}{\partial v} \right| \Delta v^*.$$

输入是偏导数与两个自变量的绝对误差限，输出是函数绝对误差的一阶上界。四则运算的估计误差为

运算	记号	估计误差
加法	$\Delta(\tilde{u} + \tilde{v})$	$\Delta \tilde{u} + \Delta \tilde{v}$
减法	$\Delta(\tilde{u} - \tilde{v})$	$\Delta \tilde{u} + \Delta \tilde{v}$
乘法	$\Delta(\tilde{u} \times \tilde{v})$	$ \tilde{u} \Delta \tilde{v} + \tilde{v} \Delta \tilde{u}$
除法	$\Delta(\tilde{u}/\tilde{v})$	$(\tilde{u} \Delta \tilde{v} + \tilde{v} \Delta \tilde{u}) / \tilde{v} ^2$

符号： $\tilde{u}, \tilde{v}$ 为近似值； Δ 表示绝对误差限，均取非负。减法与加法的绝对误差限相同，但真值接近时相对误差会被放大，这就是相消。

第 43 页 1.3 浮点数及舍入误差（计算机浮点数系统）

浮点系统 $F(\beta, t, m, M)$ 中,

$$x = W \times \beta^j, \quad W = \pm 0.d_1 d_2 \dots d_t = \pm \sum_{r=1}^t d_r \beta^{-r}.$$

W 是尾数, β 是基 (正整数进制), j 是阶码, t 是尾数位数, $-m \leq j \leq M$ 是阶的范围。规格化要求 $1 \leq d_1 \leq \beta - 1$, $0 \leq d_i \leq \beta - 1$ ($i = 2, \dots, t$)。输入是四元组 (β, t, m, M) , 输出是可表示的有限点集 F 。 F 只能表示有限个实数, 不是连续的数轴。

对 $F(2, t, m, M)$, 可表示范围

$$x_R \in [-0.11\dots 1 \times 2^M, -2^{-m-1}] \cup [2^{-m-1}, 0.11\dots 1 \times 2^M].$$

尾数绝对值 $W = N_i \times 2^{-t}$, $N_i \in \{2^{t-1}, \dots, 2^t - 1\}$ 。浮点数个数 (含零) 为

$$2(M + m + 1)(2^t - 2^{t-1}) + 1.$$

该式输出的是集合基数, 无量纲, 用来衡量「机器能区分多少个」。

第 44 页 1.3 浮点数及舍入误差（计算机浮点数表示）

二进制形式

$$(-1)^S W 2^j.$$

$S \in \{0, 1\}$ 是符号位, j 是阶码, W 是尾数。单精度: 32 位, 符号 1 位, 阶码 $E = 8$ 位, 尾数 $M = 23$ 位。双精度: 64 位, 符号 1 位, 阶码 $E = 11$ 位, 尾数 $M = 52$ 位。(课件把 64 位那一行误写成「64 位单精度形式」, 按位宽应理解为双精度。) 输入是这 32 或 64 个比特, 输出是一个实数 (或特殊值 Inf/NaN, 本页未展开)。尾数位数决定相对精度, 阶码位数决定可表示的指数范围。

第 45 页 1.3 浮点数及舍入误差（舍入误差）

实数 x_R 只能用 $F(\beta, t, m, M)$ 中最近的 x_f 表示 (四舍五入)。若 x_R 的阶为 j , 相邻浮点间距为 β^{j-t} , 则

$$|x_f - x_R| \leq \frac{1}{2} \beta^{j-t}.$$

左端是绝对舍入误差, 右端是半个间距, 量纲与 x_R 相同。

定理 1.3.1:

$$x_f = x_R(1 + \delta), \quad |\delta| \leq \frac{1}{2} \beta^{1-t}.$$

δ 是相对舍入误差, 无量纲; 上界只依赖于基 β 和尾数位数 t , 不依赖于 x_R 的大小 (规格化且不溢出时)。

第 46 页 1.3 浮点数及舍入误差（定理 1.3.1 的证明）

规格化浮点在阶码 j 下的间距 $\Delta = \beta^{j-t}$ 。任意 x_R 落在某相邻浮点 x_i, x_{i+1} 之间，四舍五入选最近者 x_f ，故

$$|x_R - x_f| \leq \frac{1}{2}\Delta = \frac{1}{2}\beta^{j-t}.$$

规格化数满足 $\beta^{j-1} \leq |x_R| < \beta^j$ ，因此

$$|\delta| = \frac{|x_f - x_R|}{|x_R|} \leq \frac{\frac{1}{2}\beta^{j-t}}{\beta^{j-1}} = \frac{1}{2}\beta^{1-t}.$$

令单位舍入

$$u = \frac{1}{2}\beta^{1-t},$$

则 $x_f = x_R(1 + \delta)$, $|\delta| \leq u$ 。 $\beta = 2$ 时 $u = 2^{-t}$ 。结论：四舍五入的相对误差与数的大小无关，只取决于 β 和 t 。




图 第 46 页 由浮点间距与规格化下界推出定理 1.3.1。

符号： Δ ：相邻浮点间距； u ：单位舍入； δ ：相对误差

第 47 页 1.4 向量范数与矩阵范数（向量范数）

$\mathbb{R}^n$ 上的向量范数 $\|\cdot\|$ 对任意 $\vec{x}, \vec{y} \in \mathbb{R}^n$ 满足: (1) $\|\vec{x}\| \geq 0$, 且 $\|\vec{x}\| = 0 \Leftrightarrow \vec{x} = 0$; (2) $\|\lambda\vec{x}\| = |\lambda| \|\vec{x}\|$ (课件写作 $\forall \lambda \in \mathbb{R}$); (3) 三角不等式 $\|\vec{x} + \vec{y}\| \leq \|\vec{x}\| + \|\vec{y}\|$ 。常用

$$\begin{aligned}\|\vec{x}\|_1 &= \sum_{i=1}^n |x_i|, \\ \|\vec{x}\|_2 &= \left(\sum_{i=1}^n x_i^2 \right)^{1/2}, \\ \|\vec{x}\|_\infty &= \max_{1 \leq i \leq n} |x_i|, \\ \|\vec{x}\|_p &= \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.\end{aligned}$$

输入是向量 $\vec{x}$, 输出是非负标量; 它度量 $\vec{x}$ 的「长度」, 不是某一个坐标。

例: $\vec{x} = (1, -2, 3)^\top$,

$$\|\vec{x}\|_1 = 6, \quad \|\vec{x}\|_2 = \sqrt{14}, \quad \|\vec{x}\|_\infty = 3.$$

第 48 页 1.4 向量范数与矩阵范数（主要性质）

(1) $\|-\vec{x}\| = \|\vec{x}\|$; (2) $|\|\vec{x}\| - \|\vec{y}\|| \leq \|\vec{x} - \vec{y}\|$; (3) $\|\vec{x}\|$ 是 $\mathbb{R}^n$ 上的连续函数。

定理 1.4.1: $\mathbb{R}^n$ 上一切范数等价, 即存在 $c_1 > 0$ 、 $c_2 > 0$ 使

$$c_1 \|\vec{x}\|' \leq \|\vec{x}\| \leq c_2 \|\vec{x}\|'.$$

输入是同一个向量在两种范数下的值, 输出是与 $\vec{x}$ 无关的正常数对 (c_1, c_2) ; 等价意味着「是否趋于零」不依赖于选哪一种范数, 但具体数值可以差一个常数倍。

向量序列收敛: $\vec{x}_k = (x_{k1}, \dots, x_{kn})^\top$, 若对每个分量 $\lim_{k \rightarrow \infty} x_{ki} = x_i^*$, 则 $\lim_{k \rightarrow \infty} \vec{x}_k = \vec{x}^*$ 。

定理 1.4.2: 对任意向量范数, $\lim \vec{x}_k = \vec{x}^* \Leftrightarrow \lim \|\vec{x}_k - \vec{x}^*\| = 0$ 。定理 1.4.3: $\lim(\vec{x}_k \pm \vec{y}_k) = \vec{x}^* \pm \vec{y}^*$ 。 $\|\vec{x}_k - \vec{x}^*\|$ 是误差的长度, 非负, 趋于 0 表示逐分量都逼近。

第 49 页 1.4 向量范数与矩阵范数（矩阵范数）

$\mathbb{R}^{n \times n}$ 上矩阵范数满足与向量范数相同的 (1)(2)(3)。若还满足

$$\|AB\| \leq \|A\| \|B\|,$$

则称相容的矩阵范数或模。Frobenius 范数

$$\|A\|_F = \left(\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2 \right)^{1/2}$$

可看作把矩阵拉成向量后的 2-范数。输入是矩阵 A ，输出是非负标量，度量「矩阵有多大」。

相容性有两层：矩阵与矩阵；矩阵与向量

$$\|A\vec{x}\| \leq \|A\| \|\vec{x}\|.$$

后者保证 $\|A\vec{x}\|$ 作为输出向量的长度，不会超过 $\|A\|$ 与 $\|\vec{x}\|$ 的乘积。

第 50 页 1.4 向量范数与矩阵范数（矩阵范数相关性质）

定理 1.4.4: $\|A\|$ 是 A 的连续函数。定理 1.4.5: 对一个相容矩阵范数，存在与之相容的向量范数。定理 1.4.6: 谱半径 $\rho(A)$ 为按模最大的特征值模，则对任一种矩阵范数

$$\rho(A) \leq \|A\|.$$

$\rho(A)$ 无量纲（若 A 把向量映到同型向量），它给出迭代 $A^k \rightarrow 0$ 的阈值： $\rho(A) < 1$ 是收敛的必要条件的常用形式。定理 1.4.7: 对任意 $\varepsilon > 0$ ，存在一种矩阵范数使 $\|A\| \leq \rho(A) + \varepsilon$ 。也就是：范数可以任意接近谱半径，但不能整体小于它。

第 51 页 1.4 向量范数与矩阵范数（算子范数）

给定向量范数，定义矩阵的算子范数（从属范数）

$$\|A\| = \sup_{\vec{x} \neq 0} \frac{\|A\vec{x}\|}{\|\vec{x}\|} = \max_{\|\vec{x}\|=1} \|A\vec{x}\|.$$

输入是线性映射 A ，输出是单位球上像的最大长度，即「最坏方向的放大倍数」。由常用向量范数诱导：

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \quad (\text{列范数}),$$

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \quad (\text{行范数}),$$

$$\|A\|_2 = \sqrt{\rho(A^T A)} \quad (\text{谱范数}).$$

$$\text{例: } A = \begin{pmatrix} 1 & -2 \\ -3 & 4 \end{pmatrix},$$

$$\|A\|_1 = \max(1+3, 2+4) = 6, \quad \|A\|_\infty = \max(1+2, 3+4) = 7,$$

$$A^T A = \begin{pmatrix} 10 & -14 \\ -14 & 20 \end{pmatrix}, \quad \rho(A^T A) = 15 + \sqrt{221}, \quad \|A\|_2 = \sqrt{15 + \sqrt{221}}.$$

第 52 页 1.4 向量范数与矩阵范数（算子范数相关性质）

定理 1.4.8: 向量范数与其从属矩阵范数相容。定理 1.4.9: 对向量范数 $\|\cdot\|_p$, 与之相容的所有矩阵范数中, 算子范数值最小。定理 1.4.10: 从属范数满足 $\|I\| = 1$ 。定理 1.4.11: A 的不同从属范数互相等价。

例 1: 若对某个算子范数 $\|A\| < 1$, 则 $I \pm A$ 可逆, 且

$$\frac{1}{1 + \|A\|} \leq \|(I \pm A)^{-1}\| \leq \frac{1}{1 - \|A\|}.$$

左、右两端是 $\|(I \pm A)^{-1}\|$ 的界; 分母 $1 - \|A\| > 0$ 来自 $\|A\| < 1$ 。

例 2: $\mathbb{R}^{n \times n}$ 上任一相容矩阵范数, 必存在 $\mathbb{R}^n$ 上与它相容的向量范数。

例 3: $\|A\vec{x}\|_2 \leq \|A\|_F \|\vec{x}\|_2$, 且 $\|AB\|_F \leq \|A\|_F \|B\|_F$ 。

第 53 页 1.5 线性方程组的性态, 算法的稳定性（右端扰动）

解 $A\vec{x} = b$ 时, A 和 b 的误差都会进入 $\vec{x}$ 。先设 b 受扰动 δb ,

$$A(\vec{x} + \delta\vec{x}) = b + \delta b \Rightarrow \delta\vec{x} = A^{-1}\delta b.$$

从而

$$\|\delta\vec{x}\| \leq \|A^{-1}\| \|\delta b\|, \quad \frac{\|\delta\vec{x}\|}{\|\vec{x}\|} \leq \|A\| \|A^{-1}\| \frac{\|\delta b\|}{\|b\|}.$$

$\|A^{-1}\|$ 是绝对误差放大因子, $\|A\| \|A^{-1}\|$ 是相对误差放大因子。输入是相对右端扰动, 输出是相对解扰动的上界; 放大因子无量纲, 越大越敏感。

第 54 页 1.5 线性方程组的性态, 算法的稳定性（矩阵扰动）

再设 A 受扰动 δA ,

$$(A + \delta A)(\vec{x} + \delta\vec{x}) = b.$$

课件给出

$$\delta\vec{x} = -A^{-1}\delta A(\vec{x} + \delta\vec{x})$$

以及

$$\delta \vec{x} = -(I + A^{-1}\delta A)^{-1}A^{-1}\delta A \vec{x},$$

从而

$$\frac{\|\delta \vec{x}\|}{\|\vec{x} + \delta \vec{x}\|} \leq \|A\| \|A^{-1}\| \frac{\|\delta A\|}{\|A\|},$$

$$\frac{\|\delta \vec{x}\|}{\|\vec{x}\|} \leq \frac{\|A\| \|A^{-1}\|}{1 - \|A\| \|A^{-1}\| \frac{\|\delta A\|}{\|A\|}} \frac{\|\delta A\|}{\|A\|},$$

后者要求分母为正，即相对矩阵扰动不能太大。状态数（条件数）

$$\text{cond}(A) = \|A\| \|A^{-1}\|.$$

$\text{cond}(A)$ 越大越难求准确解，称为病态；反之良态。不同矩阵范数对应不同条件数。性质： $\text{cond}(A) \geq 1$ ， $\text{cond}(kA) = \text{cond}(A)$ ($k \neq 0$)。 $\text{cond}(A)$ 无量纲，不随把 A 与 b 同时乘 k 而改变。

第 55 页 1.5 线性方程组的性态，算法的稳定性（病态经验与算法稳定性）

一般并不先算 A^{-1} 再判断病态，而用经验：行列式很大或很小（某些行、列近似相关）；元素间数量级相差很大且无规则；主元消去过程中出现小主元；特征值数量级相差很大。以上均可视为病态迹象。

算法稳定性：算法必然引入浮点误差，若算法过程中对应矩阵的条件数较小，则数值解误差也较小，称算法稳定。稳定性描述的是「舍入被放大多少」，条件数描述的是「问题本身对扰动有多敏感」；病态问题即使用稳定算法也难得到很多正确有效位。

第 56 页 1.5 线性方程组的性态，算法的稳定性（例题）

例 1。两组

$$\begin{cases} x_1 + x_2 = 2, \\ x_1 + 1.001x_2 = 2, \end{cases} \quad \begin{cases} x_1 + x_2 = 2, \\ x_1 + 1.001x_2 = 2.001. \end{cases}$$

第一组： $x_2 = 0$ ， $x_1 = 2$ 。第二组：两式相减得 $0.001x_2 = 0.001$ ，故 $x_2 = 1$ ， $x_1 = 1$ 。右端只改 0.001，解从 (2, 0) 跳到 (1, 1)。相对右端扰动约为 $0.001/2 = 5 \times 10^{-4}$ ，相对解扰动约为 1，放大约 2×10^3 ，与 $\text{cond}(A)$ 同量级。

例 2。课件写出的 15 阶组为

$$\left\{ \begin{array}{l} x_1 + \frac{1}{2}x_2 + \frac{1}{3}x_3 + \cdots + \frac{1}{15}x_{15} = 1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{15}, \\ \frac{1}{2}x_1 + \frac{1}{3}x_2 + \frac{1}{4}x_3 + \cdots + \frac{1}{16}x_{15} = \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \cdots + \frac{1}{16}, \\ \vdots \\ \frac{1}{15}x_1 + \frac{1}{16}x_2 + \frac{1}{17}x_3 + \cdots + \frac{1}{29}x_{15} = \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \cdots + \frac{1}{29}. \end{array} \right.$$

系数矩阵是 Hilbert 矩阵 (Hilbert matrix)

$$H_{ij} = \frac{1}{i+j-1}, \quad i, j = 1, \dots, 15,$$

右端恰是各行之和 $b = H\mathbf{1}$ 。因此精确算术下

$$H\mathbf{1} = b \quad \Rightarrow \quad x^* = (1, 1, \dots, 1)^\top.$$

H 的输入是下标 (i, j) , 输出是正标量 $H_{ij} \in [\frac{1}{29}, 1]$; x^* 的每个分量都是 1, 无量纲 (若把未知量就看成纯数值)。

双精度 (约 16 位十进制、 $u \approx 1.11 \times 10^{-16}$) 下,

$$\text{cond}_2(H) \approx 8.72 \times 10^{17}.$$

由第 53 页的扰动界, 相对误差可放大到

$$u \cdot \text{cond}_2(H) \approx 10^2,$$

即有效数字可以全部丢失。用 `numpy.linalg.solve` 得到的 x 与真解之差为

i	x_i	$x_i - 1$	i	x_i	$x_i - 1$
1	1.0000	-7.2×10^{-8}	9	-8.699	-9.699
2	1.0000	1.2×10^{-5}	10	12.755	11.755
3	0.9995	-4.8×10^{-4}	11	-8.124	-9.124
4	1.0087	8.7×10^{-3}	12	4.925	3.925
5	0.9143	-0.086	13	0.608	-0.392
6	1.517	0.517	14	0.631	-0.369
7	-1.033	-2.033	15	1.116	0.116
8	6.382	5.382			

符号: x_i 为浮点解的第 i 个分量; $x_i - 1$ 是对真解分量 1 的绝对误差。

$$\frac{\|Hx - b\|_2}{\|b\|_2} \approx 2.1 \times 10^{-16}, \quad \frac{\|x - x^*\|_2}{\|x^*\|_2} \approx 4.93.$$

左边残差达到机器精度，右边相对误差却是 $O(1)$ ：残差小并不表示解对。这正是病态的定义性现象： H 的行几乎线性相关，奇异值比

$$\frac{\sigma_{\max}(H)}{\sigma_{\min}(H)} = \text{cond}_2(H) \approx 8.72 \times 10^{17}$$

跨越约 18 个数量级。 $\sigma_{\max}$ 、 $\sigma_{\min}$ 是 H 的最大、最小奇异值，二者都是非负标量；比值无量纲，就是 2-范数条件数。

```
import numpy as np
n = 15
idx = np.arange(1, n + 1)
H = 1.0 / (idx[:, None] + idx[None, :] - 1.0)
b = H @ np.ones(n)
x = np.linalg.solve(H, b)
```

`solve` 的输入是 H 与 b ，输出是 $x \in \mathbb{R}^{15}$ ；在本例中它满足 $Hx \approx b$ ，但不是 x^* 。

第 57 页 小结

需要记住的对象是：误差——绝对/相对误差与有效数字；范数——向量范数与矩阵范数，等价性，相容性，常用的 1-、2-、 ∞ -范数及对应从属范数，以及条件数。

例：已知 $A, B \in \mathbb{R}^{n \times n}$ 非奇异，证明对任一算子范数

$$\|A^{-1}\| \geq \frac{1}{\|A\|}, \quad \|A^{-1} - B^{-1}\| \leq \|A^{-1}\| \|B^{-1}\| \|A - B\|.$$

第一式由 $\|I\| = 1 \leq \|A\| \|A^{-1}\|$ 得到， $\|A^{-1}\|$ 不能比 $1/\|A\|$ 更小。第二式用 $A^{-1} - B^{-1} = A^{-1}(B - A)B^{-1}$ 与相容性得到；右端是两逆之差的范数上界，输入为 $\|A - B\|$ ，输出控制「矩阵一变，逆能变多少」。